



DISCLAIMER

Il materiale contenuto nel drive è stato raccolto e richiesto tramite autorizzazione ai ragazzi frequentanti il corso di studi di Informatica dell'Università degli Studi di Salerno. Gli appunti e gli esercizi nascono da un uso e consumo degli autori che li hanno creati e risistemati per tanto non ci assumiamo la responsabilità di eventuali mancanze o difetti all'interno del materiale pubblicato.


Il materiale sarà modificato aggiungendo il logo dell'associazione, in tal caso questo possa recare problemi ad alcuni autori di materiale pubblicato, tale persona può contattarci in privato ed elimineremo o modificheremo il materiale in base alle sue preferenze.

Ringraziamo eventuali segnalazioni di errori così da poter modificare e fornire il miglior materiale possibile a supporto degli studenti.



CoScienze
Associazione

Appunti del corso di Cloud Computing



A.A. 2020/2021

CoScienze
Associazione



Indice

1	Informazioni sul corso	7
2	Concetti base del Cloud Computing	9
2.1	Le origini	9
2.2	Definizioni	9
2.3	Business Drivers	10
2.3.1	Capacity planning	11
2.3.2	Cost Reduction	11
2.3.3	Organization Agility	12
2.4	Technology Innovations	12
2.4.1	Clustering	12
2.4.2	Grid computing	12
2.4.3	Virtualization	12
2.4.4	Altre enabling technologies	12
2.5	Terminologia	13
2.5.1	Scaling	13
2.5.2	Service Level Agreement	14
2.6	Obiettivi e benefici	14
2.6.1	Reduced Investments and Proportional Costs	14
2.6.2	Increased Scalability	14
2.6.3	Increased Availability and Reliability	15
2.7	Risks and Challenges	15
2.8	Learning Check	16
3	Caratteristiche fondamentali del Cloud Computing	19
3.1	Ruoli	19
3.2	Boundaries	20
3.3	Caratteristiche di un Cloud	21
3.4	Cloud Delivery Models	22
3.4.1	Infrastructure-as-a-Service (IaaS)	23
3.4.2	Platform-as-a-Service (PaaS)	23
3.4.3	Software-as-a-Service (SaaS)	23
3.4.4	Function-as-a-Service (FaaS)	23
3.4.5	Modelli ibridi	24
3.4.6	Business Process-as-a-Service e Information-as-a-Service	24
3.4.7	Riquadro generale	25
3.5	Cloud Deployment Models	26
3.6	Learning Check	26

4	Tecnologie chiave del Cloud Computing	29
4.1	Broadband Networks and Internet Architecture	29
4.1.1	Funzionamento della rete	30
4.1.2	Limitazioni e problemi	31
4.2	Data Center Technology	31
4.2.1	Funzionamento	31
4.3	Virtualization Technology	32
4.4	Web Technology	32
4.5	Multitenant Technology	33
4.6	Service Technology	33
4.7	Caso d'uso: DTGOV	33
4.8	Learning Check	34
5	Paradigm Shift	35
5.1	Paradigm Shift e Disruptive Technology	35
5.1.1	Le rivoluzioni nel Paradigm Shift	36
5.1.2	Scientific Paradigm Shift	37
5.2	Social Paradigm Shift	37
5.2.1	Societal Cloud	37
5.2.2	Personal Cloud	37
5.2.3	Cloud of Things	37
5.3	Work Paradigm Shift	37
5.4	Business Paradigm Shift	38
5.5	Learning Check	38
6	Price and value models	39
6.1	Price models	39
6.1.1	Utility Price models	40
6.1.2	Service Price models	40
6.1.3	Performance Price models	41
6.1.4	Marketing-oriented Price models	42
6.1.5	Hybrid Price models	42
6.2	Value models	43
6.2.1	Operating expense	43
6.2.2	User demand flexibility	44
6.2.3	Price flexibility	44
6.2.4	Agility for time to market	45
6.2.5	Location flexibility	45
6.2.6	Asset optimization	46
6.2.7	Profit margin	46
6.3	Financial metrics	47
6.3.1	Payback Method	47
6.3.2	Return on Investment (ROI)	47
6.3.3	Net Present Value (NPV)	48
6.4	Learning Check	49
7	Cloud Security	51
7.1	Threat agents	52
7.2	Risk Management	53
7.2.1	Risk Management Framework	55
7.3	Case Study: ATN	55
7.4	Learning Check	56

8	Cloud Infrastructure Mechanisms	57
8.1	Logical Network Perimeter	57
8.2	Virtual Server	59
8.3	Cloud Storage Device	59
8.4	Cloud Usage Monitor	60
8.5	Resource Replication	60
8.6	Ready-Made Environment	61
8.7	Learning Check	61
9	Specialized Cloud Mechanisms	63
9.1	Automated Scaling Listener	63
9.2	Load Balancer	64
9.3	SLA Monitor	64
9.4	Pay-per-use Monitor	64
9.5	Audit Monitor	65
9.6	Failover System	65
9.7	Hypervisor	65
9.8	Resource Cluster	65
9.9	Multi-device Broker	66
9.10	State Management Database	66
9.11	Mappa concettuale delle caratteristiche del Cloud Computing	67
9.12	Learning Check	67
10	Other Cloud Mechanisms	69
10.1	Cloud Management Mechanisms	69
10.1.1	Remote Administration System	69
10.1.2	Resource Management System	69
10.1.3	SLA Management System	70
10.1.4	Billing Management System	71
10.2	Cloud Security Mechanisms	71
10.2.1	Encryption	71
10.2.2	Hashing	71
10.2.3	Digital Signature	72
10.2.4	Public Key Infrastructure (PKI)	72
10.2.5	Identity and Access Management (IAM)	72
10.2.6	Single Sign-On (SSO)	73
10.2.7	Cloud-Based Security Groups	73
10.2.8	Hardened Virtual Server Images	74
10.3	Learning Check	74
11	Fundamental Architecture	77
11.1	Workload Distribution	77
11.2	Resource Pooling	78
11.3	Dynamic Scalability	79
11.4	Elastic Resource Capacity	80
11.5	Service Load Balancing	80
11.6	Cloud Bursting	81
11.7	Elastic Disk Provisioning	82
11.8	Redundant Storage	82
11.9	Learning Check	83

12 Advanced Architectures	85
12.1 Hypervisor Clustering	85
12.2 Load Balanced Virtual Servers	87
12.3 Non-disruptive Service Relocation	89
12.4 Zero Downtime	91
12.5 Cloud Balancing	92
12.6 Resource Reservation	93
12.7 Dynamic Failure Detect/Recovery	93
12.8 Bare-Metal Provisioning	94
12.9 Rapid Provisioning	95
12.10 Storage Workload Management	95
12.11 Learning Check	97
13 Specialized Architectures	99
13.1 Storage related architectures	99
13.1.1 Direct I/O Access	99
13.1.2 Direct LUN Access	100
13.1.3 Dynamic Data Normalization	101
13.1.4 Device Vertical Tiering	101
13.1.5 Storage Maintenance Window	103
13.2 Network related architectures	104
13.2.1 Elastic Network Capacity	104
13.2.2 Load Balanced Virtual Switches	104
13.2.3 Multipath Resource Access	105
13.2.4 Persistent Virtual Network Configuration	106
13.2.5 Redundant Physical Connection for Virtual Servers	107
13.3 Learning Check	107
14 Microsoft Azure	109
14.1 Introduzione	109
14.1.1 Regioni	111
14.1.2 Gestione	112
14.1.3 Accounting	112
14.1.4 Cenni storici	113
14.2 Fundamentals	113
14.2.1 Architecture	113
14.2.2 Service Management	114
14.2.3 Login	114
14.3 Basics	114
14.3.1 Compute Options	115
14.3.2 Data Storage Options	118
14.3.3 Networking Options	120
14.4 Learning Check	120

Capitolo 1

Informazioni sul corso

Le modalità di esame sono costituite da un progetto in gruppi di 1/2 persone ed un esame orale.

Link utili

- Canale telegram: t.me/cloudcomputingdinfunisa
- Server discord: discord.gg/2cxdpat

Suggerimenti per il corso

- corso concettuale: capacità di astrazione necessaria;
- necessario essere in grado di esporre con completezza e ricchezza di dettagli;
- parte applicativa: supporto e collaborazione con Microsoft.

Libri di testo


- Cloud Computing: Concepts, Technology and Architecture - T. Ertl, Z. Mahmood, R. Puttini (Prentice Hall)
- Cloud Computing Design Patterns - T. Ertl, R. Cope, A. Naserpur (Prentice Hall)



Capitolo 2

Concetti base del Cloud Computing

Consideriamo il normale utilizzo di un computer. Avendo a disposizione una capacità di calcolo fissata, può capitare lo scenario illustrato di seguente:



In media vengono utilizzati il 10% di CPU, il 60% di memoria e il 20% di larghezza di banda.

2.1 Le origini

Le prime tracce di quello che si può definire **Cloud computing** risalgono al 1961, quando lo scienziato John McCarthy affermò che in breve tempo sarebbe stato possibile usufruire della capacità di calcolo come una risorsa pubblica.

Verso fine anni '90 Salesforce.com iniziò a fornire servizi di gestione dell'azienda. Solo nel 2002 Amazon fece debuttare il primo servizio di Cloud computing, **Amazon Elastic Compute Cloud (EC2)**.

2.2 Definizioni

Nel corso degli anni sono state presentate diverse definizioni di **Cloud computing**, tutte legate all'utilizzo che se ne faceva nel periodo di riferimento.

La prima definizione fu data dalla multinazionale Gartner:

"...a style of computing in which scalable and elastic IT-enabled capabilities are delivered as a service to external customers using Internet technologies."

Il concetto espresso da questa definizione si rifà a scalabilità ed elasticità. Il cloud computing in questo senso è uno stile di calcolo che cambia le modalità con cui siamo stati abituati a fare computazioni. Successivamente fu la Forrester Research che provò a dare una definizione:

"...a standardized IT capability (service, software or infrastructure) delivered via Internet technologies in a pay-per-use, self-service way."

Qui vengono introdotti gli importanti concetti di **pay-per-use** e **self-service**, che offrono vantaggi come indipendenza dalla piattaforma e flessibilità, ma anche degli svantaggi come la complessità, in quanto esistono migliaia di servizi, e sapersi orientare richiede tempo. Possiamo dire che c'è una sorta di barriera di ingresso.

La definizione data dal NIST invece risale al 2011:

"Cloud computing is a model for enabling ubiquitous, convenient, on-demand network access to a shared pool of configurable computing resources that can be rapidly provisioned and released with minimal management effort or service provider interaction. This cloud model is composed of five essential characteristics, three service models, and four deployment models."

In pratica questa definizione afferma che il Cloud computing è un modello di calcolo per abilitare accesso alla rete on-demand su una serie di risorse di calcolo configurabili. Questo garantisce una fornitura veloce, quindi poca interazione con il provider. Inoltre per la prima volta si parla di *modello di calcolo*: questo rappresenta un passo avanti rispetto al modello di calcolo precedente.

Infine, la definizione del libro di testo adottato:

"Cloud computing is a specialized form of distributed computing that introduces utilization models for remotely provisioning scalable and measured resources."

Ovvero si parla di una forma di calcolo distribuito che fornisce risorse scalabili accessibili da remoto e misurate. Quindi possiamo affermare che il cloud computing è una diretta evoluzione del calcolo distribuito. È importante enfatizzare anche il concetto di risorse misurate, in quanto la gestione dei costi è uno degli argomenti principali su cui approfondire.

2.3 Business Drivers

Alcune delle nozioni fondamentali definite in questo capitolo si basano sullo scenario principale, che vede opporsi i **cloud provider**, che offrono infrastrutture e servizi, e i **cloud consumer**, rappresentati dagli utilizzatori delle infrastrutture sia in modo privato che in modo aziendale.


Il mercato generato dal cloud quindi è influenzato da entrambi i lati, ed è questo che spinge le organizzazioni a diventare cloud provider. Possiamo distinguere tre business driver:

- capacity planning;
- cost reduction;
- operational agility.

2.3.1 Capacity planning

Il **capacity planning** è il processo utilizzato per prevedere i servizi e le richieste future da utilizzare partendo dai dati a disposizione. *Avrò bisogno di un nuovo disco tra un anno? Il servizio che sto utilizzando ora è sufficiente?*

La capacity è la massima capacità di lavoro che una risorsa può fornire nel tempo, e deve infacciarsi con la richiesta. Una discrepanza tra la capacità di una risorsa IT e la domanda di questa risorsa può rendere tutto il sistema inefficiente. La previsione della quantità di risorse da utilizzare deve essere il più precisa possibile, in quanto può portare ad un *overprovisioning* o a un *underprovisioning*. Il primo scenario si verifica nel caso non viene utilizzata la totalità della capacity che è stata pagata, mentre il secondo è nel caso opposto, ovvero quando non sono state allocate abbastanza risorse.



Al contrario di come può sembrare, sono entrambi scenari negativi, in quanto non ci dimentichiamo che stiamo pagando la capacity. Per questo si parla di *planning* per minimizzare la discrepanza. Possiamo distinguere tre diverse strategie di capacity planning:

- **Lead strategy:** aggiungere capacità a una risorsa IT in anticipo rispetto alla domanda;
- **Lag strategy:** aggiungere capacità quando questa raggiunge la sua capacità massima;
- **Match strategy:** aggiungere capacità in piccoli incrementi, insieme all'aumento della domanda.

Il capacity planning può essere difficile in quanto c'è bisogno spesso di investimenti e soprattutto non è semplice prevedere le necessità esatte di una certa risorsa.

2.3.2 Cost Reduction

Il business generato dal cloud ha delle prestazioni che vanno tutelate, per cui ci sono dei costi da affrontare. Possiamo distinguere due tipi di spese:

- le spese in conto capitale ovvero spese immobilizzate, come l'acquisto di beni immobiliari e di infrastrutture (server, rack, postazioni per il raffreddamento o gruppi di continuità).
- le spese operative sono rappresentate dai costi correnti: una volta acquistata l'infrastruttura c'è bisogno di pagare un system manager per configurarla, degli assistenti, un'azienda di pulizia per i locali, senza dimenticare le spese per mantenere l'infrastruttura (stipendi, fitti, manutenzione).

Le spese in conto capitale generano sempre spese operative.

Questo perché oltre al fatto che i costi operativi superano quelli in conto capitale, bisogna attuare misure di sicurezza per proteggere le proprie infrastrutture, e non parliamo di cybersecurity ma proprio di sicurezza fisica! Quindi ci saranno spese come opportune serrature, guardie notturne, ecc. A queste poi si aggiungono le spese amministrative per il supporto e le licenze. Non è difficile infatti capire che di solito i reparti IT delle aziende sono quelli che generano più spese.

2.3.3 Organization Agility

L'agilità organizzativa permette a un'azienda di reagire velocemente ai cambi del mercato, ed è la misura di quanto un'azienda è capace di rispondere ai cambiamenti. È fortemente dipendente dal budget dell'azienda, e se impostata male può portare ad avere un sistema sempre stressato, cioè che funziona peggio, e ciò porta a non fornire un servizio di qualità, soprattutto nei casi in cui bisogna erogare servizi in maniera continua.

2.4 Technology Innovations

Rappresentano quelle tecnologie che hanno influenzato il cloud computing, a volte dette anche (impropriamente) cause del cloud computing. Possiamo distinguere le tecnologie in **technology drivers**, ovvero le scelte del passato, ed **enabling technologies**, ovvero quelle presenti e quelle future¹. Per quanto riguarda le prime, ce ne sono tre che possiamo considerare le più importanti:

- Clustering;
- Grid computing;
- Virtualization.

2.4.1 Clustering

I cluster rappresentano macchine e risorse indipendenti che lavorano come se fossero un unico sistema: permettono di ottenere un'affidabilità maggiore ed una percentuale di fallimenti minore. Un cluster è formato da hardware identico che fornisce prestazioni simili tra di loro. Anche un data center locale è un cluster.

2.4.2 Grid computing

Il grid computing (o griglie computazionali) fornisce una piattaforma in cui le risorse con un basso accoppiamento sono poste in un unico pool logico, per fornire alte performance. Un esempio di grid computing si può trovare nelle availability zones offerte da **Amazon Web Services**: le risorse sono eterogenee e geograficamente disperse. Il cloud computing può essere visto come una normale evoluzione del grid computing.

2.4.3 Virtualization

Il sistema di virtualizzazione permette di simulare macchine diverse su uno stesso hardware. È possibile letteralmente tagliare la dipendenza che intercorre tra hardware e software, rendendo l'infrastruttura indipendente. La virtualizzazione fa parte anche delle enabling technologies, in quanto ancora oggi è usata praticamente in ogni ambito del cloud computing.

2.4.4 Altre enabling technologies


- reti a banda larga
- data center
- container
- multitenant technology

¹Vedi par. 2.6

2.5 Terminologia

Con **Cloud** intendiamo un ambiente IT configurato per offrire risorse tramite internet che siano scalabili e misurabili. C'è da fare una distinzione tra Cloud e Internet. Infatti mentre possiamo dire che Internet non ha confini, il cloud ha invece un perimetro ben definito. Al suo interno possiamo trovare risorse hardware e software, servizi e calcolatori.

Con **risorsa IT** si intende un artefatto fisico o virtuale che può essere messo a disposizione tramite un servizio cloud. Ogni risorsa viene indicata con simboli diversi.




Una risorsa ospitata nei confini dell'organizzazione a cui appartiene viene detta **on-premise**. Una risorsa on-premise non può essere cloud-based e viceversa, ma può accedere o interagire con una risorsa cloud-based. Esiste poi il *Redudant deployment*, che permette di avere risorse sia on-premise che su cloud, aumentando l'affidabilità.

2.5.1 Scaling

Lo scaling rappresenta la capacità di una risorsa di poter gestire le richieste d'uso (che aumentano e diminuiscono), mantenendo la stessa architettura. Esistono due tipi di scaling.

Horizontal scaling

L'Horizontal scaling è quello tipico dei sistemi distribuiti, e consiste nell'allocare o rilasciare risorse di uno stesso tipo. Ad esempio, supponiamo di avere a disposizione un certo numero di server fisici e un numero di server virtuali che possono essere aumentati per offrire più risorse di calcolo (scaling out) o diminuiti per ridurre gli sprechi quando non tutti vengono utilizzati (scaling in).



Vertical scaling

Il vertical scaling permette di eseguire una risorsa con più o meno capacità, ad esempio come dare più CPU a una risorsa (scaling up), o meno storage ad un'altra risorsa (scaling down). In breve, le risorse hardware utilizzate sono le stesse ma possono essere rese più o meno performanti a seconda della domanda.

Il vertical scaling, a differenza di quello orizzontale, non è potenzialmente infinito, in quanto è limitato dalla capacità dell'hardware, tuttavia è estremamente veloce ed efficace. Inoltre l'horizontal scaling

utilizza lo stesso hardware che è possibile trovare normalmente in commercio (se voglio costruire un cluster posso benissimo acquistare 100 computer e gestirmeli da solo); il vertical scaling utilizza invece hardware specializzato.

2.5.2 Service Level Agreement

Le condizioni di utilizzo di un **cloud service** sono spesso indicate in un accordo chiamato **Service Level Agreement** (SLA). Uno SLA è scritto in linguaggio naturale (quindi è leggibile da umani) e mette in relazione il cloud provider con il cloud consumer, stabilendo e garantendo la **Quality of Service** (QoS). È una specifica critica nel mondo del cloud computing, perché nella stragrande maggioranza dei casi le implementazioni delle architetture sono nascoste al cloud consumer².

2.6 Obiettivi e benefici


Come in precedenza sono state affrontate le tecnologie che hanno permesso lo sviluppo e l'evoluzione del cloud computing, ora analizziamo quali sono gli obiettivi principali e i benefici che esso porta.

2.6.1 Reduced Investments and Proportional Costs

Il problema di acquistare hardware e software e i costi di manutenzione impattano in maniera forte su un centro di calcolo, quindi la possibilità di effettuare accessi on-demand pagando solo per ciò che si usa è uno degli obiettivi del cloud computing. La percezione di avere risorse infinite riduce il bisogno di ricorrere a planning e provisioning, e questo garantisce un beneficio all'azienda che affidandosi a servizi cloud riducendo i costi dell'hardware può concentrarsi sul suo obiettivo principale. Inoltre c'è un livello di scelta molto granulare, che permette di evitare la necessità di *upfront commitments*. Inoltre l'infrastruttura delle macchine non è vincolata fisicamente, il che significa che è possibile spostarla con relativa facilità.

2.6.2 Increased Scalability

Grazie alla scalabilità il cloud può allocare dinamicamente risorse in modo molto veloce. Ad esempio, se so che il mio servizio viene utilizzato prevalentemente dalle 10 alle 22, posso organizzare le risorse per fare in modo che scalino in base al traffico che si genera sulla piattaforma, e posso impostare un limite per tutelarli da eventuali spese non considerate. Le strategie di business driver utilizzate in questi casi sono *lag strategy* e *match strategy*.



²Un cloud consumer spesso è anche indicato come **Cloud Service Consumer**, ruolo temporaneo che viene assunto quando usufruisce di un servizio cloud.

2.6.3 Increased Availability and Reliability

La struttura modulare delle architetture cloud permettono di far fronte a diversi problemi che si verificano spesso, come tempi di downtime necessari, che possono essere annullati grazie alla disponibilità di più macchine che possono essere interscambiate per effettuare le stesse operazioni. Le risorse IT che hanno maggiore affidabilità riescono anche ad evitare più facilmente le condizioni di fallimento.


Summary of Key Points

- Gli ambienti cloud comprendono un'estesa infrastruttura che offre una serie di risorse IT che possono essere noleggiate utilizzando un modello *pay-per-use*. Messi a confronto con ambienti equivalenti on-premise, hanno il potenziale per ridurre gli investimenti iniziali e i costi operazionali.
- L'abilità di un cloud di scalare le risorse permette alle organizzazioni di sostenere cambiamenti imprevedibili di utilizzo delle risorse senza far fronte a quei costi che dovrebbero essere sostenuti senza cloud.
- Utilizzando il cloud per aumentare la disponibilità di risorse a disposizione, le aziende possono aumentare la qualità del servizio offerto e ridurre o evitare del tutto potenziali perdite di utenti e di denaro.

2.7 Risks and Challenges

Esistono principalmente quattro principali categorie di rischio:

- **Increased security vulnerabilities:** con il cloud si ha un'espansione dei *trust boundaries*, ovvero è come se l'azienda diventasse più grande. Il cloud provider ha accesso ai nostri dati, e nonostante siano implementati metodi di crittografia end-to-end per la comunicazione, questi boundaries estesi possono essere vittima di interventi maliziosi. Di seguito è illustrato uno scenario dove due aziende che si affidano allo stesso cloud provider devono convivere con una situazione che viene chiamata di **boundaries overlapping**: i dati presenti nel cloud possono costituire un rischio per le aziende.



- **Reduced operational governance control:** significa che i cloud consumer devono considerare rischi derivanti dalla lontananza delle regioni in cui si trovano le infrastrutture che ospitano le loro risorse sul cloud. Ad esempio, queste distanze potrebbero richiedere ulteriori step di

connessione e introdurre vincoli di larghezza di banda, che causano problemi di connessione e l'impossibilità di accedere alle risorse.

- **Limited portability between cloud providers:** di norma le tecniche utilizzate per la costruzione delle infrastrutture cloud sono proprietarie a causa della mancanza di standard nell'industria del cloud computing, per cui potrebbe risultare difficile o in certi casi impossibile spostare su un altro cloud l'infrastruttura hostata da un certo cloud provider. È chiaro che ci sono principalmente problemi di portabilità e di migrazione, ad esempio un certo cloud su cui metto a disposizione le mie risorse potrebbe fornire crittografia e firma digitale come sicurezza mentre un altro solo crittografia standard: in questo caso mi risulterebbe particolarmente complicato riorganizzare l'architettura per effettuare la migrazione.
- **Multi-regional compliance and legal issues:** i data center vengono costruiti di norma in posti quasi isolati e in regioni che offrono elettricità a buon prezzo. Il problema sta nel fatto che i dati presenti in quel cloud sono sottoposti alle leggi vigenti in quella regione, e nessuno mi garantisce che siano le stesse che vigono nel paese in cui mi trovo. I dati devono sempre essere tutelati, ma spesso accade che i cloud consumer non sanno neanche in che regioni stanno i loro dati. Alcuni esempi: a seguito della Brexit la società ServiceNow ha spostato molte delle sue infrastrutture dal Regno Unito in Olanda, per garantire la tutela delle normative europee. Un cloud consumer europeo dovrebbe fare attenzione ai suoi dati se sono hostati negli USA, in quanto secondo il Patriot Act qualsiasi organizzazione governativa può accedere ai dati presenti nel territorio statunitense.

Summary of Key Points

- Gli ambienti cloud possono introdurre diverse sfide di sicurezza, alcune delle quali portano al fenomeno del *boundary overlapping*, nel quale un cloud provider condivide le stesse risorse con più cloud consumer.
- Le scelte operazionali di un cloud consumer possono essere limitate dagli ambienti ospitati dal cloud a causa del controllo esercitato da un cloud provider sulle sue piattaforme.
- La portabilità delle risorse cloud-based può essere compromessa dalle dipendenze di caratteristiche proprietarie imposte da un cloud provider.
- La posizione geografica dei dati e delle risorse potrebbero trovarsi fuori dal controllo di un cloud consumer nel caso fossero ospitate da un cloud provider di terze parti. Questo potrebbe causare diversi problemi o incongruenze a livello legale, perché la maggior parte delle volte le leggi indicano come responsabile il cloud consumer e non il cloud provider.

2.8 Learning Check

Alla fine di ogni capitolo verranno elencate delle domande che potrebbero essere poste all'esame.

1. Descrivi la diffusione del cloud computing partendo da una combinazione di business drivers e innovazioni tecnologiche e descrivi l'evoluzione delle definizioni associate al cloud computing.
2. Descrivi le responsabilità e le sfide del capacity planning per le organizzazioni IT e spiega il problema dei costi operazionali per le aziende che presentano requisiti di utilizzo variabili e/o imprevedibili.
3. Spiega il bisogno di agilità organizzativa per un'azienda IT di rispondere a cambiamenti del business.

4. Spiega il concetto di grid computing e la definizione del modello *pay-as-you-go*.
5. Spiega la natura demand-driven e le tecnologie delle architetture di back-end che sono comunemente utilizzate nelle applicazioni web.
6. Spiega la causa della diffusione del cloud computing come un campo distinto di competenza risultante dai business drivers e dalle innovazioni tecnologiche.
7. Descrivi il termine "servizio" nel contesto del cloud computing e spiega cosa costituisce una risorsa IT.
8. Descrivi l'horizontal scaling e i due tipi di horizontal scaling, il vertical scaling e i due tipi di vertical scaling.
9. Spiega perché la virtualizzazione è una tecnologia chiave degli ambienti del cloud computing, e i benefici di un ambiente virtualizzato.
10. Spiega da cosa è formato un cloud e la differenza tra una risorsa on-premise e una risorsa cloud-based.
11. Spiega cosa vuol dire "servizio" da una prospettiva IT e cosa costituisce un servizio cloud (cloud service).
12. Spiega cos'è un *service agent* e perché è comunemente usato nel cloud.
13. Descrivi i benefici degli investimenti ridotti e dei costi proporzionali e spiega la relazione di questi benefici con il modello *pay-per-use*, e come il beneficio dei costi di noleggio di risorse IT cloud-based differisce da quello delle risorse on-premise.
14. Descrivi il beneficio della *Increased Scalability* e spiega come questo beneficio può essere in relazione con la reattività di un'organizzazione.
15. Descrivi il beneficio della *Increased Availability and Reliability* e spiega come questo beneficio può essere in relazione con il supportare situazioni di fallimento, e come è fornito in maniera trasparente ai cloud consumer.
16. Descrivi la sfida che caratterizza le *Increased Security Vulnerabilities* e spiega come questa sfida può essere messa in relazione all'espansione e all'overlapping dei trust boundaries come può essere in relazione con i problemi di compatibilità e di sicurezza tra cloud provider e cloud consumer.
17. Descrivi il rischio scaturito dal *Reduced Operational Governance Control* e spiega come questo rischio sorge negli ambienti cloud e come è in relazione con l'utilizzo dei SLA da parte dei cloud consumer. Spiega poi anche come questo rischio può portare a problemi nel caso di cloud provider irresponsabili.
18. Descrivi la sfida della portabilità limitata tra cloud provider e spiega perché i cloud provider impongono caratteristiche proprietarie nei loro cloud, indicando il ruolo degli standard industriali in relazione con questa sfida.
19. Descrivi i rischi causati dal fenomeno del *Multi-Regional Compliance* e spiega come problemi di natura legale possono sorgere a causa della posizione geografica dei dati di un cloud consumer.



Capitolo 3

Caratteristiche fondamentali del Cloud Computing

I modelli fondamentali usati per definire servizi, proprietà e fasi del cloud computing si dividono sottocategorie che vanno affrontate separatamente.

3.1 Ruoli

Le organizzazioni e le persone possono assumere diversi tipi di ruoli in base a come si relazionano tra di loro e/o interagiscono con il cloud e le risorse ospitate in rete.

Cloud Provider

L'organizzazione che fornisce le risorse IT cloud-based è detta **Cloud provider**. I cloud provider si occupano di garantire i servizi offerti da un SLA, e di solito posseggono fisicamente le risorse IT che noleggiavano; tuttavia ci sono cloud provider che rivendono risorse comprate o noleggiate da altri cloud provider.

Cloud Consumer

Un **cloud consumer** è un'organizzazione o una persona che possiede un contratto formale con un cloud provider per usufruire di certe risorse IT messe a disposizione da quest'ultimo. In particolare, un cloud consumer utilizza un *cloud service consumer* per accedere a un servizio cloud.

Cloud Service Owner

È la persona o l'organizzazione che possiede la risorsa IT che mette a disposizione. Può essere anche il cloud consumer stesso, in quanto è colui che istanzia la risorsa.

Cloud Resource Administrator

È la persona o l'organizzazione responsabile della gestione delle risorse IT cloud-based. Il Cloud Resource Administrator può essere (o appartenere) il cloud consumer o il cloud provider, oppure può essere un'organizzazione di terze parti entrata in gioco per amministrare le risorse.

Cloud Auditor

Una terza parte che conduce valutazioni indipendenti degli ambienti cloud. Le responsabilità del Cloud Auditor includono la valutazione dei controlli di sicurezza e delle garanzie della privacy. Il suo compito principale è quello di fornire una valutazione imparziale dell'ambiente cloud di un cloud provider che verrà utilizzato da un cloud consumer.


Cloud Broker

Un Cloud Broker si occupa di negoziare tra le parti; il suo è un ruolo di intermediario tra cloud provider e cloud consumer. I suoi compiti sono principalmente tre:

- evitare che un cloud consumer rimanga bloccato da un particolare cloud provider, in modo da poter utilizzare diversi provider per uno stesso servizio;
- aggregare i servizi da diversi provider e fornire un servizio unico che sia una specie di "fusione" tra i vari servizi;
- aiutare le aziende a orientarsi tra i vari servizi offerti.

Cloud Carrier

Il Cloud Carrier è la parte responsabile della fornitura della connessione a livello di rame tra i cloud provider e i cloud consumer. Questo ruolo viene spesso assunto da provider di servizi di rete e di telecomunicazioni. Il grafico seguente mostra costi e benefici di tutti i ruoli presentati.



Il diagramma evidenzia alcune caratteristiche importanti: innanzitutto possiamo distinguere le **CAPEX** (*capital expenses*, spese in conto capitale), e le **OPEX** (*operational expenses*, spese operative). Possiamo subito notare questo passaggio dai costi iniziali ai benefici, e in particolare possiamo facilmente fare una distinzione tra i costi e i prezzi, con i secondi che dipendono direttamente dai primi. Il creator si occupa dell'infrastruttura, definendo così i costi di fornitura. A questo punto i costi di input influenzano il creator price, che a sua volta influenzano i prezzi successivi fino ad arrivare al business price. Questo infatti viene stabilito dal cloud service consumer che acquista i servizi cloud da rivendere ai clienti. I costi sono rapportati ai benefici, in quanto la costruzione dei prezzi ed il prezzo finale determinano i benefici. I Service Level Agreements garantiscono la QoS che alla fine percepisce l'utente finale.

3.2 Boundaries

Esistono due tipi di boundary:

- Un **Organizational Boundary** è il perimetro fisico che racchiude tutte le risorse IT¹ possedute e gestite dall'organizzazione.
- Un **Trust Boundary** è un limite esteso per comprendere anche le risorse cloud-based di un'organizzazione.

3.3 Caratteristiche di un Cloud

Come già detto, un Cloud non comprende solo risorse IT ma acquista importanza anche in ambito economico. Infatti richiede un insieme specifico di caratteristiche per attivare il remote provisioning e la scalabilità delle risorse in maniera efficiente. La qualità di un Cloud Provider si misura sulle seguenti sei caratteristiche: cinque delle quali prese direttamente dalla definizione di Cloud computing del NIST, a cui viene aggiunta l'ultima per completezza.

- on-demand usage (*when*);
- ubiquitous access (*where*);
- multitenancy and resource pooling (*how*);
- elasticity (**how**);
- measured usage (*how much*);
- resiliency (*how reliable*).

On-Demand Usage

Il Cloud consumer deve poter accedere ai servizi in qualsiasi momento, e effettuare il self-provisioning tramite delle console di gestione dove tutti i servizi possono essere gestiti in maniera autonoma e automatica. Una volta configurata la risorsa non c'è più bisogno di intervento umano.

Ubiquitous Access

Rappresenta la possibilità di poter accedere alle risorse tramite più dispositivi o più protocolli di trasporto. In questo modo i servizi sono ritagliati per ogni tipo di consumer, tuttavia man mano che aumenta la user base, aumenta anche il pericolo dei dati che vengono forniti. L'accesso alle risorse è limitato di default, per farantire un accesso più sicuro.

Multitenancy and Resource Pooling


È la caratteristica che permette a una risorsa di poter essere utilizzata da più utenti contemporaneamente, ognuno però isolato dall'altro. Essenzialmente si rifà al concetto di virtualizzazione, che permette di isolare processi o anche utenti su un sistema operativo. In questo modo è possibile dividere la stessa macchina fisica in più macchine virtuali, che quindi vanno a partizionare l'hardware non fisicamente ma logicamente.

Il Resource Pooling invece permette ai cloud provider di raggruppare risorse su larga scala in base alla domanda dei consumer. Normalmente questo è possibile sfruttando la multitenancy.

Rapid Elasticity

L'elasticity è l'abilità di una piattaforma cloud di scalare in modo trasparente le risorse in base all'aumento o alla diminuzione della domanda. L'elasticity è un aspetto chiave che porta ad adottare le tecniche del cloud computing.

¹ Attenzione: racchiude solo le risorse di natura IT, non rappresenta il limite effettivo dell'organizzazione



Measured Usage

Questa caratteristica permette ad un cloud di tenere traccia dell'utilizzo delle risorse IT. Un consumer in questo modo non paga un servizio con delle quote dipendenti dall'investimento ma solamente dal consumo. Significa che è necessario fornire l'evidenza di qual è l'utilizzo delle risorse, quindi mantenere le informazioni sull'uso ad una grana finissima. Ovviamente è importante non solo per il billing ma anche per il monitoring. Il ruolo che si occupa di questa caratteristica è il Cloud Auditor.

Resiliency

Indica quanto è affidabile il servizio ed è la capacità di resistere ai fallimenti. Per fallimenti non si intendono solo quelli di natura informatica ma anche quelli causati da frane, terremoti, disastri naturali che potrebbero compromettere l'integrità di un certo data center. Grazie a questa capacità ci sono meccanismi di failover che permettono di spostare le risorse tra le zone di disponibilità, il tutto mentre il programma è in esecuzione su macchine virtuali. Implica anche la ridondanza di informazioni in diverse su diverse parti del cloud.

Summary of Key Points

- L'On-Demand Usage è l'abilità di un cloud consumer di effettuare self-provisioning delle risorse senza l'interazione di un cloud provider.
- L'Ubiquitous Access permette ai servizi cloud-based di essere accessi da diversi consumer e da diversi dispositivi, mentre la multitenancy è l'abilità di una singola istanza di risorsa di essere condivisa tra diversi consumer.

3.4 Cloud Delivery Models

Un *Cloud Delivery Model* rappresenta una combinazione specifica di risorse IT offerte da un cloud provider. Negli ultimi 10-15 anni si sono distinti principalmente tre modelli:


- Infrastructure-as-a-Service (IaaS)
- Platform-as-a-Service (PaaS)
- Software-as-a-Service (SaaS)

Più generalmente, al giorno d'oggi esiste una varietà di questi servizi, che possiamo abbreviare con *xaas*, dove *x* può rappresentare qualsiasi cosa. In particolare vedremo **Business Process-as-a-Service** (BPaaS) e **Information-as-a-Service** (INaaS).

3.4.1 Infrastructure-as-a-Service (IaaS)

Il modello IaaS presuppone che il cloud consumer sia completamente incaricato della gestione delle risorse: in breve possiede la password della macchina, quindi gestisce i tempi degli aggiornamenti, quando e come deployarli, ecc.

Come si può vedere dal grafico il collegamento tra virtual server e physical server è completamente schermato.



3.4.2 Platform-as-a-Service (PaaS)

Il modello PaaS permette di avere un pacchetto di risorse pronte all'uso per il cloud consumer. Offre però meno controllo rispetto al modello IaaS. Le risorse offerte per questo tipo di modello sono divise in diversi stack in base all'ambiente e al linguaggio di programmazione usato.



3.4.3 Software-as-a-Service (SaaS)

Si tratta direttamente di un servizio scritto da altri o dal provider al quale ci si affida. Il cloud consumer non ha nessuna responsabilità per l'amministrazione e non può intervenire. Può essere rappresentato da una RESTful API, da un'applicazione, o da qualsiasi risorsa che mostri solamente l'endpoint attraverso quale si accede.

3.4.4 Function-as-a-Service (FaaS)

È un'evoluzione di IaaS e SaaS: il cloud consumer non ha l'incombenza di gestire un'infrastruttura, ma ha più libertà di scrivere le applicazioni rispetto a PaaS. Può essere fatto il deployment di funzioni che vengono messe in container forniti dall'infrastruttura del cloud provider. Mentre il vantaggio del consumer è dato dalla libertà di sviluppo, il cloud provider deve bilanciare il carico di lavoro delle risorse rispetto alle richieste e deve farlo alla granularità più fine possibile.

Ci sono tuttavia delle limitazioni nell'utilizzo della risorsa, ad esempio i tempi di esecuzione o il fatto che si paga ogni volta che la funzione viene invocata. Il modello FaaS può addirittura dare più libertà rispetto a PaaS perché è possibile sviluppare in qualsiasi linguaggio, mentre con PaaS bisogna controllare che il cloud provider offra quel determinato ambiente di sviluppo.

3.4.5 Modelli ibridi


Un modello ibrido come quello IaaS + PaaS permette di unire i vantaggi di entrambe le architetture dando molti più vantaggi al cloud consumer. Possono esserci anche due cloud provider diversi a dare le due infrastrutture.

Il modello IaaS + PaaS + SaaS permette invece di combinare diversi livelli di risorse IT costruiti uno sull'altro. In questo modo ogni livello può essere gestito separatamente dagli altri per permettere una gestione più granulata ed efficiente.

3.4.6 Business Process-as-a-Service e Information-as-a-Service

Questi modelli di servizio rappresentano un'estensione del business domain in quanto sono i livelli più astratti dei Delivery Models. Mentre IaaS, PaaS e SaaS sono ormai presenti in ogni Cloud Provider, queste tecnologie vengono inserite in un contesto più orientato al business, che ingloba i modelli precedenti in cui vengono offerti processi di business come servizio. Un esempio è dato dalle aziende che fanno outsourcing delle risorse, ovvero l'esternalizzazione di interi processi aziendali su un'infrastruttura basata su cloud.

Tipicamente invece il modello INaaS viene utilizzato da un'azienda che fornisce informazioni legali sui meccanismi di tassazione dell'azienda committente. Questi servizi sono importanti perché rappresentano delivery model se sono su cloud.




The Enterprise architecture on Cloud

3.4.7 Riquadro generale

Di seguito è possibile osservare un grafico che mostra i diversi livelli di astrazione, e una tabella che mostra le principali differenze tra i diversi modelli.


Abstraction level	Service offering
Infrastructure as a service (IaaS)	Hardware infrastructure (servers, storage, etc.) on a utility basis.
Platform as a service (PaaS)	Same as IaaS but includes the operating system and any other core applications of the operating environment to enable you to install and run your software. Pricing generally is on a utility basis.
Software as a service (SaaS)	As per PaaS but includes hosted applications that fulfill a function. The function could be a business, social, or personal function. You simply use the application or applications that you need, when you need it, and avoid the cost of installing and maintaining the application and its supporting hardware infrastructure. Pricing is on a per-use basis.
Information as a service (INaaS)	Provides information relevant to an individual or corporation and to their businesses, business processes, or tasks. Pricing is usually on a consumption, per-use basis.
Business process as a service (BPaaS)	Fulfills a business function or replaces a business process in an organization. Typically combines business process outsourcing (BPO) with software as a service (SaaS). Pricing generally on a per use basis.



3.5 Cloud Deployment Models

I deployment models servono per differenziare gli ambienti per ownership e tipologie di accesso. Distinguiamo 4 modelli:

- **Public Cloud:** è quello più diffuso, consiste nell'utilizzare i servizi messi a disposizione dal cloud provider, che + il responsabile della creazione e la manutenzione delle infrastrutture.
- **Community Cloud:** si tratta di ambienti cloud destinati a una categoria ristretta di utenti: tipicamente utenti che decidono di lavorare insieme sulle stesse caratteristiche di una certa risorsa.
- **Private Cloud:** un cloud privato è gestito da una singola organizzazione per scopi interni, ma che solo poche aziende possono permettersi perché utilizza un gran numero di risorse e attrezzature. Organizzativamente è omogeneo, quindi il cloud diventa una risorsa formalmente esportata verso un altro dipartimento. Attenzione perché questo non vuol dire che le risorse sono on-premise, perché anche il private cloud offre le caratteristiche di resilienza ed elasticità che spesso le risorse on-premise non hanno. La cosa fondamentale è capire come funziona: spesso sono le aziende che acquistano infrastrutture da un cloud provider e le mettono a disposizione della propria azienda, da come si può vedere nel grafico.



Infatti una risorsa on-premise non è un servizio. Un cloud privato è vantaggioso perché risiede all'interno di del trust boundary di un'azienda. È comodo per avere più controllo sui dati, ed ha il vantaggio di estrarre i processi che normalmente non si può fare con le risorse on-premise, soprattutto quelli di billing e di measured usage per sapere i costi precisi.

- **Hybrid Cloud:** un cloud ibrido permette ad un'organizzazione di utilizzare sia un cloud privato che quello pubblico in modo da scalare più facilmente, avendo a disposizione risorse maggiori di quelle presenti all'interno dell'azienda.

3.6 Learning Check

1. Descrivi i ruoli che si applicano agli individui, alle organizzazioni e ai software che fanno parte di un ambiente cloud, includendo: service consumer, cloud service consumer, cloud provider, cloud consumer, cloud service owner, cloud resource administrator.
2. Descrivi i limiti fisici e logici di un ambiente cloud, includendo gli Organizational boundary (in relazione ai cloud provider e ai cloud consumer), e i Trust boundary (e come sono in relazione tra cloud consumer e cloud provider). Spiega anche la relazione tra questi due tipi di boundaries.

3. Caratteristiche fondamentali del Cloud Computing

3. Elenca e descrivi l'insieme delle caratteristiche che deve avere un ambiente IT per essere considerato un cloud.
4. Descrivi le caratteristiche dell'On-Demand Usage e come si relaziona allo scaling.
5. Descrivi le caratteristiche dell'Ubiquitous Access.
6. Descrivi la caratteristica del multitenancy in relazione all'allocazione di risorse IT.
7. Descrivi le caratteristiche dell'Elasticity e come è associata all'aumento degli investimenti e ai costi proporzionali.
8. Descrivi le caratteristiche del Measured Usage e come si relaziona col modello pay-per-use.
9. Descrivi le caratteristiche della Resiliency e come si relaziona ai failover.
10. Descrivi il modello IaaS e come si collega al provisioning delle risorse "raw". Spiega anche come i cloud consumer guadagnano un alto livello di controllo con il modello IaaS.
11. Descrivi il modello PaaS e come fornisce un ambiente cloud predefinito.
12. Descrivi il modello SaaS e come limita il controllo del cloud consumer.
13. Spiega come possono essere mescolati i modelli di cloud delivery.
14. Descrivi il modello di deployment di cloud pubblico e spiega come le risorse IT di un cloud pubblico sono fornite da una terza parte a pagamento.
15. Descrivi il modello di community cloud e spiega come l'accesso è limitato a un insieme ristretto di utenti.
16. Descrivi il modello di cloud privato e spiega come un cloud privato è posseduto da una singola organizzazione.
17. Descrivi il modello di cloud ibrido e spiega perché un cloud è detto *ibrido* in relazione agli altri modelli.



Capitolo 4

Tecnologie chiave del Cloud Computing

Come già detto in precedenza, è importante comprendere gli aspetti del fenomeno del cloud computing non solo come un fenomeno tecnologico, ma anche e principalmente economico. Infatti il cloud come lo conosciamo oggi ha avuto delle spinte economiche di grande portata. Ad esempio, come appena visto, un cloud privato gestisce le spese meglio rispetto ad una infrastruttura on premise, questo perché viene fatto accounting e billing stesso all'interno dell'azienda, rendendo tutti consapevoli dei costi e degli investimenti. In pratica il cloud privato tratta i dipendenti dell'azienda come se fossero clienti.

Le tecnologie che vedremo in questo capitolo vengono considerate importanti per aver costituito il cloud, ma solo se prese tutte insieme, in quanto singolarmente non influiscono in maniera decisiva. Alcune di queste tecnologie esistevano già prima del cloud, ma messe insieme sono diventate mature nello stesso momento, e hanno reso possibile quel movimento che ha portato alla fornitura di capacità di calcolo come servizio. Distinguiamo sei tecnologie chiave:


- **Broadband Networks and Internet Architecture**
- **Data Center Technology**
- **Virtualization Technology**
- **Web Technology**
- **Multitenant Technology**
- **Service Technology**

4.1 Broadband Networks and Internet Architecture

Uno dei principi fondamentali del cloud computing è la possibilità di accedervi ovunque, e ciò implica connettività di rete, requisito quindi critico per il corretto funzionamento. Anche nel caso di cloud che permettono di gestire una parte delle risorse offline, la rete è comunque necessaria per effettuare il *remote provisioning* delle risorse.

4.1.1 Funzionamento della rete

Gli ISP hanno il compito di fare da backbone a tutte le reti, collegandole tra di loro. Come illustra il grafico, partendo dall'alto si può notare come il cloud consumer, che in questo caso è un'organizzazione, ha una rete da cui accede ben strutturata. Le comunicazioni con l'esterno avvengono tramite gli ISP che con la loro struttura modulare si occupano di gestire un'enorme quantità di traffico di rete. Il backbone connette anche i service provider a cui il cloud provider è collegato. Qui si vede anche la centralità del ruolo del **Cloud Carrier**, che offre ridondanza a livello di gestione per garantire la qualità della rete anche in caso di malfunzionamenti.



La topologia della rete è divisa in maniera gerarchica in tre Tier:

- Al **Tier 1** appartengono le tecnologie di rete utilizzate per connessione con cavi sottomarini di tutto il mondo;
- Il **Tier 2** è rappresentato dai grandi provider regionali;
- Al **Tier 3** appartengono gli ISP locali (Vodafone, TIM, ecc.).


La comunicazione di rete avviene generalmente tramite protocollo TCP: è previsto il riassettaggio di pacchetti che possono arrivare tramite diversi ISP. Il routing dei pacchetti avviene al layer 7 della pila ISO/OSI e non al layer 4 in quanto permette un load balancing migliore.

4.1.2 Limitazioni e problemi

Due punti cruciali delle comunicazioni di rete sono la latenza e la larghezza di banda: da un lato ci sono i provider che migliorano sempre di più la qualità della rete, dall'altra gli utenti che utilizzano e richiedono sempre più banda. La latenza invece rappresenta un problema perché rallenta i pacchetti nel caso di nodi congestionati. Infatti le applicazioni che si basano sulla rete spesso devono rispondere a requisiti molto stretti e che quindi vengono influenzati in maniera importante da latenza e larghezza di banda, quindi la scelta di un cloud carrier diventa importante.

4.2 Data Center Technology

I centri di calcolo si basano su alcune componenti chiave come la virtualizzazione, che permette di rendere standard e modulare la fornitura di hardware, in quanto viene fornito hardware sempre identico perché astratto. Le strutture sono basate su rack di componenti facilmente rimpiazzabili e affidabili. Alcuni di questi componenti supportano lo swap a caldo, migliorando le prestazioni, grazie all'esistenza di blade che condividono componenti critiche (gestione, console, periferiche di massa locali) che costituiscono i nodi di calcolo del data center.



4.2.1 Funzionamento

Lo storage è organizzato in maniera ridondante, dove è possibile l'accesso sia a blocchi sia a livello di file. Le reti che vanno verso l'esterno si interconnettono direttamente con un cloud carrier, fatto con tecnologie estremamente veloci. Il load balancing, come detto anche in precedenza, avviene guardando il contenuto dei pacchetti (quindi a level 7), in questo modo si può riconoscere un certo tipo di richiesta, e se già è stata fatta in precedenza, viene inoltrata allo stesso nodo che la ha già in cache, aumentando le prestazioni.

I data center hanno un ciclo di vita di 5-7 anni. Per calcolare il ciclo di vita si analizzano alcuni parametri, tra cui l'ammortamento del costo, la velocità di crescita delle tecnologie, il fatto per cui i costi di gestione aumentano per macchine più vecchie: infatti un centro di calcolo è eterogeneo per definizione. La sicurezza di un data center è fondamentale perché i dati si trovano tutti in un solo posto e vanno protetti bene. I vantaggi dell'utilizzo vanno dalla condivisione dell'energia elettrica al raffreddamento, al contesto operativo, più facile da gestire a livello organizzativo.

4.3 Virtualization Technology


Virtualizzare significa portare qualcosa di fisico a livello software. È possibile virtualizzare:

- server;
- storage: ha diversi vantaggi, ad esempio è possibile replicare dati e ottenere dischi virtuali di qualsiasi dimensione, non rimanendo vincolati dalle dimensioni dei dischi in commercio. Ad esempio è possibile virtualizzare un disco da 4.20 GB.
- network: incapsulando pacchetti in altri pacchetti e facendo in modo che il routing venga svolto in maniera logica;
- power: anche l'energia elettrica si può virtualizzare, utilizzando un UPS (Uninterruptable Power Supply).

I principali vantaggi sono l'indipendenza dall'hardware, magari attraverso server più potenti che permettono ad una stessa macchina virtuale di offrire prestazioni migliori, ma anche la possibilità di fare rollback in qualsiasi momento e con pochissimo sforzo.

Le due opzioni più diffuse sono la **OS based virtualization** e la **hardware based virtualization**. La prima è meno efficiente perché il sistema operativo consuma più risorse, e spesso finisce per rallentare la macchina a causa delle molteplici dipendenze e colli di bottiglia. Un altro problema è rappresentato dal costo delle licenze.

L'hardware based virtualization invece utilizza un **hypervisor** che non è altro che una versione molto semplificata di un sistema operativo contenente solo il minimo necessario per permettere il corretto funzionamento delle applicazioni che ci girano sopra. Permette la gestione di più virtual machine all'interno utilizzando dati ottimizzati per i server. Il tutto è organizzato da un Virtual Infrastructure Manager (VIM). Il grafico illustra le differenze tra i due tipi di virtualizzazione.



4.4 Web Technology

Le tecnologie web sono utilizzate generalmente come implementazione a livello intermedio e a livello di interfaccia per i servizi cloud based. Le componenti fondamentali del web sono il web browser client e il web server. A questi due si uniscono le strutture quali gateways, router, load balancer che ne migliorano l'affidabilità e la scalabilità. L'architettura del web si basa fundamentalmente su:

- **Uniform Resource Locator (URL)**: una sintassi standard per creare identificativi che puntano a risorse web;
- **HyperText Transfer Protocol (HTTP)**: il protocollo principale di comunicazione utilizzato nel web;

- **Markup Languages (HTML, XML):** linguaggi di etichettatura che servono a presentare graficamente le risorse accessibili.

Le applicazioni web che conosciamo sono divise in più layer, ognuno dei quali si occupa di specifici compiti. Esistono dei PaaS per tutte le applicazioni web hostate su un cloud, forniti direttamente dal cloud provider.

4.5 Multitenant Technology

Tramite la multitenant technology è possibile far accedere diversi consumer allo stesso servizio, ognuno con la propria visione dell'applicazione. Non solo, ma è possibile anche definire la gestione dell'amministrazione e della personalizzazione di un'istanza di questo software condiviso, in maniera totalmente isolata tra un utente e l'altro. Principali vantaggi di questa tecnologia sono personalizzazione (UI, business process, data model), access control, data security, recovery, upgrade, data tier isolation. La differenza tra multitenancy e virtualization è essenzialmente che virtualizzazione indica stesse copie virtuali di uno stesso ambiente, mentre multitenancy indica ambienti progettati per l'accesso di diversi utenti quindi configurati in modo differente e non come semplici repliche.

4.6 Service Technology

Per Service Technology intendiamo qualsiasi tipo di tecnologia offerto come servizio. Come già spiegato precedentemente si tratta del concetto di XaaS, dove X può rappresentare qualsiasi tipo di tecnologia.

4.7 Caso d'uso: DTGOV

Analizziamo un caso d'uso, nell'ambito di DTGOV, società di pubblica amministrazione statunitense creata dal ministero della social security che serve per decentralizzare tutti i servizi di IT. Essa offre una serie di servizi per le organizzazioni del settore pubblico, sia infrastrutture IT sia software. I servizi sono personalizzati per ogni cliente, a partire dalla gestione dei contratti, fino ad arrivare alla reingegnerizzazione dei modelli IT per ridurre complessità e costi.

L'infrastruttura comprende tre data center, uno dedicato a piattaforme low-level e altri due che offrono supporto a mainframe. I mainframe sono riservati alle attività del ministero e quindi non sono disponibili per outsourcing. Il cloud computing viene identificato come una linea guida e in particolare:

- **business benefit:** cercare di standardizzare i servizi per metterli all'interno dei modelli cloud;
- **technical challenges:** l'infrastruttura deve adeguarsi alla fornitura di nuovi servizi;
- **service portfolio:** si cerca di capire cosa si può offrire e quali servizi dovrebbero diventare cloud based;
- **pricing and SLA:** stabilire i contratti, il prezzo e la Quality of Service.

L'azienda mette inoltre a disposizione dei servizi di migrazione che convincano utenti e aziende a migrare verso il cloud. Viene stabilita una roadmap: dopo alcuni survey viene scelta la target delivery platform per iniziare l'attività del lavoro di migrazione, per poi identificare un'azienda per guidare questo processo. In breve quest'azienda sta diventando pian piano fornitore di servizi cloud per le pubbliche amministrazioni.

4.8 Learning Check

1. Descrivi la relazione tra le reti a banda larga e gli ISP e il Cloud computing.
2. Spiega come funziona il *connectionless packet switching*, l'interconnettività router-based e i protocolli a livello di trasporto e a livello di applicazione.
3. Spiega perché i problemi che riguardano larghezza di banda e latenza sono comuni nell'architettura di Internet.
4. Descrivi la data center technology e la sua rilevanza oggi nel cloud computing.
5. Sempre per quanto riguarda i data center, spiega la standardizzazione, la modularità, l'automazione e il controllo remoto.
6. Spiega l'importanza della *high availability* e della security nei data center e le componenti hardware e dei servizi primari di un data center.
7. Spiega l'importanza contemporanea della virtualization technology nel cloud computing, indicando perché sono importanti l'indipendenza dall'hardware, la *server consolidation* e la replicazione delle risorse.
8. Spiega la differenza tra la virtualizzazione OS e hardware-based.
9. Descrivi la rilevanza delle tecnologie web e le applicazioni web-based nel cloud computing.
10. Descrivi la *multitenancy* e l'importanza della multitenant technology nel cloud computing.
11. Descrivi le principali service technologies e la loro importanza nel cloud computing, includendo i servizi web SOAP-based, i servizi REST, i service agents e i service middleware.
12. Descrivi quali sono le tecnologie e gli standard più diffusi per lo sviluppo di servizi web.
13. Descrivi i servizi REST e spiega come sono in relazione con un contratto uniforme fornito dai metodi di HTTP.

Capitolo 5

Paradigm Shift


Il Paradigm Shift rappresenta una importante caratteristica di tutti i fenomeni sociali ma principalmente economici che evidenzia un completo cambiamento di direzione, qualcosa che rompe gli equilibri e rende evidenti nuovi bisogni che possono essere soddisfatti con nuove soluzioni e tecnologie.

Cercare di capire quali tecnologie possono modificare il futuro in maniera significativa a medio e breve termine ci permette di investire su quelle tecnologie. Vedremo nel dettaglio tre tipi di Paradigm Shift (Social, Work, Business).

5.1 Paradigm Shift e Disruptive Technology

Una delle maggiori aziende di consulenza direzionale che si occupa di effettuare analisi di mercato, Gartner, ha sviluppato uno strumento chiamato **Hype Cycle**. Il punto fondamentale è distinguere le promesse di ambizione e successo e di nuovi servizi da quella che è l'esagerazione (hype), che rende le cose presentate più belle e importanti di quello che siano. Bisogna capire quindi quando queste tecnologie riescono finalmente a ripagare degli investimenti.

L'Hype Cycle è uno strumento usato con molta diffusione per descrivere questi fenomeni e quindi è perfetto per rappresentare il livello di maturità, di adozione e applicazione di una certa tecnologia.



La dinamicità offerta da questo strumento permette alle tecnologie di muoversi sulla curva a velocità differenti. Distinguiamo le diverse fasi:


- **Innovation Trigger:** nasce una nuova tecnologia che rappresenta qualcosa di molto innovativo, e viene immediatamente recepita e catturata dai media e iniziano ad apparire delle prime *proof of concept*. A questo punto però affidabilità e commercializzabilità sono ancora da scoprire: a volte

può capitare che certe tecnologie abbiano bisogno di competenze specifiche o di vincoli stretti sulle infrastrutture interne, e quindi soffrire di una bassa commercializzabilità.

- **Peak of Inflated Expectations:** il momento della vetta delle attese gonfiate è quando la pubblicità continua a produrre *success stories*, mentre ai fallimenti che vengono identificati non si dà altrettanto peso. Una volta arrivati in cima al picco, si cade nell'abisso della disillusione.
- **Trough of Disillusionment:** appena la tecnologia supera il picco, vengono immediatamente enfatizzati i fallimenti che prima erano stati messi da parte e iniziano ad esserci i problemi dei produttori, che possono potenzialmente fallire. I provider che sopravvivono cercano di migliorare il prodotto per risollevarsi e convincersi che sia una buona tecnologia. Questi spesso vengono chiamati *early adopters*.
- **Slope of Enlightenment:** si iniziano ad evidenziare i benefici della tecnologia che vengono dimostrati all'interno delle aziende perché iniziano ad apparire la seconda e la terza generazione, e se la disillusione non è stata sufficiente a buttare via i produttori dal mercato, alla fine si riesce ad arrivare al pianoro della produttività.
- **Plateau of Productivity:** finalmente le principali aziende adottano la tecnologia ed iniziano a comparire dei criteri per definire l'affidabilità dei provider in modo da creare un mercato in cui il valore appare chiaro. I brand principali iniziano ad avere i vantaggi da questo punto di vista.

5.1.1 Le rivoluzioni nel Paradigm Shift

Le rivoluzioni tecnologiche avvengono quando viene avvertita la possibilità di cambiare in maniera radicale le nostre abitudini con cui approcciamo ad un sistema. Il progresso non è stabile, ci sono miglioramenti che portano a queste modifiche: vengono rotti degli equilibri e mostrano nuovi scenari di business. Il ruolo della **disruptive technology** può essere notato facilmente nel grafico seguente.



Una tecnologia di basso livello è in grado di assicurare un miglioramento di prestazioni nel tempo. La disruptive technology invece riesce ad assicurare molto velocemente il cambiamento e la qualità di prestazioni sul tempo e chiaramente riesce a soppiantare queste tecnologie perché assicura un altissimo payoff in pochissimo tempo. Alcune disruptive technologies:

- Automobili: quando Henry Ford chiese ai suoi clienti cosa volessero, questi risposero cavalli più veloci e più resistenti;
- Fotocamere digitali: hanno portato alla chiusura di fabbriche di rullini fotografici, brand e reti di distribuzione;
- Musicassette, dischi in vinile, CD.

5.1.2 Scientific Paradigm Shift

Possiamo distinguere alcuni dei paradigmi utilizzati nella computer science. La prima azienda fu IBM con l'invenzione del Personal Computer, in pratica ogni utente poteva possedere una macchina. Microsoft invece asserì la commerciabilità del software, ovvero di qualcosa di intangibile rispetto all'hardware: era importante costruire computer ma era importante scrivere software innovativo e piazzarlo su ogni computer per creare un mercato (che poi è diventato quasi un monopolio). DELL invece fu la prima azienda a permettere la possibilità di acquistare computer secondo delle configurazioni hardware personalizzate.

5.2 Social Paradigm Shift

Il cloud influenza la vita sociale delle persone in maniera significativa, in un certo senso può essere considerato come un agente di cambiamento. Quando parliamo di Social Paradigm Shift ci vengono subito in mente tre applicazioni: societal cloud, personal cloud e cloud of things.

5.2.1 Societal Cloud

Un Societal Cloud è un tipo di cloud che serve una community. In questo ambito l'utilizzo di modelli PaaS fornisce una serie di servizi che permette alle community di lavorare, offrendo un ambiente sicuro che ha una sua contestualizzazione a livello internazionale e nazionale (EU e NATO sono societal clouds). Una community cloud si occupa di convertire i social media a cloud sociali usando le caratteristiche del cloud: dal punto di vista individuale potrebbe non essere considerato un paradigm shift in quanto già tutti utilizziamo i social. Tuttavia dal punto di vista della community è più semplice riuscire a definire dei servizi che vengono personalizzati in base alle necessità delle community.

5.2.2 Personal Cloud

Ogni giorno utilizziamo il Personal Cloud (esempi sono Dropbox o Google Drive), sia per svago e divertimento oppure per finanza e shopping. Sono elementi importanti, infatti man mano che i servizi diventano economici (e a volte gratuiti) diventa più semplice avere un proprio spazio online come strumento di comunicazione (YouTube, Twitch).

5.2.3 Cloud of Things

Come l'Internet of Things riguarda tutto ciò che comprende la domotica e la gestione della sicurezza. Può essere integrato nell'ambiente di lavoro con diverse possibilità, le quali possono essere realizzate con l'automazione di determinate task.

5.3 Work Paradigm Shift

Riguarda due importanti trend abilitati dal cloud:

- Rimpiazzare le workstation con *thin client*, che non possono compiere operazioni se non quelle abilitate dal cloud: la gestione di un laptop prende tempo (c'è bisogno di manutenzione continua per software, sistema operativo). L'idea è quella di accedere a terminali da remoto: il lavoro di gestione delle macchine è semplificato perché si trovano fisicamente tutti insieme. Il secondo beneficio è che i dati si trovano sul cloud, quindi la macchina è indipendente e non pone alcun problema per la sicurezza.
- Ubiquitous computing: seguendo il paradigma del *Bring Your Own Device* (BYOD), l'idea è quella di poter utilizzare qualsiasi periferica per lavorare. In questo modo l'IT department assume

sempre più il ruolo di Cloud Service Broker. Tutto ciò è possibile grazie a dei meccanismi di sandbox presenti sulle macchine che permettono di memorizzare dati critici e criptare i dati nel caso in cui la periferica cada in mani sbagliate.

5.4 Business Paradigm Shift

Dal punto di vista del business c'è un aspetto particolarmente importante che va considerato: nelle grandi aziende c'è una relazione tra Work Paradigm Shift e Business Paradigm Shift: il primo punto importante è quello del dipartimento IT, che possiamo immaginare come la divisione di un'azienda che fornisce supporto IT per l'azienda stessa (ovviamente nel caso in cui il core business non riguardi l'IT). Il punto cruciale è che spesso c'è uno scollamento tra la gestione dell'IT fatta dal dipartimento e quella legata al business, che spesso è gestita localmente dalla business unit.

Il Business Paradigm Shift è motivato da ragioni immediate a breve termine di efficienza: una macchina la cui configurazione è gestita dal suo diretto utilizzatore è pronta in modo più veloce.

Quello che tipicamente si fa è utilizzare il modello *hub and spoke*, nel quale i servizi centralizzati fungono da hub (mail, servizi di rete, periferiche di stampa, gruppi di continuità) e i gruppi di business lavorano autonomamente, ovvero dalle proprie macchine e gestite in maniera separata. Questo fenomeno è anche conosciuto come **Shadow IT** e riguarda le applicazioni di cui il dipartimento centrale IT non è consapevole né responsabile. Di solito se capita un problema il supporto è molto complesso. Un central IT department molto forte dovrebbe rifiutarsi di offrire supporto per shadow IT, in quanto questo è un rischio per il business.

5.5 Learning Check

1. Quali sono i *social paradigm shift* indotti dal cloud computing?
2. Come è cambiata (e cambierà) l'esperienza lavorativa a causa del cloud computing?
3. Qual è il *business paradigm shift* più comune?

Capitolo 6


Price and value models

In questo capitolo saranno mostrati alcuni dei fondamenti economici del Cloud computing. Molte tecnologie infatti vengono progettate in funzione del prezzo e dei modelli di vendita: ciò risulta necessario perché il prezzo rappresenta l'interfaccia verso l'utente. Il beneficio di un servizio deve giustificare il prezzo.

Ogni impresa, azione, prodotto, è soggetto ad un costo e ad un beneficio. Il costo di un cloud service spesso è il primo elemento che viene considerato, e i servizi vengono divisi in base ai modelli di prezzo (*price models*).

I *value models* invece sono quelli che il customer deve considerare per valutare in maniera quantitativa i benefici di cui godrà usufruendo di certi servizi.

- I **price models** rispondono alla domanda "*quanto costa?*" e sono definiti dal provider.
- I **value models** rispondono alla domanda "*quanto beneficio mi dà?*" e sono misurati dal consumer.



6.1 Price models

I price models permettono di stabilire il prezzo che un cliente è disposto a pagare per ricevere il valore di un prodotto o di un servizio. Un cloud service provider calcola questo prezzo considerando i costi operativi e di fornitura. Il modello di costo poi viene convertito in un price model. Tuttavia i price models non dipendono solo dal modello di costo, ma anche da altri fattori come il business model, le strategie di marketing, o dalle attese di guadagno e profitto.

Esempi chiari sono dati dai pionieri in alcune tecnologie, si pensi ad Apple con il primo telefono con touchscreen facile da usare, a Google con il primo motore di ricerca funzionale e Mark Zuckerberg con il primo social network mondiale.

Ogni modello di prezzo parte da un modello di costo, che comprende sia le spese in conto capitale che che quelle operative per la manutenzione e l'aggiornamento di un servizio. Normalmente infatti ogni 3-5 anni è necessario un cambio di tecnologie a causa di obsolescenza (hardware), oppure sicurezza, portabilità, efficienza (software).

Il *cost model* include l'inflazione, le variazioni di cambio, la svalutazione, i costi di elettricità, licenze software e costo della manodopera. I modelli di prezzo si dividono in varie categorie (le prime due proprie del Cloud, le altre utilizzate anche da business innovativi):

- Utility Price models
- Service Price models
- Performance Price models
- Marketing-oriented Price models
- Hybrid Price models

6.1.1 Utility Price models

Sono quelli che prevedono il monitoraggio dell'utilizzo della risorsa o del servizio da vendere. Il pagamento è in base al monitoraggio effettuato. Distinguiamo tre tipologie di Utility Price models:

CONSUMPTION-BASED

È il modello più usato per IaaS e PaaS, perché si integra perfettamente con il modello pay-per-use. Il prezzo viene fornito in base alla misurazione dell'utilizzo che il cliente fa del servizio, su base giornaliera, settimanale o mensile. Va molto bene per misurare risorse "grezze", come velocità del processore, GB trasferiti, memoria utilizzata, ecc. Per modelli come SaaS, INaaS o BPaaS è meno indicato: nel caso di INaaS ad esempio, dato un servizio che fornisce regole sulla tassazione, avrebbe poco senso calcolare la quantità di CPU utilizzata in quanto ci sono categorie di costi diversi.

TRANSACTION-BASED

È un modello business-related: il prezzo si basa su transazioni anziché sulla quantità di risorse consumate. Più evoluto rispetto al modello consumption-based ma può essere utilizzato anche per le modalità più grezze, usando ad esempio la larghezza di banda come indicatore di calcolo. Un modello consumption-based può infatti diventare transaction-based controllando la banda utilizzata per ogni transazione.

Dividendo il costo del servizio per un certo periodo si ottiene l'**Unit Transaction price**. Il modello transaction-based è utile se il volume delle transazioni è conosciuto o predicibile, oppure se il volume delle transazioni è legato ad alcuni fattori come ad esempio il numero di ore di lavoro. Molto adatto per INaaS e BPaaS, perché standardizza le transazioni, facendole diventare l'unità atomica del servizio offerto.

SUBSCRIPTION-BASED

Il prezzo del servizio è fisso e si paga periodicamente. A prescindere dall'utilizzo, il prezzo da pagare è sempre lo stesso. Può essere utilizzato per tutti i modelli di deployment. Netflix è un servizio subscription-based.

6.1.2 Service Price models

In questi modelli di prezzo non ci si riferisce più ad un consumo di risorse, bensì ai benefici che vengono dati in accordo ad un SLA. La differenza sta nel fatto che i servizi vengono offerti basandosi sulla QoS stabilita negli SLA. Distinguiamo tre modelli.

FIXED


Il prezzo (fisso) viene specificato su base mensile/annuale. Si può utilizzare se lo scopo è definito in maniera chiara ed è allineato con gli obiettivi a breve termine. Trasferisce i rischi nel senso che il consumer paga il provider per prendersi il rischio di gestire il servizio al posto suo. I rischi vengono misurati negli SLA e possono essere di vario tipo, come ad esempio che il costo possa essere più oneroso rispetto al pagamento pattuito.

VOLUME-BASED

Indica il volume di utenti, storage, transazioni, banda, ecc. Definisce in pratica il volume di un servizio, da misurare e da calcolare. Ovviamente anche qui cambia in base al business. Molto simile al subscription-based.

TIERED

Basato su SLA, su volume, o su un certo tipo di ammontare speso. Vengono definiti dei Tier, e a seconda del costo i servizi vengono offerti in modo diverso. È molto importante perché aggiunge valore al lavoro svolto, e soprattutto i clienti non sanno mai di cosa hanno bisogno quindi metterli davanti a più scelte spesso si rivela la strategia vincente. Questo modello può essere usato in tutti i modelli di deployment.



6.1.3 Performance Price models


Si basa sul fatto che esiste una soglia considerata per valutare e decidere il prezzo. Questa metrica è tipicamente legata al business goal del cliente, per cui richiede un output chiaro e definito, e allineato con il processo di business. Distinguiamo tre tipi: Outcome-based, Business-linked e Gain-share.

OUTCOME-BASED

Essenzialmente lega il pagamento "bonus" al cloud provider per un risultato che riduce il *time to market* di un certo servizio (è legata quindi al valore percepito dal customer). Se si raggiunge un certo obiettivo di performance viene di solito assegnato un premio, e tipicamente viene usato insieme ad altri modelli, come ad esempio il fixed price.

BUSINESS-LINKED

Serve a collegare i contributi del cloud computing con alcuni indicatori di performance che influenzano il business model. Si può vedere chiaramente nel grafico seguente.



GAIN-SHARE

È un meccanismo abbastanza diffuso nelle startup per avere delle *equity*, ovvero delle azioni dell'azienda. Il concetto è lavorare nella stessa direzione per favorire le acquisizioni delle azioni, ad esempio il service provider potrebbe essere premiato con una condivisione dei profitti del consumer se si raggiunge una certa quota. Anche questo può essere combinato con altri modelli.

6.1.4 Marketing-oriented Price models

A volte i price model vengono guidati dal marketing piuttosto che dalle prestazioni: i modelli osservati di seguito si impongono l'obiettivo di attrarre più clienti possibili, per poi monetizzare grazie a loro.

FREEMIUM

Il modello freemium ha due sottomodelli:

- **try before buy**: di solito viene offerto un periodo di prova che permette di usufruire del servizio al 100% senza pagare ma solo per una quantità di tempo stabilita, di solito 7 o 30 giorni.
- **pure freemium**: il servizio viene offerto gratuitamente ma spesso contiene annunci pubblicitari. È molto usato soprattutto nei modelli SaaS (Dropbox, LinkedIn). Offrono funzionalità limitate ma permettono un upgrade ad un servizio premium con feature aggiuntive.

L'idea di questo modello consiste nell'attrarre una grande quantità di clienti per poi convincere una piccola quantità ad acquistare il servizio.

RAZOR AND BLADES

Come suggerisce il nome, si rifà proprio al mercato delle lamette usa e getta: che consiste nella vendita di una parte base (il rasoio) e di parti intercambiabili che vengono acquistate a cadenza temporale (le lamette). Basti pensare anche dalle stampanti a inchiostro o dalle macchinette del caffè. Alcuni esempi sono Amazon Alexa, Google Home o Amazon Kindle.

6.1.5 Hybrid Price models

Questi modelli consistono nel combinare diversi dei modelli visti in precedenza. Si rifanno tutti ad una strategia base, ovvero quella secondo la quale quando un utente entra in un ecosistema e si trova

bene, diventa più facile indurlo a pagare per i servizi offerti, vedi Apple, Microsoft 365, ecc. I modelli ibridi si possono applicare a tutti i deployment models.

6.2 Value models


Indicano qual è il valore del servizio. Il valore è una qualità che viene percepita in base a ciò che rimane dopo che i benefici sono stati pesati. I benefici che l'utente riceve sono indicati nel SLA. Nel Cloud computing un model value è un pattern comune che definisce il valore per i customers. Distinguiamo sette modelli:

- Operating expense;
- User demand flexibility;
- Price flexibility;
- Agility for time to market;
- Location flexibility;
- Asset optimization;
- Profit margin;

cost → price → value → financial metrics

6.2.1 Operating expense


Le spese del dipartimento IT dovrebbero essere all'inizio, per creare e mantenere il servizio, come d'altronde viene fatto con i SLA che sono stabiliti con il provider, i quali dettano la qualità del servizio che il dipartimento IT deve fornire. È importante che vengano considerate queste spese per gli investimenti che vengono fatti all'inizio in azienda, in quanto le spese per risorse IT sono sempre molto elevate. In due casi si verificano perdite nell'azienda: se la richiesta di capacity eccede la disponibilità del traditional computing oppure se si sta offrendo più capacità rispetto alle richieste.



6.2.2 User demand flexibility


Ogni prodotto ha un proprio ciclo di vita, che in maniera astratta può essere sintetizzato in *sviluppo, testing, lancio, marketing, gestione quotidiana*. In ciascuna di queste fasi ci sono differenti carichi di richieste, il che implica che bisogna gestire le richieste in modo differente, investendo o meno nella computing capacity, in quanto ad esempio durante il lancio del prodotto e le campagne di marketing sarà difficile adeguare le risorse in premesse. Con il Cloud Computing inoltre l'audience di un prodotto è diventata globale, e la capacity deve flettersi in corrispondenza delle richieste durante il ciclo di vita del prodotto.

Curiosità: agli inizi dell'era di internet, le startup informatiche tremavano di fronte agli articoli tecnologici pubblicati dal giornale *San Francisco Chronicles*. Spesso infatti accadeva che in seguito alla pubblicazione di un articolo su una certa startup, improvvisamente il carico di richieste aumentava vertiginosamente a causa dei lettori del giornale che volevano provare il servizio presentato, mandando nel panico i componenti della piccola impresa, che vedevano il loro sito andare down. Questo fenomeno è ancora conosciuto come *Kiss of Death*.





6.2.3 Price flexibility

Con "prezzo" in questo modello intendiamo il prezzo del prodotto finale offerto dal consumer utilizzando i servizi del cloud provider. La price flexibility è chiara soprattutto nell'economia di scala: acquistando ad esempio 1000 server risparmierò sul prezzo unitario rispetto a se ne compro 5. Questo permette l'adozione di nuove tecnologie man mano che le vecchie raggiungono l'obsolescenza. Il valore che assume da parte del consumer è quello di poter contare su modelli di prezzo diversi che permettono di essere flessibile nell'offrire il servizio. Tipicamente i modelli tiered o quelli ibridi favoriscono la price flexibility.




6.2.4 Agility for time to market

Il *time to market* è uno degli aspetti più importanti e il valore del cloud computing consiste nel fatto che diminuisce di tanto il tempo per lanciare il prodotto sul mercato. Questo è dovuto anche al fatto che è possibile switchare facilmente tra varie piattaforme, o fare il commissioning/decommissioning di componenti in maniera pressoché istantanea. È facile notare che nel traditional computing i tempi necessari per queste procedure ritardano l'arrivo del prodotto sul mercato.




6.2.5 Location flexibility

La possibilità di generare un mercato globale grazie al cloud computing viene raggiunta implicitamente senza dover richiedere un investimento separato e distinto. Con il traditional computing dovresti avere a disposizione diversi partner commerciali in giro per il mondo per il deploy del prodotto, mentre grazie al Cloud qualsiasi azienda ha già un potenziale mercato mondiale.



6.2.6 Asset optimization


Questo modello ha come obiettivo l'ottimizzazione delle risorse fisiche dell'azienda. Uno degli aspetti da evitare infatti è la necessità di avere investimenti extra, per evitare perdita di affari o di reputazione. Anche l'ottimizzazione è importante quando ci si avvicina al termine del ciclo di vita del proprio servizio, in quanto è possibile terminare ad esempio un'istanza di un servizio in maniera brusca senza avere alcun problema dovuto al fatto che si hanno risorse inutilizzate.



6.2.7 Profit margin

I margini di profitto sono importanti perché quando si produce un servizio i costi a valore aggiunto cadono ogni volta che l'esperienza o il valore raddoppia, ovvero le spese diminuiscono man mano che si produce esperienza¹. Un consumer affida le risorse IT della sua azienda ad un provider che gestisce molte situazioni e contesti simili, quindi può fare leva su un'esperienza molto ampia in modo da far diminuire i costi per il provider e anche per il consumer.

¹È stimato che con l'aumentare dell'esperienza i costi possano diminuire fino al 25%.



6.3 Financial metrics

Le metriche finanziarie servono a fornire un valore effettivo ad un servizio cloud, utilizzando sia i price models che i value models. Possiamo distinguere quattro principali metriche finanziarie: payback method, net present value (NPV), return on investment (ROI), e time to market (TTM). Ce ne sono altre che possono essere utilizzate, come economic value added (EVA), return on assets (ROA), e return on equity (ROE). Tuttavia, queste metriche non sono adatte a servizi cloud ma vengono utilizzate principalmente per il settore business.

6.3.1 Payback Method

Misura il tempo necessario per recuperare un investimento per un prodotto o un servizio. Un servizio che ha un periodo di payback corto è meglio di uno che ha un periodo di payback lungo, come si può notare da questo esempio: supponiamo di acquistare un cloud service per \$1,000 al mese in modo da elaborare le fatture al doppio della velocità rispetto al sistema attuale di fatturazione. Considerando un anno, il prezzo è di \$12,000. Supponiamo ora che il vecchio sistema produce \$10,000 al mese di fatture, mentre il nuovo ne produce \$20,000. Il valore che cerchiamo è banalmente la differenza tra i due valori, quindi \$10,000. Considerando 30 giorni al mese, il guadagno giornaliero è di \$333. Ciò significa che il servizio cloud appena acquistato ci ripagherà (payback) dopo 36 giorni ($12,000/333$).

Generalmente il Payback Method viene utilizzato per le spese in conto capitale in quanto sono spese facili da analizzare e avvengono a monte di un progetto. Uno degli svantaggi di questo metodo è che non considera il tempo come valore, in quanto un bene posseduto ora ha valore maggiore dello stesso bene posseduto tra un anno, inoltre non tiene conto degli interessi. Per risolvere questo problema si utilizza il ROI.

6.3.2 Return on Investment (ROI)

Il ROI è utilizzatissimo nell'industria IT per gestire gli investimenti di capitale. La formula del ROI è la seguente:

$$ROI = \frac{\text{guadagnodell'investimento} - \text{costodell'investimento}}{\text{costodell'investimento}}$$


Prendiamo come esempio lo stesso cloud service di prima che costa \$1,000 al mese. Il ROI si calcola come segue: il guadagno dell'investimento come abbiamo detto è \$10,000 al mese, mentre il costo dell'investimento è \$1,000 al mese.

$$ROI = \frac{\$10,000 - \$1,000}{\$1,000} = 900\%$$

Per ottenere un valore più realistico del ROI si utilizza il NPV.

6.3.3 Net Present Value (NPV)

Quando sono presenti regolarmente più flussi di cassa dello stesso ammontare, questi si traducono in rendite per un'azienda. A causa degli effetti dell'inflazione e degli interessi nel tempo, un flusso di cassa di \$1,000 il mese prossimo vale di più rispetto alla stessa somma cinque mesi dopo. Per valutare la variazione di questi valori vengono utilizzati i calcoli NPV. Il New Present Value di un investimento è il valore che questo ha nel presente considerando tutti i benefici futuri come flussi di cassa generati dall'investimento, al netto dei costi iniziali e scontati a intervalli di tempo. Per esempio, se ricevessimo \$1,000 ogni anno per tre anni con un tasso di interesse del 10%, facendo i calcoli mostrati nel grafico seguente otterremmo che il NPV è di \$2,486.85. Se avessimo fatto un investimento di \$2,000 per ottenere questi flussi di cassa, dovremmo sottrarli dall'investimento iniziale per ottenere un NPV di \$486.85, che rappresenterebbe un profitto del 24.3% per un investimento di \$2,000.



Quindi il New Present Value offre un modo per convertire le CAPEX in OPEX. I vantaggi di utilizzare il NPV sono dati dalla precisione dei risultati e dalla semplicità della loro interpretazione.

Consideriamo ancora una volta l'esempio iniziale, che ha un costo di \$1,000 al mese. Supponiamo che ci sia un tasso di interesse del 5% annuale e che decidiamo di utilizzare il servizio per almeno tre anni. Utilizzando l'analisi NPV questo esempio può essere rappresentato come una spesa capitale:

- $r = 5\% \div 12 = 0.4167\%$ (convertito in tasso mensile)
- $N = 36$ mesi
- $A = \$1,000$ (quantità mensile)
- $FV = 0$

Il New Present Value è dato da:

$$\sum_{k=0}^N \frac{A}{(1+r)^k} = \$33,365.70$$

A questo punto basta confrontare questo valore con quello che il dipartimento IT ci presenta: il valore più basso vince.

6.4 Learning Check

1. Descrivi le relazioni e le motivazioni dei *price models*, *value models* e metriche finanziarie, e perché sono importanti nel cloud computing.
2. Descrivi gli Utility price models.
3. Descrivi i Service price models.
4. Descrivi i Performance price models.
5. Descrivi i Marketing-oriented price models.
6. Descrivi gli Hybrid price models.
7. Mostra degli esempi di tutti i tipi di price models.
8. Descrivi come il *cost model* influenza il *price model*.
9. Come fa il cloud provider a scegliere un price model?
10. Perché i Marketing-oriented price models sono particolarmente appropriati per i cloud services verso gli utenti finali?
11. Descrivi ognuno dei 7 value models, con motivazioni ed esempi.
12. Descrivi il Payback Method.
13. Descrivi cos'è e come si calcola il Net Present Value.
14. Spiega cos'è il Return On Investment.
15. Descrivi il Time to Market.
16. Descrivi come l'economia di scala influenza la *price flexibility* dei cloud services.
17. In che modo la *price flexibility* aiuta il cloud consumer ad essere più competitivo sul mercato?



Capitolo 7

Cloud Security

La IT security è un insieme complesso di tecniche e tecnologie di regolamentazione riguardo due aspetti importanti: i regolamenti utilizzati per implementare le politiche di sicurezza all'interno di un'azienda, e i comportamenti che vengono utilizzati. Questo secondo aspetto è molto importante ed è stato possibile vederlo da vicino con l'app Immuni: è stata progettata con estrema cura da esperti del settore in sicurezza e privacy, ma non si è compresa la natura socio-tecnica dell'esperimento, a causa degli "strani" comportamenti del Bluetooth Low Energy, che fatica a comprendere quando dover registrare un contatto o meno, e a che distanza. Il fallimento di Immuni è dovuto al fatto che ci si è concentrati solo sulla parte tecnica dell'esperimento.


Lo scopo della security è proteggere l'integrità dei dati e l'accesso ad essi, sia da intenti maliziosi che da eventuali errori. Alcuni concetti base:

- La **confidenzialità** implica che un messaggio scambiato tra provider e consumer non possa essere intercettato e visto da qualcuno non autorizzato.
- L'**integrità** consiste nell'evitare che il messaggio sia alterato da qualcuno non autorizzato. L'integrità non vale solo per la trasmissione ma anche per lo storage.
- L'**autenticazione** significa essere in grado di definire chi ha fornito questi dati, ovvero poter risalire ad una sorgente.
- La **non repudiation** indica poter provare che l'interazione effettuata è stata davvero effettuata.
- L'**availability** implica che una risorsa sia sempre disponibile per un periodo di tempo specifico. È una responsabilità condivisa tra cloud provider e cloud carrier, che di solito devono mantenere i log per un certo periodo di tempo stabilito dal SLA.
- Per **minaccia** (threat) si indica qualsiasi cosa che mette a rischio e può danneggiare le difese messe in atto dal sistema; possono essere manuali o costruite in maniera automatica per sfruttare le vulnerabilità note. Un attacco è definito come una minaccia che ottiene dei risultati.
- Una **vulnerabilità** è un qualsiasi tipo di debolezza che può essere dovuta a errori di configurazione, di policy, degli sviluppatori, o a causa di poche misure di sicurezza nell'architettura.
- Un **rischio** è la possibilità di subire perdite o danneggiamenti durante un'attività e viene misurata rispetto al livello della minaccia con delle metriche:
 - probabilità di una minaccia di avvenire;
 - attesa di danni dopo che la risorsa è stata compromessa.

In generale tutti i controlli di sicurezza sono le contromisure adatte per controllare queste minacce, quindi vanno stabilite regole chiare e buone prassi che specificano come progettare e implementare un sistema per offrire il massimo della protezione.

7.1 Threat agents

Un threat agent è un'entità capace di effettuare un attacco, che può essere interno o esterno al cloud, umano o automatizzato. La figura illustra un ruolo che un threat agent assume in relazione alle vulnerabilità, alle minacce e ai rischi.



Le security policies sono stabilite dal cloud service owner e regolano le contromisure che hanno come obiettivo quello di fornire salvaguardia alle risorse. Distinguiamo diversi tipi di agenti:

- **Anonymous attacker:** un agente esterno che consuma il servizio senza permessi, tipicamente è un programma che lancia attacchi a livello di network o ruba le credenziali di un utente.
- **Malicious service:** intercetta il traffico e può far credere di essere un service agent reale. Può essere anche un programma esterno che si occupa di intercettare i messaggi.
- **Trusted attacker:** è un attaccante che condivide le risorse del provider con altri consumer e può attaccare i loro punti deboli, quindi più pericoloso degli altri perché già possiede parecchi permessi.
- **Malicious insider:** lavora dall'interno del cloud provider, quindi vanno controllati con cautela gli impiegati e la loro conoscenza di meccanismi o password che possono portare a terze parti non autorizzate ad avere accesso al sistema.

Le minacce che possono colpire il sistema sono:


- **Traffic eavesdropping:** il traffico che viene trasferito da un cloud consumer ad un cloud provider e viceversa che viene intercettato da un agente esterno, può compromettere la confidenzialità dei dati, ed essendo un attacco passivo può essere notato anche dopo molto tempo.
- **Malicious intermediary:** un intermediario accede al messaggio e ne altera il contenuto, danneggiandone confidenzialità e integrità.

- **Denial of Service:** l'attacco più diffuso il cui obiettivo è quello di sovraccaricare le risorse del server in modo da comprometterne il corretto funzionamento. Può essere attuato aumentando artificialmente la mole di informazioni da scambiare e lavorando sulla rete occupando tutte le connessioni, oppure inviare richieste mirate che consumano le risorse disponibili.

Il traffico che genera l'attaccante impedisce a richieste valide di poter essere fruite. Il problema di un DoS attack è che se il sistema scala automaticamente potrebbe causare costi molto elevati, soprattutto se l'attacco dura a lungo e non viene notato subito.

- **Insufficient authorization:** consiste nel non mettere in atto contromisure permettendo ad un attaccante di accedere a risorse IT che normalmente dovrebbero essere protette. Può essere risolto implementando l'autenticazione a due fattori.
- **Virtualization attack:** tipico della sicurezza del cloud, perché si basa sul concetto di una singola risorsa fisica che virtualizza più risorse logiche. Se una macchina logica viene attaccata con successo, potrebbe essere compromessa anche la macchina fisica e di conseguenza le altre macchine logiche in esecuzione su di essa.
- **Overlapping trust boundaries:** quando diversi consumer condividono delle risorse sul provider, un attacco ad uno di loro può compromettere anche l'altro.

I possibili problemi che vanno tenuti d'occhio riguardano le implementazioni di software con exploit, perché un errore che avviene in una certa implementazione può compromettere anche le altre.



Ci sono poi problemi dovuti alle policy di sicurezza: bisogna considerare che non sempre consumer e provider attuano le stesse policy, e questo può accadere per diversi motivi, primo tra tutti il budget a disposizione per la IT security. Se ad esempio la sicurezza da parte del consumer è molto bassa, la sicurezza totale del sistema diminuisce in quanto il sistema è tanto forte quanto il suo anello più debole. Questo implica che la sicurezza non è un problema soltanto del provider, ed è per ciò che esistono gli *assessment di incompatibilità*, ovvero limitazioni che spesso vengono messe in atto dal provider nei confronti del consumer (limitati aggiornamenti alla macchina in uso, permessi non di amministratore, ecc.).

Tutte le policy di sicurezza vengono specificate nel SLA assieme alle responsabilità che assume il cloud provider. Maggiore è la responsabilità del provider, minore è il rischio del consumer, ma maggiori saranno le restrizioni che il provider imporrà.


7.2 Risk Management

Nei sistemi IT di grandi dimensioni il Risk Management va attuato nei data center. Negli ambienti cloud ci sono molteplici attori quindi il rischio va calcolato per ogni attore. Il compito del provider è quello di partizionare le risorse in modo che il risk management sia fatto in rapporto 1:1 con i vari consumer, mentre il compito dei consumer è essere sicuro che il risk management fatto dal provider sia adeguato ai costi richiesti.

Il Risk Management è un processo ciclico che deve essere ripetuto per assicurare sicurezza strategica (a livello di sistema) e tattica (a livello di componenti), e può essere iniziato da qualsiasi fase. Di seguito sono illustrate le diverse fasi.

ASSESSMENT

Nella prima fase vanno identificate le potenziali vulnerabilità, visualizzando le statistiche a disposizione e estraendone le informazioni utili per la quantificazione del rischio, sulla base della probabilità di occorrenza di certe situazioni.



TREATMENT

Una volta scoperti i rischi, bisogna cercare di definire delle politiche per arginarli e cosa fare nel caso si verifichino. Alcuni rischi possono essere eliminati, altri solo mitigati, per altri è possibile rivolgersi a terze parti oppure in certi casi si è disposti a perdere una parte del budget. La parte di risk treatment viene affrontata nei SLA.

CONTROL


Il risk control avviene dopo. Come dice il saggio, *"shit happens"*, quindi bisogna monitorare le soluzioni attuate e capire se hanno risolto o meno il problema. Alla fine di questa fase, viene effettuato di nuovo un assessment per stabilire quali sono le nuove vulnerabilità e quali sono state risolte.

7.2.1 Risk Management Framework

La tabella mostra le fasi di un corretto risk management e gli step che le compongono.

CRMF	CRMF Steps
Risk assessment	Step 1. Si categorizza il sistema e tutto quello che processa, in breve calcolo e storage.
	Step 2. Si identificano una serie di controlli di sicurezza in modo che siano proporzionali al rischio e si sviluppa una strategia per il monitoring.
Risk Treatment	Step 3. Bisogna interpretare i security control e descrivere come tutti i controlli arrivano al security plan e come vengono portati all'interno del sistema.
	Step 4. Si verificano i security control con le procedure di risk assessment. Sono fasi importanti perché non coinvolgono le stesse persone.
Risk control	Step 5. Si valuta se il rischio è accettabile in quanto dipende direttamente dalla <i>mission</i> dell'azienda. Non bisogna dimenticare che il rischio agisce sul nome e sulla reputazione dell'azienda.
	Step 6. Si monitorano i controlli di sicurezza per dare feedback necessari alle fasi successive del ciclo.

Il grafico seguente invece mostra come sono divise le responsabilità nei vari deployment models tra cloud consumer e cloud provider.



7.3 Case Study: ATN

ATN (nome fittizio) è un'azienda che fornisce network equipment a livello mondiale ed è cresciuta in maniera significativa attraverso diverse acquisizioni di aziende specializzate per componenti internet, gsm e cellulari. Adesso è un fornitore di punta di un'ampia gamma di infrastruttura di rete, cellulari e telecomunicazioni.

A causa di queste acquisizioni il sistema è diventato eterogeneo e quindi soggetto a forti pressioni da parte del mercato. Il costo quindi aumenta per mantenere la gestione dei reparti IT con i partner in tutto il mondo. Sembra utile a questo punto adottare il cloud, viene quindi stabilita una roadmap producendo una serie di vantaggi tra cui abbreviare gli investimenti a breve termine e i costi a lungo termine, cercando di ottenere un'ottimizzazione del servizio e una riduzione di costi con i soliti vantaggi di scalabilità, availability e business. ATN deve capire quale modello adottare e quindi quale offre più vantaggi, contando però dei problemi: potrebbero infatti perdere il controllo sulle loro applicazioni, e inoltre va considerato il fatto che bisogna avere fiducia nel cloud provider per quanto

riguarda le compliance. Un altro problema è rappresentato dalle legacy applications e come devono essere integrate.

Viene suggerito di provvedere ad una valutazione delle applicazioni sulla base di alcuni fattori quali complessità, business critical, frequenza di utilizzo e numero di utenti attivi, in modo da identificare i candidati per la migrazione sul cloud. Per ognuno dei candidati si fa un assessment usando un tool proprietario e poi si suggerisce lo sviluppo di un'architettura target che rende evidente l'interazione tra le applicazioni cloud based e l'infrastruttura esistente. Infine va fatto un piano di sviluppo.

Gli analisti ATN individuano una serie di rischi: tra le applicazioni delle varie aziende che sono state acquisite ce n'è una che ha il problema degli accessi differenti, non utilizza password complesse e la comunicazione tra i dati non è cifrata. Viene quindi deciso di non migrare quest'applicazione sul cloud, perché i rischi sono troppi e il rapporto prestazioni/prezzo non soddisfa gli obiettivi dell'azienda. Quindi abbiamo visto come non sempre il cloud sia la soluzione giusta.

7.4 Learning Check

1. Descrivi i principali threat agents relativi al cloud computing, tra cui: Anonymous Attacker, Malicious Service Agent, Trusted Attacker, Malicious Insider.
2. Descrivi la minaccia alla sicurezza del malicious intermediary, come può compromettere l'integrità e la confidenzialità dei messaggi e come questi attacchi possono essere portati a termine da servizi guidati da eventi.
3. Descrivi la minaccia alla sicurezza Denial of Service e come viene eseguita sovraccaricando l'utilizzo della memoria e del processore.
4. Descrivi la minaccia alla sicurezza delle autorizzazioni insufficienti e come una variante di questa minaccia è conosciuta come "weak authentication".
5. Descrivi la minaccia alla sicurezza noto come virtualization attack, come mai è specifico delle risorse IT virtualizzate e come può essere portato avanti da un cloud service consumer fidato.
6. Descrivi la minaccia degli overlapping trust boundaries e come risulta da diversi cloud consumer che condividono le stesse risorse IT cloud-based.
7. Spiega ulteriormente le vulnerabilità associate ad implementazioni imperfette, disparità nelle policy di sicurezza e l'importanza del risk management.
8. Descrivi il caso d'uso di ATN e le motivazioni delle decisioni prese.

Capitolo 8

Cloud Infrastructure Mechanisms


I meccanismi di base di alto livello che vengono utilizzati nel cloud sono di quattro tipi: Cloud Infrastructure Mechanisms (questo capitolo), Specialized Cloud Mechanisms (cap. 9), Cloud Management Mechanisms, Cloud Security Mechanisms (cap. 10). Ognuno di questi si divide in sottocategorie. In questo capitolo vediamo i *Cloud Infrastructure Mechanisms*, che si dividono in sei sottocategorie:

1. Logical Network Perimeter
2. Virtual Server
3. Cloud Storage Device
4. Cloud Usage Monitor
5. Resource Replication
6. Ready-Made Environment

I primi tre rappresentano i pilastri dell'IT: network, computation, storage, mentre gli altri tre rappresentano le caratteristiche basilari del cloud.


8.1 Logical Network Perimeter

Isola completamente una rete dal resto dell'infrastruttura del provider. Il perimetro è soltanto virtuale, e serve ad evitare che utenti non autorizzati o altri consumer accedano a risorse a cui non possono, oppure serve a controllare la larghezza di banda per le risorse isolate. Tutto ciò viene realizzato con diversi device virtualizzati, tra cui un firewall che filtra il traffico da e verso il network isolato (choking point). Il virtual network separa il network environment dalla struttura, e agisce come se fosse un enorme router virtuale che gestisce le comunicazioni all'interno del perimetro.



CASE STUDY: DTGOV

DTGOV, vista in precedenza, è un'azienda americana pubblica creata nel 1980 dal ministero della social security che permette di decentralizzare tutti i servizi informatici ad un'azienda indipendente ma a capitale pubblico. DTGOV virtualizza la sua infrastruttura di rete definendo un logical network perimeter che offre varie strutture:



I router collegano il perimetro ad internet e extranet¹. Un logical network perimeter è classificato come DMZ (*demilitarized zone*): ci sono una serie di servizi necessariamente esposti all'esterno (come DNS o email) che si trovano in una parte attivamente protetta per separare i servizi esterni da quelli interni e capace di collegarsi con l'esterno.

Il traffico che passa nei firewall viene isolato entrando nella rete di management, che è la rete delle periferiche che si occupano di gestire il monitoraggio. Il traffico che va verso le risorse cloud passa attraverso la DMZ e nei firewall che isolano la parte dei servizi a cui il consumer può accedere. Per fare questo si passa dai router che forniscono i servizi di network perimeter attraverso i data center.

Questo tipo di architettura prevede risorse, management e DMZ. I firewall virtuali sono allocati per un singolo cloud consumer, in questo modo il consumer può regolare il suo traffico di rete virtuale in modo che sia isolato da tutti gli altri consumer.


¹Extranet rappresenta una serie di intranet collegate per avere una rete aziendale distribuita ma privata.

8.2 Virtual Server

È una struttura di base che consiste nell'eseguire dei server virtuali che vengono forniti da server fisici. I server virtuali sono erogati come un bene di consumo, quindi possono essere acquistati e sono fondamentali per un ambiente cloud, perché le macchine virtuali sono rappresentate come file immagine, cioè un insieme di file che rappresentano la macchina virtuale in esecuzione, quindi risulta molto semplice crearne al volo o usarle durante l'esecuzione.

CASE STUDY: DTGOV

Le necessità computazionali vengono mappate su server virtuali. L'infrastruttura si basa su hypervisor che fungono da gestione e rendono il sistema leggero. Inoltre il sistema è coordinato da una Virtual Infrastructure Manager (VIM) che tramite gli hypervisor gestisce i vari server fisici. Questo approccio viene utilizzato in tutti i data center di DTGOV per assicurare l'uniformità.



8.3 Cloud Storage Device


I device di storage vengono forniti esclusivamente via cloud ed esistono storage virtualizzati, allocati con un incremento fissato secondo un modello pay-per-use e vengono esposti attraverso i servizi. La situazione quindi è molto flessibile perché è possibile acquistare la taglia giusta di GB. I livelli di storage sono divisi in:

- **File:** file e directory
- **Blocks:** il livello più basso fisicamente accessibile
- **Dataset:** organizzato in tabelle
- **Objects:** dati e metadati organizzati come risorse accessibili via web

CASE STUDY: DTGOV

Viene utilizzato un servizio che sfrutta metodi CRUD e la funzione di ricerca che usa una gerarchia di memorizzazione simile ad un filesystem, offrendo al contempo la creazione di cloud storage con un'interfaccia a blocchi. Il vantaggio di un'architettura object based è che lo storage sottostante ha capacità variabile a seconda della necessità degli oggetti da memorizzare. Inoltre è possibile creare device virtualizzati allocandoli a singoli consumer.

Ogni device ha un *local unit number* (LUN) che lo identifica e la creazione di un blocco viene fatta istanziando questa LUN sullo storage virtuale: questo serve alla VIM per assegnare una partizione al virtual server.



8.4 Cloud Usage Monitor

L'obiettivo è monitorare esattamente cosa sta usando il cloud. C'è una serie di monitor specifici per ogni servizio e queste statistiche vengono collezionate e mandate su un db per post processing o reporting. Ci sono tre implementazioni:

- **MONITORING AGENT** - è un intermediario, cioè un programma guidato dagli eventi che risiede sul communication path per monitorare gli eventi e analizzare i dataflow. Il servizio viene fornito ma in maniera parallela la richiesta viene monitorata in un db di log.
- **REPORTING AGENT** - si trova più all'interno e si occupa di monitorare quello che avviene all'interno di un software, cioè c'è un'azione attiva da parte dell'agente che monitora il db. Viene usato per controllare le metriche basate su eventi osservabili come scaling verticale, inizializzazione o sospensione di un software.
- **POLLING AGENT** - fa in continuazione polling dei servizi per memorizzare i dati, monitora periodicamente lo stato delle risorse e verifica uptime e downtime. Utile per gestire le metriche stabilite dal SLA.

CASE STUDY: DTGOV

Servono misure accurate per evitare billing basato solo su server fisici a prescindere dall'utilizzo. Serve anche per stabilire il leasing dei server virtuali, legati ai vari livelli di performance, per macchine usate poco e macchine usate a pieno regime. Si implementa un resource agent che si occupa di monitorare tutti gli eventi generati dalla VIM per calcolare l'utilizzo delle macchine fisiche. Il periodo di misurazione inizia dalla creazione dei virtual server e si ferma alla loro terminazione.

8.5 Resource Replication

La replicazione delle risorse è uno degli strumenti più potenti per assicurare scaling e resilienza ai malfunzionamenti. Il meccanismo utilizzato è quello della virtualizzazione, con uno o più hypervisor che gestiscono diversi server e ognuno degli hypervisor può decidere di creare un certo numero di copie delle macchine che stanno sullo stesso device di storage fisico.

CASE STUDY: DTGOV

Due centri di calcolo sono collegati tra di loro attraverso un virtual private network (VPN). Il fatto che venga assicurata la replicazione delle risorse è importante perché in caso di malfunzionamenti la replica serve per poter effettuare la migrazione di uno dei server in un altro data center. La migrazione ovviamente è puramente virtuale.

8.6 Ready-Made Environment

È un meccanismo che fa parte del modello PaaS, pronto per essere utilizzato e può essere customizzato, in modo che il consumer possa utilizzare delle macchine pre-configurate. Tipicamente includono varie risorse come IDE, strumenti di gestione, ecc. Ci sono varie configurazioni a seconda delle esigenze, ad esempio una macchina che deve lavorare sul frontend avrà bisogno di infrastruttura di rete potente, mentre una macchina che lavora sul backend avrà bisogno di più risorse di calcolo. Queste istanze possono essere combinate per ottimizzare performance e costi.

CASE STUDY: ATN

Utilizza un ambiente PaaS, con applicazioni basate su Java per il catalogo dei magazzini che memorizza informazioni su switch e router. Questo tipo di software è usato da diverse factories ma non gestisce la parte delle transazioni. Fornisce delle istanze ready-made.

Una volta affrontati tutti i meccanismi, possiamo mapparli con le caratteristiche del cloud definite dal NIST:

Logical Network Perimeter	Ubiquitous Access, Multitenancy/Resource Pooling
Virtual Server	On-demand Usage
Cloud Storage Device	Elasticity
Cloud Usage Monitor	Elasticity, Measured Usage
Resource Replication	On-demand Usage, Multitenancy/Resource Pooling, Elasticity, Resiliency
Ready-Made Environment	On-demand Usage

8.7 Learning Check

1. Descrivi l'obiettivo del meccanismo del Logical Network Perimeter e come esso definisce un limite logico.
2. Elenca le componenti usate comunemente per costruire un Logical Network Perimeter.
3. Descrivi il meccanismo del virtual server e spiega la differenza tra un server virtuale e un server fisico e come è configurato l'ambiente di virtualizzazione.
4. Descrivi l'obiettivo del meccanismo del Cloud Storage Device.
5. Elenca le componenti che possono essere usate per esporre o garantire l'accesso ai dispositivi di cloud storage.

6. Descrivi l'obiettivo del meccanismo del Cloud Usage Monitor ed elenca i meccanismi che sono considerate variazioni specializzate.
7. Elenca e spiega le tre implementazioni iutilizzate per i Cloud Usage Monitor.
8. Descrivi il meccanismo del Resource Replication e come si relaziona con il meccanismo dell'hy-pervisor.
9. Descrivi il meccanismo del Ready-Made Environment e spiega le risorse IT che fornisce, le sue relazioni con il modello di delivery PaaS e come può esistere su un server fisico o virtuale.



Capitolo 9

Specialized Cloud Mechanisms

Abbiamo visto i meccanismi di base, ora passiamo ai meccanismi specializzati, che si appoggiano su quelli visti prima. Rappresentano uno stato superiore ai meccanismi di cui sopra e possono essere combinati in maniera diversa come parte di un'architettura specializzata per fornire un certo tipo di servizio. Nella figura

9.1 Automated Scaling Listener

È un service agent che monitora e traccia le comunicazioni tra i consumer e i servizi cloud per uno scaling dinamico delle risorse. I listener sono all'interno del Cloud e tengono traccia automaticamente delle informazioni sul carico di lavoro, il quale viene determinato in modo grezzo (ad esempio byte/secondo) o dalla semantica delle richieste. Ci sono due diversi tipi di risposta al variare del carico di lavoro:

- **Auto-scaling:** scala automaticamente le risorse IT basandosi sui parametri precedentemente definiti dal cloud consumer. Visto che il carico può aumentare in maniera significativa, occorre prendere in considerazione il fatto che i prezzi potrebbero aumentare inaspettatamente.
- **Notification:** inviare una notifica quando i carichi di lavoro eccedono i limiti impostati oppure scendono al di sotto delle risorse allocate.

In figura è mostrato un esempio: supponiamo di avere abbastanza risorse per 3 utenti (consumer) che dopo aver passato un firewall incontrano la componente di automated scaling listener che si occupa di servire le istanze del servizio allocate sulla macchina virtuale e contemporaneamente di monitorare quello che succede. Quando entra in gioco un quarto customer, lo scaling listener avvisa il Cloud resource administrator che è in grado di allocare maggiori risorse per soddisfare tutti gli utenti.

Caso d'uso: DTGOV

I server fisici scalano verticalmente dalla configurazione più bassa (1 vCPU, 4GB RAM) a quella più alta (128 vCPU 512GB RAM) automaticamente. Viene fatto scale up ogni volta che la VIM alloca 3 server virtuali e aumenta l'utilizzo della CPU all'80% per 60 secondi. Se non è possibile scalare virtualmente, viene migrata la macchina virtuale su un'altra macchina fisica meno carica per alleggerire il carico di lavoro e tenere le prestazioni alte. Lo scale down avviene quando la VIM diminuisce le prestazioni di RAM e CPU al 15% per 60 secondi. Il service agent che si occupa di rilevare questi cambi è appunto l'Automatic Scaling listener.

9.2 Load Balancer

Se l'ASL si occupa di scalare verticalmente, il Load Balancer è un meccanismo che si occupa dello scaling orizzontale: bilancia infatti i carichi di lavoro tra differenti risorse. Un Load Balancer può utilizzare diverse strategie in base al carico di lavoro:

- **Asymmetric Distribution** - utilizzata in caso di risorse eterogenee, assegna i carichi di lavoro più onerosi alle risorse con più capacità di calcolo.
- **Workload Prioritization** - assegna i carichi di lavoro in base alle priorità delle richieste.
- **Content-Aware Distribution** - il carico di lavoro viene assegnato in base al contenuto della richiesta.

I Load Balancer usano un insieme di parametri di performance e qualità del servizio per ottimizzare l'utilizzo delle risorse IT, ed il loro scopo è massimizzare le richieste e minimizzare l'uso delle risorse. Di solito il Load Balancer si trova tra consumer e provider, ovvero tra chi genera il carico di lavoro e tra chi lo processa. Può essere trasparente, come dei proxy al livello 7 della pila ISO/OSI. Scambia richieste esattamente come dovrebbero essere scambiate. Può essere anche un dispositivo hardware, come uno switch multilayer.

9.3 SLA Monitor

È un meccanismo che ha particolare interesse nell'ambito del management: osserva le performance di un servizio per stabilire se sono rispettati i requisiti di QoS stabiliti nel Service Level Agreement. I dati raccolti dal SLA monitor sono processati da un *SLA Management System* per essere aggregate nelle statistiche di un SLA. Risulta anche utile a segnalare servizi o risorse in stato *down*¹, per permettere al sistema di ripararle o sostituirle.

Si comporta come un agente di polling, che invia dei messaggi di richiesta e memorizza le risposte in un database di log. Se i messaggi riportano un problema, il SLA monitor riporta una condizione di down.

Caso d'uso: DTGOV

La minima percentuale di availability per DTGOV è del 99.95%. È tracciata usando due SLA monitor: uno basato su un polling agent e l'altro su un normale monitoring agent. Mentre il polling agent controlla con timeout di 20 secondi che tutti i servizi siano disponibili, il monitoring agent viene implementato direttamente dalla VIM, quindi agisce a stretto contatto con le risorse. Gli eventi generati dal polling agent hanno una marca temporale e sono salvati in un DB di log e poi utilizzati dal SLA Management System per calcolare l'availability delle risorse.

9.4 Pay-per-use Monitor

È collegato al precedente, perché raccoglie anch'esso informazioni, non per controllare la qualità del servizio offerto ma per calcolare il prezzo da pagare per la qualità offerta. Tipicamente controlla la quantità di richieste e di risposte, il volume dei dati trasferiti ed il consumo di banda (quindi relativo al tempo). I dati raccolti dal Pay-per-use monitor sono processati da un Billing Management System che calcola le quote da pagare.

¹Per servizio down non si intende solo un server che non risponde o una risorsa non disponibile. Anche aspettare 12 secondi per caricare una pagina HTML può essere considerato una condizione di down, perché è un tempo troppo lungo in normali condizioni.

Caso d'uso: DTGOV

DTGOV ha un sistema commerciale che può generare fatture basate sugli eventi. Ha due database proprietari, uno dove salva gli eventi di billing e uno dove salva lo schema dei prezzi. Gli eventi a runtime sono raccolti tramite cloud usage monitor che sono implementati come estensioni della piattaforma VIM utilizzando le sue API.

9.5 Audit Monitor

L'audit monitor si occupa di verificare la correttezza dei dati e delle procedure: il suo utilizzo è reso necessario da obblighi contrattuali e regolatori. È implementato come un monitoring agent che intercetta le richieste di accesso e salva le credenziali di sicurezza del richiedente, i tentativi di accesso riusciti o falliti, in un database, per eventuali utilizzi futuri.

9.6 Failover System

È un meccanismo utilizzato per aumentare la reliability e l'availability delle risorse utilizzando tecnologie di clustering per fornire implementazioni ridondanti. È configurato per switchare su una risorsa copiata o in standby nel caso di malfunzionamento di un'altra risorsa ed è spesso utilizzato nel caso di presenza di *single point of failure*. Ci sono due tipi di configurazioni:

- **Active/Active** - le risorse ridondanti vengono fornite e servite contemporaneamente, ne viene utilizzata una sola solo in caso di fallimento dell'altra.
- **Active/Passive** - viene utilizzata una risorsa, mentre l'altra viene utilizzata solo in caso di malfunzionamento della prima, spostando il carico di lavoro su di essa.

9.7 Hypervisor

Come abbiamo già visto, l'Hypervisor è una parte fondamentale per la virtualizzazione di un'infrastruttura, per generare risorse virtuali anziché risorse fisiche. Il suo utilizzo è limitato ad una singola macchina, e ha capacità funzionali limitate. Il software di un hypervisor può essere installato su qualsiasi macchina

9.8 Resource Cluster

Le risorse IT cloud-based possono essere combinate logicamente per migliorare la loro allocazione e il loro utilizzo. Il meccanismo di **Resource Cluster** viene usato per raggruppare diverse istanze di risorse IT in modo che possano operare come una singola risorsa: questo aumenta la capacità computazionale, il bilanciamento del carico, e l'availability delle risorse stesse. Ci sono diversi meccanismi di *clusterizzazione*:


- **Server Cluster** - server fisici o virtuali sono raggruppati in cluster per aumentare le performance e l'availability. Gli hypervisor girano su diversi server fisici e possono essere configurati per condividere gli stati di esecuzione al fine di creare dei server virtuali clusterizzati.
- **Database Cluster** - pensati per migliorare l'availability dei dati: hanno una feature di sincronizzazione che permette la consistenza dei dati, i quali sono conservati fisicamente in dispositivi diversi.
- **Large Dataset Cluster** - i dati vengono partizionati e distribuiti in modo da aumentare l'efficienza senza compromettere la precisione e di calcolo o l'integrità degli stessi.

Inoltre, ci sono due tipi di resource cluster:

- **Load Balancer Cluster** - specializzato in carichi di lavoro molto pesanti, aumentano la capacità delle risorse preservando la gestione centralizzata delle risorse IT grazie a un load balancer.
- **High Availability Cluster** - mantiene la disponibilità del sistema anche a seguito di fallimento di nodi, grazie al resource replication.

9.9 Multi-device Broker

Un cloud service potrebbe essere utilizzato da un insieme di cloud consumer che sono differenziati dai loro dispositivi di hosting e/o requisiti di comunicazione. Per risolvere problemi di compatibilità tra un cloud service e diversi cloud service consumer, bisogna convertire le informazioni che si scambiano a runtime. Il meccanismo di *multi-device broker* è utilizzato per facilitare questa trasformazione in modo che i servizi siano accessibili ad un range più ampio di cloud consumer.




9.10 State Management Database

È un dispositivo di storage utilizzato per conservare temporaneamente i dati persistenti dei software che vengono utilizzati. Può essere visto come un'alternativa al meccanismo di caching, e in più la scalabilità del sistema è aumentata: infatti non sempre i dati di un servizio devono essere utilizzati al 100%, ed è per questo che questo meccanismo risulta importante.

	pre- invocation	begin participation in activity	pause participation in activity	end participation in activity	post invocation
active + stateful					
active + stateless					
state data repository					

9.11 Mappa concettuale delle caratteristiche del Cloud Computing



9.12 Learning Check

1. Descrivi il meccanismo dell'Automated Scaling Listener e spiega le due risposte comuni che questo meccanismo può avere in base alle condizioni di carico.
2. Descrivi gli obiettivi del meccanismo del Load Balancer, elenca le tre funzioni base di bilanciamento del carico e spiega in che modo un load balancer viene posizionato all'interno dell'architettura cloud.
3. Descrivi gli obiettivi del meccanismo di SLA Monitor e spiega l'importanza del monitoring dell'utilizzo in relazione con un SLA e alle garanzie pubblicate in esso.
4. Descrivi il meccanismo e spiega come è in relazione con la fatturazione del cloud provider.
5. Descrivi gli obiettivi del meccanismo Audit Monitor e spiega la sua importanza nelle regolamentazioni di carattere legale.
6. Descrivi il funzionamento del meccanismo di Failover System e spiega la sua relazione con le tecnologie di clustering.
7. Descrivi gli obiettivi del meccanismo di Hypervisor e spiega la sua relazione con il meccanismo di virtual server. Inoltre spiega che relazione c'è tra l'Hypervisor e un virtual server.
8. Descrivi gli obiettivi del meccanismo di Resource CLuster e spiega come funzionano le risorse raggruppate in cluster. Inoltre spiega la differenza tra cluster che possiedono high availability da quelli sottoposti a bilanciamento del carico.
9. Descrivi il meccanismo di Multi-Device Broker e spiega come utilizza le tecnologie del cloud per supportare l'accesso a diversi cloud service da parte dei cloud consumer.

10. Descrivi il meccanismo di State Management Database e la sua importanza rispetto alla scalabilità. Spiega come i cloud services possono beneficiare particolarmente di questo meccanismo quando partecipano in attività di lunga durata.

Cloud Characteristics	Cloud Mechanisms
On-Demand Usage	Hypervisor
	Virtual Server
	Ready-Made Environment
	Resource Replication
	Remote Administration Environment
	Resource Management System
	SLA Management System
	Billing Management System
Ubiquitous Access	Logical Network Perimeter
	Multi-Device Broker
Multitenancy/Resource Pooling	Logical Network Perimeter
	Hypervisor
	Resource Replication
	Resource Cluster
	Resource Management System
Elasticity	Hypervisor
	Cloud Usage Monitor
	Automated Scaled Listener
	Resource Replication
	Load Balancer
Measured Usage	Resource Management System
	Hypervisor
	Cloud Usage Monitor
	SLA Monitor
	Pay-Per-Use Monitor
	Audit Monitor
	SLA Management System
	Billing Management System
Resiliency	Hypervisor
	Resource Replication
	Failover System
	Resource Cluster
	Resource Management System

Capitolo 10

Other Cloud Mechanisms

Le risorse IT cloud-based necessitano di essere configurate, impostate, e soprattutto sono soggette molto spesso a manutenzione. In questo capitolo sono illustrati alcuni meccanismi che riguardano questo tipo di attività, e che riguardano la sicurezza, e in particolare distingueremo i meccanismi in *Cloud Management Mechanisms* e *Cloud Security Mechanisms*.

10.1 Cloud Management Mechanisms

Dei primi fanno parte: Remote Administration System, Resource Management System, SLA Management System, Billing Management System.

10.1.1 Remote Administration System


È un meccanismo che fornisce strumenti e interfacce utente per i cloud resource administrator esterni per configurare e amministrare le risorse IT cloud-based. Gli strumenti e le API messe a disposizione da un remote administration system sono utilizzate dal cloud provider per sviluppare e personalizzare i portali online che forniscono poi al cloud consumer con una varietà di controlli di amministrazione. I due tipi principali di portali sono:

- **Usage and Administration Portal** - un portale general purpose che permette ai cloud consumer di centralizzare la gestione dei controlli di diverse risorse IT cloud-based.
- **Self-Service Portal** - è una specie di portale shopping che permette ai cloud consumer di cercare in una lista di servizi cloud e risorse IT messe a disposizione dal cloud provider quello che più si avvicina ai loro requisiti.

10.1.2 Resource Management System

È un meccanismo che aiuta a coordinare l'utilizzo delle risorse IT a seguito di azioni di gestione fatte dai consumer e dai provider. Tutto ciò è possibile grazie alla VIM che coordina l'hardware dei server, ad esempio creando istanze multiple di un hypervisor a cavallo di diversi server fisici. Le attività che normalmente sono automatizzate tramite il Resource Management System sono:

- gestione dei template delle risorse IT virtuali che sono utilizzate per creare istanze preconfigurate;
- allocazione e rilascio di risorse IT virtuali nelle infrastrutture fisiche in risposta alla terminazione o la messa in pausa di altre risorse IT virtuali;




- coordinazione delle risorse IT in relazione al coinvolgimento di nuovi meccanismi come resource replication, load balancer e failover system.

Le funzioni di gestione possono essere accessibili sia dal cloud consumer che dai cloud provider, e tipicamente espongono delle API che permettono ai cloud provider di costruire sistemi di amministrazione remota che possono essere personalizzati per gestire meglio il controllo delle risorse.

10.1.3 SLA Management System

Rappresenta una serie di prodotti commerciali disponibili che forniscono funzioni riguardanti l'amministrazione, la collezione, lo storage, il reporting e la notifica dei dati degli SLA. Il deployment di un SLA management system di solito include una repository usata per salvare e per recuperare i dati di un SLA basati su metriche predefinite e parametri di reporting.



10.1.4 Billing Management System

È un meccanismo dedicato alla collezione e al processing dei dati di utilizzo che riguardano la gestione degli account da parte del cloud provider e la fatturazione da parte del cloud consumer. Nello specifico, il billing management system si basa su dei monitor pay-per-use per acquisire dati di utilizzo durante l'esecuzione che sono salvati in repository che le componenti del sistema raccolgono per propositi di fatturazione. Grazie a questo meccanismo è possibile personalizzare l'utilizzo di certe risorse e stabilire dei modelli di prezzo personalizzati.

10.2 Cloud Security Mechanisms

I meccanismi di sicurezza affrontati in questa sezione tornano utili per affrontare le minacce affrontate nei capitoli precedenti e per migliorare l'affidabilità di un ambiente cloud.

10.2.1 Encryption

I dati normalmente sono codificati in un formato leggibile chiamato *plaintext* (testo in chiaro). Il testo in chiaro è vulnerabile ad attacchi quando trasmesso su canali insicuri, per cui si utilizza il meccanismo della crittografia (encryption): serve a preservare la confidenzialità e l'integrità dei dati. Questo meccanismo si basa su un algoritmo di cifratura che trasforma il testo in chiaro in un cifrato (cipher-text). Quando viene applicato un algoritmo di cifratura, si utilizza una stringa di caratteri chiamata **chiave di cifratura**, che è stabilita precedentemente e scambiata tra le parti interessate. La chiave viene poi utilizzata per decifrare il cifrato nel testo in chiaro. Ci sono due tipi di cifratura: simmetrica e asimmetrica.

SYMMETRIC ENCRYPTION

La cifratura simmetrica usa la stessa chiave per cifrare e per decifrare: queste due funzioni sono eseguite da entrambi i partecipanti alla discussione. Viene eseguito sempre un controllo di autenticazione perché solo le parti autorizzate che posseggono la chiave possono generare i messaggi. Questo tipo di cifratura non ha la caratteristica del non ripudio, perché se qualcun altro entra in possesso della chiave può inviare anch'esso messaggi.

ASYMMETRIC ENCRYPTION

La cifratura asimmetrica, chiamata anche crittografia a chiave pubblica, si basa sull'utilizzo di due chiavi, ovvero chiave pubblica e chiave privata. La prima è di dominio pubblico mentre la seconda è nota solo al proprietario: per cifrare un messaggio si utilizza la chiave pubblica di Bob, e quel messaggio può essere decifrato solo con la chiave privata di Bob. Il fatto che ci siano due chiavi anziché una fa sì che la crittografia asimmetrica sia più lenta computazionalmente di quella a chiave privata.


Il meccanismo di crittografia, quando usato per mettere al sicuro le trasmissioni web, è applicato di norma tramite via HTTPS, il quale fa uso di SSL e TLS tramite HTTP. Il protocollo TLS (*transport layer security*) è il successore del SSL (*secure socket layer*). Dato che la crittografia asimmetrica è più time-consuming di quella simmetrica, il protocollo TLS usa il primo solo per lo scambio di chiavi, e poi passa alla modalità simmetrica.

10.2.2 Hashing

È usato quando viene richiesto un tipo di protezione univoca, senza possibilità di tornare indietro. Una volta che l'hash viene applicato ad un messaggio, viene bloccato e non viene fornita alcuna chiave. Un caso d'uso di questa tecnologia è nello storage delle password. Per controllare se un messaggio è integro, si calcola l'hash e si confronta con quello ricevuto.

10.2.3 Digital Signature

La firma digitale serve a fornire autenticità e integrità attraverso autenticazione e non ripudio. A un messaggio viene assegnata una firma digitale prima della sua trasmissione, la quale viene resa non valida nel caso di modifiche non autorizzate al messaggio. La firma digitale rappresenta una prova che il messaggio ricevuto è lo stesso che è stato inviato dal mittente. Nella costruzione di una firma digitale vengono utilizzati sia l'hashing che la crittografia asimmetrica, e questo meccanismo viene utilizzato per evitare le minacce di *malicious intermediary*, *insufficient authorization* e *overlapping trust boundaries*.



10.2.4 Public Key Infrastructure (PKI)


Rappresenta un approccio comune per gestire le problematiche delle chiavi asimmetriche: consiste in una serie di protocolli e regole che permettono a sistemi molto grandi di utilizzare in modo sicuro la crittografia a chiave pubblica. Il PKI si basa sui certificati digitali, che sono strutture dati firmate digitalmente che uniscono tra loro le chiavi pubbliche per certificare l'identità del loro possessore. I certificati digitali spesso sono firmati da una terza parte rappresentata da una CA (*Certificate Authority*), come mostrato nella figura alla pagina successiva.

Alcune CA molto famose sono VeriSign e Comodo, ma capita anche che grandi aziende come Microsoft pubblicino i loro certificati. Un certificato può essere tuttavia generato da chiunque, a patto che abbia a disposizione gli strumenti giusti. Il PKI viene usato per contrastare la minaccia di *insufficient authorization*.

10.2.5 Identity and Access Management (IAM)

Utilizza le componenti e le policy necessarie per controllare e tracciare gli utenti, le loro identità e i loro privilegi di accesso per le risorse, gli ambienti e i sistemi. In particolare, il meccanismo di IAM comprende quattro componenti principali:

- **Authentication** - le combinazioni username/password restano la forma più comune di credenziali di accesso gestite dall'IAM, che supporta anche firme digitali o metodi di autenticazione biometrica, come le impronte digitali.
- **Authorization** - definisce la giusta granularità per il controllo degli accessi e riguarda anche la relazione tra le identità e i privilegi di accesso a una risorsa IT o ad una componente.



- **User Management** - riguarda le capacità di amministratore del sistema, che può creare profili, assegnare ruoli, modificare privilegi.
- **Credential Management** - la gestione delle credenziali stabilisce le identità e i ruoli per gli account già esistenti.


IAM viene usato per contrastare le minacce di *insufficient authorization*, *denial of service* e *overlapping trust boundaries*.

10.2.6 Single Sign-On (SSO)

La propagazione delle autenticazioni e delle informazioni sulle autorizzazioni per un cloud service consumer attraverso diversi servizi cloud può essere problematico, soprattutto se diverse risorse e servizi devono essere invocati per una stessa routine. Il meccanismo di Single Sign-On permette ad un cloud service consumer di essere autenticato da un security broker, che stabilisce un contesto di sicurezza che persiste durante l'utilizzo di servizi che si trovano in punti diversi del cloud. Nonostante non migliora la sicurezza del sistema, e non combatte nessuna minaccia, migliora di molto l'usabilità in quanto evita al consumer di autenticarsi ogni volta.

10.2.7 Cloud-Based Security Groups

Come può sembrare scontato, alzare delle barriere tra i dati aumenta la protezione degli stessi. La segmentazione delle risorse cloud-based è un processo che separa gli ambienti fisici da quelli virtuali che sono creati per diversi utenti o gruppi, come abbiamo visto già molte volte. Vengono definite delle policy per ogni gruppo basate sulle condizioni di utilizzo o sugli obiettivi comuni, e vengono dati dei permessi per utilizzare determinate risorse piuttosto che altre. Ad esempio diversi server virtuali che girano su uno stesso server fisico possono essere membri di due security group diversi. Il cloud resource administrator è colui che si occupa di questa divisione.



Questo meccanismo può essere utilizzato per combattere le minacce di *denial of service* e *overlapping trust boundaries*, ed è molto simile al concetto di **Logical Network Perimeter**.

10.2.8 Hardened Virtual Server Images

Come abbiamo visto in precedenza, le macchine virtuali in un ambiente cloud, tra cui anche i server, vengono generate a partire da un file immagine preconfigurato, in modo da migliorare prestazioni e usabilità. Le *Hardened Virtual Server Images* sono dei template per la creazione di macchine virtuali a cui è stata migliorata la robustezza disabilitando ad esempio porte inutilizzate, servizi inutili o software ridondanti. Questo meccanismo combatte le minacce di *denial of service*, *insufficient authorization* e *overlapping trust boundaries*.

10.3 Learning Check

1. Descrivi il meccanismo di Remote Administration System e spiega la sua relazione con i sistemi di fatturazione e con i SLA.
2. Descrivi gli obiettivi del meccanismo di Resource Management System ed elenca i task comuni che possono essere portati a termine con esso.
3. Descrivi gli obiettivi del meccanismo di SLA Management System e spiega come è in relazione con il meccanismo di SLA Monitor. Inoltre illustra l'importanza dell'elaborazione dell'utilizzo dei dati in relazione alle garanzie presenti in un SLA.
4. Descrivi gli obiettivi del meccanismo di Billing Management System e spiega la sua relazione con il meccanismo di Pay-Per-Use Monitor.
5. Descrivi il meccanismo di Encryption Security e spiega come funziona in relazione a testo in chiaro, testo cifrato e chiavi condivise. Inoltre spiega come le cifrature possono essere applicate sia all'interno che all'esterno dei cloud boundaries.
6. Elenca le possibili minacce alla sicurezza che possono verificarsi in seguito alla cifratura.

7. Descrivi il meccanismo di Hashing e spiega la sua relazione con i meccanismi di cifratura.
8. Elenca le possibili minacce alla sicurezza che possono verificarsi in seguito all'hashing.
9. Descrivi il meccanismo Digital Signatures Security e spiega come funzionano le firme digitali in relazione ad autenticazione e integrità. Inoltre spiega come le firme digitali possono essere applicate sia all'interno che all'esterno dei cloud boundaries.
10. Elenca le possibili minacce alla sicurezza che possono verificarsi in seguito all'utilizzo di firme digitali.
11. Descrivi il meccanismo di Public Key Infrastructure (PKI) e la sua relazione con i meccanismi appena illustrati.
12. Elenca le possibili minacce alla sicurezza che possono verificarsi in seguito all'utilizzo di PKI.
13. Descrivi il meccanismo di IAM (Identity and Access Management) e spiega l'obiettivo del salvataggio dell'identità messo in atto da un IAM. Inoltre spiega come un IAM può stabilire ruoli e regole.
14. Elenca le possibili minacce alla sicurezza che possono verificarsi in seguito all'utilizzo di IAM.
15. Descrivi il meccanismo di Single Sign-On e descrivi l'obiettivo del Security Broker. Spiega inoltre perché questo meccanismo non ha a che fare direttamente con le minacce alla sicurezza viste in precedenza.
16. Descrivi il meccanismo di Cloud-Based Security Groups e come questi gruppi sono messi insieme logicamente e non fisicamente. Inoltre spiega come possono essere assegnate le risorse IT ai gruppi.
17. Elenca le possibili minacce alla sicurezza che possono verificarsi in seguito all'utilizzo del meccanismo di Cloud-Based Security Groups.
18. Descrivi il meccanismo di Hardened Virtual Server Images e spiega come l'immagine di un virtual server può essere resa più robusta per questioni di sicurezza.
19. Elenca le possibili minacce alla sicurezza che possono verificarsi in seguito all'utilizzo del meccanismo di Hardened Virtual Server Images.




Capitolo 11

Fundamental Architecture

Dopo aver analizzato nel dettaglio i meccanismi del Cloud Computing passiamo alle architetture fondamentali, che essenzialmente hanno come obiettivo quello di essere una rappresentazione formale dei domini funzionali, cioè un'astrazione delle richieste, requisiti e risposte ai requisiti specifici del dominio di applicazione. I meccanismi visti finora rappresentano dei building block che vengono messi insieme per costruire delle architetture che sono le soluzioni che specificano le interazioni, i comportamenti e le combinazioni tra meccanismi.

11.1 Workload Distribution

Come sappiamo le risorse IT possono scalare orizzontalmente attraverso una quantità di risorse identiche replicate, e con un load balancer con una logica a runtime che decide di distribuire in maniera equa il carico attraverso le risorse. Come sappiamo serve ad evitare errori di sovrautilizzo e viene applicato ad ogni risorsa (non solo ai server). Ci sono versioni specializzate che riguardano server load balancing e switch virtuali, in quanto anche la rete può scalare.



In questo scenario i meccanismi che usiamo sono:

- Load balancer
- Virtual server
- Cloud storage device
- Audit monitor: serve per poter monitorare i log, gli accessi in modo da poter fornire certificazione e documentazione degli utenti che hanno compiuto operazioni, ma anche per controllare l'aspetto regolatorio del servizio che viene fornito, definito nel SLA.


- Cloud usage monitor, per capire quante risorse vengono adoperate per fornire il servizio in maniera scalabile.
- Hypervisor, perché il meccanismo comporta l'uso delle macchine virtuali.
- Logical Network Perimeter: è necessario l'isolamento dei livelli dove i carichi di lavoro sono distribuiti.
- Resource Cluster: per supportare il balancing.

11.2 Resource Pooling

I pool di risorse mettono a disposizione una serie di risorse di base, che sono:

- server fisici, cioè server che vengono considerati insieme un'unica risorsa e possono essere utilizzati in maniera comune coordinata.
- server virtuali, più semplici da gestire in quanto esistono dei template.
- storage pool: cioè un'insieme di risorse di storage che vengono allocate in caso di necessità.
- Network: risorse di rete fornite con caratteristiche come ridondanza e link aggregation, tramite il quale diversi link fisici vengono usati come un unico link "virtuale" che ha come larghezza di banda la somma delle larghezze di banda dei singoli link.
- CPU: tipicamente si hanno più core o processori virtuali e non singoli processori standard.
- memoria: anche la RAM viene messa insieme in pool di risorse.

Questi pool possono essere messi insieme oppure possono essere isolati, o innestati, rappresentando un partizionamento. L'obiettivo di questo partizionamento si può vedere dall'immagine: le richieste inviate al pool A.1 non possono eccedere le risorse del pool A.1, e stessa cosa vale per il pool A.2.



I meccanismi utilizzati sono:

- Virtual server

- Cloud storage device
- Audit Monitor: per monitorare l'utilizzo per le regolazioni dei dati e anche per la privacy.
- Cloud Usage Monitor, per capire quanto pagare per un pool di risorse.
- Hypervisor
- Logical Network Perimeter
- Pay-Per-Use Monitor, per tariffare l'utilizzo di risorse nel pool: trasforma le risorse in denaro per il provider.
- Remote Administration Systems (per i soldi)
- Resource Administration System (per le risorse)
- Resource replication

11.3 Dynamic Scalability

La scalabilità dinamica è sia molto utile che pericoloso perché può porre problemi sotto una determinata configurazione durante un attacco DoS. Funziona facendo il trigger per l'allocazione delle risorse in base a condizioni predefinite senza alcun intervento manuale: riesce quindi a mantenere le prestazioni del servizio e la QoS all'interno dei termini specificati nel SLA allocando le risorse automaticamente in base alle fluttuazioni del carico. Il vantaggio è che non richiede intervento umano, lo svantaggio è che può portare a costi imprevisti in caso di picchi non prevedibili.

Lo scaling viene effettuato in tre modi:


- **Dynamic Horizontal Scaling** - classico scaling orizzontale che fa scaling out e scaling in, l'Automated Scaling Listener segnala che è necessario replicare le risorse.
- **Dynamic Vertical Scaling** - classico scaling verticale che fa scaling up e scaling down, l'Automated Scaling Listener segnala che è necessario aumentare le risorse che vengono date alle macchine.
- **Dynamic Relocation** - l'istanza del servizio viene spostata verso un host che ha maggiore capacità. La differenza principalmente è che mentre nei due precedenti parliamo di istanze virtuali, qui si parla di istanze fisiche.

I meccanismi utilizzati sono:

- Automated Scaling Listener (fondamentale)
- Resource Replication (anch'esso fondamentale)
- Cloud Usage Monitor, per loggare l'utilizzo di nuove risorse o di risorse più potenti.
- Hypervisor
- Pay-Per-Use Monitor

11.4 Elastic Resource Capacity

Tipicamente legata alla fornitura di server virtuali (con CPU e RAM), l'interazione è tipicamente con l'hypervisor o con la VIM per ottenere le risorse che vengono elasticamente aggiunte a quello che viene fornito al customer. In questa struttura è importante anticipare le richieste, prima che si arrivi a una threshold fissata. Una componente automatica, chiamata *intelligent automation engine* manda le scaling requests alla VIM oppure direttamente all'hypervisor, e in certi casi è necessario il reboot della risorsa. È tipico del modello di deployment IaaS. Nella figura è mostrato il funzionamento: all'aumentare dei cloud service consumer, l'intelligent automation engine usa degli script comunicando all'hypervisor la necessità di aumentare le risorse per la macchina virtuale (scaling verticale).




I meccanismi utilizzati sono:

- Cloud Usage Monitor
- Pay-Per-Use Monitor, che raccoglie i costi dello scaling.
- Resource Replication

11.5 Service Load Balancing

Permette il bilanciamento dei servizi, ed è tipico del modello di deployment SaaS. Può essere considerato una variazione della workload distribution architecture, ma per far scalare le implementazioni dei servizi cloud. Si basa su una serie di implementazioni duplicate del servizio da bilanciare: un load balancer quindi è esterno a queste implementazioni, oppure può essere il servizio stesso ad applicare politiche di bilanciamento (ovviamente solo in senso orizzontale). La figura mostra le due possibili implementazioni: nello scenario A il load balancer è indipendente dal servizio, nello scenario B è il servizio stesso a bilanciare il carico. Lo scenario A può essere più semplice da implementare ma può avere degli svantaggi nel caso ci siano bilanciamenti molto precisi da fare, in quanto essendo indipendente dal servizio non ne conosce l'implementazione e non può ottimizzarne le prestazioni, cosa che è possibile nello scenario B.


I meccanismi utilizzati sono:



- Cloud Usage Monitor
- Resource Cluster
- Resource Replication

11.6 Cloud Bursting

Questo meccanismo stabilisce una forma di scaling dinamico che scala o "fa esplodere" una risorsa IT on-premise sul cloud quando è necessario, e questo può accadere per motivi politici, logistici o economici. In breve, l'utilizzo della risorsa potrebbe essere basso per cui può restare on premise, ma se dovesse aumentare questo meccanismo permette di spostarla su cloud in maniera agile. Questo avviene anche al contrario, ovvero quando non è più necessaria, la risorsa torna nell'ambiente on-premise. Ovviamente questo meccanismo richiede che siano utilizzati un Automated Scaling Listener e un meccanismo di Resource Replication.



Come si può vedere dalla figura, un ASL verifica costantemente l'utilizzo del cloud service A e nel caso in cui venga superata una certa soglia, le richieste vengono redirette su un'istanza perfettamente identica (grazie allo state replication) sul cloud.


11.7 Elastic Disk Provisioning

Permette di utilizzare taglie variabili di storage, basandosi ovviamente su dischi virtuali, per offrire una fatturazione più granulare. Grazie all'allocazione dinamica inoltre spesso la maggior parte delle spese non vengono affrontate perché il consumer viene addebitato solo per ciò che effettivamente usa. I meccanismi utilizzati sono:

- Cloud Storage Device
- Virtual Server
- Hypervisor
- Pay-per-use monitor
- Cloud usage monitor
- Resource replication, usato per convertire i diversi tipi di elastic disk provisioning.

11.8 Redundant Storage

La ridondanza dello storage è utile per offrire alta disponibilità, resilienza, e tolleranza ai fallimenti. Un LUN (Logical Unit Number), visto anche in precedenza, è un disco logico che rappresenta una partizione di un disco fisico. Lo **Storage Service Gateway** è una componente che si comporta come un dispositivo di storage ma non fa il gateway verso dischi fisici. Tipicamente per favorire il Redundant Storage si definisce una replica dello storage per poter gestire i fallimenti: in caso di fallimenti del nodo tutte le richieste vengono redirette verso la copia.



Lo Storage Service Gateway fornisce accesso al primary storage device, che però mantiene automaticamente duplicato il suo stato, quindi ogni LUN viene replicata nel nuovo storage. In caso di fallimenti o malfunzionamenti del primary storage, il SSG switcha automaticamente sul secondary storage device. Per risparmiare, i cloud providers potrebbero localizzare i cloud storage secondari in regioni geografiche differenti dal primary storage, e dunque sorgono i tipici problemi del data residency sui tipi di dati che vengono salvati che possono portare anche a problemi legali. Per questo i protocolli e i metodi utilizzati per lo scambio di messaggi e per la sincronizzazione tra lo storage primario e quello secondario devono supportare crittografia e meccanismi di sicurezza avanzati per poter supportare la QoS dei dati che sono stati duplicati in un altro contesto. Ovviamente, anche i protocolli di replica potrebbero essere soggetti a restrizioni dovute alle diverse zone geografiche.

La replica dello storage in differenti aree geografiche viene utilizzata anche per supportare il disaster recovery.

11.9 Learning Check

1. Descrivi l'obiettivo dell'architettura di Workload Distribution e spiega come viene utilizzato il Load Balancer in relazione ad essa. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
2. Descrivi l'obiettivo dell'architettura di Resource Pooling ed elenca i tipi comuni di risorse che possono essere raggruppate. Elenca i tre tipi principali di gruppi di resource pool e spiegane le gerarchie. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
3. Descrivi l'obiettivo dell'architettura Dynamic Scalability e spiega come questa è in relazione con le condizioni di scaling predefinite e con il meccanismo di Automated Scaling Listener. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
4. Descrivi l'obiettivo dell'architettura Elastic Resource Capacity e spiegane l'utilizzo in relazione ai resource pool e a un sistema di elastic provisioning. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
5. Descrivi l'obiettivo dell'architettura Service Load Balancing. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
6. Descrivi l'obiettivo dell'architettura Cloud Bursting e spiega come vengono utilizzati i meccanismi di Automated Scaling Listener e Resource Replication. Inoltre illustra la differenza tra un'architettura che effettua un *burst* verso un cloud pubblico rispetto ad un cloud privato.
7. Descrivi l'obiettivo dell'architettura Elastic Disk Provisioning e spiega come viene utilizzato insieme al Dynamic Storage Provisioning System. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
8. Descrivi l'obiettivo dell'architettura Redundant Storage e spiega come storage primario e storage secondario vengono utilizzati in un Failover System. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.



Capitolo 12


Advanced Architectures

In questo capitolo vengono presentate le architetture avanzate del cloud che vengono utilizzate per seguire i requisiti che il cloud si pone di soddisfare. La maggior parte di queste architetture riguardano il computing, e utilizzano i meccanismi di base visti nei capitoli precedenti. Le architetture avanzate rappresentano la formalizzazione dei domini funzionali, e definiscono le interazioni, i comportamenti e le combinazioni dei meccanismi e di altre componenti, e hanno come obiettivo offrire soluzioni specifiche.


12.1 Hypervisor Clustering

Quando vengono introdotti meccanismi per favorire la resilienza uno dei punti forti è dato dalla presenza dell'hypervisor. Essendo un punto critico, lo stesso hypervisor può essere soggetto a malfunzionamenti, per cui anche questa componente deve essere replicata e i meccanismi al suo interno devono essere gestiti. Questo è possibile grazie all'Hypervisor Clustering, che gestisce diversi server fisici assicurando il funzionamento delle varie macchine virtuali nonostante i malfunzionamenti che possono affliggere sia il server fisico che gli hypervisor. Quello che si fa normalmente nella migrazione di una macchina virtuale in casi di malfunzionamento viene fatto allo stesso modo per gli hypervisor: viene utilizzata una serie di hypervisor in esecuzione che possono prendere in carico diversi host. Il funzionamento è il seguente:

1. I server fisici A, B e C rappresentano un cluster di server aventi lo stesso dominio di gestione, mentre gli hypervisor che sono eseguiti sui server hanno in carico un certo numero di macchine virtuali, la cui immagine si trova all'interno dello storage (3). Tutti gli hypervisor sono coordinati dalla VIM.



2. In ogni momento la comunicazione tra le macchine fisiche e la VIM avviene tramite messaggi di *heartbeat*. Gli heartbeat sono tipi di messaggi che vengono scambiati a intervalli regolari tra i nodi del cluster. In caso di malfunzionamenti ci si rende subito conto quale nodo ha fallito perché non vengono inviati più messaggi di heartbeat.



3. A questo punto si avvia un meccanismo di live migration grazie al quale le macchine virtuali si spostano dalla macchina fisica che ha fallito ad una funzionante passando per l'hypervisor. Questo è possibile grazie ai file immagine degli stati delle macchine che si trovano in uno storage condiviso.

I meccanismi utilizzati nell'Hypervisor Clustering sono:


- Hypervisor
- Resource Cluster
- Logical Network Perimeter, in quanto tutte le componenti viste nel funzionamento devono risiedere nello stesso perimetro.
- Resource replication, attraverso il VIM agli hypervisor.

12.2 Load Balanced Virtual Servers


Un altro meccanismo avanzato del cloud è il bilanciamento del carico di lavoro, che serve per migliorare le prestazioni delle macchine e garantire un'alta qualità del servizio, come stabilito nei SLA. L'obiettivo quindi è quello di effettuare il bilanciamento del carico ma tra server fisici e non virtuali come il bilanciamento classico. Questo perché un server fisico potrebbe ricevere più carico di lavoro di quello che sopportare, anche a causa dei diversi server virtuali che sono in esecuzione su di esso. Quello che si fa allora è bilanciare il carico attraverso i server fisici per fare in modo che non siano sovraccaricati oppure sottoutilizzati.

L'architettura del Load Balanced Virtual Server utilizza un *capacity watchdog system* per calcolare le istanze di server virtuali e il loro carico di lavoro prima di distribuirlo al processing. Di seguito il funzionamento:


1. L'architettura di Hypervisor Clustering fornisce le basi sulle quali è costruita l'architettura del Load Balanced Virtual Server (1). Le policy e le soglie di sopportamento sono definite nel watchdog capacity monitor (2), che confronta le capacità dei server fisici con il carico dei server virtuali in esecuzioni su di essi (3). Invia quindi un segnale alla VIM indicando un sovraccarico (4).



2. La VIM invia un segnale al load balancer per ridistribuire il carico basato sulle soglie predefinite (5). Il load balancer inizializza la Live Migration per spostare i virtual server (6), che quindi cambiano host.



3. Il carico di lavoro viene bilanciato tra i server fisici presenti nel cluster. Il capacity watchdog monitor continua a monitorare il carico di lavoro e il consumo delle risorse (9).



I meccanismi utilizzati sono:

- Automated Scaling Listener
- Load Balancer
- Logical Network Perimeter
- Resource Replication

12.3 Non-disruptive Service Relocation

Mentre le architetture precedenti riguardavano principalmente il modello di deployment IaaS, quest'architettura e le successive riguardano più da vicino il modello SaaS: mentre prima andavano rilocati elementi della struttura, come server e hypervisor, qui vengono rilocati invece i servizi e le risorse non fisiche.


In base a ciò che viene definito nel SLA, i servizi devono essere sempre disponibili, e se un servizio non è disponibile le cause potrebbero essere diverse: numero di richieste troppo alto, aggiornamento o manutenzione del servizio. La rilocazione di un servizio viene realizzata attraverso il riconoscimento di un evento programmato e che suggerisce la duplicazione o la rimozione di un servizio a tempo di esecuzione - per questo si parla di non-disruptive relocation. Ciò può essere fatto in due modi:

- il servizio viene temporaneamente spostato in un altro ambiente di hosting mentre è in esecuzione aggiungendo un'implementazione duplicata in un nuovo host;
- il servizio viene spostato permanentemente.


In ogni caso questa rilocazione deve assicurare la continuità del servizio: la nuova copia del servizio deve essere attiva e deve poter rispondere prima che la vecchia copia sia terminata.

Vediamo nel dettaglio il funzionamento:"


1. L'Automated Scaling Listener monitora il carico di lavoro di un servizio cloud (1). La soglia predefinita del cloud service viene raggiunta quando il carico di lavoro aumenta (2), e ciò porta l'ASL ad inviare un messaggio alla VIM per iniziare la rilocazione (3). La VIM utilizza il meccanismo della Live VM Migration per fornire agli hypervisor coinvolti nella migrazione le informazioni necessarie per gestire una migrazione del servizio (4).



2. Una seconda copia del server virtuale e del servizio cloud sono creati dall'hypervisor di destinazione sul server fisico B (5).



3. Lo stato di entrambi i server virtuali viene sincronizzato (6). L'istanza del primo virtual server viene rimossa dal server fisico A dopo che le richieste del cloud service consumer vengono reindirizzate correttamente verso la nuova istanza del servizio sul server fisico B (7). A questo punto le richieste del cloud service consumer vengono inviate permanentemente al server fisico B (8).



La **virtual server migration** è differente a seconda della locazione dei dischi e della configurazione del server. Inizialmente si fa una copia del disco sull'host di destinazione (in caso di storage remoto non condiviso oppure di storage locale). Dopo che la copia è stata creata, entrambe le istanze del server sono sincronizzate e i file sono rimossi dall'host originale. Se i file sono salvati su uno storage remoto condiviso, non è necessario copiare i file in quanto sono direttamente accessibili. A questo

punto le autorizzazioni e i permessi del virtual server sono semplicemente trasferiti al nuovo server, e dunque lo stato viene automaticamente sincronizzato. In questo scenario acquistano importanza le configurazioni fissate di rete, in quanto anche cambiando host, questo si può connettere facilmente alla rete utilizzando le stesse impostazioni dell'host precedente.

I meccanismi utilizzati sono:

- Automated Scaling Listener
- Load Balancer
- Cloud Storage Device
- Hypervisor
- Virtual Server
- Cloud Usage Monitor
- Pay-Per-Use Monitor, in quanto ogni volta che c'è una replicazione vengono calcolati i costi.
- Resource Replication
- SLA Management System
- SLA Monitor

12.4 Zero Downtime

Come sappiamo, un server fisico rappresenta un Single Point of Failure, quindi in caso di fallimento di un server potrebbe fallire l'intero sistema. Avere quindi la possibilità di offrire un sistema con zero downtime diventa difficile. La chiave di tutto questo meccanismo è un sistema di failover che permette ai server virtuali di essere spostati sui server fisici. L'idea anche qui si basa sul load balancing di file immagini di virtual server e di storage condiviso per poter fare la Live VM Migration.

I meccanismi utilizzati sono:


- Failover system
- Cloud Storage Device
- Virtual Server
- Audit Monitor, nel caso la rilocalizzazione di un server abbia bisogno di una rilocalizzazione dei dati.
- Cloud Usage Monitor
- Hypervisor
- Logical Network Perimeter, in quanto ogni rilocalizzazione viene fatta nello stesso perimetro.
- Resource Cluster
- Resource Replication, per gestire il pool di risorse che in questo caso sono le macchine virtuali.

12.5 Cloud Balancing

Mentre le architetture viste finora si basano su specifiche componenti, come sostituzione di hypervisor o di una singola risorsa, le prossime architetture riguardano una visione un po' più d'insieme. Ad esempio, quando le risorse vengono gestite da un load balancer attraverso diversi cloud, gli obiettivi sono:

- migliorare le performance e la scalabilità delle risorse IT;
- aumentare la disponibilità e la reliability delle risorse IT;
- migliorare il bilanciamento del carico e l'ottimizzazione delle risorse IT. Non bisogna trascurare il fatto che diversi cloud possono avere diverse politiche di pricing e quindi *ottimizzare* una risorsa può voler dire cose diverse in base al tipo di politica utilizzata.

Il meccanismo su scala più ampia è simile a quello già visto ma ovviamente con un numero maggiore di componenti dovuti alla maggiore dimensione. Il lavoro dell'Automated Scaling Listener è quello di redirigere le richieste del service consumer a una delle copie ridondanti di implementazione del servizio. Il sistema di failover si assicura che le risorse IT ridondanti siano capaci di gestire un failover cross-cloud, quindi che riguarda diversi provider. I malfunzionamenti sono annunciati, in modo che l'ASL possa evitare di inviare richieste alla risorsa che in quel momento non risponde o che è instabile.



Nella figura possiamo vedere tre cloud provider che offrono lo stesso servizio. L'ASL è anch'esso su un cloud e il meccanismo di failover che è in grado di monitorare i vari provider permette di indirizzare le richieste dove decide l'Automated Scaling Listener.

I meccanismi utilizzati sono:

- Automated Scaling Listener
- Resource Replication
- Logical Network Perimeter
- Resource Replication (cross-cloud)

12.6 Resource Reservation


Un *resource constraint* si ha quando a due o più consumer sono stati allocati una risorsa che non può essere condivisa oppure non ha abbastanza potenza. Un esempio è quando ci sono più macchine virtuali che si danneggiano l'una con l'altra, se stanno sulla stessa macchina fisica. Questo porta a un degrado delle prestazioni. Ci possono essere anche conflitti di prestiti non restituiti. La possibilità di potersi riservare una risorsa impatta sulla gestione delle risorse stesse: un customer può bloccare una serie di risorse mentre il resto del pool è ancora a disposizione per sharing e borrowing. Questo può essere fatto direttamente dal customer, e ovviamente ha un costo.

I meccanismi utilizzati sono:

- Cloud Storage Device
- Virtual Server
- Audit Monitor: per controllare che le reservation siano in compliance con i permessi e le autorizzazioni del customer
- Cloud Usage Monitor
- Hypervisor
- Logical Network Perimeter
- Resource Replication

12.7 Dynamic Failure Detect/Recovery

I cloud sono composti da una grande quantità di risorse a cui accedono contemporaneamente moltissimi consumer. Queste risorse ovviamente possono fallire, quindi hanno bisogno di essere tenute sotto controllo. La gestione manuale delle risorse tipicamente non è la soluzione migliore da attuare in quanto inefficiente e poco pratica. Il meccanismo di Dynamic Failure Detect, che si basa sempre un watchdog, è in grado di rispondere automaticamente a una serie predefinita di scenari, come i failure. Notifica le failure condition se non possono essere risolte automaticamente. Un Cloud Usage Monitor più intelligente, che viene chiamato *Intelligent Watchdog Monitor*, traccia le risorse IT e compie azioni predefinite in risposta ad eventi predefiniti, come ad esempio riavviare un servizio se questo non risponde, oppure riavviare l'intera macchina se questa dà problemi. Se nessun'azione va a buon fine, viene notificato l'admin.



Tipicamente le azioni che vengono notificate sono:

- esecuzione di file batch
- invio di un messaggio su terminale
- invio di un messaggio di testo
- invio di un messaggio email
- invio di una SNMP trap¹
- logging di un ticket

I meccanismi utilizzati sono:

- Audit Monitor, per controllare che il recupero dei dati sia conforme alla legge e alle policy stabilite nei requisiti.
- Failover System
- SLA Management

12.8 Bare-Metal Provisioning

Normalmente il sistema remoto di management è nativo al sistema operativo dei vari server e quando il cloud provider deve fornire bare metal non può contare su questi sistemi di gestione remota: quindi il bare metal soffre della mancanza di gestione remota che permette a questi compiti di essere eseguiti con più facilità. Tipicamente queste opzioni si trovano nella ROM del server. L'architettura per attuare la fornitura di bare metal usa dei Service Agent specializzati che nel momento in cui il server parte, avvia il sistema di management remoto. Tipicamente a questi sistemi si accede via un'interfaccia web-based.

Ovviamente ci sono delle attenzioni da pagare: una è la possibilità di errori, perché l'installazione è comunque eseguita da parte di una persona fisica, e l'altra è rappresentata dalle risorse necessarie offerte dal remote management software, che spesso richiedono risorse di calcolo molto potenti.

Le componenti dell'architettura sono:

- **Discovery Agent**, che trova i server fisici liberi da assegnare ai cloud consumer.
- **Deployment Agent**, che viene installato nella memoria di un server fisico per fungere da client per la fornitura di bare metal.
- **Discovery Section**, che analizza la rete per trovare i server fisici a cui è possibile connettersi.
- **Management Loader**, che si connette al server fisico e carica le opzioni di gestione per il cloud consumer.
- **Deployment Component**, che server per installare il sistema operativo sui server fisici.

Questa infrastruttura software viene utilizzata per poter accedere a macchine fisiche e permettere al consumer di installare il sistema operativo richiesto su queste macchine.

Il bare metal provisioning viene fornito in maniera automatica: i consumer si collegano al software di gestione che già è preconfigurato per accogliere le richieste dei consumer, che possono configurare anche più macchine contemporaneamente o possono installare più sistemi operativi sulla stessa macchina. Il sistema di deployment centrale si connette ai server attraverso l'interfaccia di gestione e

¹Simple Network Management Protocol (SNMP) è un protocollo di gestione di tutti gli apparati che stanno su un network. Una *trap* è un metodo per indicare un evento.

utilizza lo stesso protocollo per agire nella RAM della macchina fisica. A questo punto l'agente presente sulla macchina, senza ancora il sistema operativo, può configurarla per il SO che ha scelto il consumer.

I meccanismi utilizzati sono:

- Cloud Storage Device, per salvare i template di sistemi operativi e i file di installazione
- Hypervisor
- Logical Network Perimeter, in quanto ai server fisici possono accedere sono i cloud consumer autorizzati.
- Resource Replication
- SLA Management System, perché il tipo di servizi che viene offerto può essere soggetto a restrizioni nel SLA.

12.9 Rapid Provisioning

Il processo di fornitura convenzionale può comprendere una serie di task che devono essere svolte manualmente. Nel cloud, la fornitura manuale di solito è inefficiente e soggetta ad errori, quindi non risulta adeguata. L'architettura del Rapid Provisioning automatizza la fornitura di una vasta gamma di risorse IT, sia individualmente che in maniera collettiva. Le componenti usate in quest'architettura comprendono un programma automatico di fornitura, un engine e degli script per poter gestire la fornitura di richieste on-demand. Inoltre ci sono componenti aggiuntive come server templates, application packages, custom scripts, sequence manager, sequence logger, operating system baseline, application configuration baseline e deployment data store. Ovviamente a seconda della risorsa si utilizza una combinazione di queste componenti.

Nel momento in cui l'utente utilizza il self-service portal per scegliere quali sono le caratteristiche, questo instruisce l'engine a rappresentare il cloud service che poi viene usato dall'amministratore della risorsa. Tutto il punto critico sta in queste due parti, che assicurano che tutto questo venga fatto automaticamente e senza interventi manuali di norma.

I meccanismi utilizzati sono:




- Cloud Storage Device
- Resource Replication

12.10 Storage Workload Management

Il sovrautilizzo dei dispositivi di storage sul cloud aumenta ovviamente il carico di lavoro sullo storage controller, e causa problemi di prestazioni o spreco di risorse (nel caso di sottoutilizzo). Lo Storage Workload Management permette alle LUN di poter essere distribuite in maniera uniforme attraverso diversi dispositivi di cloud storage disponibili, come si può vedere nelle immagini successive.

I meccanismi utilizzati sono:

- Audit Monitor
- Automated Scaling Listener
- Cloud Usage Monitor
- Load Balancer
- Logical Network Perimeter



12.11 Learning Check

1. Descrivi l'obiettivo dell'architettura Hypervisor Clustering e spiega come viene utilizzato l'hypervisor. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
2. Descrivi l'obiettivo dell'architettura Load Balanced Virtual Server Instances e spiega l'utilizzo delle policy di bilanciamento del carico e l'obiettivo del Capacity Watchdog Monitor. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
3. Descrivi l'obiettivo dell'architettura Non-Disruptive Service Relocation e spiega come viene utilizzata la VIM e le sue componenti di live VM migration. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
4. Descrivi l'obiettivo dell'architettura Zero Downtime e spiega il suo utilizzo come sistema di resistenza ai fallimenti. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
5. Descrivi l'obiettivo dell'architettura Cloud Balancing e spiega come vengono utilizzati i meccanismi di Automated Scaling Listener e Resource Replication.
6. Descrivi l'obiettivo dell'architettura Resource Reservation e descrivi a cosa serve il vincolo di condizione sulle risorse. Spiega anche come funziona lo scenario del prestito delle risorse. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
7. Descrivi l'obiettivo dell'architettura di Dynamic Failure Detection and Recovery e spiega come funziona il watchdog system e come si basa sul SLA monitor. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
8. Descrivi l'obiettivo dell'architettura Bare-Metal Provisioning e spiega l'utilizzo di un central deployment system e l'utilizzo di RAM visiva via il meccanismo di remote management system. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
9. Descrivi l'obiettivo dell'architettura Rapid Provisioning ed elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
10. Descrivi l'obiettivo dell'architettura Storage Workload Management ed elenca i meccanismi del Cloud Computing utilizzati in questa architettura.



Capitolo 13

Specialized Architectures

Le architetture specializzate si rivolgono principalmente a problemi di ottimizzazione di storage e networking, e hanno lo scopo di massimizzare le prestazioni negli scenari dove è più difficile richiederle. Infatti storage e network, che sono punti chiave dei sistemi informativi, possono essere collegati rispettivamente agli obiettivi di prestazioni e ridondanza.

L'approccio a queste architetture è particolarmente pragmatico, cercando di eliminare quei livelli di astrazione spesso introdotti per facilitare l'organizzazione ma che degradano le prestazioni. La domanda è semplice: dopo quanto tempo dalla lettura di un'istruzione questa viene eseguita effettivamente dall'hardware? La risposta non è altrettanto semplice, basti pensare a tutti i livelli di astrazione posti dalle macchine virtuali, dagli hypervisor e da altre componenti non strettamente necessarie.

A differenza del libro, queste architetture sono riorganizzate in base al loro obiettivo: architetture legate allo storage e architetture legate alla rete.

13.1 Storage related architectures


13.1.1 Direct I/O Access

L'accesso alle schede di I/O fisiche (quindi i server fisici) spesso avviene da parte dei server virtuali tramite un livello composto da hypervisor, chiamato livello di virtualizzazione I/O. Questa architettura permette l'accesso diretto alle schede di I/O fisiche da parte dei virtual server senza passare per questo livello intermedio.

Di norma l'accesso viene fatto dalla macchina virtuale tramite un hypervisor che sta su un server fisico, il quale ha accesso al disco. L'aumento di richieste da parte dei cloud service consumer può causare problemi di prestazioni e portare a un bottle neck per l'hypervisor. N.B. Qui si parla di un collo di bottiglia per l'accesso allo storage, non per la computazione. La soluzione sta nel permettere al server virtuale di bypassare l'hypervisor e connettersi così al database attraverso un link fisico che permette di accedere direttamente allo storage.

I meccanismi utilizzati sono:

- Virtual server
- Hypervisor
- Cloud Usage Monitor, che raccoglie dati sugli accessi diretti all'I/O. A causa dell'accesso diretto bisogna calcolare il costo specifico perché non è presente un load balancer.
- Logical Network Perimeter, in quanto le schede I/O fisiche sono accessibili dall'interno del perimetro.




- Pay-Per-Use Monitor, come detto prima.
- Resource Replication, per rimpiazzare le schede di I/O virtuali con schede I/O fisiche.

13.1.2 Direct LUN Access

Anche quest'architettura permette di bypassare la virtualizzazione per migliorare le prestazioni dello storage. Tipicamente le LUN riguardanti lo storage sono mappate tramite un **Host Bus Adapter (HBA)** sugli hypervisor, mentre lo spazio di archiviazione viene emulato sui virtual server. Tuttavia a volte può essere necessario accedere direttamente allo storage in quanto l'emulazione non è sufficiente per il cluster quando questo deve hostare la LUN.

Viene fornito quindi un accesso tramite questo HBA, che permette di accedere anche ai volumi del disco che sono utilizzati nel cluster. In questo modo la connessione fisica ai virtual server da parte delle LUN viene attivata dagli stessi host fisici. Le LUN quindi sono create e configurate sul cloud storage device per accedere anche a device fisici.




Il cloud storage device viene installato e configurato, dopodiché vengono impostati gli hypervisor in modo che possano avere accesso alle LUN, e mostrano lo storage a cui possono accedere ai virtual server sovrastanti. Lo storage appare come se fosse uno storage normale, ma invece è emulato. La soluzione è di fare in modo di presentare direttamente le LUN ai server virtuali, in modo che questi possano accedere direttamente ai volumi e non ad un "servizio" che mostra lo storage come file-based. I meccanismi utilizzati sono:

- Virtual server
- Hypervisor
- Cloud storage device
- Cloud usage monitor, per avere informazioni sull'utilizzo diretto delle LUN.
- Pay-Per-Use Monitor: raccoglie informazioni sull'utilizzo per decidere i costi.
- Resource Replication, per sostituire file-based storage con block-based storage.

13.1.3 Dynamic Data Normalization

La ridondanza dei dati può causare una serie di problemi negli ambienti cloud, ad esempio l'aumento del tempo necessario a salvare e catalogare i file, l'aumento dello storage necessario per il backup e l'aumento dei costi dovuto a capacità di archiviazione più elevate. Se un consumer carica su cloud un file di 100 MB e la ridondanza è di 10 copie, il consumer pagherà e avrà bisogno di 1000 MB, senza contare il fatto che sarà necessario più tempo per recuperare ed archiviare il file.

La Dynamic Data Normalization Architecture stabilisce un sistema di "de-duplicazione", che impedisce al cloud consumer di sprecare più risorse di quante ne siano veramente necessarie per quanto riguarda la ridondanza dei dati. Questo sistema può essere applicato sia al block-based storage che al file-based, ma è più efficiente sul primo. Di ogni blocco viene calcolato l'hash e viene controllato per determinare se è stato già ricevuto o meno. I blocchi ridondanti vengono sostituiti da puntatori all'effettivo blocco che è archiviato.




13.1.4 Device Vertical Tiering

Il Device Vertical Tiering è un'architettura che permette di rendere le risorse scalabili anche in particolari situazioni dove potrebbe apparire difficile effettuare uno scaling a causa di restrizioni denotate dall'hardware. Distinguiamo due tipi di DVT: intra-storage e cross-storage.

Intra-storage DVT

Alcuni cloud consumer potrebbero avere dei requisiti di data storage restrittivi che obbligano le risorse ad essere archiviate su un singolo Cloud Storage Device, magari a causa della sicurezza dei dati, della privacy, o per motivi legislativi. Il Device Vertical Tiering intra-storage stabilisce un sistema che supporta lo scaling verticale in un singolo cloud storage device: per implementare questo meccanismo è necessario l'utilizzo di uno storage complesso che supporti diversi tipi di dischi, specialmente quelli ad alte prestazioni. I tipi di dischi sono poi organizzati in livelli in modo che le LUN possano migrare verticalmente tra i dischi di livelli diversi.




Nella figura sono state create due LUN sul Disk Group 1 (3). L'Automated Scaling Listener monitora le richieste in relazione a soglie predefinite (4). Il Pay-Per-Use Monitor traccia l'ammontare attuale di disco utilizzato (5). L'ASL determina che il numero di richieste sta raggiungendo una soglia e informa lo storage management program che le LUN devono essere spostate su un Disk Group più performante (6). Viene quindi avviato il programma di migrazione LUN (7) e le LUN vengono spostate (8).

Cross-storage DVT

I tradizionali metodi di scaling verticale possono risultare inefficienti o time-consuming quando oltre ad aumentare la quantità di richieste aumentano di colpo le specifiche di potenza, storage e rete richieste. Il Device Vertical Scaling cross-storage stabilisce un sistema che riesce a sopperire ai limiti dettati dalla potenza e dalla larghezza di banda scalando tra device che hanno capacità differenti. Le LUN possono fare scaling up e down automaticamente tra diversi device in questo sistema in modo che le richieste utilizzano il device più consono al loro livello di requisiti. L'ASL monitora le richieste inviate alle singole LUN e segnala lo storage management program per spostare un LUN su un altro dispositivo quando viene raggiunta una certa soglia. Il dispositivo originale rimane intatto e le richieste vengono automaticamente smistate al dispositivo più consono.


I meccanismi utilizzati sono:

- Automated Scaling Listener
- Cloud Storage Device
- Audit Monitor, controlla che la rilocalizzazione delle risorse rispetti i requisiti legislativi delle regioni in cui si trovano i dispositivi.
- Cloud Usage Monitor Pay-Per-Use Monitor



13.1.5 Storage Maintenance Window

I dispositivi di cloud storage che sono soggetti a manutenzione e task amministrativi a volte necessitano di essere riavviati o spenti, il che implica l'inutilizzabilità delle risorse IT che giacciono al loro interno. Lo Storage Maintenance Window permette ai cloud service consumer di essere redirezionati automaticamente e in modo trasparente verso dispositivi di storage secondari, senza rendere noto che il dispositivo primario è offline, utilizzando un programma di **Live Storage Migration**¹




¹Un programma di Live Storage Migration è un sistema sofisticato che utilizza le componenti di migrazione delle LUN per spostare le unità logiche in modo *reliable* permettendo alle copie originali di rimanere attive fino a che la copia di destinazione non sia completamente attiva.

13.2 Network related architectures

13.2.1 Elastic Network Capacity

Nonostante le risorse IT siano distribuite on-demand e in modo scalabile sul cloud, le prestazioni e l'availability possono essere compromesse quando l'accesso remoto alle risorse è colpito da limitazioni alla banda di rete.

Grazie all'elastic network è possibile stabilire un sistema che può allocare larghezza di banda dinamicamente alla rete per evitare colli di bottiglia durante l'esecuzione. Script di intelligent automation engine insieme all'Automated Scaling Listener si occupano di capire quando il traffico raggiunge la soglia stabilita e quindi quando allocare risorse aggiuntive.



I meccanismi utilizzati sono:


- Automated Scaling Listener
- Cloud Usage Monitor
- Hypervisor
- Logical Network Perimeter
- Pay-Per-Use Monitor
- Resource Replication, per aggiungere server e porte
- Virtual Server

13.2.2 Load Balanced Virtual Switches

I server virtuali sono collegati al mondo esterno tramite dei virtual switch, che inviano e ricevono dati. Ovviamente possono verificarsi rallentamenti dovuti a problemi di prestazioni, perdita di pacchetti, o lag time. L'architettura di Load Balanced Virtual Switches permette di bilanciare il carico tramite diversi uplink che distribuiscono il traffico di dati attraverso diversi path ridondanti, per evitare trasferimenti lenti di dati.


I virtual switch devono essere configurati per supportare diversi uplink fisici, che normalmente possono gestire diversi flussi di dati. I meccanismi utilizzati sono:

- Cloud Usage Monitor
- Hypervisor
- Load Balancer
- Logical Network Perimeter
- Resource Replication
- Virtual Server



13.2.3 Multipath Resource Access

Alcune risorse IT permettono l'accesso solo attraverso un percorso specifico o un hyperlink che punta alla loro locazione esatta. Questo link potrebbe essere perso dal consumer o cambiato dal provider, rendendo inaccessibile la risorsa e quindi non più disponibile. Il Multipath Resource Access permette di stabilire percorsi alternativi che puntano ad una stessa risorsa, in modo che il cloud consumer vi possa accedere con modalità diverse ed equivalenti. Questa architettura richiede l'utilizzo di un multipathing system e la creazione di hyperlink virtuali o fisici che siano assegnati alle risorse. Il multipathing system risiede sul server o su un hypervisor e controlla che ogni risorsa sia accessibile in modo equivalente da tutti i suoi hyperlink.




I meccanismi utilizzati sono:

- Cloud Storage Device
- Hypervisor
- Logical Network Perimeter, che garantisce la privacy del cloud consumer anche quando vengono creati percorsi aggiuntivi per una risorsa.
- Resource Replication
- Virtual Server

13.2.4 Persistent Virtual Network Configuration

La configurazione di rete e l'assegnamento delle porte per i virtual server viene generata durante la creazione dei virtual switch sul server fisico ospitante e sull'hypervisor. Queste configurazioni sono salvate nell'ambiente di hosting del virtual server, per cui se questo viene rilocato su un altro server fisico si verificano quasi sicuramente problemi di connessione dovuti alla non configurazione delle porte e delle informazioni di rete. Grazie alla Persistent Virtual Network Configuration, le informazioni di connessione sono salvate in una locazione centralizzata e replicate sui server fisici che fungono da host. In questo modo è possibile migrare un server virtuale verso un altro server fisico senza che ci sia la necessità di effettuare un'ulteriore configurazione.




I meccanismi utilizzati sono:

- Virtual server
- Hypervisor
- Logical Network Perimeter
- Resource Replication

13.2.5 Redundant Physical Connection for Virtual Servers

Come abbiamo visto in precedenza, un server virtuale si collega al mondo esterno tramite virtual switch collegati ad un uplink. Se l'uplink fallisce, il server diventa isolato e viene disconnesso dal mondo esterno. La Redundant Physical Connection for Virtual Servers permette di configurare più connessioni per diversi uplink e impostarne alcune in standby. In questo modo si crea un'architettura ridondante di uplink che permette ai server virtual di collegarsi velocemente ad un altro uplink nel caso quello primario fallisca.




I meccanismi utilizzati sono:

- Virtual Server
- Hypervisor
- Logical Network Perimeter, per assicurare che le connessioni ad un uplink di un consumer rimangano isolate dagli altri.
- Resource Replication

13.3 Learning Check

1. Descrivi l'obiettivo dell'architettura Direct I/O Access e spiega come fa sì che sia possibile l'accesso diretto a una scheda fisica di I/O da parte di un virtual server. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
2. Descrivi gli obiettivi dell'architettura Direct LUN Access e spiega come grazie ad essa è possibile che un virtual server acceda allo storage block-based delle LUN. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
3. Descrivi l'obiettivo dell'architettura Dynamic Data Normalization e spiega cos'è la de-duplicazione e come fa ad evitare l'archiviazione di dati ridondanti. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
4. Descrivi l'obiettivo dell'architettura Elastic Network Capacity e descrivi l'utilizzo dell'Automated Scaling Listener e degli script automatici. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.

5. Descrivi l'obiettivo dell'architettura Cross-Storage Device Vertical Tiering e spiega come realizza il vertical tiering con dispositivi di cloud storage con capacità differenti. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
6. Descrivi l'obiettivo dell'architettura Intra-Storage Device Vertical Tiering e spiega l'utilizzo relativo di diversi tipi di dischi. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
7. Descrivi l'obiettivo dell'architettura Load Balanced Virtual Switches e spiega come fa a fornire uplink multipli per scopi di bilanciamento del traffico di rete. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
8. Descrivi l'obiettivo dell'architettura Multipath Resource Access e spiega come il suo sistema di multipathing viene utilizzato per fornire percorsi di accesso alternativi alle risorse. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
9. Descrivi l'obiettivo dell'architettura Persistent Virtual Network Configuration e spiega l'utilizzo della VIM e di un virtual switch centralizzato per archiviare e rendere disponibili le configurazioni di rete dei virtual server. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
10. Descrivi l'obiettivo dell'architettura Redundant Physical Connection for Virtual Servers e spiega perché utilizza connessioni di rete a backup fisici. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.
11. Descrivi l'obiettivo dell'architettura Storage Maintenance Window e spiega il suo utilizzo del meccanismo della replicazione di risorse. Inoltre elenca i meccanismi del Cloud Computing utilizzati in questa architettura.



Capitolo 14


Microsoft Azure

In questi capitoli sarà presentato Azure, il cloud provider di Microsoft, cercando di affrontare aspetti generici dell'architettura ed esempi specifici. Azure, come tutti i cloud provider, è in perenne evoluzione e quindi risulta difficile possedere una conoscenza specifica di tutti i servizi che offre: Microsoft infatti mette a disposizione dei corsi per ottenere certificazioni di utilizzo del proprio provider. Lo scopo di questi capitoli è cercare di ottenere una visione d'insieme di tutta la piattaforma e delle tecnologie che attualmente Azure mette a disposizione, e di fare pratica su alcuni esempi specifici. Il materiale utilizzato dalle lezioni del prof. e in questi appunti è presente sulla piattaforma elearning di ateneo.

14.1 Introduzione

Azure è una piattaforma Cloud completa che permette di ospitare le applicazioni, gestire lo sviluppo e migliorare il rendimento delle risorse on-premise. Integra i servizi cloud necessari a sviluppare, testare e distribuire le applicazioni, ed ha come obiettivo quello di rendere possibile la scalabilità in base alle richieste dei cloud consumer. Azure offre la reliability necessaria a far sì che le applicazioni siano sempre disponibili e che siano funzionali in diverse regioni, il tutto grazie ad una gestione semplificata attraverso il portale web, ma anche attraverso le API e i template.

Azure offre diversi tipi di servizi che supportano lo sviluppo in qualsiasi direzione, coprendo quindi tutti i possibili modelli di deployment, da IaaS a FaaS (Function as a Service).



- Con IaaS è possibile ottenere il massimo del controllo sull'hosting dell'applicazione hostata su Azure;. Per quanto riguarda l'application hosting, è possibile fare il deploy di ambienti Windows e Linux, ed è possibile configurare la rete per supportare l'hosting di macchine virtuali Windows e Linux. Con IaaS è possibile configurare qualsiasi aspetto della VM: tutte le installazioni di software, manutenzione del sistema operativo e delle patch di sistema devono essere effettuate

manualmente. È possibile scegliere tra diversi servizi di server workload su Azure: database, Windows Server Active Directory e Microsoft SharePoint. **Azure Service Fabric** è una piattaforma distribuita che permette di realizzare con facilità l'intero ciclo di vita di un microservizio (build, package, deploy, gestione). Fornisce anche degli strumenti di gestione per il monitoring, l'aggiornamento e il patching delle applicazioni pubblicate. Il vantaggio di queste app è che è molto facile scalare in quanto sono in esecuzione su pool condivisi. Service Fabric supporta le WebAPI con interfaccia Open Web per .NET e ASP.NET Core e diversi SDK per costruire servizi su Linux sia in .NET che in Java.

- PaaS offre tutti i servizi necessari per far funzionare l'applicazione. Il vantaggio di Azure è l'integrazione con gli ambienti di sviluppo di Microsoft e con il sistema operativo e gli strumenti di Microsoft. **Azure App Service** è la maniera più semplice per pubblicare progetti web-based su REST API, fornisce l'autenticazione tramite social provider (Google, Facebook) e tutta una serie di feature per l'auto scaling, oltre che a strumenti per il testing in produzione e strumenti di supporto come ambienti di deployment basati su container. È possibile lavorare a tutti i livelli, quindi creare webapps, backend di applicazioni mobile o semplici API. Dato che tutti e tre i tipi di applicazioni condividono l'App Service Runtime, uno stesso progetto può gestire un sito web, supportare client mobile oppure esporre le proprie API su Azure. App Service è pensato per funzionare nativamente con DevOps, quindi offre supporto alle webhooks di GitHub, Jenkins, Azure DevOps, TeamCity e altri.
- FaaS permette l'esecuzione di codice in maniera efficiente e scalabile. Con Azure è possibile anche mettere su cloud solamente delle funzioni scritte in un certo linguaggio, ed evocarle in seguito a trigger o eventi, come richieste HTTP, webhooks o cloud service events, secondo il "serveless style". I linguaggi supportati sono C#, F#, Node.js, Python o PHP. Il serveless si paga solamente per il tempo di utilizzo.

In aggiunta all'hosting di applicazioni Azure mette a disposizione diversi servizi che migliorano il ciclo di vita di un'applicazione, tra cui:

- Accesso a storage e dati
- Supporto a Docker
- Autenticazione
- Monitoring (Pay-Per-Use Monitor, Audit Monitor, ecc.)
- Integrazione con DevOps

ACCESSO A STORAGE E DATI

Riguardo questa tipologia di servizi viene offerto **Azure Cosmos DB**: un database multimodello capace di scalare in maniera molto ampia su diverse regioni con un SLA estremamente ricco di vincoli che garantiscono l'affidabilità e le prestazioni di questo database. **Azure Storage** offre invece servizi di archiviazione per blob, oggetti e file non relazionali, e viene utilizzato per le VM. **Azure SQL Database** invece è una versione di Microsoft SQL Server basata su Azure per salvare dati in forma tabulare sul cloud con tutti i suoi benefici che conosciamo (prestazioni, scalabilità, no downtime e protezione dei dati). Il **Data Factory** di Azure permette di portare sul cloud le risorse on-premise o collegare i servizi presenti sul cloud con le risorse on-premise.

SUPPORTO A DOCKER

Un'applicazione *containerizzata* lavora allo stesso modo in sviluppo, in test e in produzione, questo grazie ai Docker tools. Azure mette a disposizione la **Docker VM extension** che permette di configurare una macchina virtuale con gli strumenti di Docker per renderla pronta per funzionare come

un host. **Azure Container Service** serve invece a creare, configurare e gestire un cluster di macchine virtuali preconfigurate per eseguire applicazioni basate su container. **Docker Machine** serve a installare e gestire un Docker Engine su macchine virtuali utilizzando una linea di comando. Il servizio che permette di ottenere file immagine di un Docker container e pubblicare l'immagine su Linux è **Custom Docker image for App Service**.

AUTENTICAZIONE

Per quanto riguarda l'autenticazione **Azure Active Directory** è il prodotto di punta di Microsoft, che fornisce servizi per autenticazione, controllo degli accessi e identità cloud. Con Azure AD è possibile aggiungere il Single-Sign On (SSO) alle applicazioni, grazie all'integrazione con provider esterni come OAuth 2.0, Open ID Connect e endpoint nativi HTTP/REST. Il supporto all'autenticazione nativo di Azure AD è chiamato **App Service Authentication**, e fornisce possibilità di autenticarsi con diversi provider, tra i quali ci sono Facebook, Google, Microsoft e Twitter.

MONITORING

Una delle cose più importanti che aumentano la qualità del servizio è l'integrazione di Azure con gli ambienti di sviluppo e in particolare con Visual Studio, grazie a **Visual Studio Application Insights**, che permette di monitorare tutte le componenti di applicazioni che riguardano progetti web-based e non solo. Grazie ad **Azure Monitor** è possibile visualizzare, gestire, archiviare e controllare le metriche e i log che sono generati dall'infrastruttura e dalle risorse.

INTEGRAZIONE CON DEVOPS


Azure fornisce l'integrazione con i più popolari strumenti per DevOps, come Jenkins, GitHub, Puppet, Chef, TeamCity, Ansible, Azure DevOps. Uno degli aspetti classici di Azure è fornire gli standard di riferimento ma fornire anche gli strumenti proprietari.

14.1.1 Regioni

Azure è disponibile in 54 regioni in tutto il mondo (2019). Quando un servizio/macchina virtuale/applicazione viene sviluppata sul cloud, è possibile selezionare una regione, che rappresenta lo specifico centro di calcolo (data center) dove l'applicazione sarà ospitata, così come i dati. Una regione è un insieme di centri di calcolo distribuiti in un perimetro definito in base alla velocità di connessione e connessi tramite una rete regionale a bassa latenza.

Una zona geografica (Geography) contiene due o più regioni che preservano la residenza dei dati e limiti di conformità. Sono molto utili per utenti con specifici vincoli di consistenza e residenza dei dati oppure che vogliono semplicemente che i propri dati siano ospitati in una regione vicina. Le zone geografiche sono resistenti ai fallimenti della regione in cui si trovano grazie a un'infrastruttura basata su connessioni ad alta velocità. Le **Availability Zones** sono posizioni separate fisicamente all'interno di una regione. Ogni AZ è composta da più datacenter provvisti di corrente elettrica indipendente, sistemi di raffreddamento e infrastrutture di rete, per permettere ad applicazioni critiche di poter funzionare sempre e comunque grazie ad un'alta availability e a una replicazione dei dati a bassa latenza.

Un importante vantaggio nell'utilizzo di Azure è quello di poter pubblicare le applicazioni in diversi datacenter contemporaneamente. La regione scelta influenza le prestazioni del servizio, in quanto la latenza di connessione aumenta con la distanza dai datacenter. Conviene per lo stesso motivo archiviare i dati dell'applicazione nello stesso datacenter dell'applicazione o in quello immediatamente vicino. È possibile inoltre distribuire un'app in più regioni per fornire massima disponibilità. I servizi VM e App Service usano **Azure Traffic Manager** per attivare il supporto multi-regione con resistenza ai fallimenti tra le regioni.



14.1.2 Gestione

Azure fornisce due modi per gestire le applicazioni e i servizi da riga di comando utilizzando Bash, il terminale o il prompt dei comandi: Azure CLI (Command-Line Interface) e Azure PowerShell. I servizi possibili sono gli stessi accessibili tramite il portale web. Questo portale è utilizzato per creare e gestire le risorse e i servizi su Azure, e vi si può accedere all'indirizzo <https://portal.azure.com>. Azure è costruito su un insieme di REST API che supportano l'interfaccia del portale web. La maggior parte di queste API sono supportate anche per gli utenti di Azure, per fornire e gestire le proprie risorse da qualsiasi dispositivo con accesso a internet. Inoltre include SDK specifici per le piattaforme, tra cui .NET, Node.js, Java, PHP, Python, Ruby, Go. Per lo sviluppo mobile invece fornisce SDK lato client per accedere ai servizi dal web e dalle app mobile.

Normalmente un'applicazione hostata su Azure accede a più servizi, ognuno dei quali segue lo stesso ciclo di vita e può essere pensato come un'unità logica. L'Azure Resource Manager permette di lavorare con le risorse di un'applicazione come se fossero un gruppo: è possibile pubblicare, aggiornare o eliminare tutte le risorse in una singola operazione coordinata. Il template di Azure Resource Manager non è altro che un file JSON: in questo modo è più leggero e più semplice rispetto agli scripts lavorare su risorse eterogenee.

14.1.3 Accounting

Per lavorare con i piani di abbonamento di Azure è necessario creare un account, la cui identità è salvata nella Azure Active Directory, che comprende vantaggi per organizzazioni, organi scolastici e accademici che sono *trusted* da Azure AD. Viene utilizzata in quanto crea una sorta di relazione di fiducia con le componenti presenti al suo interno, per migliorare sicurezza e autenticazione. È possibile anche creare dei gruppi in una directory utilizzando un accesso basato su ruoli (RBAC - Role-Based Access Control).

Una **subscription** è un raggruppamento logico di servizi di Azure che sono legati ad un account. Un singolo account può contenere molteplici subscriptions, e la fatturazione viene fatta sulla base delle subscription. Ogni subscription ha un Account Administrator che ha il controllo totale su di essa, e un Service Administrator, che ha il controllo sui servizi della subscription.

Ogni servizio che viene creato da Azure viene fornito in una data subscription. I servizi individuali, chiamati anche *resources*, sono creati nel contesto di un **resource group**. I resource groups rendono più semplice il deploy e la gestione delle risorse di un'applicazione: un gruppo contiene tutte le risorse disponibili per lavorare come una singola entità. Ovviamente è possibile spostare le risorse tra

resource groups e anche tra diverse subscriptions. **Azure Resource Explorer** è il tool per visualizzare le risorse presenti in una data subscription.

Normalmente è possibile garantire l'accesso agli user account per un preciso scopo: subscription, resource group oppure risorse individuali. Grazie al RBAC è possibile distribuire una serie di risorse in un resource group e fornire accesso solo a determinati utenti o gruppi, così come è possibile assegnare l'accesso a risorse singole come macchine virtuali o virtual network. C'è una serie predefinita di ruoli, ma è possibile crearne di nuovi e personalizzarli. Quando il codice necessita di accedere o di modificare le risorse, è possibile identificare l'applicazione come **Service Principal Object**.

Per tenere sotto controllo i costi di ogni servizio utilizzato, Azure mette a disposizione una serie di REST API per la fatturazione che danno accesso ai dati sul consumo di risorse e ai metadati per le subscription.

14.1.4 Cenni storici

All'inizio degli anni 2000, quando Microsoft Azure era nel pieno dello sviluppo e il suo nome in codice era *Project Red Dog*, la gara del cloud computing era già iniziata in quanto Amazon aveva già lanciato il suo AWS. Nel 2008 fu annunciato il servizio cloud di Microsoft, che comprendeva cinque servizi chiave: Windows Azure, Microsoft .NET services, Live services, Microsoft SQL services, e Microsoft Sharepoint services & Dynamics CRM services. Windows Azure arrivò ufficialmente sul mercato a febbraio 2010. Solo nel 2014 il servizio fu rinominato in **Microsoft Azure**. L'anno dopo furono introdotte le distribuzioni cross-platform con Linux grazie ad Azure Cloud Switch. Attualmente Azure offre più di 600 servizi.

14.2 Fundamentals

Per chi possiede un business una difficoltà che spesso si presenta è quella dei clienti che potrebbero subire problemi di connessione quando si accede ai servizi da distanze importanti. Questo problema è difficile da risolvere senza cloud.

Microsoft Azure fornisce un'infrastruttura reliable, sempre disponibile ed efficiente che è formata da centri di calcolo e di archiviazione dati in tutto il mondo, dove ogni nodo è collegato agli altri con connessioni ad alta velocità e bassa latenza, per assicurare sempre le migliori prestazioni.

14.2.1 Architecture

Le risorse fisiche di Azure sono rappresentate dai centri di calcolo sparsi per il mondo. Questi non sono esposti agli utenti direttamente ma sono organizzati in regioni. Una regione è un'area geografica che contiene uno o più datacenter che sono collegati da una rete a bassa latenza. Azure assegna e controlla le risorse tra i vari datacenter per assicurarsi che i carichi di lavoro siano bilanciati. Quando una risorsa viene caricata su Azure, è possibile scegliere la regione nella quale la risorsa sarà pubblicata: alcuni servizi o opzioni sono disponibili solo in particolari regioni, come ad esempio AC, DNS e Traffic Manager. Alcuni esempi di regioni sono West US, Canada Central, West Europe, Australia East, Japan West. Le regioni servono anche per definire i confini giurisdizionali delle regole imposte da Azure in quella specifica regione. Ci sono poi regioni speciali: US DoD Central, US Gov Virginia e US Gov Iowa sono istanze isolate utilizzate dal governo statunitense e loro partner. Le regioni China East, China North ed altre regioni asiatiche sono disponibili grazie ad una partnership tra Microsoft e 21Vianet, la quale si occupa della loro manutenzione.

Azure divide il pianeta in Geografie che sono definite da confini geopolitici o confini tra paesi. I vantaggi delle geografie sono:

- gli utenti con specifici requisiti di residenza e conformità dei dati possono tenere vicine le loro applicazioni e i loro dati;

- la resistenza ai fallimenti è possibile grazie alla potente rete di comunicazione intraregionale e interregionale.

Le Geografie si dividono nelle seguenti aree: Americhe, Europa, Asia Pacifica, Medio Oriente e Africa. Ogni regione appartiene ad una singola geografia e ha specifici disponibilità di servizi.

Le Availability Zones invece rappresentano la divisione tra i datacenter in una stessa regione. Ogni AZ è formata da uno o più datacenter. Se una AZ fallisce, le altre continuano a funzionare. Le seguenti aree posseggono almeno 3 AZ: Central US, East US 2, West US 2, West Europe, France Central, North Europe, Southeast Asia. I servizi di Azure che supportano le AZ si dividono in due categorie:

- **Zonal services:** la risorsa viene fissata in una specifica zona (per esempio VM, dischi o indirizzi IP);
- **Zone-redundant services:** la piattaforma viene replicata automaticamente tra le zone (per esempio SQL database).

Ogni regione di Azure è accoppiata con un'altra regione nella stessa geografia ma almeno a 300 miglia di distanza. Questo è utile perché permette ai dati e alle applicazioni di continuare a funzionare anche in caso di disastri naturali, guerre civili, interruzioni di corrente elettrica che colpiscono più territori. Alcuni esempi di coppie: West US - East US, Southeast Asia - East Asia.

14.2.2 Service Management

I Service Level Agreements emessi da Azure hanno tre caratteristiche chiave:

- **Performance Targets** - specifici per ogni servizio o prodotto di Azure, ad esempio i tempi di uptime garantiti in base alle connessioni.
- **Uptime and Connectivity Guarantees** - misurazioni basate sulla qualità delle prestazioni, da 99.9% ("three nines") fino a 99.999% ("five nines").
- **Service Credits** - i SLA descrivono anche le situazioni in caso di fallimento di un prodotto o un servizio, tipicamente sconti applicati alla fatturazione periodica.

Un esempio è il SLA per Azure Cosmos DB che offre il 99.999% di uptime, che include connessione a bassa latenza e operazioni di lettura e scrittura su database che impiegano max 10 ms.

14.2.3 Login

Esistono due modi per entrare in Azure:

- **Azure for Students:** 100\$ di crediti, registrazione senza carta di credito, all'indirizzo <https://azure.microsoft.com/it-it/free/students/>
- **Azure Free:** 200\$ di crediti, ma carta di credito necessaria, all'indirizzo <https://azure.microsoft.com/it-it/free/>

Oltre a strumenti classici come dashboard personalizzate, ci sono strumenti più interessanti: un esempio è l'Advisor, che suggerisce una serie di attività in base alla subscription corrente per aumentare la sicurezza, la disponibilità delle risorse e ridurre i costi.

14.3 Basics

I servizi fondamentali di ogni sistema informatico sono calcolo, storage e rete. Senza questi servizi nessun cloud provider può definirsi completo.

14.3.1 Compute Options

Azure Compute è il servizio on-demand che serve per eseguire applicazioni cloud-based. Si va da macchine virtuali di piccole dimensioni a veri e propri supercomputer, oppure a container. Offre inoltre anche la possibilità di serverless computing per eseguire applicazioni senza richiedere particolari infrastrutture o configurazioni. Le risorse sono disponibili on-demand e possono essere create solitamente in pochi minuti o addirittura secondi. Come al solito si paga solo per quello che si usa. Le quattro modalità attraverso cui Azure fornisce capacità di calcolo sono:

- macchine virtuali;
- containers;
- Azure App Service;
- serverless computing.

MACCHINE VIRTUALI

Le macchine virtuali, come sappiamo bene, sono emulazione software di macchine fisiche: includono un processore virtuale, memoria RAM, archiviazione di massa e risorse di rete. Ospitano un sistema operativo che funziona in modo identico a come se fosse installato su una macchina fisica. Utilizzando un client per la connessione desktop remota, una macchina virtuale può essere utilizzata come se l'utente ci fosse seduto davanti.


Le macchine virtuali di Azure vengono distribuite con modello IaaS e permettono diverse configurazioni, dal controllo totale sul sistema operativo all'utilizzare soluzioni preconfigurate. I costi da affrontare oltre a quelli espliciti per la macchina virtuale sono quelli per la manutenzione della stessa. È possibile accedere ad una macchina virtuale in pochi secondi a partire da una lista di VM preconfigurate. Le macchine virtuali sono utili in diverse situazioni:

- **Durante il testing e lo sviluppo** - le VM forniscono un modo semplice e veloce per creare configurazioni diverse di sistemi operativi ed applicazioni. Le VM possono essere eliminate facilmente quando non servono più.
- **Durante l'esecuzione di applicazioni sul cloud** - la possibilità di eseguire applicazioni su cloud anziché creare infrastrutture on-premise apposta può far diminuire i costi di gestione. Ad esempio applicazioni che scalano automaticamente possono in pochi secondi accendere e spegnere nuove macchine virtuali senza grosse modifiche ai costi.
- **Per estendere il centro di calcolo sul cloud** - un'azienda può estendere le funzionalità delle sue risorse on-premise creando un virtual network su Azure e aggiungendo le VM alla rete. Le applicazioni come Sharepoint vengono eseguite sulle macchine virtuali piuttosto che localmente. È possibile anche creare l'immagine di un server fisico e renderlo virtuale caricandola sul cloud.
- **Durante un disaster recovery** - utilizzando un approccio basato su IaaS c'è un importante risparmio sulle spese.

La scalabilità delle macchine virtuali è fondamentale per poter soddisfare tutti i requisiti richiesti. Le funzionalità che propone Azure sono **availability sets** e **virtual machine scale sets**.

Un **availability set** è un raggruppamento logico di due o più macchine virtuali che aiutano a mantenere l'applicazione disponibile durante la manutenzione, la quale viene effettuata direttamente da Azure per correggere bug o applicare patch di sicurezza, e spesso richiede un reboot della macchina. Per le VM che fanno parte di un gruppo di disponibilità le manutenzioni sono schedate in modo che le macchine non si riavviano mai nello stesso momento. Nel caso di eventi di manutenzione non pianificati potrebbero facilmente verificarsi fallimenti hardware nel datacenter. Gruppi di VM che

condividono lo stesso hardware sono posti in uno stesso fault domain. Un fault domain è un rack di server che forniscono la separazione fisica del carico di lavoro attraverso diverse componenti hardware che supportano i server fisici. Con un availability set, un cliente ottiene fino a tre fault domains ognuno dei quali ha un rack di server con elettricità dedicata e risorse di rete. I clienti piazzano ogni carico di lavoro in un availability set per evitare single point of failure, come mostrato di seguito.



Grazie ai **Virtual Machine scale sets** è possibile creare e gestire insiemi di VM identiche e già bilanciate. Con i duplicati di macchine virtuali gli utenti devono configurare un servizio aggiuntivo per instradare le richieste tra istanze multiple dell'applicazione: il Virtual Machine scale sets può fare questo lavoro automaticamente.

CONTAINERS

Un container è un ambiente di virtualizzazione per applicazioni in esecuzione. Anch'essi, come le macchine virtuali, eseguono su un sistema operativo host, ma a differenza delle VM non utilizzano un sistema operativo per le app che sono in esecuzione al loro interno. I container utilizzano pacchetti di librerie e componenti necessari ad eseguire l'applicazione e il sistema operativo che esegue il container.

Azure Batch permette di effettuare scheduling di operazioni a larga scala per la gestione di centinaia di macchine virtuali contemporaneamente. I task che può effettuare Azure batch sono:

- avvio di un pool di VM;
- installazione di applicazioni e dati;
- identificazione di fallimenti;
- scaling del pool di risorse.

I servizi di containerizzazione di Azure si dividono in **Azure Container Instances**, servizi PaaS che offrono la possibilità di caricare le proprie applicazioni containerizzate con scaling automatico, e **Azure Kubernetes Service**, servizio di distribuzione completo per container o per architetture che contengono più container.

Kubernetes monitora le richieste delle applicazioni e scala di conseguenza grazie a servizi e ad API messe a disposizione degli utenti: l'infrastruttura è divisa in *Pods*: un pod rappresenta un Kubernetes cluster node, formato da più container, in questo modo è resistente ai fallimenti e gestisce i dati contenuti nel container automaticamente. Il traffico di rete è bilanciato tra i pod e limitato in base alle policy stabilite. I container aiutano a costruire architetture a microservizi.

È possibile migrare le applicazioni su container tramite AKS. Il controllo degli accessi avviene tramite Azure Active Directory e servizi di controllo degli SLA, tramite Open Service Broker for Azure. Gli step sono i seguenti:

- Convertire un'applicazione esistente in uno o più container e pubblicare una o più immagini dei container nell'Azure Container Registry.
- Utilizzando il portale Azure o tramite riga di comando, distribuire i container in un cluster AKS.
- Azure AD controlla l'accesso ai cluster AKS.
- L'accesso ai servizi SLA viene gestito da OSBA.
- Opzionalmente, AKS può essere distribuito con un virtual network.

AZURE APP SERVICE

È una piattaforma PaaS progettata per ospitare applicazioni web-oriented di grado enterprise. Permette di soddisfare requisiti rigorosi di performance, scalabilità, sicurezza e conformità, utilizzando una piattaforma completamente gestita per la manutenzione dell'infrastruttura.

Azure App Service permette di sviluppare e distribuire applicazioni web, servizi background, backend e REST API in qualsiasi linguaggio di programmazione senza dover gestire l'infrastruttura. Supporta sia Windows che Linux, e permette deployment automatici da GitHub, Azure DevOps, e qualsiasi repository git. Questo modello PaaS permette ai clienti di focalizzarsi sul proprio sito e la logica delle API mentre Azure si occupa della parte dell'infrastruttura. Azure App Service gestisce la maggior parte delle decisioni infrastrutturali da prendere quando si ospitano le applicazioni sul cloud. Il deployment e la gestione sono integrate nella piattaforma, così come la sicurezza degli endpoint. Sono già integrate soluzioni di scaling automatico e load balancing. Può essere distribuito quasi ogni tipo di applicazione:

- **Web Apps:** ASP.NET, ASP.NET Core, Java, Ruby, Node.js, PHP, Python.
- **API Apps:** REST-based web API utilizzando qualsiasi linguaggio.
- **Webjobs:** avvio di programmi o di script con funzionamento uguale ad un'applicazione o avvio schedulato.
- **Mobile Apps:** backend per app Android/iOS.

SERVERLESS COMPUTING

Il serverless computing è un ambiente di esecuzione ospitato sul cloud che esegue codice completamente indipendente dall'ambiente di host. Non è necessaria e non è permessa alcuna configurazione o manutenzione.

Grazie al **serverless computing** Azure si preoccupa di gestire le infrastrutture dei server e l'allocazione/deallocazione delle risorse basate sulla domanda: l'infrastruttura non è più un problema del consumer. Lo scaling e le prestazioni sono gestite automaticamente e la fatturazione viene fatta solo per le risorse utilizzate. Ci sono tre idee: astrazione dei server, scaling guidato dagli eventi e microfatturazione.

L'idea di carichi di lavoro che si attivano con gli eventi funziona in quanto un evento può essere rappresentato con un trigger o con un timer, ad esempio un blocco di codice che deve essere eseguito ogni giorno a un determinato orario. Anziché scrivere un intero programma lo sviluppatore deve soltanto scrivere una funzione e stabilire dei trigger, e la piattaforma schedulerà automaticamente l'esecuzione della funzione e scalerà o meno in base alle richieste che arriveranno.

La microfatturazione è estremamente importante nel serverless computing in quanto non si va a pagare tutta l'infrastruttura ma si paga solo per quei pochi minuti o secondi in cui la funzione è in esecuzione. Se la funzione non viene chiamata da nessuno, non bisogna pagare.

Il serverless computing in Azure viene implementato in due modi diversi:

- con le **Azure Functions**, che possono eseguire codice in qualsiasi linguaggio di programmazione moderno.
- con le **Azure Logic Apps**, che sono progettate sulla base di applicazioni web-based e permettono di eseguire funzioni attivate da servizi di Azure senza scrivere una riga di codice.

Le Azure Functions sono molto utili quando il servizio risiede nell'esecuzione di codice e non dipende da una particolare infrastruttura. Possono rispondere in pochissimo tempo e rispondono ad eventi via timer, via REST, o via messaggi da altri servizi Azure. Permettono di essere cost-effective perché le risorse vengono utilizzate solo quando le funzioni vengono chiamate, dopodiché vengono deallocate. Le Azure Functions possono essere stateless (di default) oppure stateful (dette anche **Durable Functions**), dove un contesto viene passato attraverso la funzione per tracciare l'attività principale. Le Azure Logic Apps sono simili alle Funzioni, entrambi vengono attivati da eventi, ma mentre le Funzioni eseguono codice le Logic Apps eseguono dei flussi di lavoro progettati per automatizzare degli scenari di business costruiti ad hoc da interazioni predefinite. La creazione di Logic Apps può avvenire tramite un visual designer sul portale di Azure o in Visual Studio. I workflow sono salvati in file JSON.

	Power Automate	Logic Apps	WebJobs	Azure Functions
Target Audience	Office/Business Users	IT Professionals/Developers	Developers	Developers
Autoscale	Yes	Yes	w/ App Service Plan	Yes
Pricing	Free/\$5 (Plan 1)/\$15 (Plan 2) per user and month	Per Action	App Service Plan	Per use of App Service Plan
Trigger Events	100+	100+	4	9
Supported Programming Languages	n/a	n/a	8	C#, F#, Node.js

14.3.2 Data Storage Options

Archiviare i propri dati su Azure ha una serie di benefici, tra cui:

- **backup e ripristino automatici:** mitigano il rischio di perdere i dati a causa di fallimenti o interruzioni.
- **duplicazione in tutto il mondo:** vengono effettuate delle copie in modo da proteggere i dati da qualsiasi tipo di errore o disastro.
- **supporto all'analisi dei dati**
- **supporto alla crittografia**
- **tipi di dati multipli:** Azure può salvare quasi tutti i tipi di dati esistenti, video, immagini, file di testo o file binari di grandi dimensioni, e supporta DMBS e database NoSQL.
- **Archiviazione di dati in dischi virtuali:** è possibile salvare i dati fino a 32 TB in dischi virtuali, utili nel caso di file molto pesanti o di simulazioni di modelli 3D.
- **Dato strutturati e semi-strutturati:** un dato viene chiamato strutturato quando è conforme a un determinato schema, ovvero quando due dati diversi hanno le stesse proprietà o campi. I dati strutturati si trovano ad esempio in un database fatto di righe e colonne. I dati semistruutturati non seguono tutti lo stesso schema e spesso vengono utilizzati per definire una gerarchia di dati. Ci si riferisce ai dati strutturati anche come dati non relazionali.

Azure SQL Database è un DaaS (Database as a Service) basato sulla versione più recente di Microsoft SQL Server Database. Ha prestazioni molto elevate e un livello di sicurezza alto. È possibile migrare database SQL Server già esistenti su Azure database in pochissimo tempo, grazie all'assistente di migrazione di Microsoft.

Azure Cosmos DB è un servizio distribuito di database che supporta dati non strutturati e permette quindi di costruire applicazioni always on che hanno la capacità di visualizzare dati che cambiano continuamente.

Azure Blob Storage è un servizio di archiviazione che supporta dati non strutturati: i blob sono facilmente scalabili e le applicazioni lavorano con essi pressoché allo stesso modo di come lavorano con i dati su un disco, con le normali operazioni di lettura e di scrittura. Può gestire migliaia di upload simultanei, log che crescono costantemente e vi si può accedere da qualsiasi locazione a patto di avere una connessione ad Internet. Un blob può contenere GB di dati binari e può rappresentare qualsiasi tipo di dato. I blob vengono utilizzati anche per salvare i backup in caso di disaster recovery e per l'archiviazione. Ogni macchina virtuale può salvare circa 8 TB di dati in formato blob.

Azure Files offre un servizio di gestione file nel cloud accessibile via il protocollo standard Server Message Block (SMB), che assicura anche che i dati siano criptati. Le applicazioni che sono in esecuzione su Azure condividono un file share per accedere ai dati. È molto utile per condividere file ovunque nel mondo.

Azure Queue Storage è un servizio per archiviare un grande numero di messaggi a cui vi si può accedere in qualsiasi momento. Può essere utilizzato per costruire applicazioni flessibili e funzioni separate per aumentare la durabilità delle componenti con carichi di lavoro molto elevati. Le componenti con basso accoppiamento in un'applicazione possono scalare indipendentemente una dall'altra. Azure Queue Storage fornisce un sistema a coda asincrona di messaggi per le comunicazioni tra le componenti delle applicazioni, a prescindere se queste siano in esecuzione sul cloud oppure on-premise.

Azure Disk Storage fornisce i dischi per le macchine virtuali, per le applicazioni e per altri servizi che necessitano di spazio di archiviazione. Permette di archiviare permanentemente i dati e di accedervi ogni qualvolta ce ne sia bisogno. I dischi possono essere gestiti sia dall'utente che direttamente da Azure. I dischi vengono forniti in diverse dimensioni e livelli di performance, da dischi a stato solido (SSD) a classici hard disk (HDD).

Needs	On-premise	Azure Data Storage
 Compliance and Security	1 Dedicated servers required for privacy and security	Client side encryption and encryption at rest
 Store structured and unstructured data	2 Additional IT resources with dedicated servers required	Azure Data Lake and portal analyzes and manages all types of data
 Replication and High Availability	3 More resources, licensing, and servers required	Built-in replication and redundancy features available
 Application sharing and access to shared resources	4 File sharing requires additional administration resources	File sharing options available without additional license
 Relational Data storage	5 Needs a database server with database admin role	Offers Database-as-a-Service option
 Distributed storage and data access	6 Expensive storage, networking, and compute resources needed	Azure Cosmos DB provides price-winning distributed access
 Messaging and load balancing	7 Hardware redundancy impacts budget and resources	Azure Queue provides effective load balancing
 Tiered storage	8 Management of tiered storage needs technology and labor skillset	Azure offers automated tiered storage of data

14.3.3 Networking Options

Quando si parla di availability per un sito, ci si riferisce a quanto tempo il servizio riesce ad essere in esecuzione senza essere interrotto. High availability, quindi alta disponibilità, indica un servizio che esegue da molto tempo senza fermarsi. Con resilienza intendiamo l'abilità di un sistema di essere attivo durante condizioni anormali (disastri naturali, manutenzioni di sistema, picchi nel traffico). Un load balancer distribuisce il traffico attraverso i vari sistemi presenti in un pool di risorse: il suo scopo è quello di raggiungere un'alta disponibilità e una forte resilienza. **Azure Load Balancer** supporta bilanciamento del traffico in uscita e in entrata del sistema, fornisce bassa latenza e altro throughput, e scala milioni di flussi per tutte le trasmissioni che avvengono tramite TCP e UDP. La cosa più importante è che non occorre alcuna infrastruttura o software per la manutenzione.

Application Gateway è un load balancer progettato per le applicazioni web. Il bilanciamento del traffico a livello 7 della pila ISO/OSI offre una serie di vantaggi:

- **Cookie affinity:** per mantenere attiva la sessione dell'utente sullo stesso server.
- **SSL termination:** gestisce i certificati SSL e passa il traffico non criptato ai server di backend per evitare un overhead dovuto alla cifratura e alla decifratura dei messaggi. Supporta anche la crittografia end-to-end per le applicazioni che la richiedono.
- **Web Application Firewall (WAF):** monitora dettagliatamente i tentativi di attacchi al sistema e li salva nei log.
- **URL rule-based routes:** instradamento del traffico basato su pattern URL, con indirizzo IP di partenza, di destinazione, e porta. Molto utile quando si installa un Content Delivery Network.

14.4 Learning Check

1. Cos'è Microsoft Azure?
2. Quali sono i servizi offerti per l'hosting di applicazioni?
3. Quali sono i servizi offerti per il data storage?
4. Qual è lo scopo di avere diverse regioni/geografie/availability zones?
5. Come possono essere gestiti i servizi?
6. Per ogni servizio fornito da Azure (inclusi la gestione, la fatturazione, ecc.) fornisci un collegamento con le architetture viste nelle lezioni precedenti.