



DISCLAIMER

Il materiale contenuto nel drive è stato raccolto e richiesto tramite autorizzazione ai ragazzi frequentanti il corso di studi di Informatica dell'Università degli Studi di Salerno. Gli appunti e gli esercizi nascono da un uso e consumo degli autori che li hanno creati e risistemati per tanto non ci assumiamo la responsabilità di eventuali mancanze o difetti all'interno del materiale pubblicato.

Il materiale sarà modificato aggiungendo il logo dell'associazione, in tal caso questo possa recare problemi ad alcuni autori di materiale pubblicato, tale persona può contattarci in privato ed elimineremo o modificheremo il materiale in base alle sue preferenze.

Ringraziamo eventuali segnalazioni di errori così da poter modificare e fornire il miglior materiale possibile a supporto degli studenti.



CoScienze
Associazione


“Cloud Computing Concepts Technology & Architecture” e “Cloud Computing Ruparella”

Traduzione e Riassunto dei capitoli



Indice

Origins, Basic Concepts and Terminology.....	3
Cloud Fundamentals	11
Key Technologies	18
Price Models	25
Value Models	29
Cloud: A Paradigm Shift	34
Cloud Security	38
Cloud Infrastructure Mechanisms	45
Specialized Cloud Mechanisms	52
Other Cloud Mechanisms	60
Fundamental Cloud Architectures	70
Advanced Cloud Architectures	77
Specialized Cloud Architectures	88



CoScienze
Associazione

Lezione - Origins, Basic Concepts and Terminology

Una Breve Storia...

L'idea di calcolare in una "nuvola" risale alle origini dell'utilità informatica, un concetto che lo scienziato informatico John McCarthy ha pubblicamente proposto nel 1961: "Se i computer del tipo che ho sostenuto diventano i computer del futuro, allora il computer potrebbe un giorno essere organizzato come un servizio pubblico così come il sistema telefonico è un servizio pubblico. ... il calcolo può essere utilizzato come una utility, come risorsa disponibile per le persone. ". Nel 1969, Leonard Kleinrock, uno scienziato capo della ricerca avanzata Projects Agency Network e progetto ARPANET ha dichiarato: "A partire da ora, le reti di computer sono ancora agli inizi, ma come loro crescere e diventare sofisticati, probabilmente vedremo la diffusione di "Utilità per computer". Kleinrock vedeva ARPANET come un qualcosa che servisse allo spreading delle computer utilities, con delle possibilità di accedere a risorse di calcolo come se fossero gestite da una rete di distribuzione. Il pubblico in generale ha sfruttato utilità di Internet per computer dalla metà degli anni '90 attraverso varie incarnazioni di motori di ricerca (Yahoo!, Google), servizi di posta elettronica (Hotmail, Gmail), aperti piattaforme di pubblicazione (MySpace, Facebook, YouTube) e altri tipi di file social media (Twitter, LinkedIn). Sebbene incentrati sul consumatore, questi servizi hanno reso popolari e hanno convalidato i concetti fondamentali che costituiscono la base del cloud computing moderno. Alla fine degli anni '90, Salesforce.com ha aperto la strada al concetto di portare servizi forniti in remoto nell'azienda. Nel 2002 Amazon.com ha lanciato la piattaforma Amazon Web Services (AWS), una suite di servizi orientati all'azienda che forniscono storage con provisioning remoto, risorse di calcolo e funzionalità aziendali. Un'evocazione leggermente diversa del termine "Network Cloud" o "Cloud" è stato introdotto all'inizio degli anni '90 in tutto il settore delle reti IT riferito a un livello di astrazione derivato nei metodi di consegna dei dati attraverso reti pubbliche e semi-pubbliche eterogenee che erano principalmente a commutazione di pacchetto, sebbene le reti cellulari utilizzassero il "Cloud" anche il termine. Il metodo di rete a questo punto supportava la trasmissione dei dati da un endpoint (rete locale) al "Cloud"(Wide Area Network) e poi ulteriormente scomposto in un altro previsto punto finale. Ciò è rilevante, poiché l'industria del networking fa ancora riferimento a uso di questo termine ed è considerato uno dei primi a adottare i concetti che alla base dell'utility computing. È stato fino al 2006 che il termine "cloud computing" è emerso nell'arena commerciale. È stato durante questo periodo che Amazon ha lanciato il suo Servizi Elastic Compute Cloud (EC2) che hanno consentito alle organizzazioni di "Affittare" capacità di elaborazione e potenza di elaborazione per gestire la propria azienda applicazioni.

Definizioni

Gartner, leader di mercato nell'ambito delle analisi di mercato, definisce il cloud mettendo il focus su scalabilità ed elasticità, abilità dell'Information Technology recapitate come servizio a customer esterni all'organizzazione usando la tecnologia di internet. Questa è una leggera revisione della definizione originale di Gartner del 2008, dove "massicciamente scalabile" è stato utilizzato invece di "scalabile ed elastico". Ciò riconosce l'importanza della scalabilità in relazione all'abilità per scalare verticalmente e non solo per proporzioni enormi. Forrester Research ha fornito la propria definizione di cloud computing come: "... una capacità IT standardizzata (servizi, software o infrastruttura) forniti tramite tecnologie Internet in modalità pay-per-use, cioè la possibilità di accedere pagando per l'uso che se ne fa delle risorse e non per l'accesso o acquisto di una risorsa. Altro aspetto molto importante è il self-service, cioè i servizi di cloud non sono forniti con interventi manuali o di operatori, ma servizi

in maniera significativa con modalità di self-service dove è l'utente stesso che fa configurare i propri servizi. La definizione che ha ricevuto l'accettazione a livello di settore è stata composta dal National Institute of Standards and Technology (NIST). NIST ha pubblicato la sua definizione originale nel 2009, seguita da una versione rivista versione dopo un'ulteriore revisione e input del settore pubblicato nel settembre del 2011: "Il cloud computing è un modello per abilitare l'accesso via rete onnipresente, conveniente, on-demand, con accesso di rete a un pool condiviso di elaborazione configurabile di risorse (ad es. reti, server, archiviazione, applicazioni e servizi) che può essere rapidamente fornito e rilasciato con un minimo di sforzo di gestione o interazione con il fornitore di servizi. Questo modello cloud è composto da cinque caratteristiche essenziali, tre modelli di servizio e quattro modelli di implementazione.

Il cloud computing è una forma specializzata di elaborazione distribuita che introduce modelli di utilizzo per il provisioning remoto scalabile e risorse misurate.

Business Innovations

Molti dei principali driver di business che hanno promosso la moderna tecnologia basata su cloud è presentata in questa sezione. I drivers hanno motivato le organizzazioni a adottare il cloud computing a sostegno dei loro requisiti di automazione aziendale. Loro hanno di conseguenza motivato altre organizzazioni a diventare fornitori di ambienti cloud e fornitori di tecnologia cloud per creare e soddisfare la domanda e soddisfare le esigenze dei consumatori. I Drivers di business sono:

- **Capacity Planning:** è il processo per determinare e soddisfare le esigenze future di risorse, prodotti e servizi IT di un'organizzazione. In questo contesto, la capacità rappresenta la quantità massima di lavoro che una risorsa IT è in grado di fornire in un determinato periodo di tempo. Una discrepanza tra la capacità di una risorsa IT e la sua domanda può comportare che un sistema diventi inefficiente (over-provisioning) o incapace di soddisfare le esigenze degli utenti (under-provisioning). Capacity Planning è incentrato sulla riduzione al minimo di questa discrepanza per ottenere un'efficienza prevedibile. Esistono diverse strategie di Capacity planning:

- **Lead- Strategy:** aggiungere la capacità in anticipo della richiesta
- **Lag Strategy:** aggiungere la capacità quando si arriva al massimo della richiesta
- **Match Strategy:** aggiungere la capacità con piccoli incrementi

La Capacity Planning può essere impegnativa perché richiede la stima delle fluttuazioni del carico di utilizzo. Vi è una costante necessità di bilanciare i requisiti di utilizzo massimo senza spese eccessive per l'infrastruttura. Un esempio è l'allestimento dell'infrastruttura IT per soddisfare i carichi di utilizzo massimi che possono imporre investimenti finanziari irragionevoli. In tali casi, la moderazione degli investimenti può comportare un insufficiente approvvigionamento, portando a perdite di transazioni e altre limitazioni di utilizzo dovute a soglie di utilizzo ridotte.

- **Cost Reduction:** Un allineamento diretto tra i costi IT e le prestazioni aziendali può essere difficile da mantenere. La crescita degli ambienti IT spesso corrisponde alla valutazione dei loro requisiti di utilizzo massimo. Ciò può rendere il supporto di automazioni aziendali nuove e ampliare un investimento sempre maggiore. Gran parte di questo investimento richiesto viene incanalato nell'espansione dell'infrastruttura perché il potenziale di utilizzo di una data soluzione di automazione sarà sempre limitato dalla potenza di elaborazione della sua infrastruttura sottostante. È necessario tenere conto di due costi:

- **Costo Capitale:** il costo per l'acquisizione di nuova infrastruttura e il costo della sua proprietà in corso.
- **Costo Operativo:** le spese generali rappresentano una quota considerevole dei budget IT, spesso superando i costi di investimento iniziali per via di: Personale tecnico richiesto per mantenere l'ambiente operativo, Aggiornamenti e patch per ulteriori cicli di test e

implementazione, Spese in conto capitale per utenze e investimenti, Sicurezza di alimentazione e raffreddamento ecc...

- **Organizational Agility:** Le aziende hanno bisogno della capacità di adattarsi ed evolversi per affrontare con successo il cambiamento causato da fattori sia interni che esterni. L'agilità organizzativa è la misura della reattività di un'organizzazione al cambiamento. Un'azienda IT spesso ha bisogno di rispondere ai cambiamenti aziendali ridimensionando le proprie risorse IT oltre l'ambito di ciò che era stato previsto o pianificato in precedenza. Ad esempio, l'infrastruttura può essere soggetta a limitazioni che impediscono all'organizzazione di rispondere alle fluttuazioni di utilizzo, anche se previste, se i precedenti sforzi di pianificazione della capacità erano limitati da budget inadeguati. In altri casi, il cambiamento delle esigenze e delle priorità aziendali potrebbe richiedere l'IT risorse per essere più disponibili e affidabili di prima. Anche se è disponibile un'infrastruttura sufficiente per consentire a un'organizzazione di supportare i volumi di utilizzo previsti, la natura dell'utilizzo può generare eccezioni di runtime che arrestano i server di hosting. A causa della mancanza di controlli sull'affidabilità all'interno dell'infrastruttura, la reattività ai requisiti dei consumatori o dei clienti può essere ridotta al punto da minacciare la continuità complessiva di un'azienda. Su una scala più ampia, gli investimenti iniziali e i costi di proprietà dell'infrastruttura necessari per abilitare soluzioni di automazione aziendale nuove o ampliate possono essere di per sé abbastanza proibitivi da consentire a un'azienda di accontentarsi di un'infrastruttura IT di qualità non ideale, diminuendo così la sua capacità per soddisfare i requisiti del mondo reale. Peggio ancora, l'azienda può decidere di non procedere con una soluzione di automazione del tutto dopo la revisione del budget dell'infrastruttura, perché semplicemente non può permetterselo. Questa forma di incapacità di rispondere può impedire a un'organizzazione di tenere il passo con le richieste del mercato, le pressioni competitive e i propri obiettivi strategici di business.

Technology Innovation

Le innovazioni tecnologiche sono le tecnologie che hanno influenzato il cloud computing. La distinzione tra technology driver dalle tecnologie che abilitano si riferisce al fatto che le technology driver si riferiscono al passato mentre le enabling technologies si riferiscono al presente/futuro. Sono 3 i drivers tecnologici:

- **Clustering:** Un cluster è un gruppo di risorse IT indipendenti che sono interconnesse e funzionano come un unico sistema. I tassi di errore del sistema vengono ridotti mentre la disponibilità e l'affidabilità aumentano, poiché le funzionalità di ridondanza e failover sono intrinseche al cluster. Un prerequisito generale del clustering hardware è che i suoi componenti di sistema abbiano hardware e sistemi operativi ragionevolmente identici per fornire livelli di prestazioni simili quando un componente guasto deve essere sostituito da un altro. I dispositivi che formano un cluster vengono mantenuti sincronizzati tramite collegamenti di comunicazione dedicati e ad alta velocità. Il concetto di base di ridondanza e failover integrati è fondamentale per le piattaforme cloud.
- **Grid Computing:** Una griglia di calcolo fornisce una piattaforma in cui le risorse di elaborazione sono organizzate in uno o più pool logici. Questi pool sono coordinati collettivamente per fornire prestazioni elevate griglia distribuita, a volte indicata come "computer super virtuale". Il Grid computing differisce dal clustering in quanto i sistemi grid sono molto più liberamente accoppiati e distribuiti. Di conseguenza, con il grid computing i sistemi possono coinvolgere risorse di elaborazione che sono eterogenee, cosa generalmente non possibile con i cluster sistemi basati su computer. I progressi tecnologici raggiunti dai progetti di grid computing hanno influenzato

vari aspetti del cloud, in particolare in relazione a set di funzionalità comuni come accesso in rete, pool di risorse e scalabilità e resilienza.

- **Virtualization:** La virtualizzazione rappresenta una piattaforma tecnologica utilizzata per la creazione di istanze virtuali di risorse IT. Un livello di software di virtualizzazione consente alle risorse IT fisiche di fornire più immagini virtuali di sé stesse in modo che le capacità di elaborazione sottostanti possano essere condivise da più utenti. Prima dell'avvento delle tecnologie di virtualizzazione, il software era limitato a risiedere e ad essere accoppiato con ambienti hardware statici. Il processo di virtualizzazione separa questa dipendenza software-hardware, poiché i requisiti hardware possono essere simulati da software di emulazione in esecuzione in ambienti virtualizzati. Le tecnologie di virtualizzazione consolidate possono essere ricondotte a diverse caratteristiche del cloud e meccanismi di cloud computing, che hanno ispirato molte delle loro caratteristiche principali. Con l'evoluzione del cloud computing, è emersa una generazione di moderne tecnologie di virtualizzazione per superare i limiti di prestazioni, affidabilità e scalabilità delle piattaforme di virtualizzazione tradizionali.

Basic Concepts e terminologie

Un cloud si riferisce a un ambiente IT distinto progettato per lo scopo del provisioning remoto di risorse IT scalabili e misurate. Il termine è nato come metafora di Internet che è, in sostanza, una rete di reti che fornisce accesso remoto a un insieme di risorse IT decentralizzate. Essendo un ambiente specifico utilizzato per il provisioning remoto delle risorse IT, un cloud ha un confine finito. Ci sono molti singoli cloud accessibili tramite Internet. Mentre Internet fornisce un accesso aperto a molte risorse IT basate sul Web, un cloud è in genere di proprietà privata e offre accesso a risorse IT misurate. Gran parte di Internet è dedicata all'accesso alle risorse IT basate sui contenuti pubblicate tramite il World Wide Web. Le risorse IT fornite dagli ambienti cloud, d'altra parte, sono dedicate a fornire capacità di elaborazione back-end e accesso basato sull'utente a queste capacità. Un'altra distinzione fondamentale è che non è necessario che i cloud siano basati sul Web anche se sono comunemente basati su protocolli e tecnologie Internet. I protocolli si riferiscono a standard e metodi che consentono ai computer di comunicare tra loro in modo predefinito e strutturato. Un cloud può essere basato sull'utilizzo di qualsiasi protocollo che consenta l'accesso remoto alle sue risorse IT.

On-Premise

Il termine "On-Premise" è l'esatto contrario di cloud, definito come qualcosa ospitata all'interno dell'organizzazione. Una risorsa on-premise realizza interazioni con le risorse presenti sul cloud. Questo termine viene utilizzato per qualificare una risorsa IT come alternativa a "basata su cloud". Una risorsa IT On-Premise non può essere basata su cloud e viceversa. Nota i seguenti punti chiave:

- Una risorsa IT in sede può accedere e interagire con una risorsa IT basata su cloud.
- Una risorsa IT in sede può essere spostata su un cloud, trasformandola in tal modo in una risorsa IT basata su cloud.
- Le distribuzioni ridondanti di una risorsa IT possono esistere sia in ambienti on-premise che basati su cloud.

Cloud Consumers e Cloud Providers

La parte che fornisce le risorse IT basate su cloud è il fornitore di servizi cloud. La parte che utilizza le risorse IT basate su cloud è il Cloud consumer. Questi termini rappresentano i ruoli normalmente assunti dalle organizzazioni in relazione ai cloud e ai corrispondenti contratti di fornitura del cloud.

Scaling

La scalabilità, dal punto di vista delle risorse IT, rappresenta la capacità di una risorsa di poter gestire le richieste di uso che aumentano o diminuiscono, in grado di sopportare mantenendo la stessa architettura. I seguenti sono tipi di ridimensionamento:

- **Horizontal Scaling:** Scalabilità orizzontale e verticale. È l'allocazione o il rilascio di risorse IT che sono dello stesso tipo. L'allocazione orizzontale delle risorse viene definita scalabilità orizzontale e il rilascio orizzontale delle risorse viene definita scalabilità orizzontale. La scalabilità orizzontale è una forma comune di scalabilità all'interno degli ambienti cloud.
- **Vertical Scaling:** ingrandimento e ridimensionamento. Quando una risorsa IT esistente viene sostituita da un'altra con capacità maggiore o minore, si considera che si sia verificato un ridimensionamento verticale. In particolare, la sostituzione di una risorsa IT con un'altra che ha una capacità maggiore viene definita scalabilità verticale e la sostituzione di una risorsa IT con un'altra che ha una capacità inferiore è considerata ridimensionamento. Il ridimensionamento verticale è meno comune negli ambienti cloud a causa dei tempi di inattività necessari durante la sostituzione. Il Vertical scaling è estremamente veloce ed efficace da ottenere, cioè dare la possibilità di avere una macchina virtuale che usa più risorse fisiche all'interno della stessa risorsa hardware è una cosa veloce e immediata, ma ha dei limiti.

Cloud Service

Sebbene un cloud sia un ambiente accessibile da remoto, non tutte le risorse IT che risiedono in un cloud possono essere rese disponibili con accesso remoto. Ad esempio, un database o un server fisico distribuito all'interno di un cloud può essere accessibile solo da altre risorse IT che si trovano all'interno dello stesso cloud. Un servizio cloud è qualsiasi risorsa IT resa accessibile in remoto tramite un cloud. Un servizio cloud può essere un semplice programma software basato sul Web con un'interfaccia tecnica richiamata tramite l'uso di un protocollo di messaggistica o come un punto di accesso remoto per strumenti amministrativi o ambienti più grandi e altre risorse IT.

La motivazione alla base del cloud computing è fornire risorse IT come servizi che incapsulano altre risorse IT, offrendo al contempo funzioni che i clienti possono utilizzare e sfruttare in remoto. È emersa una moltitudine di modelli per tipi generici di servizi cloud, la maggior parte dei quali sono etichettati con il suffisso "as-a-service". Le condizioni di utilizzo di un cloud service sono generalmente espresse in un accordo sul livello di servizio (SLA) che è la parte leggibile dall'uomo di un contratto di servizio tra un fornitore di servizi cloud e un consumatore di cloud che descrive le caratteristiche, i comportamenti e i limiti di QoS di un servizio basato su cloud. Uno SLA fornisce i dettagli di varie caratteristiche misurabili relative ai risultati IT, come il tempo di attività, le caratteristiche di sicurezza e altre funzionalità QoS specifiche, tra cui disponibilità, affidabilità e prestazioni. Poiché l'implementazione di un servizio è nascosta al consumatore cloud, uno SLA diventa una specifica critica, definendo la quality of service dei servizi che vengono offerti affinché essi siano disponibili.

Cloud Service Consumer

Il consumatore del servizio cloud è un ruolo di runtime temporaneo assunto da un programma software quando accede a un servizio cloud. I tipi comuni di consumatori di servizi cloud possono includere programmi software e servizi in grado di accedere da remoto ai servizi cloud con contratti di servizio pubblicati, nonché workstation, laptop e dispositivi mobili che eseguono software in grado di accedere da remoto ad altre risorse IT posizionate come Servizi cloud.

Obiettivi e Benefici del Cloud

I vantaggi comuni associati all'adozione del cloud computing si dividono in:

- **Investimenti ridotti e costi proporzionali:** i fornitori di cloud pubblico basano il loro modello di business su acquisizione di massa di risorse IT che vengono poi messe a disposizione dei consumatori cloud tramite pacchetti di leasing a prezzi interessanti. Questo apre la porta alle organizzazioni per accedere a una potente infrastruttura senza doverla acquistare autonomamente. La logica economica più comune per investire in risorse IT basate su cloud è la riduzione o l'eliminazione definitiva degli investimenti IT iniziali, ovvero gli acquisti di hardware e software e i costi di proprietà. La caratteristica di utilizzo misurato di un cloud rappresenta un set di funzionalità che consente alle spese operative misurate (direttamente correlate alle prestazioni aziendali) di sostituire le spese in conto capitale previste. Questo è indicato anche come costi proporzionali. Questa eliminazione o riduzione al minimo degli impegni finanziari iniziali consente alle aziende di iniziare in piccolo e di conseguenza aumentare l'allocazione delle risorse IT secondo necessità. Inoltre, la riduzione delle spese in conto capitale iniziali consente di reindirizzare il capitale verso l'investimento del core business. Nella sua forma più elementare, le opportunità di ridurre i costi derivano dall'implementazione e dal funzionamento di data center su larga scala da parte dei principali fornitori di cloud. Tali data center si trovano comunemente in destinazioni in cui sono presenti immobili, professionisti IT e larghezza di banda di rete può essere ottenuto a costi inferiori, con conseguenti risparmi sia di capitale che operativi. La stessa logica si applica ai sistemi operativi, al middleware o al software della piattaforma e al software applicativo. Le risorse IT in pool vengono messe a disposizione e condivise da più utenti cloud, con un conseguente utilizzo maggiore o addirittura massimo possibile. I costi operativi e le inefficienze possono essere ulteriormente ridotti applicando pratiche e modelli comprovati per l'ottimizzazione delle architetture cloud, della loro gestione e della loro governance. I vantaggi comuni misurabili per i consumatori di cloud includono:
 - Accesso su richiesta alle risorse di elaborazione con pagamento in base al consumo a breve termine (come i processori a ore) e la possibilità di rilasciare queste risorse di elaborazione quando non sono più necessarie.
 - La percezione di avere risorse di elaborazione illimitate che sono disponibili su richiesta, riducendo così la necessità di prepararsi all'approvvigionamento.
 - La capacità di aggiungere o rimuovere risorse IT a un livello dettagliato, come la modifica dello spazio su disco di archiviazione disponibile con incrementi di un singolo gigabyte.
 - Astrazione dell'infrastruttura in modo che le applicazioni non siano bloccate in dispositivi o posizioni e possono essere facilmente spostati se necessario.

Ad esempio, un'azienda con attività incentrate su batch di notevoli dimensioni può completarle con la stessa rapidità con cui è possibile scalare il proprio software applicativo. Utilizzare 100 server per un'ora costa come utilizzare un server per 100 ore. Questa "elasticità" delle risorse IT, ottenuta senza richiedere forti investimenti iniziali per creare un'infrastruttura informatica su larga scala, può essere estremamente convincente. Nonostante la facilità con cui molti identificano i vantaggi finanziari del cloud computing, l'economia reale può essere complessa da calcolare e valutare. La decisione di procedere con una strategia di adozione del cloud computing comporta molto di più di un semplice confronto tra il costo del leasing e il costo dell'acquisto.

- **Incremento della Scalabilità:** Fornendo pool di risorse IT, insieme a strumenti e tecnologie progettate per sfruttarli collettivamente, i cloud possono istantaneamente allocare dinamicamente le risorse IT ai consumatori cloud, su richiesta o tramite la configurazione diretta del consumatore cloud. Questo permette ai cloud consumers di scalare le proprie risorse IT basate su cloud per adattarsi ai picchi automaticamente o manualmente. Allo stesso modo, le risorse IT basate su cloud possono essere rilasciate (automaticamente o manualmente) man

mano che le richieste di elaborazione diminuiscono. Oltre all'evidente guadagno finanziario e alla riduzione automatizzata della scalabilità, la capacità delle risorse IT di soddisfare esigenze di utilizzo imprevedibili evita la potenziale perdita di business che può verificarsi quando vengono raggiunte le soglie di utilizzo.

- **Maggiore disponibilità e affidabilità:** La disponibilità e l'affidabilità delle risorse IT sono direttamente associate a vantaggi aziendali tangibili. Le interruzioni limitano il tempo in cui una risorsa IT può essere "aperta al lavoro" per i suoi clienti, limitandone l'utilizzo e il potenziale di generazione dei ricavi. Gli errori di runtime che non vengono corretti immediatamente possono avere un impatto più significativo durante i periodi di utilizzo ad alto volume. Non solo la risorsa IT non è in grado di rispondere alle richieste dei clienti, ma il suo guasto imprevedibile può diminuire la fiducia complessiva del cliente. Un segno distintivo del tipico ambiente cloud è la sua capacità intrinseca di fornire ampio supporto per aumentare la disponibilità di una risorsa IT basata su cloud per ridurre al minimo o addirittura eliminare le interruzioni e per aumentare la sua affidabilità in modo da ridurre al minimo l'impatto delle condizioni di errore di runtime. Nello specifico:
 - Una risorsa IT con maggiore disponibilità è accessibile più a lungo periodi di tempo (ad esempio, 22 ore su un giorno di 24 ore). I cloud provider generalmente offrono risorse IT "resilienti" per le quali sono in grado di garantire alti livelli di disponibilità.
 - Una risorsa IT con maggiore affidabilità è in grado di evitare meglio e riprendersi da condizioni di eccezione. L'architettura modulare del cloud fornisce un ampio supporto di failover che aumenta l'affidabilità. È importante che le organizzazioni esaminino attentamente gli SLA offerti dai fornitori di servizi cloud quando considerano il leasing di servizi basati su cloud e risorse IT. Sebbene molti ambienti cloud siano in grado di offrire livelli di disponibilità e affidabilità notevolmente elevati, ciò si riduce alle garanzie fornite nello SLA che tipicamente rappresentano i loro effettivi obblighi contrattuali.


Rischi e Sfide

Vengono presentate ed esaminate molte delle sfide più critiche del cloud computing che riguardano principalmente i cloud consumers che utilizzano risorse IT situate nei cloud pubblici.

- **Vulnerabilità di sicurezza aumentate:** Lo spostamento dei dati aziendali nel cloud significa che la responsabilità sulla sicurezza dei dati viene condivisa con il fornitore del cloud. L'utilizzo remoto delle risorse IT richiede un'espansione dei confini di fiducia da parte del consumatore di cloud per includere il cloud esterno. Può essere difficile stabilire un'architettura di sicurezza che si estenda su un tale limite di fiducia senza introdurre vulnerabilità, a meno che i consumatori e i fornitori di cloud non supportino gli stessi framework di sicurezza o compatibili, il che è improbabile con i cloud pubblici. Un'altra conseguenza della sovrapposizione dei confini di fiducia riguarda l'accesso privilegiato del cloud provider ai dati dei cloud consumers. La misura in cui i dati sono protetti è limitata ai controlli di sicurezza e ai criteri applicati sia dal consumatore che dal fornitore di servizi cloud. Inoltre, possono esserci confini di fiducia sovrapposti da diversi consumatori di cloud a causa del fatto che le risorse IT basate su cloud lo sono comunemente condivise. La sovrapposizione dei confini di fiducia e la maggiore esposizione dei dati possono fornire ai consumatori di cloud (umani e automatizzati) maggiori opportunità di attaccare le risorse IT e rubare o danneggiare i dati aziendali.
- **Riduzione del controllo operativo:** Agli utenti del cloud viene generalmente assegnato un livello di controllo della governance inferiore a quello delle risorse IT locali. Ciò può introdurre rischi associati al modo in cui il cloud provider gestisce il proprio cloud, nonché le connessioni esterne

necessarie per la comunicazione tra il cloud e il consumatore cloud. Consideriamo i seguenti esempi:

- Un fornitore di servizi cloud inaffidabile potrebbe non mantenere le garanzie che offre negli SLA pubblicati per i suoi servizi cloud. Questo può mettere a repentaglio la qualità delle soluzioni cloud consumer che si affidano a questi servizi cloud.
- Distanze geografiche maggiori tra il consumatore e il fornitore del cloud possono richiedere salti di rete aggiuntivi che introducono latenza fluttuante e potenziali vincoli di larghezza di banda.
- **Portabilità limitata tra Cloud Provider:** A causa della mancanza di standard di settore consolidati all'interno del cloud nell'industria informatica, i cloud pubblici sono comunemente proprietari in vari modi. Per i consumatori di cloud che dispongono di soluzioni personalizzate con dipendenze da questi ambienti proprietari, può essere difficile passare da un fornitore di servizi cloud a un altro. La portabilità è una misura utilizzata per determinare l'impatto dello spostamento delle risorse IT e dei dati dei consumatori cloud tra i cloud
- **Problemi di multi-regional compliance e legali:** I fornitori di servizi cloud di terze parti stabiliranno spesso data center in posizioni geografiche convenienti o non convenienti. I consumatori di cloud spesso non saranno consapevoli della posizione fisica delle proprie risorse e dati IT quando sono ospitati da cloud pubblici. Per alcune organizzazioni, ciò può porre seri problemi legali relativi a regolamenti di settore o governativi che specificano le politiche di privacy e archiviazione dei dati. Un altro potenziale problema legale riguarda l'accessibilità e la divulgazione dei dati. I paesi hanno leggi che richiedono la divulgazione di alcuni tipi di dati a determinate agenzie governative o all'oggetto dei dati. Ad esempio, i dati di un consumatore di cloud europeo che si trovano negli Stati Uniti possono essere più facilmente accessibili dalle agenzie governative (grazie allo U.S. Patriot Act) rispetto ai dati situati in molti paesi dell'Unione europea. La maggior parte dei quadri normativi riconosce che le organizzazioni dei consumatori del cloud sono in ultima analisi responsabili della sicurezza, dell'integrità e dell'archiviazione dei propri dati, anche quando sono detenuti da un provider di cloud esterno.



Lezione – Cloud Fundamentals

Ruoli

Le organizzazioni e gli esseri umani possono assumere diversi tipi di ruoli a seconda di come si relazionano e / o interagiscono con un cloud e le sue risorse IT ospitate. Ciascuno dei ruoli imminenti partecipa e svolge responsabilità in relazione all'attività basata su cloud.

Cloud Provider

L'organizzazione che fornisce risorse IT basate su cloud è il cloud provider. Quando assume il ruolo di fornitore di servizi cloud, un'organizzazione è responsabile della messa a disposizione dei servizi cloud per i consumatori cloud, come da garanzie SLA concordate. Il fornitore di servizi cloud è inoltre incaricato di qualsiasi compito amministrativo e gestionale richiesto per garantire il funzionamento in corso dell'intera infrastruttura cloud. I fornitori di servizi cloud normalmente possiedono le risorse IT messe a disposizione per il noleggio dai consumatori di cloud; tuttavia, alcuni fornitori di servizi cloud "rivendono" anche le risorse IT noleggiate da altri fornitori di servizi cloud.

Cloud Consumer

Un cloud consumer è un'organizzazione (o un essere umano) che ha un contratto o accordo con un fornitore di servizi cloud per utilizzare le risorse IT messe a disposizione dal fornitore di servizi cloud. In particolare, il consumatore cloud utilizza un cloud service consumer per accedere a un servizio cloud.

Cloud Service Creator

Un fornitore di servizi può opzionalmente agire come creatore di servizi. Un creatore di servizi crea il servizio e lo fornisce al fornitore di servizi. La funzione principale del creatore del servizio, quando fornisce un servizio al fornitore, è quella di organizzare e ottimizzare la fornitura di risorse che sono alla base di un servizio.

Cloud Service Owner

Viene chiamata la persona o l'organizzazione che possiede legalmente un servizio cloud proprietario. Il proprietario del servizio cloud può essere il cloud consumer o il provider di servizi cloud. Si noti che un consumatore cloud che possiede un servizio cloud ospitato da un cloud di terze parti non deve necessariamente essere l'utente (o consumatore) del servizio cloud. Diverse organizzazioni di cloud consumer sviluppano e distribuiscono servizi cloud in cloud di proprietà di altre parti allo scopo di rendere i servizi cloud disponibili al pubblico in generale. Il motivo per cui il proprietario di un servizio cloud non viene definito proprietario di una risorsa cloud è perché il ruolo di proprietario del servizio cloud si applica solo ai servizi cloud.

Cloud Resource Administrator

Un amministratore di risorse cloud è la persona o l'organizzazione responsabile dell'amministrazione di una risorsa IT basata su cloud (inclusi i servizi cloud). L'amministratore della risorsa cloud può

essere (o appartenere a) il consumatore o il fornitore del cloud in cui risiede il servizio. In alternativa, può essere (o appartenere a) un'organizzazione di terze parti incaricata di amministrare la risorsa IT basata su cloud. Può essere sia locata all'interno del cloud consumer, ma anche esterna in quanto il cloud resource administrator può configurare il servizio che viene fornito. Il motivo per cui un amministratore di risorse cloud non viene definito "amministratore di servizi cloud" è perché questo ruolo potrebbe essere responsabile dell'amministrazione di risorse IT basate su cloud che non esistono come servizi cloud. Ad esempio, se l'amministratore delle risorse cloud appartiene (o è assunto da) il provider cloud, le risorse IT non rese accessibili in remoto possono essere amministrate da questo ruolo.

Ruoli Aggiuntivi

L'architettura di riferimento del cloud computing del NIST definisce i seguenti ruoli supplementari:

- **Cloud Auditor** - Una terza parte (spesso accreditata) che conduce valutazioni indipendenti degli ambienti cloud assume il ruolo di cloud auditor. Le responsabilità tipiche associate a questo ruolo include la valutazione dei controlli di sicurezza, degli impatti sulla privacy e prestazioni. Lo scopo principale del ruolo del cloud auditor è di fornire una valutazione imparziale (e l'eventuale approvazione) di un ambiente cloud per contribuire a rafforzare il rapporto di fiducia tra il cloud consumer e i cloud service providers.
- **Cloud Broker**: questo ruolo è assunto da una parte che assume il responsabilità di gestire e negoziare l'utilizzo dei servizi cloud tra consumatori e fornitori di servizi cloud. I servizi di mediazione forniti dai cloud broker includono l'intermediazione, l'aggregazione e l'arbitraggio dei servizi.
- **Cloud Carrier**: la parte responsabile della fornitura del livello di rete, la connettività tra consumatori e fornitori di servizi cloud assume il ruolo di vettore cloud. Questo ruolo è spesso assunto dai fornitori di reti e telecomunicazioni.

Organizational Boundary

Un Organizational Boundary rappresenta il perimetro fisico che circonda un insieme di risorse IT di proprietà e governate da un organizzazione. Il confine organizzativo non rappresenta il confine di un'organizzazione reale, solo un insieme organizzativo di IT asset e risorse IT, nel senso che nel momento in cui un'organizzazione sta fornendo un servizio, Organizational Boundary si estende.

Trust Boundary

Quando un'organizzazione assume il ruolo di cloud consumer per l'accesso a risorse IT basate su cloud, deve estendere la propria fiducia oltre i confini fisici dell'organizzazione per includere parti dell'ambiente cloud. Un confine di fiducia è un perimetro logico che in genere si estende oltre i confini fisici per rappresentare la misura in cui le risorse IT sono affidabili. Quando si analizzano gli ambienti cloud, il limite di fiducia è più frequentemente associato alla fiducia rilasciata dall'organizzazione che funge da consumatore cloud.

Cloud Characteristics

Un ambiente IT richiede un insieme specifico di caratteristiche per consentire il provisioning remoto di risorse IT scalabili e misurate in un modo efficace. Queste caratteristiche devono esistere per una misura in cui l'ambiente IT può essere considerato un cloud efficace. Le seguenti sei caratteristiche specifiche sono comuni alla maggior parte degli ambienti cloud, dove cinque provengono dalla definizione del NIST + una aggiuntiva ovvero la resilienza. Quindi:

- On-Demand usage (Quando vengono acceduti i servizi)

- Ubiquitous access (Dove vengono acceduti servizi)
- Multitenancy (Come vengono forniti servizi)
- Elasticity (Come vengono forniti servizi)
- Measured usage (Quanto dei servizi viene fornito)
- Resiliency (Quanto sono affidabili)

I fornitori di servizi cloud e i consumatori di cloud possono valutare queste caratteristiche individualmente e collettivamente per misurare l'offerta di valore di una data piattaforma cloud. Sebbene i servizi basati su cloud e le risorse IT ereditano e mostreranno caratteristiche individuali in misura variabile, di solito maggiore è il grado di supporto e utilizzo, maggiore è la proposta di valore risultante.

On-Demand Usage

Un consumatore cloud può accedere unilateralmente alle risorse IT basate sul cloud e ha la libertà di eseguire autonomamente il provisioning di queste risorse IT. Una volta configurato, è possibile utilizzare le risorse IT con provisioning autonomo automatizzato, che non richiede ulteriore coinvolgimento umano da parte del cloud consumer o del fornitore di servizi cloud. Ciò si traduce in un ambiente di utilizzo on-demand. Noto anche come "utilizzo self-service su richiesta", tale caratteristica abilita le funzionalità basate sul servizio e basate sull'utilizzo del cloud.

Ubiquitous Access

L'accesso onnipresente rappresenta la capacità di un servizio cloud di essere ampiamente accessibile. Può richiedere un accesso onnipresente per un servizio cloud di supporto per una vasta gamma di dispositivi, protocolli di trasporto, interfacce e tecnologie di sicurezza. Per abilitare questo livello di accesso generalmente è necessario che l'architettura del servizio cloud sia adattata alle particolari esigenze di diversi consumatori di servizi cloud.

Multitenancy

La caratteristica di un programma software che consente a un'istanza del programma di servire diversi consumatori in cui ciascuno è isolato dall'altro, viene definita multitenancy. Un fornitore di servizi cloud mette in comune le proprie risorse IT per servire più consumatori di servizi cloud utilizzando modelli multi-tenancy che spesso si basano sull'uso di tecnologie di virtualizzazione. Attraverso l'uso della tecnologia multi-tenancy, le risorse IT possono essere assegnate e riassegnate dinamicamente, in base alle richieste dei consumatori di servizi cloud. Il pool di risorse consente ai cloud provider di mettere in comune risorse IT su larga scala per servire più consumatori di cloud. Diverse risorse IT fisiche e virtuali vengono assegnate e riassegnate dinamicamente in base alla domanda dei consumatori di cloud, in genere seguite dall'esecuzione tramite multiplexing statistico. Il pooling delle risorse è comunemente ottenuto tramite la tecnologia multi-tenancy e quindi è compreso da questa caratteristica multi-tenancy.

Elasticity

L'elasticità è la capacità automatizzata di un cloud di scalare in modo trasparente le risorse IT, come richiesto in risposta alle condizioni di runtime o come predeterminato consumatore o fornitore di servizi cloud. L'elasticità è spesso considerata una giustificazione fondamentale per l'adozione del cloud computing, principalmente per il fatto che è strettamente associato al ridotto beneficio degli investimenti e dei costi proporzionali. Fornitori di cloud con un vasto numero di risorse IT possono offrire la più ampia gamma di elasticità.

Measured usage

La caratteristica di utilizzo misurata rappresenta la capacità di una piattaforma cloud di tenere traccia dell'utilizzo delle proprie risorse IT, principalmente tramite cloud consumer. In base a quanto misurato, il fornitore di servizi cloud può addebitare un consumatore cloud solo per le risorse IT effettivamente utilizzate e / o per il periodo di tempo durante il quale è stato concesso l'accesso alle risorse IT. In questo contesto, l'utilizzo misurato è strettamente correlato all'on demand. L'utilizzo misurato non si limita al monitoraggio delle statistiche a fini di fatturazione. Comprende anche il monitoraggio generale delle risorse IT e report sull'utilizzo (sia per provider di servizi cloud che per consumatori di cloud).

Resiliency

L'elaborazione resiliente è una forma di failover che distribuisce in modo ridondante implementazioni di risorse IT in sedi fisiche. Le risorse IT possono essere preconfigurate in modo che, se una diventa carente, l'elaborazione viene automaticamente trasferita a un'altra implementazione ridondante. All'interno del cloud computing, la caratteristica della resilienza può fare riferimento a risorse IT ridondanti all'interno dello stesso cloud (ma in posizioni fisiche diverse) o su più cloud. I consumatori del cloud possono aumentare sia l'affidabilità che la disponibilità delle loro applicazioni sfruttando la resilienza delle risorse IT basate sul cloud. Quindi permette di capire quanto è affidabile il servizio che viene fornito.

Cloud delivery models

Un cloud delivery model rappresenta una combinazione specifica e preconfezionata di risorse IT offerte da un fornitore di servizi cloud. Tre modelli comuni di cloud delivery sono diventati ampiamente consolidati e formalizzati:

- Infrastructure-as-a-Service (IaaS)
- Platform-as-a-Services (Paas)
- Software-as-a-Services (Saas)

Questi tre modelli sono correlati nel modo in cui lo scopo di uno può includere quello di un altro.

Infrastructure-as-a-Service (IaaS)

Il modello di consegna IaaS rappresenta un ambiente IT autonomo, composto da risorse IT incentrate sull'infrastruttura a cui è possibile accedere e gestito tramite interfacce e strumenti basati su servizi cloud. Questo ambiente può includere hardware, rete, connettività, funzionamento sistemi e altre risorse IT "grezze". A differenza dei tradizionali ambienti di hosting o outsourcing, con IaaS, le risorse IT sono tipicamente virtualizzate e confezionate in bundle che semplificano la scalabilità iniziale del runtime e la personalizzazione dell'infrastruttura. Lo scopo generale di un ambiente IaaS è fornire ai consumatori del cloud un elevato livello di controllo e responsabilità sulla sua configurazione e utilizzo. Le risorse IT fornite da IaaS non sono generalmente preconfigurate, affidando la responsabilità amministrativa direttamente al consumatore cloud. Questo modello viene quindi utilizzato dai consumatori di cloud che richiedono un elevato livello di controllo sull'ambiente basato su cloud che intendono creare. A volte i fornitori di servizi cloud contraggono offerte IaaS da altri fornitori di servizi cloud per scalare i propri ambienti cloud. I tipi e i marchi delle risorse IT fornite dai prodotti IaaS offerti da diversi fornitori di cloud possono variare. Le risorse IT disponibili tramite gli ambienti IaaS sono generalmente offerte come istanze virtuali appena inizializzate. Una risorsa IT centrale e primaria all'interno di un tipico ambiente IaaS è il server virtuale.

Platform-as-a-Services (Paas)

Il modello di erogazione PaaS rappresenta un ambiente "ready-to-use" predefinito, generalmente costituito da risorse IT già distribuite e configurate. In particolare, PaaS si basa (ed è principalmente definito da) l'utilizzo di un ambiente già pronto che stabilisce una serie di prodotti e strumenti preconfezionati utilizzati per supportare l'intero ciclo di vita di consegna delle applicazioni personalizzate. Motivi comuni per cui un consumatore cloud utilizzerebbe e investirebbe in un ambiente PaaS include:

- Il consumatore cloud desidera estendere gli ambienti on-premise nel cloud per scopi economici e di scalabilità.
- Il consumatore cloud utilizza completamente l'ambiente già pronto sostituire un ambiente locale.
- Il consumatore di cloud desidera diventare un provider di cloud e distribuisce i propri servizi cloud per renderli disponibili ad altri consumatori cloud esterni. Lavorando all'interno di una piattaforma già pronta, al consumatore del cloud viene risparmiato l'onere amministrativo di impostare e mantenere le risorse IT dell'infrastruttura nuda fornite tramite il modello IaaS. Al contrario, al consumatore del cloud viene concesso un livello inferiore di controllo sulle risorse IT sottostanti che ospitano e forniscono la piattaforma. Il vantaggio è ignorare la parte di gestione dell'hardware sottostante (Patch di sicurezza, sistema operativo ecc.), anche se c'è meno controllo delle risorse.

Software-as-a-Services (SaaS)

Un programma software posizionato come servizio cloud condiviso, realizzato e disponibile come "prodotto" o utilità generica che rappresenta il profilo tipico di un'offerta SaaS. Il modello di consegna SaaS viene in genere utilizzato per rendere un servizio cloud riutilizzabile e ampiamente disponibile (spesso in commercio) a una vasta gamma di consumatori di cloud. Esiste un intero mercato attorno ai prodotti SaaS che possono essere noleggiati e utilizzati per scopi diversi e con termini diversi. A un consumatore cloud viene generalmente concesso un livello amministrativo molto limitato su un'implementazione SaaS. Il più delle volte viene fornito dal fornitore di servizi cloud, ma può essere legalmente di proprietà di qualsiasi entità che assuma il ruolo di proprietario del servizio cloud. Ad esempio, un'organizzazione che agisce come consumatore cloud mentre utilizza e lavora con un ambiente PaaS può creare un servizio cloud che decide di distribuire nello stesso ambiente di un'offerta SaaS. La stessa organizzazione assume quindi effettivamente il ruolo di fornitore di servizi cloud poiché il servizio cloud basato su SaaS viene reso disponibile ad altre organizzazioni che agiscono come consumatori di cloud quando utilizzano tale servizio.

I tre modelli di consegna del cloud di base comprendono un provisioning naturale, consentendo di esplorare opportunità per l'applicazione combinata dei modelli.

IaaS + PaaS

Un ambiente PaaS sarà costruito su un'infrastruttura sottostante paragonabile ai server fisici e virtuali e ad altre risorse IT fornite in un ambiente IaaS. Normalmente un fornitore di servizi cloud non dovrebbe fornire un ambiente IaaS dal proprio cloud per creare un ambiente PaaS disponibile per i consumatori cloud. È possibile costruire/offrire IaaS e PaaS fornendo una Platform installata su un'infrastruttura, quindi un consumer può decidere di fornire un servizio come una platform chiedendo l'infrastruttura al provider e mettendo un certo tipo di environment che ne permettono lo sviluppo.

Questi tre livelli di astrazione (IaaS, PaaS e SaaS) sono i modelli di servizio a cui si fa riferimento nella definizione NIST. E se la nostra società di revisione decidesse di esternalizzare l'intera funzione di revisione contabile a un'altra società in modo che possano concentrarsi sulla consulenza in materia

fiscale? La nostra azienda accetterebbe uno SLA e il costo con l'altra azienda, che poi controllerebbe i conti di conseguenza. Ciò equivale a esternalizzare un'intera funzione aziendale, o processo, a un'altra azienda. Quell'altra azienda potrebbe anche essere sostituita da un servizio cloud. Pertanto, il servizio cloud, quando fornisce una funzione aziendale, fornisce un'attività come servizio (BPaaS). Supponiamo che per ottenere le ultime normative fiscali si possa fornire un servizio di informazione alla società di contabilità. Questo sarebbe simile a Information as a Service (INaaS). Poiché i codici e le normative fiscali vengono aggiornati regolarmente con i cambiamenti di legge, questo è un servizio che si basa non solo sulla memorizzazione dei dati, che sarebbe poi IaaS, ma anche sulla manipolazione di tali dati per fornire informazioni significative. Quindi INaaS è distinto da IaaS. Il modello NIST deve essere aggiornato con queste due astrazioni di servizio: INaaS e BPaaS.

Cloud Deployment models

Il modello di distribuzione cloud rappresenta un tipo specifico di ambiente cloud, caratterizzato principalmente da proprietà, dimensioni e accesso. Esistono quattro modelli comuni di distribuzione cloud:

- Public Cloud
- Community Cloud
- Private Cloud
- Hybrid Cloud

Public Cloud

Un cloud pubblico è un ambiente cloud accessibile pubblicamente, di proprietà di un provider di servizi cloud di terze parti. Le risorse IT sui cloud pubblici vengono solitamente fornite tramite i modelli di distribuzione cloud e sono generalmente offerte ai consumatori di cloud a un costo o sono commercializzate tramite altre vie (come la pubblicità). Il fornitore di servizi cloud è responsabile della creazione e dell'operazione di manutenzione del cloud pubblico e delle sue risorse IT. Molti dei file coinvolgono scenari e architetture esplorate nei prossimi capitoli cloud pubblici e la relazione tra fornitori e consumatori di risorse IT tramite cloud pubblici.

Community Cloud

Un cloud di comunità è simile a un cloud pubblico, tranne per il fatto che il suo accesso è limitato a una comunità specifica di consumatori di cloud. Il cloud di comunità può essere di proprietà congiunta dei membri della comunità o di un fornitore di cloud di terze parti che fornisce un cloud pubblico con accesso limitato. I consumatori del cloud membro della comunità in genere condividono la responsabilità di definire ed evolvere il cloud della comunità. L'appartenenza alla community non garantisce necessariamente l'accesso o il controllo di tutte le risorse IT del cloud. Alle parti esterne alla comunità non è generalmente concesso l'accesso a meno che non sia consentito dalla comunità.

Private Cloud

Un cloud privato è di proprietà di una singola organizzazione. I cloud privati consentono a un'organizzazione di utilizzare la tecnologia del cloud computing come mezzo per centralizzare l'accesso alle risorse IT da parti, posizioni o dipartimenti diversi dell'organizzazione. Quando un cloud privato esiste come ambiente controllato, i problemi descritti nella sezione Rischi e sfide tendono a non essere applicabili. L'utilizzo di un cloud privato può cambiare il modo in cui i confini organizzativi e di fiducia sono definiti e applicati. L'attuale amministrazione di un file nell'ambiente cloud privato

può essere eseguita da personale interno o esterno. Con un cloud privato, la stessa organizzazione è tecnicamente sia il consumatore che il fornitore di cloud. Per differenziare questi ruoli:

- un dipartimento organizzativo separato assume tipicamente il responsabilità per il provisioning del cloud (e pertanto assume il ruolo di provider cloud)
- i reparti che richiedono l'accesso al cloud privato assumono il ruolo del cloud consumer.

È importante utilizzare i termini "on-premise" e "cloud-based" correttamente nel contesto di un cloud privato. Anche se il cloud privato può risiedere fisicamente in locale nell'organizzazione, le risorse IT che ospita sono ancora considerate "basate sul cloud" fintanto che sono rese accessibili in remoto ai consumatori del cloud. Le risorse IT ospitate al di fuori del cloud privato dai dipartimenti che agiscono come consumatori di cloud sono quindi considerate "in sede" in relazione alle risorse IT basate sul cloud privato.

Qual è la differenza tra private cloud e calcolo on-premise?

Il private cloud offre delle caratteristiche di resilienza e elasticità che on-premise non è detto che offra. L'aspetto importante è il "Formal Arrangements", dove nel cloud provider privato il dipartimento "acquista" i servizi dal proprio private cloud ed è diverso da usare le risorse on-premise.

Hybrid Cloud

Un cloud ibrido è un ambiente cloud composto da due o più diversi modelli di implementazione del cloud. Ad esempio, un consumatore di cloud può scegliere di distribuire servizi cloud che elaborano dati sensibili su un cloud privato e altri servizi cloud meno sensibili su un cloud pubblico. Il risultato di questa combinazione è un modello di distribuzione ibrido.



Lezione – Key Technologies

Key Enabling Technologies

I cloud moderni sono sostenuti da una serie di componenti tecnologici primari che consentono collettivamente funzionalità e caratteristiche chiave associate al cloud computing contemporaneo. Messe insieme sono diventate mature e collettivamente hanno reso possibile il movimento che ha portato alla fornitura di computing come servizio. Tali tecnologie non solo sono abilitanti ma ricevono una spinta alla loro evoluzione grazie al client. Le seguenti tecnologie di questo tipo sono:

- Broadband Networks e L'architettura di internet
- Data Center Technology
- Virtualization Technology
- Web Technology
- Multitenant Technology
- Service Technology

Broadband Networks

Tutti i cloud devono essere collegati a una rete. Questo requisito inevitabile forma una dipendenza intrinseca dall'internetworking. Internetworks, o Internet, consentono il provisioning remoto delle risorse IT e supportano direttamente l'accesso alla rete onnipresente. I consumatori di cloud hanno la possibilità di accedere al cloud utilizzando solo collegamenti di rete privati e dedicati nelle LAN, sebbene la maggior parte dei cloud siano abilitati a Internet. Il potenziale delle piattaforme cloud cresce in genere parallelamente ai progressi nella connettività Internet e quindi nella qualità del servizio.

La topologia di Internet è diventata un aggregato dinamico e complesso di ISP altamente interconnessi tramite i suoi protocolli principali. I rami più piccoli si estendono da questi principali nodi di interconnessione, ramificandosi verso l'esterno attraverso reti più piccole fino a raggiungere ogni dispositivo elettronico abilitato a Internet. La connettività mondiale è abilitata tramite una topologia gerarchica composta dai livelli 1, 2 e 3. Il core Tier 1 è costituito da provider di cloud internazionali su larga scala che supervisionano enormi reti globali interconnesse, che sono collegate ai grandi provider regionali di Tier 2. Gli ISP interconnessi di Livello 2 si connettono con i fornitori di Livello 1, così come gli ISP locali di Livello 3. I consumatori e i fornitori di servizi cloud possono connettersi direttamente utilizzando un provider di Livello 1, poiché qualsiasi ISP operativo può abilitare la connessione Internet.

Internet Service Provider (ISP)

Istituite e implementate dagli ISP, le reti backbone più grandi di Internet sono strategicamente interconnesse da router core che collegano le reti multinazionali del mondo. Il concetto di Internet era basato su un modello di fornitura e gestione decentralizzato. Gli ISP possono distribuire liberamente, operare e gestire le proprie reti oltre a selezionare gli ISP partner per l'interconnessione. Nessuna entità centralizzata governa in modo completo Internet, sebbene organismi come Internet Corporation for Assigned Names and Numbers (ICANN) supervisiona e coordina le comunicazioni Internet. La topologia di Internet è diventata un aggregato dinamico e complesso di ISP altamente interconnessi tramite protocolli. I rami più piccoli si estendono da questi nodi principali di interconnessione, ramificandosi verso l'esterno attraverso i più piccoli, fino a raggiungere ogni dispositivo elettronico abilitato a Internet.

Una caratteristica importante del cloud che si applica alla funzionalità degli utenti finali è il modo in cui è possibile accedere alle risorse IT centralizzate utilizzando gli stessi protocolli di rete indipendentemente dal fatto che risiedano all'interno o all'esterno di una rete aziendale. Il fatto che le risorse IT siano in sede o basate su Internet determina il modo in cui gli utenti finali interni o esterni accedono ai servizi, anche se gli utenti finali stessi non sono interessati alla posizione fisica delle risorse IT basate su cloud. I fornitori di servizi cloud possono configurare facilmente le risorse IT basate su cloud in modo che siano accessibili sia agli utenti esterni che interni tramite una connessione Internet. Questa architettura di internetworking è vantaggiosa per gli utenti interni che richiedono un accesso onnipresente alle soluzioni IT aziendali, nonché per i consumatori cloud che devono fornire servizi basati su Internet agli utenti esterni. I principali fornitori di servizi cloud offrono una connettività Internet superiore alla connettività delle singole organizzazioni, con conseguenti costi aggiuntivi per l'utilizzo della rete come parte del loro modello di prezzo.

Data Center Technology

Raggruppare le risorse IT in stretta vicinanza l'una con l'altra, invece di averle disperse geograficamente, consente la condivisione dell'alimentazione, una maggiore efficienza nell'utilizzo delle risorse IT condivise e una migliore accessibilità per il personale IT. Questi sono i vantaggi che hanno naturalmente reso popolare il concetto di data center. I data center moderni esistono come infrastrutture IT specializzate utilizzate per ospitare risorse IT centralizzate, come server, database, dispositivi di rete e di telecomunicazione e sistemi software. I data center sono generalmente costituiti dalle seguenti tecnologie e componenti:

Virtualizzazione: I data center sono costituiti da risorse IT fisiche e virtualizzate. Il livello delle risorse IT fisiche si riferisce all'infrastruttura della struttura che ospita i sistemi e le apparecchiature di elaborazione/ rete, insieme ai sistemi hardware e ai loro sistemi operativi. L'astrazione delle risorse e il controllo del livello di virtualizzazione sono costituiti da strumenti operativi e di gestione che sono spesso basati su piattaforme di virtualizzazione che astraggono il calcolo fisico e mettono in rete le risorse IT come componenti virtualizzati che sono più facili da allocare, utilizzare, rilasciare, monitorare e controllare. Il meccanismo di configurazione è totalmente automatico e prevede l'utilizzo di diversi componenti. La memorizzazione delle immagini in esecuzione in una macchina virtuale viene effettuata su physical storage.

Standardizzazione e Modularità: I data center sono costruiti su hardware standardizzato e progettati con architetture modulari, aggregando più elementi costitutivi identici dell'infrastruttura e delle attrezzature della struttura per supportare la scalabilità, la crescita e la rapida sostituzione dell'hardware. La modularità e la standardizzazione sono requisiti chiave per ridurre i costi di investimento e operativi poiché consentono economie di scala per l'approvvigionamento, l'acquisizione, l'implementazione, il funzionamento e la manutenzione processi.

Operazione e Gestione da remoto: La maggior parte delle attività operative e amministrative delle risorse IT nei data center vengono comandate tramite le console remote e i sistemi di gestione della rete. Il personale tecnico non è tenuto a visitare le sale dedicate che ospitano i server, tranne che per eseguire attività altamente specifiche, come la movimentazione e il cablaggio delle apparecchiature o l'installazione e la manutenzione a livello di hardware.

Alta Disponibilità: Poiché qualsiasi forma di interruzione del data center influisce in modo significativo sulla continuità aziendale per le organizzazioni che utilizzano i loro servizi, i data center

sono progettati per funzionare con livelli di ridondanza sempre più elevati per sostenere la disponibilità. I data center di solito hanno alimentatori ridondanti e senza interruzioni, cablaggio e sottosistemi di controllo ambientale in previsione di guasti del sistema, insieme a collegamenti di comunicazione e hardware in cluster per il bilanciamento del carico.

Computing: Gran parte dell'elaborazione nei data center viene spesso eseguita da server di prodotti standardizzati che hanno una notevole potenza di calcolo e capacità di archiviazione. Diverse tecnologie hardware di elaborazione sono integrate in questi moduli server, come:

- Design server con fattore di forma per montaggio su rack composto da rack standardizzati con interconnessioni per alimentazione, rete e raffreddamento interno
- supporto per diverse architetture di elaborazione hardware, come x86-32bits, x86-64 e RISC
- un'architettura CPU multicore ad alta efficienza energetica che ospita centinaia di core di elaborazione in uno spazio piccolo come una singola unità di rack standardizzati
- componenti ridondanti e sostituibili a caldo, come dischi rigidi, alimentatori, interfacce di rete e schede controller di archiviazione

Le architetture di elaborazione come le tecnologie dei server blade utilizzano interconnessioni fisiche incorporate nel rack (contenitori blade), fabric (switch) e unità di alimentazione condivise e ventole di raffreddamento. Le interconnessioni migliorano il networking e la gestione tra i componenti ottimizzando lo spazio fisico e l'alimentazione. Questi sistemi in genere supportano lo scambio a caldo, la scalabilità, la sostituzione e la manutenzione di singoli server, a vantaggio della distribuzione di sistemi a tolleranza di errore basati su cluster di computer.

Storage: I data center dispongono di sistemi di archiviazione specializzati che conservano enormi quantità di informazioni digitali al fine di soddisfare notevoli esigenze di capacità di archiviazione. Questi sistemi di archiviazione sono contenitori che ospitano numerosi dischi rigidi organizzati in array. I sistemi di archiviazione solitamente coinvolgono le seguenti tecnologie:

- Array di dischi rigidi: questi array dividono e replicano intrinsecamente i dati tra più unità fisiche e aumentano le prestazioni e la ridondanza includendo dischi di riserva. Questa tecnologia viene spesso implementata utilizzando array ridondanti di schemi RAID (Independent Disks), che sono generalmente realizzati tramite controller di array di dischi hardware.
- Caching I/O: generalmente viene eseguito tramite controller di array di dischi rigidi, che migliorano i tempi di accesso al disco e le prestazioni mediante il caching dei dati.
- Dischi rigidi sostituibili a caldo: possono essere rimossi in sicurezza dagli array senza dover prima spegnere.
- Virtualizzazione dello storage: si ottiene tramite l'uso di dischi rigidi virtualizzati e la condivisione dello storage.
- Meccanismi di replica rapida dei dati: includono lo snapshot, che salva la memoria di una macchina virtuale in un file leggibile dall'hypervisor per il successivo ricaricamento, e la clonazione del volume, che copia i volumi e le partizioni del disco rigido virtuale o fisico. I sistemi di archiviazione comprendono ridondanze terziarie, come le librerie a nastro robotizzate, utilizzate come sistemi di backup e ripristino che in genere si basano su supporti rimovibili.

Network:

I data center richiedono un ampio hardware di rete per abilitare più livelli di connettività. Per una versione semplificata dell'infrastruttura di rete, il data center è suddiviso in cinque sottosistemi di rete, seguiti da un riepilogo degli elementi più comuni utilizzati per la loro implementazione.

Interconnessione di carrier e reti esterne correlato all'infrastruttura di internetworking, questa interconnessione è solitamente costituita da router backbone che forniscono il routing tra le connessioni WAN esterne e la LAN del data center, nonché dispositivi di sicurezza della rete perimetrale come firewall e gateway VPN.

Virtualization Technology

La virtualizzazione è il processo di conversione di una risorsa IT fisica in una risorsa IT virtuale. È possibile virtualizzare la maggior parte dei tipi di risorse IT, tra cui:

- Server: un server fisico può essere astratto in un server virtuale.
- Archiviazione: un dispositivo di archiviazione fisico può essere astratto in un dispositivo di archiviazione virtuale o in un disco virtuale.
- Rete: i router e gli switch fisici possono essere astratti in fabric di rete logici, come le VLAN.
- Alimentazione: un UPS fisico e le unità di distribuzione dell'alimentazione possono essere astratte in ciò che viene comunemente definito UPS virtuale.

Uno dei processi che ha acceso la virtualizzazione è il meccanismo di server consolidation, cioè prendere diversi server fisici e farli diventare tanti server virtuali eseguiti su un'unica macchina, risparmiando hardware e gestire repliche, bilanciamento del carico ecc. Sia il sistema operativo che il software applicativo in esecuzione sul server virtuale non sono a conoscenza di processo di virtualizzazione, ovvero queste risorse IT virtualizzate vengono installate ed eseguite come se fossero in esecuzione su un server fisico separato. Questa uniformità di esecuzione che consente ai programmi di funzionare sui sistemi fisici come farebbero sui sistemi virtuali è una caratteristica fondamentale della virtualizzazione. I sistemi operativi guest in genere richiedono un utilizzo continuo di prodotti software e applicazioni che non devono essere personalizzati, configurati o applicati a patch per essere eseguiti in un software di virtualizzazione viene eseguito su un server fisico chiamato host o host fisico, il cui hardware sottostante è reso accessibile dal software di virtualizzazione. La funzionalità del software di virtualizzazione comprende servizi di sistema specificamente correlati alla gestione della macchina virtuale e normalmente non presenti nei sistemi operativi standard. Questo è il motivo per cui questo software viene talvolta definito gestore di macchine virtuali o monitor di macchine virtuali (VMM), ma più comunemente noto come hypervisor.

L'indipendenza hardware abilitata dalla virtualizzazione consente un utilizzo più flessibile delle risorse IT hardware. Ad esempio, si consideri uno scenario in cui il sistema operativo host dispone del software necessario per controllare cinque schede di rete disponibili per il computer fisico. Il software di virtualizzazione può rendere disponibili i cinque adattatori di rete al server virtuale, anche se il sistema operativo virtualizzato non è in grado di ospitare fisicamente cinque adattatori di rete. Il software di virtualizzazione traduce le risorse IT hardware che richiedono un software unico per il funzionamento in risorse IT virtualizzate compatibili con una vasta gamma di sistemi operativi. Poiché il sistema operativo host è di per sé un sistema operativo completo, molti servizi basati sul sistema operativo disponibili come strumenti di amministrazione possono essere utilizzati per gestire l'host fisico.

Un problema con la virtualizzazione basata sul sistema operativo è il sovraccarico di elaborazione necessario per eseguire il software di virtualizzazione e i sistemi operativi host. L'implementazione di un livello di virtualizzazione influirà negativamente sulle prestazioni complessive del sistema. La stima, il monitoraggio e la gestione dell'impatto risultante possono essere impegnativi perché richiedono esperienza nei carichi di lavoro del sistema, ambienti software e hardware e strumenti di monitoraggio sofisticati.

Web Technology

A causa della fondamentale dipendenza del cloud computing dall'internetworking, dall'universalità del browser Web e dalla facilità di sviluppo di servizi basati sul Web, la tecnologia Web viene generalmente utilizzata sia come mezzo di implementazione che come interfaccia di gestione per i servizi cloud. Questa sezione introduce le principali tecnologie Web e discute il loro rapporto con i servizi cloud. Il World Wide Web è un sistema di risorse IT interconnesse a cui si accede tramite Internet. I due componenti di base del Web sono il client del browser Web e il server Web. Altri componenti, come proxy, servizi di memorizzazione nella cache, gateway e bilanciatori del carico, vengono utilizzati per migliorare le caratteristiche delle applicazioni Web come la scalabilità e la sicurezza. Questi componenti aggiuntivi risiedono in un'architettura a più livelli posizionata tra il client e il server. Tre elementi fondamentali compongono l'architettura tecnologica del Web:

- Uniform Resource Locator (URL): sintassi standard utilizzata per creare identificatori che puntano a risorse basate sul Web, l'URL è spesso strutturato utilizzando un percorso di rete logico.
- HTTP (Hypertext Transfer Protocol): è il protocollo di comunicazione principale utilizzato per lo scambio di contenuti e dati in tutto il World Wide Web. Gli URL vengono generalmente trasmessi tramite HTTP.
- Linguaggi di markup (HTML, XML) - I linguaggi di markup forniscono un mezzo leggero per esprimere dati e metadati incentrati sul Web. I due linguaggi di markup primari sono HTML (che viene utilizzato per esprimere la presentazione di pagine Web) e XML.

Multitenant Technology

Il design dell'applicazione multi-tenant è stato creato per consentire a più utenti (tenant) di accedere contemporaneamente alla stessa logica dell'applicazione. Ogni tenant ha la propria visualizzazione dell'applicazione che utilizza, amministra e personalizza come un'istanza dedicata del software pur rimanendo ignaro degli altri tenant che utilizzano la stessa applicazione. Le applicazioni multi-tenant garantiscono che i tenant non abbiano accesso a dati e informazioni di configurazione che non sono i propri. I tenant possono personalizzare individualmente le funzionalità dell'applicazione, come:

- Interfaccia utente: i tenant possono definire un "aspetto" specifico per la loro interfaccia dell'applicazione.
- Processo aziendale: i tenant possono personalizzare le regole, la logica e i flussi di lavoro dei processi aziendali implementati nell'applicazione.
- Modello di dati: i tenant possono estendere lo schema dei dati dell'applicazione per includere, escludere o rinominare i campi nelle strutture dati dell'applicazione.
- Controllo degli accessi: i tenant possono controllare in modo indipendente i diritti di accesso per utenti e gruppi.

L'architettura delle applicazioni multi-tenant è spesso molto più complessa di quella delle applicazioni single-tenant. Le applicazioni multi-tenant devono supportare la condivisione di vari artefatti da parte di più utenti (inclusi portali, schemi di dati, middleware e database), pur mantenendo livelli di sicurezza che separano gli ambienti operativi dei singoli tenant.

Cosa si intende per Multitenant Technology?

L'idea è che si ha a disposizione la possibilità di far accedere alla stessa logica di applicazione diversi consumer dello stesso servizio, ognuno con la propria visione dell'applicazione. Non solo c'è una visione separata ma anche un'amministrazione e personalizzazione di una istanza del software in modo da mantenere completamente l'isolamento dagli altri. È possibile customizzare la user-interface, l'intero processo di business, il modello dei dati, il controllo degli accessi. Questo permette di offrire al cloud la possibilità di avere usage isolation, data security, recovery, upgrades, scalability, metered usage e data tier isolation.

Qual è la differenza tra Virtualization e Multitenancy?

La Virtualizzazione è diverse copie virtuali dello stesso server di environment invece con il multitenancy si ha un'applicazione progettata per permettere l'uso tra diversi utenti. Quindi mentre la virtualizzazione è un qualcosa che replica risorse inutilmente, con multitenancy si hanno applicazioni che sono automaticamente multitenant.

Service Technology

Il campo della tecnologia dei servizi è un fondamento importante del cloud computing che ha costituito la base dei modelli di consegna del cloud "as-a-service".

Comunemente preceduti da "basato su SOAP", i servizi Web rappresentano un mezzo comune e consolidato per la logica dei servizi sofisticati e basati sul Web. Insieme a XML, le tecnologie principali alla base dei servizi Web sono rappresentate dai seguenti standard di settore:

- WSDL (Web Service Description Language): questo linguaggio di markup viene utilizzato per creare una definizione WSDL che definisce l'interfaccia di programmazione dell'applicazione (API) di un servizio Web, comprese le sue singole operazioni (funzioni) e i messaggi di input e output di ciascuna operazione.
- XML Schema Definition Language (XML Schema): i messaggi scambiati dai servizi Web devono essere espressi utilizzando XML. Gli schemi XML vengono creati per definire la struttura dei dati dei messaggi di input e output basati su XML scambiati da servizi web.
- SOAP - Precedentemente noto come Simple Object Access Protocol, questo standard definisce un formato di messaggistica comune utilizzato per i messaggi di richiesta e risposta scambiati dai servizi Web. I messaggi SOAP sono composti da corpo e intestazione. Il primo ospita il contenuto principale del messaggio e il secondo viene utilizzato per contenere metadati che possono essere elaborati in runtime.
- Universal Description, Discovery, and Integration (UDDI): questo standard regola i registri dei servizi in cui le definizioni possono essere pubblicate come parte di un catalogo di servizi a scopo di rilevamento.

REST Service

I servizi REST sono progettati in base a una serie di vincoli che modellano l'architettura del servizio per emulare le proprietà del World Wide Web, risultando in implementazioni di servizi che si basano sull'uso delle tecnologie Web principali (descritte nella sezione Tecnologia Web).

A differenza dei servizi Web, i servizi REST non dispongono di interfacce tecniche individuali ma condividono invece un'interfaccia tecnica comune nota come contratto uniforme, che viene generalmente stabilita tramite l'uso di metodi HTTP.

Service Agents

Gli agenti di servizio sono programmi basati su eventi progettati per intercettare i messaggi in fase di esecuzione. Ci sono agenti di servizi attivi e passivi, entrambi comuni negli ambienti cloud. Gli agenti di servizio attivi eseguono un'azione dopo aver intercettato e letto il contenuto di un messaggio. L'azione in genere richiede di apportare modifiche al contenuto del messaggio (più comunemente dati dell'intestazione del messaggio e meno comunemente il contenuto del corpo) o modifiche al percorso del messaggio stesso. Agenti di servizio passivi, d'altra parte, non modificano il contenuto

del messaggio. Invece, leggono il messaggio e possono quindi catturarne per alcune parti i suoi contenuti, solitamente per scopi di monitoraggio, registrazione o reportistica.

Service Middleware

Rientra nella tecnologia di servizio il vasto mercato delle piattaforme middleware che si è evoluto da piattaforme middleware orientate alla messaggistica (MOM) utilizzate principalmente per facilitare l'integrazione, a sofisticate piattaforme middleware di servizi progettate per ospitare composizioni di servizi complesse. I due tipi più comuni di piattaforme middleware rilevanti per l'elaborazione dei servizi sono l'ESB (Enterprise Service Bus) e la piattaforma di orchestrazione. L'ESB comprende una gamma di funzionalità di elaborazione intermedia, tra cui intermediazione dei servizi, instradamento e accodamento dei messaggi. Gli ambienti di orchestrazione sono progettati per ospitare ed eseguire la logica del flusso di lavoro che guida la composizione del runtime dei servizi.

A Use Case: Social Security Public IT Company

DTGOV fornisce servizi sia di infrastruttura IT che software. DTGOV ha assemblato infrastrutture cloud-aware in ciascuno dei suoi data center, che sono costituite dai seguenti componenti:

- Infrastruttura della struttura di livello 3, che fornisce configurazioni ridondanti per tutti i sottosistemi centrali nel livello della struttura del data center.
- Connessioni ridondanti con fornitori di servizi di pubblica utilità che hanno installato capacità locale per la generazione di energia e l'approvvigionamento idrico che si attiva in caso di guasto generale.
- Una rete interna che fornisce un'interconnessione a larghezza di banda elevatissima tra i tre data center tramite collegamenti dedicati.
- Connessioni Internet ridondanti in ogni data center a più ISP e l'extranet. GOV, che interconnette DTGOV con i suoi principali clienti governativi.
- Hardware standardizzato di capacità aggregata più elevata, estratto da una piattaforma di virtualizzazione cloud-aware. I server fisici sono organizzati su rack di server, ciascuno dei quali dispone di due switch router top-of-rack ridondanti (livello 3) collegati a ciascun server fisico. Questi switch router sono interconnessi agli switch core LAN che sono stati configurati come cluster. Gli switch principali si collegano a router che forniscono funzionalità di internetworking e firewall che forniscono funzionalità di controllo dell'accesso alla rete.

Il cloud computing viene identificato come una linea guida, e identificati diversi punti chiave:

- Standardizzare i servizi, in modo da metterli all'interno di quelli che sono i modelli del cloud computing
- Capire le offerte che si danno ai clienti, in particolare quali servizi dovrebbero diventare cloud based
- Le sfide tecnologiche, cioè l'infrastruttura corrente è in grado di servire tali servizi
- Definire il contratto, che deve essere firmato dalle corrispondenti controparti economiche

Lezione – Cloud: A Paradigm Shift

Paradigm shift: an introduction

Il cloud computing rappresenta un cambiamento di paradigma. Questo perché il cloud computing è una tecnologia abilitante che aggira molte funzioni fornite dal tuo computer, dal software installato su di esso, dai dipartimenti IT e finanziari, dalle aziende e dai dipartimenti governativi del tuo posto di lavoro.

Per parlare di Paradigm Shift è importante conoscere uno strumento chiamato “Hype Cycle”. Uno degli aspetti importanti è come distinguere promesse ambiziose per nuovi servizi/mercati dall’esagerazione (Hype) che rende tutto quello che viene presentato imperdibile. Quando le nuove tecnologie fanno promesse audaci, come discernere l'hype da ciò che è commercialmente fattibile? E quando verranno ripagati tali crediti, se non del tutto? Gartner Hype Cycles fornisce una rappresentazione grafica della maturità e dell'adozione di tecnologie e applicazioni e di come queste siano potenzialmente rilevanti per risolvere problemi aziendali reali e sfruttare nuove opportunità. La metodologia Gartner Hype Cycle offre una visione di come una tecnologia o un'applicazione si evolverà nel tempo, fornendo una solida fonte di informazioni per gestire la sua implementazione nel contesto dei tuoi obiettivi aziendali specifici. Hype Cycle non è uno strumento statico ma uno strumento che in maniera dinamica e fluida mostra l’evoluzione lungo il tempo di una tecnologia in modo da prevedere il deployment/utilizzo all’interno del proprio obiettivo.

Come funzionano i cicli Hype?

Ogni ciclo di hype approfondisce le cinque fasi chiave del ciclo di vita di una tecnologia.

- **Innesco dell'innovazione:** una potenziale svolta tecnologica dà il via alle cose. Le prime storie di proof-of-concept e l'interesse dei media innescano una pubblicità significativa. Spesso non esistono prodotti utilizzabili e la fattibilità commerciale non è dimostrata.
- **Picco di aspettative gonfiate:** la pubblicità iniziale produce una serie di storie di successo, spesso accompagnate da decine di fallimenti. Alcune aziende agiscono; molti non lo fanno.
- **Trough of Disillusionment:** l’interesse diminuisce poiché gli esperimenti e le implementazioni non riescono a fornire. I produttori della tecnologia si scuotono o falliscono. Gli investimenti continuano solo se i fornitori sopravvissuti migliorano i loro prodotti con soddisfazione dei primi utenti.
- **Slope of Enlightenment:** più esempi di come la tecnologia possa portare benefici all'impresa iniziano a cristallizzarsi e ad essere più ampiamente compresi. I prodotti di seconda e terza generazione provengono da fornitori di tecnologia. Più imprese finanziano progetti pilota; le società conservatrici rimangono caute.
- **Altopiano della produttività:** l’adozione mainstream inizia a decollare. I criteri per valutare la redditività del fornitore sono definiti più chiaramente. L'ampia applicabilità e rilevanza del mercato della tecnologia sta chiaramente dando i suoi frutti.

Come viene usato Hype Cycle?

I clienti di Gartner la utilizzano per valutare le promesse di un’azienda all’interno della propria industria. La domanda che l’azienda/imprenditore è come muoversi sul mercato presto, prendendo

dei rischi che potrebbero essere ripagati da una ricompensa per l'adozione della tecnologia come primi nel mercato.

Disruptive Technology

È il cambiare la qualità di una stessa tecnologia, portarla da low a medium ad high non cambia la pendenza, ovvero la velocità con cui assicura maggiori prestazioni. È una tecnologia che riesce ad assicurare in maniera molto veloce il cambiamento, la qualità delle prestazioni, riesce a soppiantare le tecnologie perché assicura un altissimo pay-off in pochissimo tempo. Tale tecnologia permette di guardare il mondo con occhi diversi.

Il Paradigm Shift rappresenta un'importante caratteristica dei fenomeni sociali ed economici, evidenziando un cambiamento di direzione, rompendo gli equilibri e mettendo in evidenza nuovi bisogni che possono essere soddisfatti da nuove soluzioni. Il Paradigm Shift si divide in tre importanti categorie:

- Social Paradigm Shift
- Work Paradigm Shift
- Business Paradigm Shift

Social Paradigm Shift

Per considerare il cloud un cambio di paradigma nella vita sociale, vengono esaminati tre tipi di cloud che sarebbero i principali agenti di cambiamento:

- Societal/Community clouds
- Personal Cloud
- Cloud of Things



Societal/Community Clouds

Un cloud sociale è quello che serve un gruppo di persone che hanno qualcosa in comune. Ad esempio, quell'elemento comune potrebbe essere definito dalla geografia (lungo i confini di borgata, stato, nazionale o internazionale), hobby (filatelisti, numismatici, ecc.), Lingue o interessi (sindacati, scout, camere di commercio, ecc.).

Vantaggi o problemi comuni potrebbero essere presi in considerazione dai membri del cloud, che potrebbero ospitare, ad esempio, forum di discussione, messaggistica istantanea, archiviazione di documenti condivisi e videoconferenze. Tutto questo sarebbe stato fatto in un ambiente sicuro. Questo è un esempio di cloud sociale PaaS. Allo stesso modo, un cloud sociale potrebbe esistere a livello nazionale: per assistenza sanitaria, formazione, politica, agricoltura e simili. I dati raccolti potrebbero essere de-personalizzati e aggregati per fornire analisi di tendenza. Una community cloud, quindi fornisce un servizio a tutti quelli che hanno interessi, occupandosi di convertire i social-media in cloud sociali usando le caratteristiche del cloud. Da un punto di vista individuale, non è un paradigm shift in quanto siamo già abituati ad usare i social-media, tuttavia avere un social cloud che è un community cloud composto da cloud (un social cloud di cloud) consente di definire i servizi per i membri in modo unico e individuale. Pertanto, il cloud sociale, ad alto livello, funge da broker di servizi per i membri che appartengono a un cloud sociale e può personalizzare una società in base al background e agli interessi di un individuo.

Personal Cloud

Principalmente è qualcosa per single-user (Google Drive, Microsoft OneDrive, Apple iCloud...), come per il tempo libero e il benessere. In futuro, poiché l'archiviazione diventa più economica a causa delle economie di scala, si possono vedere cloud personali di streaming video che conservano una raccolta di film o clip video, ma anche altri cloud personali, come un portafoglio sanitario, potrebbero memorizzare informazioni sui medici che hai visitato per un periodo di tempo, oppure a livello finanziario, in particolare il tuo personal shopping cloud memorizzerebbe le tue preferenze di acquisto in base alla cronologia degli acquisti in tutti i negozi. Analizzerà quindi il tuo modello di acquisto e ti avviserà di ciò che devi acquistare in modo tempestivo utilizzando l'analisi predittiva. Potrebbe anche scansionare sconti o offerte in vari negozi, fisici o elettronici, per fornirti una scelta di acquisto. Inoltre, potrebbe gestire il tuo portafoglio elettronico in modo che tu possa pagare la merce in modo semplice e veloce.

Cloud of Things

Un cloud di cose è un servizio che aiuta la gestione o l'uso di una cosa (un'entità non vivente) da parte di una o più entità viventi. Quindi, ad esempio, potresti avere un cloud per la tua casa. Riceverà informazioni da una serie di sensori relativi a sicurezza, fumo, prossimità, luce e altri dispositivi installati e controllerà automaticamente anche altre cose come tende, allarmi antincendio, illuminazione e riscaldamento per te e gli altri residenti di quella casa. Inoltre, a seconda della stanza, ogni occupante di quella stanza avrebbe un profilo personalizzato in termini di quando è possibile tirare le tende o accendere l'illuminazione. Allo stesso modo, per il tuo ambiente di lavoro, potresti avere un cloud per le strutture. Un tale cloud è un esempio di BPaaS per via dei processi fisici che gestisce automaticamente a tuo vantaggio, come il disegno delle tende e il monitoraggio dell'illuminazione. Un altro esempio potrebbe essere un cloud per sale riunioni che tiene un registro della disponibilità della sala in modo da poter prenotare la sala riunioni per un determinato periodo, purché sia disponibile.

Work Paradigm Shift

Attualmente si stanno verificando due tendenze principali sul posto di lavoro:

- Postazioni di lavoro sostituite da zero o thin client.
- Informatica onnipresente: utilizza qualsiasi dispositivo per il lavoro.

Le workstation (laptop e desktop) vengono sostituite da macchine su cui non sono installate applicazioni. Tali macchine sono note come "Zero client" se hanno il sistema operativo incorporato nei chip di silicio o "Thin client" se richiedono un sistema operativo su disco. Affinché una workstation non abbia alcuna applicazione installata su di esso, è necessario utilizzare applicazioni basate su cloud per eseguire il proprio lavoro sulle workstation thin o zero client. I cloud che ospitano queste applicazioni possono avere diversi modelli di implementazione: possono essere cloud privati, pubblici, di comunità o personali, ad esempio. In genere, per applicazioni relative alla produttività come Office o E-mail, si utilizzerà un servizio di cloud pubblico mentre per le proprie applicazioni personalizzate, si utilizzerà un servizio di cloud privato. Ma le applicazioni non devono necessariamente essere basate su cloud; possono essere ospitate su server nel data center utilizzando computer fisici o virtuali tradizionali. Finché l'applicazione ti consente di accedere utilizzando un browser web, dovresti essere in grado di usarla indipendentemente dalla tecnologia sottostante per ospitarla. Il vantaggio di un ambiente di elaborazione zero o thin client è che il reparto IT della tua azienda non deve gestire tutte quelle applicazioni installate su un gran numero e varietà di workstation. Gestiscono invece una sola applicazione nel cloud o forniscono l'accesso a un'applicazione fornita da un servizio cloud di terze parti. Un altro vantaggio è che, poiché le workstation non contengono alcun disco locale o meccanismo di archiviazione dei dati, ma utilizzano

invece un archivio dati basato su cloud, le informazioni di lavoro vengono archiviate in un archivio dati centrale e, si spera, più sicuro. Ciò significa che se la workstation dovesse essere persa o rubata, quindi i dati dell'azienda non sarebbero compromessi. In effetti, in tal caso, la workstation zero o thin client sarebbe meno costosa da sostituire come la maggior parte dell'applicazione, l'hosting, l'archiviazione e l'elaborazione avvengono altrove, nel cloud.

L'informatica onnipresente è iniziata con le università che dovevano soddisfare una pletera di dispositivi informatici che gli studenti hanno portato al campus. Fornire accesso a applicazioni fornite dall'università e informazioni su vari dispositivi degli studenti significava che il dipartimento IT di un'università necessitava di consentire un modo sicuro per l'accesso a file e risorse dell'università sui dispositivi. Con lo sviluppo della tecnologia, è diventato noto come portare il proprio dispositivo (BYOD), attualmente adottato dalle aziende per fornire l'IT ai propri dipendenti. Ma informatica onnipresente è molto più che BYOD; significa che puoi calcolare e accedere alle informazioni aziendali da qualsiasi luogo, non solo dal campus o dal posto di lavoro, utilizzando qualsiasi dispositivo e in qualsiasi momento. L'inizio di un simile calcolo framework significa che il reparto IT diventa sempre più un broker di servizi cloud che mantiene un servizio di catalogo di applicazioni di cloud computing consentite per un file da utilizzare per scopi di lavoro. Quelle applicazioni basate su cloud, quindi possono essere utilizzate da qualsiasi luogo, in qualsiasi momento e su qualsiasi dispositivo.

Organizational and Business Paradigm Shift

La maggior parte delle aziende dispone di un reparto IT che si occupa di applicazioni centrali come server di posta e server Web. L'IT correlato all'attività aziendale viene eseguito localmente dalle unità o dai gruppi aziendali che si occupano direttamente della fornitura di un prodotto o servizio al cliente. Quindi si dispone di un modello hub-and-spoke in cui l'IT centralizzato funge da hub e i vari gruppi aziendali lavorano in modo autonomo nella periferia come portavoce. Se la funzione IT centrale non è a conoscenza delle applicazioni utilizzate dalle varie unità o gruppi dell'azienda, tali applicazioni e i relativi computer tendono a essere classificati come shadow IT. Se qualcosa dovesse andare storto con una simile applicazione o con il computer che la ospita, allora ci sarebbe un problema in termini di supportabilità. Un forte reparto IT centrale rifiuterebbe di supportare lo shadow IT, mentre uno debole lo supporterebbe a costo di sforzi aggiuntivi e denaro speso per imparare a conoscere il sistema. In ogni caso, lo shadow IT rappresenta una potenziale violazione della sicurezza oltre che una spesa aggiuntiva a causa della sua natura non standard. Per le aziende, lo shadow IT rappresenta quindi un rischio aziendale. Man mano che più applicazioni diventano disponibili tramite il cloud computing, è probabile che le unità aziendali aumentino la loro dipendenza dallo shadow IT perché la soglia di spesa verrà ridotta. A causa di un maggiore livello di astrazione fornito dal cloud computing, lo skillset richiesto per gestire e supportare lo shadow IT diminuirà e questo sarà un fattore determinante nella riduzione dei costi dello shadow. Pertanto, quasi tutto l'IT utilizzato in un'azienda è destinato a diventare basato sul cloud. Il dipartimento IT centrale, per sopravvivere, dovrà evolversi e diventare un broker di servizi cloud. Ciò garantirà che i dipartimenti aziendali siano autorizzati a lavorare in una struttura centralizzata semi-autonoma per quanto riguarda l'IT. Ciò garantirà ulteriormente che lo shadow IT diventi IT mainstream e quindi non sarà più classificato come shadow IT. In qualità di broker di servizi cloud, il reparto IT centrale diventerebbe un ramo specializzato del reparto acquisti, poiché la maggior parte delle risorse IT e di calcolo verrebbero acquistate come servizi o utilizzate su base pay-as-you-go. La maggiore mercificazione dell'IT dovuta al cloud computing e alle tecnologie correlate lo renderà più possibile poiché il requisito di competenze tecniche per utilizzare e acquistare IT diminuisce. La funzione del reparto IT si evolverà in quella che mantiene i contratti di servizio cloud con i fornitori di servizi cloud, i cui servizi sarebbero elencati e descritti in un catalogo di servizi cloud che il reparto IT manterrebbe.

Quindi con il Business Paradigm Shift l'IT Department fornisce supporto per l'intera azienda, ovvero supporto IT all'interno dell'azienda. Il punto cruciale è che spesso c'è uno scollamento tra quello che è la gestione dell'IT e quella che è legata al business, spesso gestita localmente dalla Business Unit, in maniera da essere più vicini ai bisogni della Business Unit e gestiscono internamente la propria IT.

Lezione – Price Models

Ogni impresa ha un costo e un vantaggio ad essa associati. Il consumo di servizi cloud non è diverso. Per compensare il prezzo pagato per il servizio cloud, è necessario realizzare un vantaggio proporzionato. Questo vantaggio viene valutato considerando modelli di valore che possono essere correlati al cloud computing. Avere una comprensione dei modelli di prezzo e valore consentirà di confrontare i vari servizi di cloud computing in modo obiettivo. Da questo ne risulta che:

- **Price Models:** Quello che definisce il cloud provider. È il “Quanto costa”, definito dal provider.
- **Value Models:** Quello che il cliente deve considerare per valutare in maniera quantitativa i benefici di cui godrà utilizzando un certo tipo di servizi. È il “Quanto è di valore/beneficio questo servizio” visto da consumer.

Price Model

I Price model forniscono un mezzo per stabilire il prezzo da pagare per ricevere il valore di un prodotto o servizio. Un fornitore di servizi cloud calcolerà i costi di provisioning e funzionamento di un servizio cloud utilizzando un modello di costo. Il modello di costo verrà quindi convertito in un modello di prezzo. Il tipo di modello di prezzo selezionato dipenderà dal modello di business, dalla strategia di marketing e dalle aspettative di entrate del fornitore di servizi cloud. Per confrontare i servizi cloud in modo obiettivo, è importante conoscere i vari tipi di modelli di prezzo. Ogni modello di prezzo inizia la sua vita come modello di costo. Il modello di costo è un modello finanziario che il fornitore di servizi cloud crea per scoprire quanti soldi spendere su un particolare servizio per crearlo, gestirlo e quindi aggiornarlo alle nuove tecnologie dopo tre anni. Tre anni è la normale durata della tecnologia prima che diventi obsoleta e cinque anni è generalmente il massimo assoluto che il fornitore di servizi cloud avrà prima di sostituire tale tecnologia. Il modello di costo includerà fattori quali inflazione, variazioni del tasso di cambio (se applicabile), deprezzamento, costi dell'elettricità (questi possono essere significativi a causa dell'alimentazione e del raffreddamento richiesti da un gran numero di server), costi di spazio, costi di licenza software, costi di manodopera e costi di capitale per acquistare e gestire i server. Alla somma di tutti i costi vengono aggiunti un margine e un fattore di rischio per arrivare a un prezzo.

Il prezzo avrà due caratteristiche: un elemento non ricorrente e uno ricorrente. L'elemento non ricorrente del prezzo viene convertito in un elemento ricorrente ammortizzando il valore attuale netto in una serie di flussi di cassa ricorrenti. Questi flussi di cassa vengono quindi aggiunti all'elemento ricorrente per arrivare a un prezzo mensile per la fornitura del servizio. Questo prezzo ricorrente è espresso come modello di prezzo e questo prezzo viene utilizzato per vendere e commercializzare il servizio cloud. Esistono diversi modelli di prezzo. In generale, classificandoli come modelli orientati all'utilità, ai servizi, alle prestazioni e al marketing. Sebbene il cloud computing oggi utilizzi principalmente modelli di prezzo basati su utilità e servizi, viene presa in considerazione un'ampia gamma di modelli perché l'innovazione finanziaria e aziendale è destinata a recuperare il ritardo con l'innovazione tecnica, consentendo così ad alcuni dei modelli meno utilizzati di entrare nel dominio del cloud computing in futuro.

Utility Price Models

I modelli di utilità sono modelli di prezzo misurato in base ai quali viene monitorato l'utilizzo del servizio e si paga di conseguenza, che derivano dai piani tariffari adottati dalle società di servizi e sono caratterizzati da pagamenti regolari, spesso mensili, al provider di servizi cloud. Sono presenti tre diverse tipologie di utility price model basati su consumo, transazione e abbonamento.

- **Consumption-based Price Model:** Il Consumption-based è un modello comunemente utilizzato per IaaS e PaaS. Paghi per le risorse di elaborazione che utilizzi, ad esempio la quantità di spazio di archiviazione (in Megabyte o Gigabyte), la potenza di elaborazione o di elaborazione (in termini di cicli della CPU o numero di core del processore utilizzati) e la memoria (in Megabyte o Gigabyte). Un tasso di consumo medio di queste risorse viene calcolato su un giorno, una settimana o un mese e tu paghi per l'utilizzo medio. Questo è un modello piuttosto rozzo che non si adatta bene a SaaS, INaaS o BPaaS, poiché per queste risorse vuoi essere addebitato in modo significativo quando si tratta di come opera la tua azienda. Ad esempio, per un servizio INaaS che fornisce le ultime norme fiscali, non dovresti davvero preoccuparti di quanti core CPU o memoria vengono utilizzati per fornire tale informazioni a te. Tuttavia, per il fornitore di servizi cloud, potrebbero esserci altri componenti che contribuiscono al costo della fornitura del servizio, come licenze dell'applicazione, raccolta di dati e costi di manutenzione. Quindi per SaaS, INaaS o BPaaS, altri modelli di prezzo sono più appropriati.

- **Transaction-based Price Model:** La determinazione del prezzo basata sulle transazioni utilizza le transazioni invece delle risorse di elaborazione, come base per la determinazione del prezzo. Le transazioni possono essere d'affari correlati, come fatture elaborate per un BPaaS di fatturazione, dati relativi a INaaS o applicazioni relative a SaaS. Puoi anche avere prezzi basati sulle transazioni con IaaS e PaaS, ad esempio, utilizzando la larghezza di banda come indicatore dell'utilizzo delle risorse di elaborazione; quindi, un modello di prezzo basato sul consumo può essere convertito in un modello basato su transazione valutando la larghezza di banda utilizzata da ciascuna transazione.

Il costo di una transazione viene calcolato dividendo il costo della fornitura di un servizio cloud per il volume stimato delle transazioni in un determinato periodo. Questo è quindi il prezzo unitario della transazione. Questo modello di prezzo è adatto nelle seguenti circostanze:

- I volumi delle transazioni sono noti e prevedibili.
- Il processo aziendale può essere definito chiaramente e può essere misurato in unità distinte per rappresentare una transazione.
- Il volume delle transazioni è legato ai fattori di costo.
- Dal punto di vista del fornitore di servizi cloud: quando i processi aziendali sono standardizzati e guidati dalle transazioni.

Il prezzo delle transazioni è più adatto per i livelli di astrazione INaaS e BPaaS ed è ugualmente adatto a tutti i modelli di distribuzione cloud.

- **Subscription-based price model:** Simile al modello all-you-can-eat, il modello Subscription-based è quando paghi un prezzo, solitamente mensile, per utilizzare un servizio. Ad esempio, quando ti iscrivi a una rivista, paghi una tariffa regolare indipendentemente dal fatto che tu la legga effettivamente tutta, in parte o nessuno dei suoi articoli. Con l'inizio delle riviste basate sul web o dei portali di notizie, il contenuto viene aggiornato abbastanza spesso, quindi il contenuto non è un importo fisso come con una rivista cartacea. Il pagamento di un abbonamento per un tale servizio si avvicina al modello all-you-can-eat poiché la tua capacità di consumare diventa inferiore al tasso di nuovi contenuti prodotti. A volte c'è un periodo contrattuale durante il quale sei tenuto a pagare l'abbonamento. Nel cloud computing, ad esempio, avresti una tariffa mensile per le risorse di elaborazione che ti vengono assegnate e pagheresti l'importo mensile indipendentemente dal fatto che tu abbia utilizzato quelle risorse allocate. Inoltre, potresti avere un periodo di preavviso di tre mesi tale che, se decidi di non utilizzare più il servizio, dovrai fornire

un preavviso tre mesi prima. Il prezzo dell'abbonamento può essere utilizzato bene per tutti i modelli di distribuzione cloud e i livelli di astrazione.

Service Price Models

I modelli di servizio utilizzano i vantaggi che vengono forniti, come lo SLA, il trasferimento del rischio o il denaro risparmiato, come criteri per definire il prezzo da pagare per il servizio cloud. In generale, il modello a prezzo fisso è un modello di trasferimento del rischio, mentre gli altri due modelli discussi, volume e livelli, offrono in gran parte vantaggi economici e di servizio a te come utente cloud.

Mentre i Consumption based si riferiscono ad un consumo di risorse, con i Service price model si parla di un servizio per il quale possono essere quantificati i benefici dati, in accordo a quello che è un Service Level Agreement. La differenza tra i Consumption based e Service price model sta nel fatto che il servizio deve essere fornito con una qualità concordata tra produttore e consumatore come accettabile all'interno del Service Level Agreement. Sono presenti tre categorie:

- **Fixed price model:** Il prezzo da pagare per questo servizio è fissato su base annuale, trimestrale o mensile. Il prezzo fisso può essere costituito da due componenti: prezzi ricorrenti e prezzi non ricorrenti. Quest'ultimo è un importo una tantum che paghi all'inizio seguito da pagamenti ricorrenti a intervalli regolari. Il modello a prezzo fisso viene generalmente scelto quando si dispone di un ambito chiaramente definito e allineato ai propri obiettivi a breve termine. Sebbene venga utilizzato per trasferire i rischi relativi alla consegna, alle persone e alla qualità, sarai comunque responsabile del rischio dell'ambito del servizio decidendo quanto del servizio utilizzare e in che misura. Il trasferimento del rischio avviene tramite gli SLA definiti e concordati con il provider di servizi cloud. Il prezzo fisso può essere utilizzato bene per tutti i modelli di distribuzione cloud e i livelli di astrazione.
- **Volume price model:** Il volume può essere correlato al numero di utenti, alla quantità di spazio di archiviazione, alla velocità delle transazioni (indicata come numero di transazioni al minuto o all'ora), alla quantità di larghezza di banda o alla potenza di elaborazione utilizzata, ad esempio. Ognuno di questi parametri può essere utilizzato come base per decidere il prezzo da pagare per il servizio cloud. Poiché il volume varia nel tempo, nel ciclo economico o in eventi come una campagna di marketing, il prezzo cambia periodicamente. È quindi imperativo definirlo, calcolarlo e misurarlo. Ad esempio, il prezzo per un servizio di elaborazione thin client in cui i dipendenti utilizzano servizi cloud su un modello di prezzo basato sul volume potrebbe essere calcolato sulla base di utenti medi, utenti di picco, utenti allocati o utenti simultanei al giorno o una combinazione di questi. Considerazioni simili si applicherebbero ad altri parametri, se invece devono essere utilizzati nel prezzo del volume. Sebbene il prezzo del volume sia utilizzato più spesso in IaaS e PaaS, è altrettanto adatto per gli altri livelli di astrazione.
- **Tiered price model:** Tale modello utilizza una forma di prezzo a più livelli che si basa su SLA, volume o importo speso. È simile ai livelli che le compagnie aeree hanno per i loro livelli di iscrizione, determinati dall'importo speso per viaggiare con la compagnia aerea. Con il cloud computing, una forma simile di prezzi differenziati può essere applicata con sconti maggiori a condizione che si spenda un determinato importo ogni anno. In alternativa, potresti avere livelli basati sugli SLA in modo tale che più rigorosi sono gli SLA, più paghi. Quindi il concetto è che definendo dei tier, con utente basic, premium ecc... e a seconda del costo viene offerto qualcosa di diverso, dando dei vantaggi in base alla spesa del consumer. Queste fasce, o livelli, che definiscono i prezzi sulla base del volume rappresentano un modello di prezzo a più livelli, e la base per la creazione dei livelli può essere il volume, gli SLA o l'importo speso. I prezzi a livelli possono essere utilizzati per tutti i modelli di distribuzione cloud e per i livelli di astrazione.

Performance Price Models

I modelli di performance sono modelli basati su benchmark che si basano su metriche chiave per decidere il prezzo pagato. La maggior parte dei modelli di prestazioni derivano dalla remunerazione dei dipendenti o dalle strategie di prezzo correlate all'outsourcing, ma possono essere applicate al cloud computing, in particolare a un servizio cloud privato o ibrido. A volte questi modelli vengono utilizzati per allineare gli obiettivi di business a quelli del tuo fornitore di servizi al fine di creare una vera partnership. I modelli di prezzo delle prestazioni mostrano alcuni tratti comuni:

- Richiedono un output o una metrica chiaramente definiti che possono essere misurati facilmente.
 - La metrica è spesso allineata a un processo o risultato aziendale con una correlazione dimostrabile al suo impatto. Consideriamo qui il risultato, i modelli di prezzo legati alle imprese e quelli basati sul guadagno delle azioni come rientranti nella categoria dei modelli di performance.
- **Outcome-Based Price Model:** Se il dipartimento vuole utilizzare il cloud computing perché vuole ridurre il time to market (essendo questo uno dei sette modelli di valore), allora potresti voler negoziare un pagamento "bonus" al fornitore di servizi cloud che è collegato a quel risultato. La maggior parte dei risultati utilizza metriche relative alla proposta di valore del cloud computing, come espressa dai modelli di valore. C'è una differenza in psicologia tra il modello basato sui risultati e alcuni modelli di prezzo correlati alle prestazioni. Con il primo, fornisci un bonus se viene raggiunto un risultato, e con il secondo, penalizzi il fornitore se uno SLA o un vantaggio non viene realizzato. I modelli basati sui risultati sono spesso usati con altri modelli, solitamente fixed price model al fine di creare una cultura del valore basata sui premi.
 - **Business-Linked Price Model:** Mentre i modelli basati sui risultati utilizzano metriche che misurano il valore del cloud computing, i modelli collegati al business misurano il contributo che il cloud computing fornisce ai KPI(Key Performance Indicator) che influenzano il modello di business. Una delle sfide è collegare i risultati aziendali al contributo fornito dal cloud computing.
 - **Gain-Share Price Model:** Il modello della quota di guadagno ha le sue radici nei sistemi di remunerazione dei dipendenti. L'idea è che man mano che l'organizzazione guadagna, condivide alcuni di questi guadagni con i suoi dipendenti. Una tipica organizzazione di condivisione dei guadagni misura le proprie prestazioni e condivide i profitti con tutti i suoi dipendenti utilizzando una formula predeterminata. Le prestazioni effettive dell'organizzazione vengono confrontate con la sua media storica (nota come prestazioni standard o di base) per determinare l'ammontare del guadagno. In un contesto di cloud computing, invece di subire sanzioni nel caso in cui determinati SLA non vengano rispettati, ricompensi il fornitore di servizi condividendo i tuoi profitti se gli SLA vengono superati. È un approccio psicologico diverso. Tuttavia, è possibile combinare il modello di condivisione del guadagno con un modello di prestazioni basato su penalità per creare un modello di prestazioni ibrido.

Marketing Price Models

Alcuni modelli di prezzo sono guidati dal marketing piuttosto che dalle prestazioni. Il fattore chiave alla base di tali modelli è attrarre il maggior numero possibile di utenti e quindi monetizzarli per creare un profitto. In questa sezione vengono discussi due modelli di prezzo basati sul marketing.

- **Freemium price model:** Esistono due tipi di freemium. Uno è dove provi prima di acquistare un servizio più avanzato, e l'altro tipo è dove ottieni un servizio gratuito ma gli annunci pubblicitari forniti aumentano i modelli di prezzo e valore per il prezzo del servizio. Questo modello è particolarmente adatto a SaaS perché molte società di software come LinkedIn e Dropbox lo usano bene. Offrono una versione gratuita del loro prodotto che ha funzionalità limitate ma ti offre la possibilità di pagare per un servizio premium con funzionalità extra. L'idea è di offrire un

valore sufficiente agli utenti nella versione gratuita per attrarli e trattenerli, mentre nella versione avanzata per garantire che gli utenti convertano e massimizzino le entrate del fornitore di servizi.

- **Razor-and-Blades Price Model:** Questo modello di determinazione del prezzo si basa su due componenti, un componente di base e un componente riutilizzabile di cui il componente di base necessita fornire un servizio. È come vendere rasoi a buon mercato, o addirittura regalarli gratuitamente, e poi compensare con i prezzi delle lame consumabili. Nel cloud computing, un dispositivo o un'app che utilizza un servizio cloud può essere dato via, ma il prezzo può essere costituito dai dati archiviati, analizzati e presentati dal servizio cloud. Ad esempio, potresti avere un monitor della pressione sanguigna che invia automaticamente i dati a un servizio cloud, che quindi archiverà e analizzerà i dati, che utilizzerà per avvisarti se viene superato un determinato livello di pressione sanguigna. Il sensore potrebbe essere fornito gratuitamente o ad un prezzo ridotto mentre si pagherebbe l'utilizzo del servizio cloud che rende significative le informazioni del sensore. Un altro esempio di questo è il kindle di Amazon che può fungere da finestra su un negozio virtuale da cui è possibile acquistare un'ampia varietà di prodotti.


Hybrid Price Models

I modelli di prezzo di utilità, servizio e prestazioni non si escludono a vicenda; possono essere combinati per produrre modelli di prezzo ibridi. Ad esempio, potresti avere un sistema basato su abbonamento che utilizza un approccio a più livelli. Se la spesa in dollari all'anno dovesse essere a un certo livello, allora quel livello deciderebbe lo sconto da applicare. Un altro approccio sarebbe quello di combinare il trasferimento del rischio del modello fisso con l'accessibilità economica di uno dei modelli di prezzo di utilità per fornire un prezzo fisso, mensile, all'utente in modo tale che possa consumare la quantità di servizio che desidera per quello canone mensile fisso. Questo tipo di modello di prezzo ibrido è abbastanza comune a molti servizi di cloud pubblico come Google docs e Microsoft Office 365. In effetti si tratta di un buon modello di prezzo per servizi di grandi dimensioni o a lungo termine, soprattutto se devono essere perfezionati nel tempo. Il modello di prezzo ibrido può essere applicato con successo a tutti i livelli di astrazione del cloud e ai modelli di distribuzione.

Lezione – Value Models

Il valore è generalmente qualcosa che un utente ricava quando compensa i vantaggi di un servizio con il suo costo. La somma totale dei vantaggi può essere considerata come quelle che dovresti specificare o ricevere come parte dello SLA. Se dovessi sottrarre i costi del cloud computing dalla somma totale dei benefici, arriveresti a una somma tangibile che connota valore. Il valore, quindi, comprende un'analisi costi-benefici poiché essenzialmente calcola i benefici meno i costi. In varie discipline esistono diversi tipi di modelli di valore. Solo per citarne alcuni, ci sono il modello del valore dell'aspettativa dell'utente, il modello del valore del luogo e il modello del valore del cliente. Per i nostri scopi nel cloud computing, un modello di valore è un modello standard che definisce il valore per te, come utente del cloud computing, e che è comune a un numero di utenti in situazioni simili. Considerando i vari vantaggi del cloud computing, esaminiamo sette modelli di valore del cloud computing:


1. **Operating Expense:** Per fornire un servizio di elaborazione, il reparto IT dovrebbe spendere un capitale in anticipo per creare e mantenere il servizio. Affinché tale servizio rimanga entro i limiti degli SLA, il reparto IT dovrebbe creare capacità aggiuntiva (extra-capacity), per ad esempio mantenere i requirements in tempi duri. Tutta questa spesa in conto capitale rappresenta un'opportunità di costo poiché il capitale avrebbe potuto essere impiegato altrove per perseguire un'opportunità di business. Al contrario, se la domanda effettiva supera la capacità di calcolo in cui hai investito il capitale, la domanda extra non sarà soddisfatta o si tradurrà in SLA degradati. Il risultato finale sarà una perdita di opportunità per l'attività, poiché la domanda non soddisfatta causerà una perdita di affari per l'azienda. Il modello di spesa operativa del cloud computing utilizza l'elasticità per evitare costi e perdite di opportunità. In generale tutto quello che è speso per l'IT potrebbe essere usato altrove.



La curva inclinata verso l'alto per la capacità di calcolo si basa su due presupposti che non si escludono a vicenda: che la domanda aziendale crescerà e che una maggiore automazione (cioè elasticità e risorse) sarà resa disponibile nel tempo tramite il cloud computing.


2. **User Domain Flexibility:** Ogni prodotto o servizio che un'azienda fornisce ai clienti ha un ciclo di vita che comprende sviluppo, test, lancio, marketing e normale utilizzo aziendale. Durante ciascuna di queste fasi, vengono poste richieste diverse al calcolo in modo da avere periodi costituiti da picchi e avvallamenti durante l'intero ciclo di vita. Per assicurare di soddisfare

tutte queste richieste, si dovrà investire e disinvestire nell'overprovisioning della capacità di elaborazione. In ogni caso, ci saranno inevitabilmente periodi in cui la domanda sarà semplicemente insoddisfatta, specialmente durante i lanci dei prodotti e le iniziative di marketing.




Il modello di flessibilità della domanda del cloud computing utilizza l'elasticità per garantire che le varie richieste di elaborazione durante il ciclo di vita del prodotto vengano soddisfatte in base alle necessità. Ciò significa che l'investimento nell'informatica è essenzialmente il prezzo che si paga per i servizi di elaborazione flette al variare della domanda nel ciclo di vita del prodotto.

3. **Price Flexibility:** Nel tempo la tendenza generale del prezzo del computing, indipendentemente dal fatto che sia tradizionale o cloud, è al ribasso. Ciò è dovuto alle nuove tecnologie che entrano in scena a un ritmo veloce e su base regolare. Un altro fattore che contribuisce alla tendenza al ribasso sono le economie di scala derivanti dall'adozione di nuove tecnologie man mano che quelle più vecchie raggiungono l'obsolescenza. Il cloud computing dà la possibilità di introdurre ulteriormente un cambiamento graduale nella curva dei prezzi al ribasso utilizzando diversi modelli di prezzo al variare delle esigenze e dei requisiti di volume. Quindi, ad esempio, a volumi inferiori, un modello di prezzo al consumo potrebbe essere ottimale per te, mentre un modello di prezzo a prestazioni potrebbe essere più adatto a volumi più elevati. Avere la possibilità di cambiare il modello di prezzo, utilizzando lo stesso provider di servizi cloud o passando a un altro, consente di ricevere un maggior rapporto qualità-prezzo.



Pertanto, il modello di valore della flessibilità del prezzo del cloud computing, come illustrato nella figura, utilizza diversi modelli di prezzo per ridurre i costi di elaborazione nel tempo al variare della domanda, del volume e delle circostanze. I modelli Tiered e Hybrid sono esempi in cui il fornitore di servizi cloud ne approfitta per offrirti sconti maggiori con aumenti di volume.

4. **Agility for Time to Market:** Il modello di valore time-to-market del cloud computing riduce il tempo necessario per accedere al mercato consentendo di passare da un ambiente di elaborazione a un altro a un ritmo più rapido. Questo perché non è necessario dedicare tempo alla messa in servizio dell'infrastruttura e degli ambienti di elaborazione in anticipo, come nel caso dei computer tradizionali. Piuttosto, in un attimo, si può avere a disposizione un numero qualsiasi di risorse di elaborazione da utilizzare per distribuire l'applicazione o il servizio aziendale.
5. **Location Flexibility:** Il modello di location flexibility del cloud computing consente di accedere al proprio ambiente di elaborazione e lavorare da qualsiasi luogo a causa della natura onnipresente del computer. Questa flessibilità aumenta la produttività e consente di avere una portata globale, che con il cloud viene raggiunto implicitamente senza richiedere un investimento separato e distinto. Ogni compagnia ha già un mercato world-wide e questo è fondamentale.
6. **Asset Optimization:** Il modello di asset optimization del cloud computing è simile al modello del valore della flessibilità della domanda, tranne per il fatto che la prospettiva è diversa. Si cerca di ottimizzare le risorse fisiche che l'azienda possiede, ed essenzialmente tra gli aspetti che si evitano vi è la necessità di investimenti extra per evitare una perdita di reputation. Tutto ciò presuppone che il ciclo di vita dell'asset che influenza l'investimento segua il ciclo di vita del prodotto. Questo ha degli aspetti importanti, tra cui l'ottimizzazione, infatti quando si avvicina la fine del ciclo di vita del servizio, rimane un'infrastruttura di elaborazione aggiuntiva che occupa spazio inutile e quindi funge da drenaggio del flusso di cassa.
7. **Profit Margin:** Quando si produce un bene o un servizio, i costi a valore aggiunto (comprese le spese generali) diminuiscono di circa il 25% ogni volta che il volume cumulativo, o la tua esperienza accumulata, raddoppia. Ciò si traduce in una curva dei prezzi inclinata verso il basso che aumenta i profitti con l'esperienza, e questa curva dei prezzi è nota come "curva dell'esperienza".



Il cloud computing è un cambiamento evolutivo, sebbene rivoluzionario in termini di applicazione, al computing tradizionale mentre attinge l'esperienza cumulativa dell'informatica. In quanto tale, rappresenta uno spostamento verso destra nella curva dell'esperienza informatica tradizionale. Questo sposta il punto di pareggio per l'utilizzo di un servizio di cloud computing in outsourcing, aumentando ulteriormente il margine di profitto. Ciò è mostrato nella figura, che è un adattamento della curva di

esperienza del BCG del margine di profitto anziché dei costi. In effetti, una delle proposte di valore del cloud computing è che aumenta il margine di profitto più del computing tradizionale a causa dell'effetto della curva dell'esperienza.

Financial Metrics

Come traduci il valore che il cloud computing ti fornisce in una misura finanziaria significativa? Esistono vari parametri finanziari che possono essere utilizzati per valutare la proposta di valore

di un servizio cloud. Possiamo considerare quattro parametri finanziari comuni: Payback Method, Net Present Value (NPV), Return on Investment (ROI), and Time To Market (TTM).

- **Payback Method:** Il metodo di rimborso misura il tempo necessario per recuperare il tuo investimento in un prodotto o servizio. Un servizio che ha un periodo di rimborso più breve è considerato migliore di uno che ha un periodo più lungo. Di solito il metodo di rimborso è più adatto per la spesa in conto capitale perché è possibile ammortizzarlo in un certo numero di anni. Uno degli svantaggi del metodo di rimborso è che non tiene conto del valore temporale del denaro, che può avere un'incidenza sostanziale sul calcolo dell'investimento in periodi di tassi di interesse elevati o per lunghi periodi di tempo. A tale scopo, vengono solitamente utilizzati i calcoli del valore attuale netto (NPV).
- **Return On Investment (ROI):** Mentre il metodo di ammortamento considera il tempo necessario per recuperare l'investimento, il ritorno sull'investimento (ROI) utilizza la percentuale dell'importo dell'investimento che verrà recuperato. Il ROI è ampiamente utilizzato nel settore IT per valutare gli investimenti di capitale. La formula per il ROI è:
$$\text{ROI} = \frac{\text{Guadagno dall'investimento} - \text{Costo dell'investimento}}{\text{Costo dell'investimento}}$$
 Anche qui non c'è la considerazione del tempo.
- **Net Present Value (NPV):** Quando si hanno più flussi di cassa che si verificano regolarmente, tali flussi sono chiamati flusso di flussi di cassa. Quando i flussi di cassa regolari hanno un valore uguale, i flussi di cassa sono noti come rendite. A causa dell'effetto dell'inflazione e dei tassi di interesse nel tempo, un importo di flusso di cassa di \$ 1.000 il mese prossimo vale più dello stesso importo pagato cinquanta mesi dopo. Per valutare il valore attuale di una serie di flussi di cassa, utilizziamo i calcoli NPV. Il NPV di un investimento è il valore attuale di tutti i benefici futuri, come i flussi di cassa, generati dall'investimento al netto dei costi iniziali, scontati su intervalli di tempo. Ad esempio, riceverai \$ 1.000 ogni anno per tre anni e il tasso di interesse è del 10 per cento. Attualizzi questi flussi di cassa con il tasso di interesse, quindi aggiungi i valori scontati per ottenere un valore attuale netto di \$ 2.486,85. Se avessi fatto un investimento iniziale di \$ 2.000 per ottenere quei flussi di cassa, sottrarre l'investimento iniziale dai flussi di cassa scontati per ottenere un NPV di \$ 486,85, e questo rappresenterebbe quindi un profitto del 24,3% per il tuo investimento di \$ 2000. Sebbene l'analisi NPV sia spesso utilizzata per giustificare le spese in conto capitale, è possibile utilizzarla per eseguire un'inversione di calcolo per elaborare le spese ricorrenti rappresentate da quella spesa in conto capitale. Pertanto, NPV fornisce un mezzo per convertire CapEx in OpEx e viceversa. I vantaggi dell'utilizzo dell'analisi NPV sono la relativa precisione dei risultati dovuta all'uso del valore temporale del denaro e la semplicità nell'interpretazione dei suoi risultati: un aspetto positivo NPV indica un investimento redditizio. Un altro vantaggio del NPV è che i costi opportunità sono contabilizzati implicitamente a causa dell'uso di un tasso di sconto. Pertanto, se un tasso di rendimento previsto è inferiore al tuo tasso di rendimento minimo o al tuo tasso di rendimento desiderato, non faresti l'investimento.
- **Time to Market (TTM):** La stima del tempo in cui si otterranno i ricavi è un altro parametro finanziario che può essere utilizzato. Ad esempio, supponiamo che utilizzando i computer tradizionali ci vorrebbe un anno per lanciare sul mercato una nuova offerta che stai sviluppando. Con il cloud computing, invece, potrebbero volerci tre mesi. Quindi il TTM sarà nove mesi prima. E se guadagnerai \$ 20.000 al mese con il nuovo sistema, il precedente TTM rappresenterebbe un afflusso aggiuntivo di \$ 180.000. In questo modo puoi esprimere TTM come tempo così come il suo equivalente in termini monetari.

Lezione – Cloud Security

Basic Terms and concepts

Information Security

La sicurezza delle informazioni è un insieme complesso di tecniche, tecnologie, normative e comportamenti che proteggono in modo collaborativo l'integrità e l'accesso ai sistemi e ai dati informatici. Le misure di sicurezza IT mirano a difendersi da minacce e interferenze che derivano sia da intenti dannosi che da errori non intenzionali dell'utente. Lo scopo è proteggere l'integrità e l'accesso ai sistemi e dati sia da agenti maliziosi sia da errori.

Confidentiality: La riservatezza è la caratteristica di qualcosa che viene reso accessibile solo alle parti autorizzate. All'interno degli ambienti cloud, la riservatezza riguarda principalmente la limitazione dell'accesso ai dati in transito e archiviazione. Un messaggio tra cloud consumer e provider può essere visto e intercettato mentre sta viaggiando

Integrity: L'integrità è la caratteristica di non essere stata alterata da una parte non autorizzata. Una questione importante che riguarda l'integrità dei dati nel cloud è se a un utente cloud può essere garantito che i dati che trasmette a un servizio cloud corrispondano ai dati ricevuti da quel servizio cloud. L'integrità può estendersi al modo in cui i dati vengono archiviati, elaborati e recuperati dai servizi cloud e dalle risorse IT basate sul cloud.

Authenticity: L'autenticità è la caratteristica di qualcosa che è stato fornito da una fonte autorizzata. Questo concetto comprende il non ripudio, ovvero l'incapacità di una parte di negare o contestare l'autenticazione di un'interazione. L'autenticazione nelle interazioni non ripudiabili fornisce la prova che queste interazioni sono collegate in modo univoco a una fonte autorizzata. Ad esempio, un utente potrebbe non essere in grado di accedere a un file non ripudiabile dopo la sua ricezione senza generare anche un record di questo accesso. Non solo si riesce a risalire a chi ha prodotto un certo dato, ma anche di poter evitare che qualcuno dica che quel dato non è stato prodotto da lui. In questa maniera si è in grado di dire che qualcosa è collegata ad una sorgente autorizzata.

Availability: La disponibilità è la caratteristica di essere accessibile e utilizzabile durante un periodo di tempo specificato. In ambienti cloud tipici, la disponibilità dei servizi cloud può essere una responsabilità condivisa tra cloud service provider e cloud carrier. La disponibilità di una soluzione basata su cloud che si estende ai consumatori di servizi cloud è ulteriormente condivisa dal consumatore di cloud.

Threat: Una minaccia è una potenziale violazione della sicurezza che può mettere in discussione le difese nel tentativo di violare la privacy e/o causare danni. Le minacce istigate manualmente e

automaticamente sono progettate per sfruttare i punti deboli noti, denominati anche vulnerabilità. Una minaccia eseguita si traduce in un attacco.

Vulnerability: Una vulnerabilità è una debolezza che può essere sfruttata perché è protetta da controlli di sicurezza insufficienti o perché i controlli di sicurezza esistenti vengono superati da un attacco. Le vulnerabilità delle risorse IT possono avere una serie di cause, tra cui carenze di configurazione, debolezze dei criteri di sicurezza, errori degli utenti, difetti hardware o firmware, bug software, un'architettura di sicurezza scadente.

Risk: Il rischio è la possibilità di perdite o danni derivanti dallo svolgimento di un'attività maliziosa. Il rischio viene generalmente misurato in base al livello di minaccia e al numero di vulnerabilità possibili o note. Due metriche che possono essere utilizzate per determinare il rischio per una risorsa IT sono:

- la probabilità che si verifichi una minaccia per sfruttare le vulnerabilità della risorsa IT
- l'aspettativa di perdita in caso di compromissione della risorsa IT

Security Controls: I controlli di sicurezza sono contromisure utilizzate per prevenire o rispondere minacce alla sicurezza e per ridurre o evitare il rischio. I dettagli su come utilizzare le contromisure di sicurezza sono generalmente delineati nella policy di sicurezza, che contiene una serie di regole e pratiche che specificano come implementare un sistema, un servizio o un piano di sicurezza per la massima protezione delle risorse IT sensibili e critiche.

Security Mechanisms: Le contromisure sono generalmente descritte in termini di meccanismi di sicurezza, che sono componenti che comprendono un framework difensivo che protegge risorse IT, informazioni e servizi.

Security Policies: Una politica di sicurezza stabilisce una serie di regole e regolamenti di sicurezza. Spesso, le politiche di sicurezza definiranno ulteriormente il modo in cui queste regole e regolamenti vengono implementati e applicati. Ad esempio, il posizionamento e l'utilizzo dei controlli e dei meccanismi di sicurezza possono essere determinati dalle politiche di sicurezza. È il Cloud Service Owner che si occupa anche di specificare le security policy, cioè quelle che regolano le contromisure.

Threat Agents

Per Threat Agent si intende qualsiasi entità capace di effettuare un attacco. Le minacce alla sicurezza del cloud possono provenire internamente o esternamente, da persone o programmi software. Gli agenti possono essere:

- **Anonymous Attacker:** Un utente malintenzionato anonimo è un consumatore di servizi cloud non attendibile senza autorizzazioni nel cloud. In genere esiste come programma software esterno che lancia attacchi a livello di rete attraverso reti pubbliche. Quando gli aggressori anonimi dispongono di informazioni limitate sulle politiche e sulle difese di sicurezza, possono inibire la loro capacità di formulare attacchi efficaci. Pertanto, gli aggressori anonimi spesso ricorrono a commettere atti come aggirare gli account utente o rubare le credenziali degli utenti, utilizzando metodi che garantiscono l'anonimato o richiedono risorse sostanziali per l'azione penale.
- **Malicious Service Agent:** Un agente di servizio dannoso è in grado di intercettare e inoltrare il traffico di rete che scorre all'interno di un cloud. In genere esiste come agente di servizio (o un programma che finge di essere un agente di servizio) con logica compromessa o dannosa, volta a fornire benefici all'attaccante e non al difensore. Può anche esistere come programma esterno in grado di intercettare in remoto e potenzialmente danneggiare il contenuto del messaggio.

- **Trusted Attacker:** Un utente malintenzionato fidato condivide le risorse IT nello stesso ambiente cloud del consumer e tenta di sfruttare credenziali legittime per prendere di mira i cloud provider e i tenant cloud con cui condivide le risorse IT. A differenza degli anonymous attacker (che non sono attendibili), di solito lanciano i loro attacchi dall'interno dei confini di fiducia di un cloud abusando di credenziali legittime o tramite l'appropriazione di informazioni sensibili e riservate. I Trusted attackers (noti anche come tenant dannosi) possono utilizzare risorse IT basate su cloud per un'ampia gamma di exploit, incluso l'hacking di processi di autenticazione deboli, violazione della crittografia, spamming degli account di posta elettronica o per lanciare attacchi comuni, come le campagne di negazione del servizio.
- **Malicious Insiders:** Gli insiders sono Human Threat Agents che agiscono per conto o in relazione al provider di cloud. In genere sono dipendenti attuali o ex dipendenti o terze parti con accesso all'interno del cloud provider. Questo tipo di threat agent comporta un enorme potenziale di danno, poiché l'insider malintenzionato potrebbe avere privilegi amministrativi per accedere alle risorse IT dei consumatori cloud. Un aspetto importante in tali sistemi sociotecnici, quindi è quello di curare con attenzione quelli che sono gli ex impiegati dalla conoscenza che hanno di alcuni meccanismi e password, che può portare al loro utilizzo da una terza parte per guadagnare accesso non autorizzato all'interno del cloud.

Cloud Security Threats

Traffic Eavesdropping

L'intercettazione del traffico si verifica quando i dati vengono trasferiti all'interno di un cloud (di solito dal consumatore cloud al provider cloud) intercettato passivamente da un agente di servizio dannoso per illecite finalità di raccolta delle informazioni. Lo scopo di questo attacco è quello di compromettere direttamente la riservatezza dei dati e, eventualmente, la riservatezza del rapporto tra il consumatore e il fornitore del cloud. A causa della natura passiva dell'attacco, può più facilmente passare inosservato per lunghi periodi di tempo.

Malicious Intermediary

La minaccia di intermediazione si verifica quando i messaggi vengono intercettati e alterati da un service agent dannoso, compromettendo così potenzialmente la riservatezza e / o l'integrità del messaggio. Può anche inserire dati dannosi nel messaggio prima di inoltrarlo alla sua destinazione.

Denial of Service

L'obiettivo dell'attacco Denial of Service (DoS) è sovraccaricare le risorse IT al punto in cui non possono più funzionare correttamente. Questa forma di attacco viene comunemente lanciata in uno dei seguenti modi:

- Il carico di lavoro sui servizi cloud è aumentato artificialmente con imitazioni di messaggi o richieste di comunicazione ripetute.
- La rete è sovraccarica di traffico per ridurre la sua reattività e paralizzare le sue prestazioni.
- A livello di semantica, in cui vengono inviate più richieste di servizi cloud, ognuna delle quali è progettata per consumare memoria e risorse di elaborazione eccessive. Gli attacchi DoS riusciti producono un degrado e / o un errore del server.

Insufficient Authorization

L'attacco di autorizzazione insufficiente si verifica quando non vengono messe in atto contromisure, concedendo l'accesso a un utente malintenzionato, con la conseguenza che l'attaccante ottiene l'accesso alle risorse IT normalmente protette. Questo è spesso il risultato del fatto che l'aggressore ottiene l'accesso diretto alle risorse IT che sono state implementate presumendo che sarebbero state accedute solo da consumer affidabili. Una variazione di questo attacco, nota come autenticazione debole (weak authentication), può verificarsi quando le password deboli o gli account condivisi sono utilizzati per proteggere le risorse IT. All'interno degli ambienti cloud, questi tipi di attacchi possono portare a impatti significativi a seconda della gamma di risorse IT e della gamma di accesso a quelle risorse IT che l'attaccante ottiene.

Virtualization Attack

La virtualizzazione fornisce a più utenti cloud l'accesso alle risorse IT che condividono l'hardware sottostante ma sono logicamente isolate l'una dall'altra. Poiché i provider cloud concedono ai consumatori cloud l'accesso amministrativo alle risorse IT virtualizzate (come i server virtuali), esiste il rischio intrinseco che i consumatori cloud possano abusare di questo accesso per attaccare le risorse IT fisiche sottostanti. Un attacco di virtualizzazione sfrutta le vulnerabilità nella piattaforma di virtualizzazione per comprometterne la riservatezza, l'integrità e / o la disponibilità. Questa minaccia si ha quando un utente malintenzionato affidabile accede con successo a un server virtuale per comprometterne il server fisico sottostante. Con i cloud pubblici, in cui una singola risorsa IT fisica può fornire risorse IT virtualizzate a più utenti cloud, un attacco di questo tipo può avere ripercussioni significative.

Overlapping Trust Boundaries

Se le risorse IT fisiche all'interno di un cloud sono condivise da diversi consumatori di servizi cloud, questi consumatori hanno confini di fiducia sovrapposti. I consumatori di servizi cloud dannosi possono prendere di mira le risorse IT condivise con l'intenzione di compromettere i consumatori di cloud o altre risorse IT che condividono lo stesso confine di fiducia. La conseguenza è che alcuni o tutti gli altri consumatori di servizi cloud potrebbero essere influenzati dall'attacco e / o l'autore dell'attacco potrebbe utilizzare risorse IT virtuali contro altri che condividono lo stesso confine di fiducia.

Considerations

Questa sezione fornisce un elenco di controllo diversificato di problemi e linee guida relativi alla sicurezza del cloud.

Flawed Implementations

La progettazione, l'implementazione o la configurazione scadenti delle distribuzioni di servizi cloud possono avere conseguenze indesiderabili, oltre alle eccezioni e agli errori di runtime. Se il software e / o l'hardware del fornitore di servizi cloud presenta falle di sicurezza intrinseche o debolezze operative, gli aggressori possono sfruttare queste vulnerabilità per compromettere l'integrità, la riservatezza e / o la disponibilità delle risorse IT del fornitore di servizi cloud e delle risorse IT dei consumatori cloud ospitate dal fornitore di servizi cloud.

Security Policy Disparity

Quando un consumatore di cloud affida risorse IT a un provider di cloud pubblico, potrebbe dover accettare che il suo approccio tradizionale alla sicurezza delle informazioni potrebbe non essere identico o addirittura simile a quello del provider di cloud. Questa incompatibilità deve essere

valutata per garantire che tutti i dati o altre risorse IT trasferite su un cloud pubblico siano adeguatamente protetti. Anche quando si noleggiavano risorse IT basate su infrastruttura grezza, al consumatore cloud potrebbe non essere concesso un controllo amministrativo sufficiente o un'influenza sulle politiche di sicurezza che si applicano alle risorse IT affittate dal provider cloud. Ciò è principalmente dovuto al fatto che tali risorse IT sono ancora legalmente di proprietà del cloud provider e continuano a ricadere sotto la sua responsabilità. Inoltre, con alcuni cloud pubblici, terze parti aggiuntive, come broker di sicurezza e autorità di certificazione, possono introdurre il proprio set distinto di politiche e pratiche di sicurezza, complicando ulteriormente qualsiasi tentativo di standardizzare la protezione delle risorse dei consumatori cloud.

Contracts and SLA

I cloud consumer devono esaminare attentamente i contratti e gli SLA proposti dai cloud provider per garantire che le politiche di sicurezza e altre garanzie pertinenti siano soddisfacenti quando si tratta di sicurezza delle risorse. È necessario un linguaggio chiaro che indichi la responsabilità assunta dal fornitore di servizi cloud e / o il livello di indennizzo che può richiedere. Maggiore è la responsabilità assunta dal fornitore di servizi cloud, minore è il rischio per il consumatore di cloud, quindi maggiori saranno le restrizioni che cloud provider imporrà sul cloud consumer per essere sicuro che il rischio che si assume sia gestibile. Un altro aspetto degli obblighi contrattuali è il punto in cui vengono tracciati i confini tra le risorse del consumer e del cloud provider. Un cloud consumer che implementa la propria soluzione sull'infrastruttura fornita dal fornitore di servizi cloud produrrà un'architettura tecnologica composta da artefatti di proprietà sia del consumatore che del fornitore di servizi cloud. Se si verifica una violazione della sicurezza (o un altro tipo di errore di runtime), come viene determinata la colpa? Inoltre, se il consumatore cloud può applicare le proprie policy di sicurezza alla sua soluzione, ma il cloud provider insiste affinché la sua infrastruttura di supporto sia governata da policy di sicurezza differenti (e forse incompatibili), come si può superare la disparità che ne risulta?

A volte la soluzione migliore è cercare un cloud provider diverso con termini contrattuali più compatibili.

Risk Management

Nel valutare i potenziali impatti e le sfide relative all'adozione del cloud, i cloud consumer sono incoraggiati a eseguire una valutazione formale del rischio come parte di una strategia di gestione del rischio. È uno degli aspetti più importanti per il fatto che sia multi-actor, cioè tanti attori presenti nello stesso ecosistema, dove ognuno ha accesso a tale ecosistema. Processo eseguito ciclicamente e utilizzato per migliorare la sicurezza strategica e tattica, la gestione del rischio comprende un insieme di attività coordinate per la supervisione e il controllo dei rischi. Le attività principali sono generalmente definite come valutazione del rischio, trattamento del rischio e controllo del rischio.

- **Risk Assessment:** Nella fase di valutazione del rischio, l'ambiente cloud viene analizzato per identificare potenziali vulnerabilità e carenze che le minacce possono sfruttare. Al fornitore di servizi cloud può essere richiesto di produrre statistiche e altre informazioni sugli attacchi passati (riusciti e non riusciti) effettuati nel suo cloud. I rischi identificati sono quantificati e qualificati in base alla probabilità di accadimento e al grado di impatto in relazione al modo in cui il cloud consumer prevede di utilizzare le risorse IT basate su cloud.

- **Risk Treatment:** le politiche e i piani di mitigazione sono progettati durante la fase di trattamento del rischio con l'intento di trattare con successo i rischi che sono stati scoperti durante la valutazione del rischio. Alcuni rischi possono essere eliminati, altri possono essere mitigati, mentre altri possono essere gestiti in outsourcing o addirittura incorporati nei budget assicurativi e / o di perdita operativa.

Lo stesso fornitore di servizi cloud può accettare di assumersi la responsabilità nell'ambito dei suoi obblighi contrattuali.

- **Risk Control** - La fase di controllo del rischio è correlata al monitoraggio del rischio, un processo in tre fasi che comprende il rilevamento degli eventi correlati, la revisione di questi eventi per determinare l'efficacia delle valutazioni e dei trattamenti precedenti, e l'identificazione di eventuali esigenze di adeguamento delle politiche. A seconda della natura del monitoraggio richiesto, questa fase può essere eseguita o condivisa dal cloud provider.

Security Conservation Principle

La responsabilità ha diversi attori. Nel cloud eco-system esistono vari attori e il loro coordinamento non è semplice, impiegando attenzione per stabilire performance o sicurezza. Ci sono vari attori: cloud consumer, provider ma anche tutti i broker di servizio. Normalmente il Cloud provider nel SaaS ha maggiori responsabilità, anche perché il cloud consumer deve semplicemente controllare il layer di applicazioni. Nell'IaaS il cloud consumer controlla tutto tranne l'hardware su cui viene eseguito, quindi significa che il cloud consumer è considerato responsabile in maniera più concreta.

Framework in Detail

Step 1 - Categorizzare il sistema e tutto quello che processa immagazzina e trasmette

Step 2 - Identificare una serie di security control di base, fare in modo di personalizzare tali controlli di sicurezza in maniera tale che siano proporzionali a quelli che è l'assessment dell'organizzazione del rischio e sviluppare una strategia per il monitor, documentare e fare il review di tale security plan.

Step 3 - Implementare i security control e descrivere come arrivano all'interno del sistema

Step 4 - Verificare i security control usando le procedure. L'assessment determina in che maniera sono stati implementati e se producono il risultato.

Step 5 - Valutare quanto di questo rischio è accettabile. Ciò è estremamente dipendente dalla mission dell'Azienda.

Case Study

ATN è un'azienda che fornisce tutto quello che riguarda hardware, networking e comunicazioni a livello globale. La caratteristica è che è cresciuta in maniera significativa attraverso varie acquisizioni di altre aziende, ciò significa avere un sistema eterogeneo dove ci sono una serie di diverse componenti in cui la fruizione del mercato è sempre in grado di essere competitiva, cercando di implementare qualcosa che permetta la riduzione dei costi. Il costo aumenta per la complessità dell'IT e per mantenere la gestione con i partner. Le funzioni non possono essere consolidate perché ancora operative, nonostante siano non sufficienti. È utile quindi adottare il cloud, ovvero fare una roadmap per il cloud computing producendo una serie di vantaggi, tra cui abbreviare gli investimenti e i costi a breve termine. Bisogna capire il modello appropriato per il tipo di adozione che ATN deve fare, dove l'aspetto cruciale è la determinazione del rischio nel migrare tali applicazioni. Alcuni problemi riguardano:


1. Perdere il controllo delle applicazioni
2. Fiducia nel cloud provider con la incomplice, politiche e regole del mercato delle telecomunicazioni
3. Legacy Application
4. Risparmio dei costi basati su indicatori di prestazioni, come i costi della migrazione.
5. Piano di sviluppo

Avendo fatto un lavoro su un certo numero di applicazioni sulla piattaforma, viene valutato positivamente e la migrazione va avanti. In particolare, per la sicurezza, gli analisti identificano un

insieme di rischi, tra i quali il problema degli accessi differenti, il problema della regulatory, il problema della migrazione dei dati. Tali problemi di sicurezza conducono a una considerazione di non procedere per tale applicazione. Questa decisione è dovuta ad argomentazioni di sicurezza e regolamenti che possono suggerire questo tipo di migrazione.

Sulla base di una valutazione delle sue applicazioni interne, gli analisti di ATN identificano una serie di rischi. Uno di questi rischi è associato all'applicazione myTrendek adottata da OTC, una società recentemente acquisita da ATN. Questa applicazione include una funzione che analizza l'utilizzo del telefono e di Internet e abilita una modalità multiutente che garantisce diritti di accesso variabili. Ad amministratori, supervisori, revisori e utenti regolari possono quindi essere assegnati privilegi diversi. La base di utenti dell'applicazione comprende utenti interni e utenti esterni, come partner commerciali e appaltatori. L'applicazione myTrendek pone una serie di sfide per la sicurezza relative all'utilizzo da parte del personale interno:

- l'autenticazione non richiede né impone password complesse
- la comunicazione con l'applicazione non è crittografata
- Le normative europee (ETelReg) richiedono che alcuni tipi di dati raccolti dall'applicazione vengano eliminati dopo sei mesi. ATN sta pianificando di migrare questa applicazione su un cloud tramite un ambiente PaaS, ma la debole minaccia di autenticazione e la mancanza di riservatezza supportate dall'applicazione la fa riconsiderare. Una successiva valutazione del rischio rivela inoltre che se l'applicazione viene migrata in un ambiente PaaS ospitato da un cloud che risiede al di fuori dell'Europa, le normative locali potrebbero essere in conflitto con ETelReg. Dato che il fornitore di servizi cloud non è interessato alla conformità a ETelReg, ciò potrebbe facilmente comportare la valutazione di sanzioni pecuniarie ad ATN. Sulla base dei risultati della valutazione del rischio, ATN decide di non procedere con il proprio piano di migrazione al cloud.



CoScienze
Associazione

Lezione – Cloud Infrastructure Mechanisms

I meccanismi dell'infrastruttura cloud sono elementi fondamentali degli ambienti cloud che stabiliscono artefatti primari per formare la base dell'architettura tecnologica del cloud.

Non tutti questi meccanismi sono necessariamente di ampia portata, né ciascuno di essi stabilisce un livello architettonico individuale. Invece, dovrebbero essere visti come componenti principali comuni alle piattaforme cloud. I meccanismi si suddividono in:

- Logical Network Perimeter
- Virtual Server
- Cloud Storage Device
- Cloud Usage Monitor
- Resource Replication
- Ready-Made Environment

Logical Network Perimeter

Definito come l'isolamento di un ambiente di rete dal resto della rete all'interno del provider, il Logical Network Perimeter stabilisce un confine di rete virtuale che può comprendere e isolare un gruppo di risorse IT basate su cloud che possono essere distribuite fisicamente. Questo meccanismo può essere implementato per:

- Isolare le risorse IT in un cloud da utenti non autorizzati
- Isolare le risorse IT in un cloud dai non utenti
- Isolare le risorse IT in un cloud dai consumatori cloud
- Controllare la larghezza di banda disponibile per le risorse IT isolate

I Logical Network Perimeter vengono generalmente stabiliti tramite dispositivi di rete che forniscono e controllano la connettività di un data center e vengono comunemente implementati come ambienti IT virtualizzati che includono:

- Firewall Virtuale: una risorsa IT che filtra attivamente il traffico di rete da e verso la rete isolata, controllandone le interazioni con Internet.
- Rete virtuale: solitamente acquisita tramite VLAN, questa risorsa IT isola l'ambiente di rete all'interno dell'infrastruttura del data center. Questi perimetri sono collegati tramite una VPN che protegge le comunicazioni, poiché la VPN è tipicamente implementata dalla crittografia point-to-point dei pacchetti di dati inviati tra gli endpoint in comunicazione.

Case Study

DTGOV ha virtualizzato la sua infrastruttura di rete per produrre un layout di rete logico che favorisca la segmentazione e l'isolamento della rete. La Figura 1 mostra il Logical Network Perimeter implementato in ogni data center DTGOV, come segue:

- I router che si connettono a Internet e all'extranet sono collegati in rete a firewall esterni, che forniscono controllo e protezione della rete fino ai confini della rete esterna più lontani utilizzando

reti virtuali che astraggono logicamente la rete esterna e i perimetri extranet. I dispositivi collegati a questi perimetri di rete sono isolati e protetti da utenti esterni. Nessuna risorsa IT cloud consumer è disponibile all'interno di questi perimetri.

- Viene stabilito un perimetro di rete logico classificato come zona demilitarizzata (DMZ) tra i firewall esterni e i propri firewall. La DMZ è astratta come una rete virtuale che ospita i server proxy che forniscono un accesso intermedio ai servizi di rete comunemente usati (DNS, e-mail, portale Web), così come i server Web con funzioni di gestione esterne.

- Il traffico di rete in uscita dai server proxy passa attraverso una serie di firewall di gestione che isolano il perimetro della rete, che ospita i server che forniscono la maggior parte dei servizi di gestione a cui i consumatori del cloud possono accedere esternamente. Questi servizi sono forniti a supporto diretto dell'allocazione self-service e su richiesta di risorse IT basate su cloud.

- Tutto il traffico verso le risorse IT basate su cloud fluisce attraverso la DMZ verso i firewall del servizio cloud che isolano la rete perimetrale di ogni consumatore cloud, che è astratta da una rete virtuale che è anche isolata da altre reti.

- Sia il perimetro di gestione che le reti virtuali isolate sono collegate ai firewall intra-data center, che regolano il traffico di rete da e verso gli altri data center DTGOV che sono anche collegati ai router intra-data center nel perimetro della rete intra-data center. I firewall virtuali sono allocati e controllati da un singolo utente cloud al fine di regolare il traffico delle risorse IT virtuali. Queste risorse IT sono connesse tramite una rete virtuale isolata da altri consumatori cloud. Il firewall virtuale e la rete virtuale isolata formano insieme il perimetro della rete logica del consumatore cloud.




Figura 1

Virtual Server

Un server virtuale è una forma di virtualizzazione del software che emula un server fisico. I server virtuali vengono utilizzati dai provider di cloud per condividere lo stesso server fisico con più consumatori di cloud fornendo ai consumatori istanze di server virtuali individuali. Il numero di istanze che un determinato server fisico può condividere è limitato dalla sua capacità, per tale motivo ci sono diversi server fisici in modo che i server virtuali possono anche migrare da una macchina all'altra. In quanto meccanismo di base, il server virtuale rappresenta l'elemento fondamentale degli ambienti cloud. Ogni server virtuale può ospitare numerose risorse IT, soluzioni basate su cloud e vari altri meccanismi di cloud computing. La creazione di istanze di server virtuali da file di immagine è un processo di allocazione delle risorse che può essere completato rapidamente e su richiesta. I consumatori cloud che installano o noleggianno server virtuali possono personalizzare i propri

ambienti indipendentemente da altri consumatori cloud che potrebbero utilizzare server virtuali ospitati dallo stesso server fisico sottostante.

L'ambiente IaaS di DTGOV contiene server virtuali ospitati che sono stati istanziati su server fisici che eseguono lo stesso software hypervisor che controlla i server virtuali. Il loro VIM viene utilizzato per coordinare i server fisici in relazione alla creazione di istanze di server virtuali. Questo approccio viene utilizzato in ogni data center per applicare un'implementazione uniforme del livello di virtualizzazione. Al fine di consentire la creazione su richiesta di server virtuali, DTGOV fornisce agli utenti del cloud un set di modelli di server virtuali che vengono resi disponibili tramite immagini VM predefinite. Queste immagini VM sono file che rappresentano le immagini del disco virtuale utilizzate dall'hypervisor per avviare il server virtuale. DTGOV consente ai modelli di server virtuali di avere varie opzioni di configurazione iniziale che differiscono, in base al sistema operativo, ai driver e agli strumenti di gestione utilizzati. Alcuni server virtuali dispongono anche di software server delle applicazioni aggiuntivo preinstallato.

Come si configura una macchina virtuale a un template?

il cloud consumer accede al portale di self-service, dove è in grado di prendere dai template una delle macchine per farla diventare una macchina in esecuzione. C'è un sistema di amministrazione che permette di istruire il VIM sulla base dell'immagine e come ultima parte la gestione della macchina attraverso il portale.

Cloud Storage Device

Il meccanismo del cloud storage device rappresenta dispositivi di archiviazione progettati specificamente per il provisioning basato su cloud. Le istanze di questi dispositivi possono essere virtualizzate, in modo simile a come i server fisici possono generare immagini di server virtuali. I dispositivi di archiviazione cloud sono comunemente in grado di fornire un'allocazione di capacità a incremento fisso a supporto del meccanismo pay-per-use. I dispositivi di archiviazione cloud possono essere esposti per l'accesso remoto tramite servizi di archiviazione cloud. Una delle principali preoccupazioni legate all'archiviazione nel cloud è la sicurezza, l'integrità e la riservatezza dei dati, che diventano più inclini a essere compromessi quando affidati a fornitori di cloud esterni e terze parti. Possono esserci anche implicazioni legali e normative che derivano dal trasferimento dei dati oltre i confini geografici o nazionali. Un altro problema si applica specificamente alle prestazioni di database di grandi dimensioni. Le LAN forniscono dati archiviati localmente con affidabilità di rete e livelli di latenza superiori a quelli delle WAN.

Cloud Storage Levels

I meccanismi dei dispositivi di archiviazione cloud forniscono unità logiche comuni di archiviazione dei dati, come:

- **File:** le raccolte di dati vengono raggruppate in file che si trovano in cartelle.
- **Blocchi:** il livello di archiviazione più basso e il più vicino all'hardware, un blocco è la più piccola unità di dati ancora accessibile individualmente.
- **Datasets:** i set di dati sono organizzati in un formato basato su tabella, delimitato o record.
- **Objects:** i dati e i metadati associati sono organizzati come risorse basate sul Web.

Ciascuno di questi livelli di archiviazione dati è comunemente associato a un certo tipo di interfaccia tecnica che corrisponde a un particolare tipo di dispositivo di archiviazione cloud e servizio di archiviazione cloud utilizzato per esporre la sua API

Case Study

Si analizza tale servizio con DTGOV. DTGOV fornisce ai consumatori cloud l'accesso a un dispositivo di archiviazione cloud basato su un'interfaccia di archiviazione oggetti. Il servizio cloud che espone questa API offre funzioni di base sugli oggetti archiviati, come ricerca, creazione, eliminazione e aggiornamento (CRUD). La funzione di ricerca utilizza una disposizione gerarchica degli oggetti che assomiglia a un file system. DTGOV offre inoltre un servizio cloud che viene utilizzato esclusivamente con server virtuali e consente la creazione di dispositivi di archiviazione cloud tramite un'interfaccia di rete di archiviazione a blocchi. Entrambi i servizi cloud utilizzano API compatibili con CDMI v1.0 di SNIA. Il dispositivo di archiviazione cloud basato su oggetti ha un sistema di archiviazione sottostante con capacità di archiviazione variabile, che è controllata direttamente da un componente software che espone anche l'interfaccia. Questo software consente la creazione di dispositivi di archiviazione cloud isolati che vengono assegnati ai consumatori cloud. Il sistema di archiviazione utilizza un sistema di gestione delle credenziali di sicurezza per amministrare il controllo degli accessi basato sull'utente agli oggetti dati del dispositivo. Il controllo degli accessi viene concesso per oggetto e utilizza criteri di accesso separati per la creazione, la lettura e la scrittura su ciascuno. Le autorizzazioni di accesso pubblico sono consentite, sebbene siano di sola lettura. I gruppi di accesso sono formati da utenti designati che devono essere preventivamente registrati tramite il sistema di gestione delle credenziali. È possibile accedere agli oggetti sia dalle applicazioni Web che dalle interfacce dei servizi Web, implementate dal software di archiviazione cloud. La creazione dei dispositivi di archiviazione cloud basati su blocchi dei cloud consumer è gestita dalla piattaforma di virtualizzazione, che istanzia l'implementazione del LUN dello spazio di archiviazione virtuale. Il dispositivo di archiviazione cloud (o LUN) deve essere assegnato dal VIM a un server virtuale esistente prima di poter essere utilizzato. La capacità dei dispositivi di archiviazione cloud basati su blocchi è espressa in incrementi di un GB. Può essere creato come archivio fisso che i consumatori del cloud possono modificare a livello amministrativo o come archivio di dimensioni variabili con una capacità iniziale di 5 GB che aumenta e diminuisce automaticamente di incrementi di 5 GB in base alle esigenze di utilizzo.

Database Storage Interfaces

I meccanismi del Cloud storage device basati sulle interfacce di archiviazione del database in genere supportano un linguaggio di query oltre alle operazioni di archiviazione di base. La gestione dello storage viene eseguita utilizzando un'API standard o un'interfaccia utente amministrativa.

Questa classificazione della storage interface è suddivisa in due categorie principali in base alla struttura di archiviazione, come segue.

Relational Data Storage

Tradizionalmente, molti ambienti IT locali archiviano i dati utilizzando database relazionali o sistemi di gestione di database relazionali (RDBMS). I database relazionali (o dispositivi di archiviazione relazionali) si basano su tabelle per organizzare dati simili in righe e colonne. Le tabelle possono avere relazioni tra loro per dare ai dati una maggiore struttura, per proteggere l'integrità dei dati e per evitare la ridondanza (che viene definita normalizzazione dei dati). Lavorare con l'archiviazione relazionale comporta comunemente l'uso dello SQL (Structured Query Language) standard del settore. Un meccanismo di cloud storage device implementato utilizzando l'archiviazione dei dati relazionali potrebbe essere basato su un numero qualsiasi di prodotti di database disponibili in commercio, come IBM DB2, Oracle Database, Microsoft SQL Server e MySQL. Le sfide con i database relazionali basati su cloud riguardano comunemente la scalabilità e le prestazioni. Il ridimensionamento di un dispositivo di archiviazione cloud relazionale verticalmente può essere più complesso e conveniente rispetto al ridimensionamento orizzontale. I database con relazioni


complesse e / o contenenti grandi volumi di dati possono essere affetti da un sovraccarico di elaborazione e una latenza più elevata, soprattutto quando si accede da remoto tramite servizi cloud.

Non-Relational Data Storage

Lo storage non relazionale (noto anche come storage NoSQL) si allontana dal modello di database relazionale tradizionale in quanto stabilisce una struttura "più flessibile" per i dati archiviati con minore enfasi sulla definizione delle relazioni e sulla realizzazione della normalizzazione dei dati. La motivazione principale per l'utilizzo dell'archiviazione non relazionale è evitare la potenziale complessità e il sovraccarico di elaborazione che possono essere imposti dai database relazionali. Inoltre, l'archiviazione non relazionale può essere più scalabile orizzontalmente rispetto all'archiviazione relazionale. Il compromesso con l'archiviazione non relazionale è che i dati perdono gran parte della forma nativa e della convalida a causa di schemi o modelli di dati limitati o primitivi. Inoltre, i repository non relazionali non tendono a supportare le funzioni del database relazionale, come transazioni o join. I dati normalizzati esportati in un repository di archiviazione non relazionale verranno solitamente de-normalizzati, il che significa che la dimensione dei dati sarà tipicamente crescente. È possibile preservare un grado di normalizzazione, ma di solito non per relazioni complesse. I fornitori di servizi cloud spesso offrono uno storage non relazionale che fornisce scalabilità e disponibilità dei dati archiviati su più ambienti server. Tuttavia, molti meccanismi di archiviazione non relazionale sono proprietari e quindi possono limitare notevolmente la portabilità dei dati.

Storage Allocation

Ogni device ha una sua LUN (Logical Unit Number, cioè una identificazione univoca logica di un disco e associata al disco virtuale che viene montato dal server virtuale). La creazione di più blocchi viene fatta istanziando la LUN sullo storage virtuale, cioè si ha accesso ad un disco che ha una sua identità nello storage virtuale ed è quello che serve alla virtual-infrastructure manager per poter assegnare una partizione al virtual server. Per il resto, tutto va su dischi virtuali che vengono montati e offerti su virtual storage.



Cloud Usage Monitor

Il meccanismo di cloud usage monitor è un programma software leggero e autonomo responsabile della raccolta e dell'elaborazione dei dati sull'utilizzo delle risorse IT. Ci sono una serie di monitor specifici, dove l'obiettivo generale è quello di prendere i dati, collezionarli e mandarli ad un database per poter fare il post-processing o porting dei dati. Sono presenti tre formati standard della implementazione dei monitor:

- **Monitoring Agent:** Un intermediario, come un programma, che esiste come agente di servizio e risiede lungo i percorsi di comunicazione esistenti per monitorare e analizzare in modo trasparente i flussi di dati. Questo tipo di monitoraggio dell'utilizzo del cloud viene comunemente utilizzato per misurare il traffico di rete e le metriche dei messaggi. Il processo parte dalla prima richiesta, passa attraverso il firewall, entra e il monitoring agent la intercetta. Il servizio viene quindi fornito ma in maniera parallela la richiesta viene monitorata all'interno del database di log. La richiesta fa il suo percorso, che provvede a fornire la risposta al consumer, ma le componenti

nel frattempo hanno provveduto a memorizzare i dati relativi all'utilizzo. Può essere fatta a livello base oppure con una certa semantica, cioè metriche rispetto ai messaggi.

- **Resource Agent:** Un Resource agent è un modulo di elaborazione che raccoglie i dati di utilizzo tramite interazioni guidate dagli eventi con un software di risorse specializzato. Questo modulo viene utilizzato per monitorare le metriche di utilizzo in base a eventi osservabili predefiniti a livello di software delle risorse, come avvio, sospensione, ripresa e ridimensionamento verticale.
- **Polling Agent:** Un polling agent è un modulo di elaborazione che raccoglie i dati sull'utilizzo del servizio cloud eseguendo il polling delle risorse IT. Questo tipo di monitoraggio del servizio cloud viene comunemente utilizzato per monitorare periodicamente lo stato delle risorse IT, come il tempo di attività e il tempo di inattività.

Case Study

DTGOV è un esempio. Una delle sfide incontrate durante l'iniziativa di adozione del cloud da DTGOV è stata garantire che i dati di utilizzo raccolti siano accurati. I metodi di allocazione delle risorse dei precedenti modelli di outsourcing IT avevano comportato la fatturazione dei costi di chargeback in base al numero di server fisici elencati nei contratti di leasing annuali, indipendentemente dall'utilizzo effettivo.


DTGOV deve ora definire un modello che consenta di noleggiare e fatturare ogni ora server virtuali con diversi livelli di prestazioni. Quello che si vuole è raggiungere un livello a grana fine, implementando un resource agent che si occupa di monitorare tutti gli eventi generati dalla piattaforma VIM, per calcolare i dati di utilizzo del server virtuale. Si procede con la misurazione dell'utilizzo, per periodi definiti dall'utente, delle macchine virtuali. C'è bisogno di un'approssimazione di tale misurazione, che è esplicitamente menzionata nel SLA e considerata un accordo comune tra provider e consumer.

Resource Replication

Definito come la creazione di più istanze della stessa risorsa IT, la replicazione viene in genere eseguita quando è necessario migliorare la disponibilità e le prestazioni di una risorsa IT. La tecnologia di virtualizzazione viene utilizzata per implementare il meccanismo per replicare le risorse IT basate su cloud.

Case Study

DTGOV stabilisce una serie di server virtuali ad alta disponibilità che possono essere riposizionati automaticamente su server fisici in esecuzione in diversi data center in risposta a gravi condizioni di guasto. I VIM di diversi data center si coordinano per superare l'indisponibilità riallocando il server virtuale su un diverso server fisico in esecuzione in un altro data center. Tale migrazione è puramente virtuale, ovvero non si migra la macchina virtuale.




Ready-Made Environment

Il Ready-made Environment è uno dei punti chiave che definisce il modello di fornitura cloud PaaS che rappresenta una piattaforma basata su cloud predefinita composta da un insieme di risorse IT già

installate, pronte per essere utilizzate e personalizzate da un cloud consumer. Questi ambienti vengono utilizzati dai cloud consumer per sviluppare e distribuire in remoto i propri servizi e applicazioni all'interno di un cloud. Gli ambienti tipici pronti all'uso includono risorse IT preinstallate, come database, middleware, strumenti di sviluppo e strumenti di governance. Un ambiente già pronto è generalmente dotato di un kit di sviluppo software completo (SDK) che fornisce ai cloud consumer l'accesso programmato alle tecnologie di sviluppo che comprendono i loro stack di programmazione preferiti. Il middleware è disponibile per piattaforme multi-tenant per supportare lo sviluppo e la distribuzione di applicazioni Web. Alcuni fornitori di servizi cloud offrono ambienti di esecuzione a runtime per servizi cloud basati su parametri di fatturazione e prestazioni diversi. Ad esempio, un'istanza front-end di un servizio cloud può essere configurata per rispondere a richieste sensibili al tempo in modo più efficace rispetto a un'istanza back-end. La prima variazione verrà fatturata a una tariffa diversa dalla seconda. Come ulteriormente dimostrato nel prossimo esempio di case study, una soluzione può essere partizionata in gruppi di logica che possono essere designati per l'invocazione di istanze sia frontend che backend in modo da ottimizzare l'esecuzione e la fatturazione del runtime.

Case Study

ATN ha sviluppato e distribuito diverse applicazioni aziendali utilizzando un ambiente PaaS in leasing. Una era un'applicazione Web del catalogo dei numeri di parte basata su Java e utilizzata per gli switch e i router che producono. Questa applicazione viene utilizzata da diverse fabbriche, ma non manipola i dati delle transazioni, che vengono invece elaborati da un sistema di controllo delle scorte separato. La logica dell'applicazione è stata suddivisa in elaborazione front-end e back-end. La logica del front-end è stata utilizzata per elaborare semplici query e aggiornamenti al catalogo. La parte back-end contiene la logica necessaria per eseguire il rendering del catalogo completo e correlare componenti simili e numeri di parte legacy. Istanziare le due parti dell'applicazione, entrambi poggiandosi sullo stesso cloud storage device, il cloud consumer end-user accede al front-end, che interagisce con il back-end e cloud storage. Il punto critico è il fatto che sono ready-made environment cioè environment che insieme contengono applicazioni server e database collezionati insieme come un unico ambiente.



Lezione – Specialized Cloud Mechanisms

Automated Scaling Listener

Il meccanismo di Automated scaling listener è un agente di servizio specializzato che monitora e tiene traccia delle comunicazioni tra i consumatori di servizi cloud e i servizi cloud per scopi di scalabilità dinamica. Gli automated scaling listener vengono distribuiti all'interno del cloud, in genere vicino al firewall, da dove tengono automaticamente traccia delle informazioni sullo stato del carico di lavoro. I carichi di lavoro possono essere determinati dal volume delle richieste cloud generate dai consumatori o tramite le richieste di elaborazione back-end attivate da determinati tipi di richieste. Ad esempio, una piccola quantità di dati in arrivo può comportare una grande quantità di elaborazione. Gli automated scaling listener possono fornire diversi tipi di risposte alle condizioni di fluttuazione del carico di lavoro, ad esempio:

- Scalabilità automatica delle risorse IT in entrata o in uscita in base a parametri precedentemente definiti dal consumatore cloud (comunemente denominata scalabilità automatica).
- Notifica automatica del consumatore cloud quando i carichi di lavoro superano le soglie attuali o scendono al di sotto delle risorse allocate. In questo modo, il consumatore cloud può scegliere di regolare la propria allocazione corrente delle risorse IT.

L'automated scaling listener si ridimensiona e avvia la creazione di tre istanze ridondanti del servizio. Un quarto consumatore di servizi cloud tenta di utilizzare il servizio cloud. Programmato per consentire solo tre istanze del servizio cloud, l'automated scaling listener rifiuta il quarto tentativo e avvisa il cloud consumer che il limite del carico di lavoro richiesto è stato superato. L'amministratore delle risorse cloud del consumatore cloud accede all'ambiente di amministrazione remota per regolare la configurazione del provisioning e aumentare il limite di istanze ridondanti.

Diversi fornitori di provider di servizi cloud hanno nomi diversi per gli agenti di servizio che agiscono come listener di ridimensionamento automatico.

Case Study

DTGOV ha dei server fisici che scalano verticalmente le istanze del server virtuale, partendo dalla configurazione della macchina virtuale più piccola (1 core del processore virtuale, 4 GB di RAM virtuale) fino alla più grande (128 core del processore virtuale, 512 GB di RAM virtuale). La piattaforma di virtualizzazione è configurata per ridimensionare automaticamente un server virtuale in fase di runtime, come segue:

- Ridimensionamento: il server virtuale continua a risiedere sullo stesso server host fisico mentre viene ridotto a una configurazione con prestazioni inferiori.

- **Scalabilità:** la capacità del server virtuale è raddoppiata sul server host fisico originale. Il VIM può anche migrare in tempo reale il server virtuale su un altro server fisico se il server host originale è sovraccarico. La migrazione viene eseguita automaticamente in fase di esecuzione e non richiede l'arresto del server virtuale. Le impostazioni di ridimensionamento automatico controllate dai consumatori cloud determinano il comportamento di runtime degli agenti listener di ridimensionamento automatico, che vengono eseguiti sull'hypervisor che monitora l'utilizzo delle risorse dei server virtuali. Ad esempio, un utente cloud lo ha configurato in modo che ogni volta che l'utilizzo delle risorse supera l'80% della capacità di un server virtuale per 60 secondi consecutivi, il listener di ridimensionamento automatizzato innesca il processo di scalabilità inviando alla piattaforma VIM un comando di scalabilità. Al contrario, il listener di ridimensionamento automatico comanda anche al VIM di ridimensionarsi ogni volta che l'utilizzo delle risorse scende del 15% al di sotto della capacità per 60 secondi consecutivi.

Cosa succede quando ci sono fluttuazioni di workload?

Autoscaling, ovvero scalare e modificare automaticamente la quantità di risorse disponibili a seconda dei parametri definiti in precedenza dal cloud consumer.

Load Balancer

Un approccio comune alla scalabilità orizzontale consiste nel bilanciare un carico di lavoro tra due o più risorse IT per aumentare le prestazioni e la capacità oltre a ciò che una singola risorsa IT può fornire. Il meccanismo di bilanciamento del carico è un agente di runtime con logica basata fondamentalmente su questa premessa. Oltre ai semplici algoritmi di divisione del lavoro, i load balancer possono eseguire una gamma di funzioni specializzate di distribuzione del carico di lavoro in fase di esecuzione che includono:

- **Distribuzione Asimmetrica:** carichi di lavoro maggiori vengono inviati alle risorse IT con capacità di elaborazione più elevate
- **Priorità dei carichi di lavoro:** i carichi di lavoro vengono pianificati, accodati, scartati e distribuiti in base ai livelli di priorità
- **Distribuzione in base al contenuto:** le richieste vengono distribuite a diverse risorse IT in base al contenuto della richiesta.

Un sistema di Load Balancer è programmato o configurato con una serie di regole e parametri di prestazioni e QoS con l'obiettivo generale di ottimizzare l'utilizzo delle risorse IT, evitare sovraccarichi e massimizzare il throughput. I meccanismi di bilanciamento del carico possono esistere come:

- switch di rete multistrato
- appliance hardware dedicata
- sistema basato su software dedicato (comune nei sistemi operativi server)
- agente di servizio (solitamente controllato da software di gestione cloud)

Il sistema di load balancer si trova in genere sul percorso di comunicazione tra le risorse IT che generano il carico di lavoro e le risorse IT che eseguono l'elaborazione del carico di lavoro. Questo meccanismo può essere progettato come un agente trasparente che rimane nascosto ai cloud service consumer o come un componente proxy che astrae le risorse IT che svolgono il loro carico di lavoro.

Case Study

ATN cerca di configurare i servizi per fornire questo tipo di servizio in maniera scalabile. Il servizio cloud ATN Part Number Catalog non manipola i dati delle transazioni anche se viene utilizzato da più fabbriche in diverse regioni. Ha periodi di utilizzo di punta durante i primi giorni di ogni mese che

coincidono con l'elaborazione delle routine di controllo delle scorte pesanti negli stabilimenti. ATN ha seguito le raccomandazioni del proprio fornitore di servizi cloud e ha aggiornato il servizio cloud per renderlo altamente scalabile al fine di supportare il carico di lavoro previsto dalle fluttuazioni. Dopo aver sviluppato gli aggiornamenti necessari, ATN decide di testare la scalabilità utilizzando uno strumento di test dell'automazione robotica che simula carichi di lavoro pesanti.

SLA Monitor

Il meccanismo di monitoraggio degli SLA viene utilizzato per osservare in modo specifico le prestazioni di runtime dei servizi cloud per garantire che soddisfino i requisiti QoS contrattuali pubblicati negli SLA. L'idea è che viene stipulato un contratto tra consumer e provider per i servizi che si vogliono ottenere. I dati raccolti dal monitor SLA vengono elaborati da un sistema di gestione SLA per essere aggregati in metriche di report SLA. Il sistema può riparare in modo proattivo o eseguire il failover dei servizi cloud quando si verificano condizioni di eccezione, ad esempio quando il monitor SLA segnala un servizio cloud come "inattivo".

Lo standard SLA per i server virtuali nei contratti di leasing di DTGOV definisce una disponibilità minima delle risorse IT del 99,95%, che viene monitorata utilizzando due monitor SLA: uno basato su un agente di polling e l'altro basato su un'implementazione dell'agente di monitoraggio regolare.

SLA Monitor Polling Agent

Il monitoraggio SLA di polling di DTGOV viene eseguito nella rete perimetrale esterna per rilevare i timeout del server fisico. È in grado di identificare i guasti di rete, hardware e software del data center (con granularità al minuto) che comportano la mancata risposta del server fisico. Sono necessari tre timeout consecutivi di periodi di polling di 20 secondi per dichiarare l'indisponibilità delle risorse IT:

- PS_Timeout: il polling del server fisico è scaduto
- PS_Unreachable: il polling del server fisico è scaduto consecutivamente tre volte
- PS_Reachable: il server fisico precedentemente non disponibile risponde nuovamente al polling

SLA Monitoring Agent

L'API basata sugli eventi di VIM implementa il monitoraggio SLA come agente di monitoraggio per generare i seguenti tre eventi:

- VM_Unreachable: il VIM non può raggiungere la VM
- VM Failure: la VM non è riuscita e non è disponibile
- VM_Reachable: la VM è raggiungibile

Gli eventi generati dall'agente di polling hanno timestamp registrati in un database del registro eventi SLA e utilizzati dal sistema di gestione degli SLA per calcolare la disponibilità delle risorse IT. Le regole complesse vengono utilizzate per correlare gli eventi da diversi monitor SLA di polling e i server virtuali interessati e per eliminare eventuali falsi positivi per periodi di non disponibilità.

Pay-per-use Monitor

Il meccanismo di monitoraggio pay-per-use misura l'utilizzo delle risorse IT basato su cloud in base a parametri di prezzo predefiniti e genera registri di utilizzo per il calcolo delle tariffe e per scopi di fatturazione. Alcune variabili di monitoraggio tipiche sono:


- Quantità di messaggi di richiesta / risposta
- Volume di dati trasmessi
- Consumo di banda

I dati raccolti dal monitor pay-per-use vengono elaborati da un sistema di gestione della fatturazione che calcola la comunicazione in runtime di pagamento con un servizio cloud.

Case Study

DTGOV decide di investire in un sistema commerciale in grado di generare fatture basate su eventi predefiniti come modelli di pricing "fatturabili" e personalizzabili. L'installazione del sistema produce due database proprietari: il database degli eventi di fatturazione e il database dello schema dei prezzi. Gli eventi di runtime vengono raccolti tramite monitoraggi dell'utilizzo del cloud implementati come estensioni della piattaforma VIM utilizzando l'API di VIM. L'agente di polling del monitoraggio pay-per-use fornisce periodicamente al sistema di fatturazione informazioni sugli eventi fatturabili. Un agente di monitoraggio separato fornisce ulteriori dati supplementari relativi alla fatturazione, come:

- Tipo di abbonamento consumatore cloud: queste informazioni vengono utilizzate per identificare il tipo di modello di prezzo per il calcolo della tariffa di utilizzo, tra cui abbonamento prepagato con quota di utilizzo, abbonamento postpagato con quota di utilizzo massima e abbonamento postpagato con utilizzo illimitato.
- Categoria di utilizzo delle risorse: il sistema di gestione della fatturazione utilizza queste informazioni per identificare la gamma di tariffe di utilizzo applicabili a ciascun evento di utilizzo. Gli esempi includono l'utilizzo normale, l'utilizzo riservato delle risorse IT e l'utilizzo del servizio premium (gestito).
- Consumo delle quote di utilizzo delle risorse: quando i contratti di utilizzo definiscono le quote di utilizzo delle risorse IT, le condizioni degli eventi di utilizzo vengono generalmente integrate con il consumo di quote e limiti di quota aggiornati.



Audit Monitor

Il meccanismo di monitoraggio dell'audit viene utilizzato per raccogliere dati di tracciamento dell'audit per le reti e le risorse IT a supporto di (o dettato da) obblighi normativi e contrattuali. La Figura 8.15 mostra un monitor di controllo implementato come agente di monitoraggio che intercetta le richieste di "accesso" e memorizza le credenziali di sicurezza del richiedente, nonché i tentativi di accesso non riusciti e riusciti, in un database di registro per futuri scopi di reporting di controllo.





Figure 8.15

Case Study

Un caso d'uso è Innovartus. Una caratteristica fondamentale della soluzione di Innovartus è la sua interfaccia utente unica. Tuttavia, le tecnologie avanzate utilizzate per il suo design hanno imposto restrizioni di licenza che impediscono legalmente a Innovartus di addebitare agli utenti in determinate regioni geografiche l'utilizzo della soluzione. L'ufficio legale di Innovartus sta lavorando per risolvere questi problemi. Ma nel frattempo ha fornito al dipartimento IT un elenco di paesi in cui gli utenti non possono accedere all'applicazione o in cui l'accesso degli utenti deve essere gratuito. Al fine di raccogliere informazioni sull'origine dei client che accedono all'applicazione, Innovartus chiede al suo fornitore di servizi cloud di istituire un sistema di monitoraggio degli audit. Il fornitore di servizi cloud distribuisce un agente di monitoraggio dell'audit per intercettare ogni messaggio in entrata, analizzare la corrispondente intestazione HTTP e raccogliere dettagli sull'origine dell'utente finale. Secondo la richiesta di Innovartus, il fornitore di servizi cloud aggiunge inoltre un database di log per raccogliere i dati regionali di ciascuna richiesta dell'utente finale a fini di reportistica futura. Innovartus aggiorna ulteriormente la sua applicazione in modo che gli utenti finali di paesi selezionati possano accedere all'applicazione gratuitamente.



Failover System

Il meccanismo del Failover System viene utilizzato per aumentare l'affidabilità e la disponibilità delle risorse IT utilizzando una tecnologia di clustering consolidata per fornire implementazioni ridondanti. Un sistema di failover è configurato per passare automaticamente a un'istanza di risorsa IT ridondante o in standby ogni volta che la risorsa IT attualmente attiva non è disponibile. I sistemi di failover sono comunemente usati per programmi mission-critical e servizi riutilizzabili che possono introdurre un singolo punto di errore per più applicazioni. Un sistema di failover può estendersi su più di una regione geografica in modo che ogni posizione ospiti una o più implementazioni ridondanti della stessa risorsa IT. Il meccanismo di replica delle risorse viene talvolta utilizzato dal sistema di failover per fornire istanze di risorse IT ridondanti, con il rilevamento di errori e condizioni di indisponibilità. I sistemi di failover sono disponibili in due configurazioni di base:

- **Active-Active:** In una configurazione attivo-attivo, le implementazioni ridondanti della risorsa IT servono attivamente il carico di lavoro in modo sincrono. È richiesto il bilanciamento del carico tra le istanze attive. Quando viene rilevato un errore, l'istanza non riuscita viene rimossa dallo scheduler di bilanciamento del carico. Qualunque risorsa IT rimanga operativa quando viene rilevato un errore assume il controllo dell'elaborazione.
- **Active-Passive:** In una configurazione attivo-passivo, un'implementazione in standby o inattiva viene attivata per subentrare all'elaborazione dalla risorsa IT che non è più disponibile e il carico di lavoro corrispondente viene reindirizzato all'istanza che assume il controllo dell'operazione.

Alcuni sistemi di failover sono progettati per reindirizzare i carichi di lavoro a risorse IT attive che si affidano a load balancer specializzati che rilevano le condizioni di errore ed escludono le istanze di risorse IT guaste dalla distribuzione del carico di lavoro. Questo tipo di sistema di failover è adatto

per le risorse IT che non richiedono la gestione dello stato di esecuzione e forniscono funzionalità di elaborazione senza stato. Nelle architetture tecnologiche tipicamente basate su tecnologie di clustering e virtualizzazione, le implementazioni di risorse IT ridondanti o in standby sono necessarie anche per condividere il loro stato e il contesto di esecuzione. Un'attività complessa eseguita su una risorsa IT guasta può rimanere operativa in una delle sue implementazioni ridondanti.

Case Study

In questo caso DTGOV crea un server virtuale resiliente per supportare l'allocazione di istanze di server virtuali che ospitano applicazioni critiche, che vengono replicate in più data center. Il server virtuale resiliente replicato dispone di un sistema di failover attivo-passivo associato. Il suo flusso di traffico di rete può essere commutato tra le istanze delle risorse IT che risiedono in diversi data center, se l'istanza attiva dovesse fallire.

Hypervisor

Il meccanismo dell'hypervisor è una parte fondamentale dell'infrastruttura di virtualizzazione che viene utilizzata principalmente per generare istanze di server virtuali di un server fisico. Un hypervisor è generalmente limitato a un server fisico e può quindi creare solo immagini virtuali di quel server. Allo stesso modo, un hypervisor può solo assegnare server virtuali che genera a pool di risorse che risiedono sullo stesso server fisico sottostante. Un hypervisor ha funzionalità limitate di gestione del server virtuale, come l'aumento della capacità del server virtuale o l'arresto. Il VIM fornisce una gamma di funzionalità per l'amministrazione di più hypervisor su server fisici. Il software hypervisor può essere installato direttamente nei server bare metal e fornisce funzionalità per il controllo, la condivisione e la pianificazione dell'utilizzo delle risorse hardware, come la potenza del processore, la memoria e l'I / O. Questi possono apparire al sistema operativo di ogni server virtuale come risorse dedicate.

Case Study

DTGOV ha stabilito una piattaforma di virtualizzazione in cui lo stesso prodotto software Hypervisor è in esecuzione su tutti i server fisici. Il VIM coordina le risorse hardware in ogni data center in modo che le istanze del server virtuale possano essere create dal server fisico sottostante più conveniente. Di conseguenza, i consumatori di cloud possono affittare server virtuali con funzionalità di scalabilità automatica. Al fine di offrire configurazioni flessibili, la piattaforma di virtualizzazione DTGOV fornisce la migrazione live delle VM di server virtuali tra server fisici all'interno dello stesso data center.

Live-VM-Migration: Migrare una macchina virtuale mentre è in esecuzione. Si fa partire una macchina con la stessa immagine, si aprono i socket ascoltando gli stessi pacchetti ascoltati dalla macchina "originale", quando le macchine sono sincronizzate è fondamentale per migrare da un server fisico particolarmente carico ad un server più scarico.

Resource Cluster

Risorse IT basate su cloud che sono geograficamente diverse e possono essere combinate logicamente in gruppi per migliorarne l'allocazione e l'utilizzo. Il meccanismo del resource cluster viene utilizzato per raggruppare più istanze di risorse IT in modo che possano essere utilizzate come un'unica risorsa IT. Ciò aumenta la capacità di elaborazione combinata, il bilanciamento del carico e la disponibilità delle risorse IT in cluster.

Le architetture dei cluster di risorse si basano su connessioni di rete dedicate ad alta velocità, o nodi del cluster, tra le istanze delle risorse IT per comunicare in merito alla distribuzione del carico di lavoro, alla pianificazione delle attività, alla condivisione dei dati e alla sincronizzazione del sistema. Una piattaforma di gestione del cluster in esecuzione come middleware distribuito in tutti i nodi del cluster è solitamente responsabile di queste attività. Questa piattaforma implementa una funzione di coordinamento che consente alle risorse IT distribuite di apparire come un'unica risorsa IT ed esegue anche le risorse IT all'interno del cluster. I tipi di resource cluster comuni includono:

- **Server Cluster:** i server fisici o virtuali sono raggruppati in cluster per aumentare le prestazioni e la disponibilità. Gli hypervisor in esecuzione su diversi server fisici possono essere configurati per condividere lo stato di esecuzione del server virtuale (come le pagine di memoria e lo stato del registro del processore) al fine di stabilire server virtuali in cluster. In tali configurazioni, che di solito richiedono che i server fisici abbiano accesso allo storage condiviso, i server virtuali sono in grado di migrare dal vivo da uno all'altro. In questo processo, la piattaforma di virtualizzazione sospende l'esecuzione di un dato server virtuale su un server fisico e la riprende su un altro server fisico. Il processo è trasparente per il sistema operativo del server virtuale e può essere utilizzato per aumentare la scalabilità migrando in tempo reale un server virtuale in esecuzione su un server fisico sovraccarico su un altro server fisico con capacità adeguata.
- **Database Cluster:** progettato per migliorare la disponibilità dei dati, questo cluster di risorse ad alta disponibilità dispone di una funzione di sincronizzazione che mantiene la coerenza dei dati archiviati in diversi dispositivi di archiviazione utilizzati nel cluster. La capacità ridondante si basa solitamente su un sistema di failover attivo-attivo o attivo-passivo impegnato a mantenere le condizioni di sincronizzazione.
- **Large Dataset Cluster:** il partizionamento e la distribuzione dei dati viene implementato in modo che i set di dati di destinazione possano essere partizionati in modo efficiente senza compromettere l'integrità dei dati o l'accuratezza del calcolo. Ogni nodo del cluster elabora i carichi di lavoro senza comunicare con altri nodi tanto quanto in altri tipi di cluster. Molti cluster di risorse richiedono che i nodi del cluster abbiano capacità di elaborazione e caratteristiche quasi identiche al fine di semplificare la progettazione e mantenere la coerenza all'interno dell'architettura del cluster di risorse. I nodi del cluster nelle architetture cluster ad alta disponibilità devono accedere e condividere risorse IT di storage comuni. Ciò può richiedere due livelli di comunicazione tra i nodi: uno per accedere al dispositivo di archiviazione e un altro per eseguire l'orchestrazione delle risorse IT. Alcuni resource cluster sono progettati con risorse IT più deboli che richiedono solo il livello di rete.

Case Study

DTGOV sta valutando la possibilità di introdurre un server virtuale in cluster da eseguire in un cluster ad alta disponibilità come parte della piattaforma di virtualizzazione. I server virtuali possono migrare in tempo reale tra i server fisici, che sono raggruppati in un cluster hardware ad alta disponibilità controllato da hypervisor coordinati abilitati per il cluster. La funzione di coordinamento mantiene le istantanee replicate dei server virtuali in esecuzione per facilitare la migrazione ad altri server fisici in caso di guasto.

Tightly Coupled Clusters

Ci sono dei cluster strettamente accoppiati dove i nodi del cluster hanno più o meno la stessa capacità di calcolo, questo permette di gestire con estrema facilità sia il load balancing che la consistenza.

Loosely Coupled Clusters

Si ha storage separato e il meccanismo di clustering che prevede la replica di risorse a seconda del tipo di spostamento, attivazione e utilizzo della risorsa all'interno della diversa macchina fisica.

Goal of a Resource Cluster

- **Load Balanced Cluster:** cercare di implementare un cluster che permette di aumentare l'intera capacità della rete per usare al massimo tutte le risorse a disposizione
- **High Availability Cluster:** avere sempre a disposizione una macchina che funzioni indipendentemente da eventuali malfunzionamenti con un meccanismo di failover all'interno del cluster.

Case Study

Con DTGOV viene realizzato un cluster di server fisici che sono clusterizzati e per la estrema disponibilità, da ogni server virtuale vengono replicati almeno due server fisici diversi. Il VIM è in grado di effettuare la replica di ogni macchina virtuale su due macchine fisiche.

Multi-device Broker

Potrebbe essere necessario accedere a un singolo servizio cloud da parte di una serie di cloud service consumer differenziati per i loro dispositivi hardware di hosting e / o requisiti di comunicazione. Per superare le incompatibilità tra un servizio cloud e un diverso consumatore di servizi cloud, è necessario creare una logica di mappatura per trasformare (o convertire) le informazioni scambiate in fase di esecuzione. Il meccanismo del broker multi-device viene utilizzato per facilitare la trasformazione dei dati di runtime in modo da rendere un servizio cloud accessibile a una gamma più ampia di programmi e dispositivi consumer di servizi cloud. I broker multi-device esistono comunemente come gateway o incorporano componenti gateway, come ad esempio:

- **XML Gateway:** trasmette e convalida i dati XML
- **Cloud Storage Gateway:** trasforma i protocolli di archiviazione cloud e codifica i dispositivi di archiviazione per facilitare il trasferimento e l'archiviazione dei dati
- **Mobile Device Gateway:** trasforma i protocolli di comunicazione utilizzati dai dispositivi mobili in protocolli compatibili con un servizio cloud. I livelli a cui è possibile creare la logica di trasformazione includono:
 - Protocolli di trasporto
 - Protocolli di messaggistica
 - Protocolli del dispositivo di archiviazione
 - Schemi di dati / modelli di dati

Ad esempio, un broker multi-device può contenere una logica di mappatura che nasconde i protocolli di trasporto e di messaggistica per un consumatore di servizi cloud che accede a un servizio cloud con un dispositivo mobile.

Case Study

Innovartus ha deciso di rendere disponibile la sua applicazione per giochi di ruolo a vari dispositivi mobili e smartphone. Una complicazione che ha ostacolato il team di sviluppo di Innovartus durante la fase di progettazione del miglioramento mobile è stata la difficoltà di riprodurre esperienze utente identiche su piattaforme mobili diverse. Per risolvere questo problema, Innovartus implementa un broker multi-device per intercettare i messaggi in arrivo dai dispositivi, identificare la piattaforma software e convertire il formato del messaggio nel formato nativo dell'applicazione lato server.

State Managment Database

Uno State Managment Database è un dispositivo di archiviazione utilizzato per mantenere temporaneamente i dati di stato per i programmi software. In alternativa alla memorizzazione nella cache dei dati di stato, i programmi software possono scaricare i dati di stato nel database per ridurre la quantità di memoria di runtime che consumano. In questo modo, i programmi software e l'infrastruttura circostante sono più scalabili. I database di gestione dello stato sono comunemente usati dai servizi cloud, in particolare quelli coinvolti in attività di runtime di lunga durata.

ATN sta espandendo la sua architettura di ambiente già pronta per consentire il differimento delle informazioni sullo stato per lunghi periodi, utilizzando il meccanismo del database di gestione dello stato.

Lezione – Other Cloud Mechanisms

Le risorse IT basate su cloud devono essere impostate, configurate, gestite e monitorate. I sistemi trattati sono meccanismi che comprendono e abilitano questi tipi di attività di gestione. Costituiscono parti fondamentali delle architetture della tecnologia cloud facilitando il controllo e l'evoluzione delle risorse IT che formano piattaforme e soluzioni cloud. Vengono descritti i seguenti meccanismi di gestione:

- Remote Administration System
- Resource Management System
- SLA Management System
- Billing Management System

Questi sistemi in genere forniscono API integrate e possono essere offerti come prodotti singoli, applicazioni personalizzate o combinati in varie suite di prodotti o applicazioni multifunzione.

Remote Administration System

Il meccanismo di Remote Administration System fornisce strumenti e interfacce utente per gli amministratori di risorse cloud esterne per configurare e amministrare le risorse IT basate su cloud. Un sistema di amministrazione remota può stabilire un portale per l'accesso alle funzioni di amministrazione e gestione di vari sistemi sottostanti, inclusi i sistemi di gestione delle risorse, degli SLA e della fatturazione. Gli strumenti e le API forniti da un sistema di amministrazione remota sono generalmente utilizzati dal fornitore di servizi cloud per sviluppare e personalizzare online portali che forniscono ai consumatori cloud una varietà di controlli delle funzioni amministrative. Di seguito sono riportati i due tipi principali di portali che vengono creati con il sistema di amministrazione remota:

- **Usage and Administration Portal:** un portale per scopi generici che centralizza i controlli di gestione su diverse risorse IT basate su cloud e può fornire ulteriori report sull'utilizzo delle risorse IT.
- **Self-service Portal:** Si tratta essenzialmente di un portale di acquisti che consente ai cloud consumer di cercare un elenco aggiornato di servizi e risorse IT disponibili da un provider di servizi cloud (solitamente in locazione). Il consumatore cloud invia gli elementi scelti al provider cloud per il provisioning. A seconda di:
 - Il tipo di prodotto cloud o modello di fornitura cloud che il consumatore di cloud sta noleggiando o utilizzando dal fornitore di servizi cloud,
 - il livello di controllo degli accessi concesso dal cloud provider al cloud consumatore e

- Ulteriormente a seconda di quali sistemi di gestione sottostanti, il sistema di amministrazione remota si interfaccia con le attività che possono essere comunemente eseguite dai consumatori di cloud tramite una console di amministrazione remota, dove include:
- Configurazione e impostazione dei servizi cloud
- Provisioning e rilascio di risorse IT per servizi cloud su richiesta
- Monitoraggio dello stato, dell'utilizzo e delle prestazioni del servizio cloud
- Monitoraggio QoS e adempimento SLA
- Gestione dei costi di locazione e canoni di utilizzo
- Gestione di account utente, credenziali di sicurezza, autorizzazione e controllo degli accessi
- Tracciamento degli accessi interni ed esterni ai servizi affittati
- Pianificazione e valutazione del provisioning delle risorse IT
- Pianificazione della capacità

Sebbene l'interfaccia utente fornita dal sistema di amministrazione remota tenderà ad essere proprietaria del fornitore di servizi cloud, i consumatori di cloud preferiscono lavorare con sistemi di amministrazione remota che offrono API standardizzate. Ciò consente a un consumatore di cloud di investire nella creazione del proprio front-end con la consapevolezza di poter riutilizzare questa console se decide di passare a un altro provider di cloud che supporta la stessa API standardizzata. Inoltre, il consumatore cloud sarebbe in grado di sfruttare ulteriormente le API standardizzate se fosse interessato al leasing e all'amministrazione centralizzata delle risorse IT da più fornitori di cloud e / o delle risorse IT residenti in ambienti cloud e on-premise.

Case Study

DTGOV offre ai suoi consumatori cloud un intuitivo remote administration system per qualche tempo e recentemente ha stabilito che sono necessari aggiornamenti per soddisfare il numero crescente di consumatori di cloud e la crescente diversità delle richieste. DTGOV sta pianificando un progetto di sviluppo per estendere il sistema di amministrazione remota per soddisfare i seguenti requisiti:

- I consumatori di cloud devono essere in grado di eseguire il provisioning automatico di server virtuali e dispositivi di archiviazione virtuali. Il sistema deve in particolare interagire con l'API proprietaria della piattaforma VIM abilitata per il cloud per abilitare le funzionalità di provisioning automatico.
- È necessario incorporare un meccanismo di Single Sign-On per autorizzare e controllare centralmente l'accesso dei consumatori al cloud.
- Deve essere esposta un'API che supporti il provisioning, l'avvio, l'arresto, il rilascio, il ridimensionamento dell'aggiornamento e la replica dei comandi per server virtuali e dispositivi di archiviazione cloud. A supporto di queste funzionalità, viene sviluppato un portale self-service e viene esteso il set di funzionalità del portale di utilizzo e amministrazione esistente di DTGOV.

Resource Management System

Il meccanismo di Resource Management System aiuta a coordinare le risorse IT in risposta alle azioni di gestione eseguite sia dai consumatori che dai fornitori di servizi cloud. Il fulcro di questo sistema è il gestore dell'infrastruttura virtuale (VIM) che coordina l'hardware del server in modo che le istanze del server virtuale possano essere create dal server fisico sottostante più conveniente. Un VIM è un prodotto commerciale che può essere utilizzato per gestire una gamma di risorse IT virtuali su più server fisici. Ad esempio, un VIM può creare e gestire più istanze di un hypervisor su diversi server fisici o allocare un server virtuale su un server fisico a un altro (o un pool di risorse). Le attività generalmente automatizzate e implementate tramite il sistema di gestione delle risorse includono:

- Gestione dei modelli di risorse IT virtuali utilizzati per creare istanze predefinite, come le immagini del server virtuale
- Allocare e rilasciare risorse IT virtuali nell'infrastruttura fisica disponibile in risposta all'avvio, alla sospensione, alla ripresa e alla chiusura di istanze di risorse IT virtuali
- Coordinamento delle risorse IT in relazione al coinvolgimento di altri meccanismi, come la replica delle risorse, il bilanciamento del carico e il sistema di failover
- Applicazione di criteri di utilizzo e sicurezza per tutto il ciclo di vita delle istanze del servizio cloud
- Monitoraggio delle condizioni operative delle risorse IT

È possibile accedere alle funzioni del sistema di gestione delle risorse tramite amministratori cloud di risorse impiegati dal fornitore di servizi cloud o dal cloud consumer. Chi lavora per conto di un fornitore di servizi cloud sarà spesso in grado di accedere direttamente alla console nativa del sistema di gestione delle risorse. I sistemi di gestione delle risorse in genere espongono API che consentono ai fornitori di cloud di creare portali di sistemi di amministrazione remota che possono essere personalizzati per offrire selettivamente controlli di gestione delle risorse agli amministratori di risorse cloud esterni che agiscono per conto delle organizzazioni di consumatori cloud tramite portali di utilizzo e amministrazione.

Case Study

Il sistema di gestione delle risorse DTGOV è un'estensione di un nuovo prodotto VIM acquistato e fornisce le seguenti funzionalità principali:

- Gestione delle risorse IT virtuali con un'allocazione flessibile delle risorse IT in pool tra diversi data center
- Gestione dei database consumer in cloud
- Isolamento delle risorse IT virtuali nelle reti perimetrali logiche
- Gestione di un inventario di immagini di un server virtuale modello disponibile per l'istanza immediata
- Replica automatizzata ("snapshot") di immagini di server virtuali per la creazione di server virtuali
- Scalabilità automatica up-down dei server virtuali in base all'utilizzo di soglie per abilitare la migrazione di VM in tempo reale tra server fisici
- Un'API per la creazione e la gestione di server virtuali e dispositivi di archiviazione virtuale
- Un'API per la creazione di regole di controllo dell'accesso alla rete
- Un'API per la scalabilità up-down delle risorse IT virtuali
- Un'API per la migrazione e la replica di risorse IT virtuali su più data center
- Interoperabilità con un meccanismo di single sign-on tramite interfaccia LDAP

Gli script di comando SNMP progettati su misura sono ulteriormente implementati per interagire anche con la gestione della rete

SLA Management System

Il meccanismo di SLA Management System rappresenta una gamma di prodotti di gestione cloud disponibili in commercio che forniscono funzionalità relative all'amministrazione, raccolta, archiviazione, reporting e notifica di runtime dei dati SLA. Una distribuzione del sistema di gestione SLA includerà generalmente un repository utilizzato per archiviare e recuperare i dati SLA raccolti in base a metriche e parametri di reporting predefiniti. Si baserà inoltre su uno o più meccanismi di monitoraggio SLA per raccogliere i dati SLA che possono quindi essere resi disponibili in tempo quasi reale ai portali di utilizzo e amministrazione per fornire un feedback continuo sui servizi cloud attivi. Le metriche monitorate per i singoli servizi cloud sono allineate con le garanzie SLA nei corrispondenti contratti di cloud provisioning.

Case Study

DTGOV implementa un sistema di gestione SLA che interagisce con il suo VIM esistente. Questa integrazione consente agli amministratori delle risorse cloud DTGOV di monitorare la disponibilità di una gamma di risorse IT ospitate tramite i monitor SLA. DTGOV lavora con le funzionalità di progettazione dei report del sistema di gestione SLA per creare i seguenti report predefiniti che vengono resi disponibili tramite dashboard personalizzati:

- Dashboard di disponibilità per data center: accessibile pubblicamente tramite il portale cloud aziendale di DTGOV, questo dashboard mostra le condizioni operative generali di ogni gruppo di risorse IT in ogni data center, in tempo reale.
- Dashboard per la disponibilità dei consumatori per cloud: questo dashboard mostra le condizioni operative in tempo reale delle singole risorse IT. È possibile accedere alle informazioni su ciascuna risorsa IT solo dal fornitore di servizi cloud e dal consumatore cloud che noleggia o possiede la risorsa IT.
- Report sugli SLA dei consumatori per cloud: questo report consolida e riepiloga le statistiche sugli SLA per le risorse IT dei consumatori cloud, inclusi i tempi di inattività e altri eventi SLA con data e ora. Gli eventi SLA generati dai monitor SLA rappresentano lo stato e le prestazioni delle risorse IT fisiche e virtuali controllate dalla piattaforma di virtualizzazione. Il sistema di gestione SLA interagisce con gli strumenti di gestione della rete tramite un agente software SNMP progettato su misura che riceve le notifiche degli eventi SLA. Il sistema di gestione degli SLA interagisce anche con il VIM attraverso la sua API proprietaria per associare ogni evento SLA di rete alla risorsa IT virtuale interessata. Il sistema include un database proprietario utilizzato per memorizzare gli eventi SLA (come il server virtuale e i tempi di inattività della rete). Il sistema di gestione SLA espone un'API REST che DTGOV utilizza per interfacciarsi con il proprio sistema di amministrazione remota centrale. L'API proprietaria ha un'implementazione del servizio componente che può essere utilizzata per l'elaborazione in batch con il sistema di gestione della fatturazione. DTGOV lo utilizza per fornire periodicamente dati sui tempi di inattività che si traducono in credito applicato alle tariffe di utilizzo del cloud per i consumatori.

Billing Management System

Il meccanismo del sistema di gestione della fatturazione è dedicato alla raccolta ed elaborazione dei dati di utilizzo per quanto riguarda la contabilità del fornitore di servizi cloud e la fatturazione per i consumatori del cloud. In particolare, il sistema di gestione della fatturazione si basa su monitor pay-per-use per raccogliere i dati sull'utilizzo del runtime che vengono archiviati in un repository da cui i componenti del sistema attingono per scopi di fatturazione e reporting. Il sistema di gestione della fatturazione consente la definizione di diverse politiche di prezzo, nonché modelli di prezzo personalizzati in base al consumatore cloud e / o alla risorsa IT. I modelli di prezzo possono variare dai tradizionali modelli pay-per-use, alle modalità forfettarie o pay-per-allocation, o combinazioni di queste. Le disposizioni di fatturazione si basano sui pagamenti pre-utilizzo e post-utilizzo. Quest'ultima tipologia può comprendere limiti predefiniti oppure può essere impostata (di comune accordo con il consumatore cloud) per consentirne l'utilizzo illimitato (e, di conseguenza, nessun limite alla fatturazione successiva). Quando vengono stabiliti dei limiti, di solito sono sotto forma di quote di utilizzo. Quando le quote vengono superate, il sistema di gestione della fatturazione può bloccare ulteriori richieste di utilizzo da parte dei consumatori cloud.

Case Study

DTGOV decide di stabilire un sistema di gestione della fatturazione che consente loro di creare fatture per eventi fatturabili definiti dall'utente, come abbonamenti e utilizzo del volume delle risorse IT. Il sistema di gestione della fatturazione è personalizzato con gli eventi necessari e i metadati dello schema tariffario. Include i seguenti due database proprietari corrispondenti:

- Archivio eventi fatturabile
- Repository di schemi tariffari

Gli eventi di utilizzo vengono raccolti dai monitor pay-per-use implementati come estensioni della piattaforma VIM. Gli eventi di utilizzo a granularità sottile, come l'avvio, l'arresto, il ridimensionamento e la disattivazione del server virtuale, vengono archiviati in un repository gestito dalla piattaforma VIM. I monitor pay-per-use forniscono inoltre regolarmente al sistema di gestione della fatturazione gli eventi fatturabili appropriati. Un modello di prezzo standard viene applicato alla maggior parte dei contratti dei consumatori cloud, sebbene possa essere personalizzato quando vengono negoziate condizioni speciali.

Security Management

Encryption

I dati, per impostazione predefinita, sono codificati in un formato leggibile noto come testo normale. Quando viene trasmesso su una rete, il testo in chiaro è vulnerabile ad accessi non autorizzati e potenzialmente dannosi. Il meccanismo di crittografia è un sistema di codifica digitale dedicato a preservare la riservatezza e l'integrità dei dati. Viene utilizzato per codificare i dati di testo in chiaro in un formato protetto e illeggibile. La tecnologia di crittografia si basa comunemente su un algoritmo standardizzato, chiamato cifrario, per trasformare i dati di testo in chiaro originali in dati crittografati, indicati come testo cifrato. L'accesso al testo cifrato non divulga i dati del testo in chiaro originali, a parte alcune forme di metadati, come la lunghezza del messaggio e la data di creazione. Quando la crittografia viene applicata ai dati in testo normale, i dati vengono associati a una stringa di caratteri denominata "chiave di crittografia", un messaggio segreto che viene stabilito e condiviso tra le parti autorizzate. La chiave di crittografia viene utilizzata per decrittografare il testo cifrato nel suo formato di testo normale originale. Il meccanismo di crittografia può aiutare a contrastare le minacce alla sicurezza che intercettano il traffico, l'intermediario dannoso, l'autorizzazione insufficiente e la sovrapposizione dei limiti di fiducia. Ad esempio, gli agenti di servizio dannosi che tentano di intercettare il traffico non sono in grado di decrittografare i messaggi in transito se non dispongono della chiave di crittografia. Esistono due forme comuni di crittografia note come:

- **Symmetric Encryption:** La crittografia simmetrica utilizza la stessa chiave sia per la crittografia che per la decrittografia, entrambe eseguite da parti autorizzate che utilizzano l'unica chiave condivisa. Nota anche come crittografia a chiave segreta, i messaggi crittografati con una chiave specifica possono essere decrittografati solo dalla stessa chiave. Ai soggetti che legittimamente decrittano i dati viene fornita la prova che la crittografia originale è stata eseguita da soggetti che legittimamente possiedono la chiave. Viene sempre eseguito un controllo di autenticazione di base, poiché solo le parti autorizzate che possiedono la chiave possono creare messaggi. Ciò mantiene e verifica la riservatezza dei dati. Si noti che la crittografia simmetrica non ha la caratteristica di non ripudio, poiché determinare esattamente quale parte ha eseguito la crittografia o la decrittografia del messaggio non è possibile se più di una parte è in possesso della chiave.

- **Asymmetric Encryption:** La crittografia asimmetrica si basa sull'uso di due chiavi diverse, ovvero una chiave privata e una chiave pubblica. Con la crittografia asimmetrica (che viene anche definita crittografia a chiave pubblica), la chiave privata è nota solo al suo proprietario mentre la chiave pubblica è comunemente disponibile. Un documento che è stato crittografato con una chiave privata può essere decrittografato correttamente solo con la chiave pubblica corrispondente. Al contrario, un documento che è stato crittografato con una chiave pubblica può essere decrittografato solo utilizzando la sua controparte con chiave privata. Come risultato dell'utilizzo di due chiavi diverse invece di una sola, la crittografia asimmetrica è quasi sempre più lenta dal punto di vista computazionale della crittografia simmetrica. Il livello di sicurezza ottenuto dipende dall'utilizzo di una chiave privata o pubblica per crittografare i dati in chiaro. Come ogni messaggio crittografato in modo asimmetrico ha una propria coppia di chiavi pubblica-privata, i messaggi crittografati con una chiave privata possono essere decrittografati correttamente da qualsiasi parte con la chiave pubblica corrispondente. Questo metodo di crittografia non offre alcuna protezione della riservatezza, anche se la decrittazione riuscita dimostra che il testo è stato crittografato dal legittimo proprietario della chiave pubblica. La crittografia della chiave privata offre quindi protezione dell'integrità oltre all'autenticità e al non ripudio. Un messaggio crittografato con una chiave pubblica può essere decrittografato solo dal legittimo proprietario della chiave privata, che fornisce protezione della riservatezza. Tuttavia, qualsiasi parte che abbia la chiave pubblica può generare il testo cifrato, il che significa che questo metodo non fornisce né l'integrità del messaggio né la protezione dell'autenticità a causa della natura comune della chiave pubblica.

Case Study

Innovartus ha recentemente appreso che gli utenti che accedono al proprio portale di registrazione tramite hot zone Wi-Fi pubbliche e LAN non protette potrebbe trasmettere i dettagli del profilo utente personale tramite testo in chiaro. Innovartus rimedia immediatamente a questa vulnerabilità applicando il meccanismo di crittografia al suo portale Web tramite l'uso di HTTPS

Hashing

Il meccanismo di hashing viene utilizzato quando è richiesta una forma di protezione dei dati unidirezionale e non reversibile. Una volta che l'hashing è stato applicato a un messaggio, questo viene bloccato e non viene fornita alcuna chiave per sbloccare il messaggio. Un'applicazione comune di questo meccanismo è la memorizzazione delle password. La tecnologia di hashing può essere utilizzata per derivare un codice hashing o un digest di un messaggio da un messaggio che spesso è di lunghezza fissa e più piccolo del messaggio originale. Il mittente del messaggio può quindi utilizzare il meccanismo di hashing per allegare il digest del messaggio al messaggio. Il destinatario applica la stessa funzione hash al messaggio per verificare che il digest del messaggio prodotto sia identico a quello che accompagnava il messaggio. Qualsiasi modifica ai dati originali si traduce in un digest del messaggio completamente diverso e indica chiaramente che si è verificata una manomissione. Oltre al suo utilizzo per proteggere i dati archiviati, le minacce cloud che possono essere mitigate dal meccanismo di hashing includono intermediari dannosi e autorizzazione insufficiente.

Case Study

Un sottoinsieme delle applicazioni che sono state selezionate per essere portate sulla piattaforma PaaS di ATN consente agli utenti di accedere e modificare dati aziendali altamente sensibili. Queste informazioni vengono ospitate su un cloud per consentire l'accesso da parte di partner fidati che potrebbero utilizzarle per calcoli critici e scopi di valutazione. Preoccupato che i dati possano essere

manomessi, ATN decide di applicare il meccanismo di hashing come mezzo per proteggere e preservare l'integrità dei dati. Gli amministratori delle risorse cloud ATN collaborano con il provider cloud per incorporare una procedura di generazione del digest con ciascuna versione dell'applicazione distribuita nel cloud. I valori correnti vengono registrati in un database sicuro in sede e la procedura viene ripetuta regolarmente con i risultati analizzati.

Digital Signature

Il meccanismo della firma digitale è un mezzo per fornire autenticità e integrità dei dati attraverso l'autenticazione e il non ripudio. A un messaggio viene assegnata una firma digitale prima della trasmissione, che viene quindi resa non valida se il messaggio subisce modifiche successive non autorizzate. Una firma digitale fornisce la prova che il messaggio ricevuto è lo stesso di quello creato dal suo legittimo mittente. Sia l'hashing che la crittografia asimmetrica sono coinvolti nella creazione di una firma digitale, che esiste essenzialmente come un digest del messaggio che è stato crittografato da una chiave privata e aggiunto al messaggio originale. Il destinatario verifica la validità della firma e utilizza la chiave pubblica corrispondente per decrittografare la firma digitale, che produce il digest del messaggio. Il meccanismo di hashing può essere applicato anche al messaggio originale per produrre questo messaggio digest. Risultati identici dai due diversi processi indicano che il messaggio ha mantenuto la sua integrità. Il meccanismo di firma digitale aiuta a mitigare le minacce alla sicurezza dell'intermediario dannoso, dell'autorizzazione insufficiente e dei limiti di fiducia sovrapposti.

Case Study

Con l'espansione del portafoglio clienti di DTGOV fino a includere organizzazioni del settore pubblico, molte delle sue politiche di cloud computing sono diventate inadatte e richiedono modifiche. Considerando che le organizzazioni del settore pubblico gestiscono frequentemente le informazioni strategiche, è necessario stabilire misure di sicurezza per proteggere la manipolazione dei dati e stabilire un mezzo per le attività di controllo che possono influire sulle operazioni del governo. DTGOV procede all'implementazione del meccanismo di firma digitale specificatamente per proteggere il proprio ambiente di gestione basato sul Web. L'auto-provisioning del server virtuale all'interno dell'ambiente IaaS e la funzionalità di tracciamento dello SLA e della fatturazione in tempo reale vengono tutti eseguiti tramite portali Web. Di conseguenza, errori dell'utente o azioni dannose potrebbero comportare conseguenze legali e finanziarie. Le firme digitali forniscono a DTGOV la garanzia che ogni azione eseguita è collegata al suo legittimo autore. Si prevede che l'accesso non autorizzato diventi altamente improbabile, poiché le firme digitali vengono accettate solo se la chiave di crittografia è identica alla chiave segreta detenuta dal legittimo proprietario. Gli utenti non avranno motivo di negare i tentativi di adulterazione del messaggio perché le firme digitali confermeranno l'integrità del messaggio.

Public Key Infrastructure (PKI)

Un approccio comune per la gestione dell'emissione di chiavi asimmetriche si basa sul meccanismo dell'infrastruttura a chiave pubblica (PKI), che esiste come un sistema di protocolli, formati di dati, regole e pratiche che consentono ai sistemi su larga scala di utilizzare in modo sicuro la crittografia a chiave pubblica. Questo sistema viene utilizzato per associare le chiavi pubbliche ai rispettivi proprietari delle chiavi (noto come identificazione della chiave pubblica) consentendo la verifica della validità della chiave. Le PKI si basano sull'uso di certificati digitali, che sono strutture di dati firmate digitalmente che legano le chiavi pubbliche alle identità del proprietario del certificato, nonché alle

informazioni correlate, come i periodi di validità. I certificati digitali sono solitamente firmati digitalmente da un'autorità di certificazione (CA) di terze parti. È possibile utilizzare altri metodi per generare firme digitali, anche se la maggior parte dei certificati digitali viene emessa solo da una manciata di CA affidabili come VeriSign e Comodo. Le organizzazioni più grandi, come Microsoft, possono agire come propria CA ed emettere certificati ai propri clienti e al pubblico, poiché anche i singoli utenti possono generare certificati purché dispongano degli strumenti software appropriati. Creare un livello di fiducia accettabile per una CA richiede molto tempo ma è necessario. Misure di sicurezza rigorose, investimenti sostanziali nell'infrastruttura e processi operativi rigorosi contribuiscono tutti a stabilire la credibilità di una CA. Maggiore è il suo livello di fiducia e affidabilità, più stimati e affidabili sono i suoi certificati. La PKI è un metodo affidabile per l'implementazione della crittografia asimmetrica, la gestione delle informazioni sull'identità del consumatore e del provider cloud e per aiutare a difendersi dall'intermediario dannoso e dalle minacce di autorizzazione insufficiente. Il meccanismo PKI viene utilizzato principalmente per contrastare la minaccia di autorizzazione insufficiente.

Case Study

DTGOV richiede che i suoi clienti utilizzino le firme digitali per accedere al proprio ambiente di gestione basato sul Web. Questi devono essere generati da chiavi pubbliche che sono state certificate da un'autorità di certificazione riconosciuta.

Identity and Access Management (IAM)

Il meccanismo di gestione dell'identità e degli accessi (IAM) comprende i componenti e le politiche necessarie per controllare e tenere traccia delle identità degli utenti e dei privilegi di accesso per risorse, ambienti e sistemi IT. Nello specifico, i meccanismi IAM esistono come sistemi composti da quattro componenti principali:

- Autenticazione: le combinazioni di nome utente e password rimangono forme più comuni di credenziali di autenticazione utente gestite dal sistema IAM, che può anche supportare firme digitali, certificati digitali, hardware biometrico (lettori di impronte digitali), software specializzato (come programmi di analisi vocale) e blocco degli account utente su indirizzi IP o MAC registrati.
- Autorizzazione: il componente di autorizzazione definisce la granularità corretta per i controlli di accesso e supervisiona le relazioni tra identità, diritti di controllo di accesso e disponibilità delle risorse IT.
- Gestione utenti: in relazione alle capacità amministrative del sistema, il programma di gestione utenti è responsabile della creazione di nuove identità utente e gruppi di accesso, reimpostazione delle password, definizione dei criteri delle password e gestione dei privilegi.
- Gestione delle credenziali: il sistema di gestione delle credenziali stabilisce le identità e le regole di controllo degli accessi per gli account utente definiti, riducendo così il rischio di un'autorizzazione insufficiente. Sebbene i suoi obiettivi siano simili a quelli del meccanismo PKI, l'ambito di implementazione del meccanismo IAM è distinto perché la sua struttura comprende controlli e policy di accesso oltre all'assegnazione di livelli specifici di privilegi utente. Il meccanismo IAM viene utilizzato principalmente per contrastare le minacce di autorizzazione insufficiente, Denial of service e sovrapposizione dei confini di trust.

Case Study

Come risultato di diverse acquisizioni aziendali passate, il panorama legacy di ATN è diventato complesso e altamente eterogeneo. I costi di manutenzione sono aumentati a causa di applicazioni e database ridondanti e simili in esecuzione contemporaneamente. I repository legacy di credenziali utente sono altrettanto assortiti. Ora che ATN ha portato diverse applicazioni in un ambiente PaaS, vengono create e configurate nuove identità per concedere l'accesso agli utenti. I consulenti di Cloud Enhance suggeriscono che ATN tragga vantaggio da questa opportunità avviando un'iniziativa pilota di sistema IAM, soprattutto perché è necessario un nuovo gruppo di identità basate su cloud. ATN è d'accordo e un sistema IAM specializzato è progettato specificamente per regolare i limiti di sicurezza all'interno del loro nuovo ambiente PaaS. Con questo sistema, le identità assegnate alle risorse IT basate su cloud differiscono dalle identità locali corrispondenti, originariamente definite in base alle politiche di sicurezza interne di ATN.

Single Sign-On (SSO)

La propagazione delle informazioni di autenticazione e autorizzazione per un consumatore di servizi cloud su più servizi può essere una sfida, soprattutto se è necessario richiamare numerosi servizi cloud o risorse IT basate su cloud come parte della stessa attività di runtime complessiva. Il meccanismo Single Sign-On (SSO) consente a un consumatore di servizi cloud di essere autenticato da un broker di sicurezza, che stabilisce un contesto di sicurezza che viene mantenuto mentre il consumatore di servizi cloud accede ad altri servizi cloud o risorse IT basate su cloud. In caso contrario, il consumatore del servizio cloud dovrebbe autenticarsi nuovamente a ogni richiesta successiva. Il meccanismo SSO consente essenzialmente a servizi cloud e risorse IT reciprocamente indipendenti di generare e far circolare le credenziali di autenticazione e autorizzazione in fase di esecuzione. Le credenziali inizialmente fornite dal consumatore del servizio cloud rimangono valide per la durata di una sessione, mentre le relative informazioni sul contesto di sicurezza vengono condivise. Il broker di sicurezza del meccanismo SSO è particolarmente utile quando un consumatore di servizi cloud deve accedere a servizi cloud che risiedono su cloud diversi.

Case Study

La migrazione delle applicazioni alla nuova piattaforma PaaS di ATN ha avuto successo, ma ha anche sollevato una serie di nuove preoccupazioni relative alla reattività e alla disponibilità delle risorse IT ospitate da PaaS. ATN intende spostare più applicazioni su una piattaforma PaaS, ma decide di farlo stabilendo un secondo ambiente PaaS con un diverso provider di cloud. Ciò consentirà loro di confrontare i fornitori di servizi cloud durante un periodo di valutazione di tre mesi. Per accogliere questa architettura cloud distribuita, il meccanismo SSO viene utilizzato per stabilire un broker di sicurezza in grado di propagare le credenziali di accesso su entrambi i cloud. Ciò consente a un singolo amministratore di risorse cloud di accedere alle risorse IT su entrambi gli ambienti PaaS senza dover accedere separatamente a ciascuno di essi.

Cloud-Based Security Groups

La protezione dei dati viene aumentata inserendo barriere tra le risorse IT. La segmentazione delle risorse cloud è un processo mediante il quale vengono creati ambienti IT fisici e virtuali separati per diversi utenti e gruppi. Ad esempio, la WAN di un'organizzazione può essere partizionata in base ai requisiti di sicurezza della rete individuale. Una rete può essere stabilita con un firewall resiliente per l'accesso a Internet esterno, mentre una seconda può essere implementata senza un firewall perché i suoi utenti sono interni e non possono accedere a Internet. La segmentazione delle risorse viene utilizzata per abilitare la virtualizzazione allocando una varietà di risorse IT fisiche alle macchine

virtuali. Deve essere ottimizzato per gli ambienti cloud pubblici, poiché i confini di fiducia dell'organizzazione di diversi consumatori di cloud si sovrappongono quando condividono le stesse risorse IT fisiche sottostanti. Il processo di segmentazione delle risorse basato su cloud crea meccanismi di security group basati su cloud determinati tramite criteri di sicurezza. Le reti sono segmentate in security groups basati sul cloud logico che formano i perimetri della rete logica. Ogni risorsa IT basata su cloud è assegnata ad almeno un gruppo di sicurezza basato su cloud logico. A ogni gruppo di sicurezza basato su cloud logico vengono assegnate regole specifiche che regolano la comunicazione tra i gruppi di sicurezza. Più server virtuali in esecuzione sullo stesso server fisico possono diventare membri di diversi gruppi di sicurezza basati su cloud logico. I server virtuali possono essere ulteriormente separati in gruppi pubblico-privato, gruppi di sviluppo-produzione o qualsiasi altra designazione configurata dall'amministratore delle risorse cloud. I gruppi di sicurezza basati su cloud delineano aree in cui è possibile applicare diverse misure di sicurezza. I gruppi di sicurezza basati su cloud correttamente implementati aiutano a limitare l'accesso non autorizzato alle risorse IT in caso di violazione della sicurezza. Questo meccanismo può essere utilizzato per contrastare le minacce di tipo Denial of Service (DoS), autorizzazione insufficiente e sovrapposizione dei confini di trust ed è strettamente correlato al meccanismo perimetrale della rete logica.

Case Study

Ora che DTGOV è diventato esso stesso un fornitore di servizi cloud, vengono sollevati problemi di sicurezza relativi all'hosting dei dati dei clienti del settore pubblico. Viene coinvolto un team di specialisti della sicurezza cloud per definire i gruppi di sicurezza basati sul cloud insieme alla firma digitale e ai meccanismi PKI. Le politiche di sicurezza sono classificate in livelli di segmentazione delle risorse prima di essere integrate nell'ambiente di gestione del portale Web di DTGOV. Coerentemente con i requisiti di sicurezza garantiti dai suoi SLA, DTGOV mappa l'allocazione delle risorse IT al gruppo di sicurezza logico basato su cloud appropriato, che ha una propria policy di sicurezza che stabilisce chiaramente i suoi livelli di isolamento e controllo delle risorse IT. DTGOV informa i propri clienti sulla disponibilità di queste nuove politiche di sicurezza. I consumatori di cloud possono opzionalmente scegliere di utilizzarli e ciò comporta un aumento delle tariffe.

Hardened Virtual Server Images

Un server virtuale viene creato da un modello di configurazione chiamata "immagine del server virtuale" (o immagine della macchina virtuale). L'indurimento è il processo di rimozione del software non necessario da un sistema per limitare le potenziali vulnerabilità che possono essere sfruttate dagli aggressori. La rimozione di programmi ridondanti, la chiusura di porte server non necessarie e la disabilitazione di servizi inutilizzati, account root interni e accesso guest sono tutti esempi di rafforzamento. Un Hardened Virtual Server Image è un modello per la creazione di istanze di servizi virtuali che è stata sottoposta a un processo di protezione avanzata. Ciò si traduce generalmente in un modello di server virtuale che è significativamente più sicuro rispetto all'immagine standard originale.

Case Study

Una delle funzionalità di sicurezza messe a disposizione degli utenti cloud come parte dell'adozione da parte di DTGOV di gruppi di sicurezza basati su cloud è un'opzione per rafforzare alcuni o tutti i server virtuali all'interno di un dato gruppo. Ogni immagine di server virtuale rinforzato comporta un costo aggiuntivo, ma evita ai consumatori di cloud di dover eseguire da soli il processo di protezione avanzata.



Lezione – Fundamental Cloud Architectures

Cloud Computing Architectures

Questo capitolo introduce e descrive molti dei più comuni modelli di architettura cloud di base, ciascuno esemplificativo di un utilizzo comune e caratteristico degli ambienti cloud contemporanei. Vengono esplorati il coinvolgimento e l'importanza di diverse combinazioni di meccanismi di cloud computing in relazione a queste architetture.

Workload Distribution Architecture

Le risorse IT possono essere ridimensionate orizzontalmente tramite l'aggiunta di una o più risorse IT identiche e un load balancer che fornisce logica di runtime in grado di distribuire uniformemente il carico di lavoro tra le risorse IT disponibili. L'architettura di distribuzione del carico di lavoro risultante riduce sia il sovrautilizzo che il sottoutilizzo delle risorse IT in una misura dipendente dalla sofisticazione degli algoritmi di bilanciamento del carico e dalla logica di runtime. Questo modello architettonico fondamentale può essere applicato a qualsiasi risorsa IT, con la distribuzione del carico di lavoro comunemente eseguita a supporto di server virtuali distribuiti, dispositivi di archiviazione cloud e servizi cloud. I sistemi di bilanciamento del carico applicati a risorse IT specifiche di solito producono variazioni specializzate di questa architettura che incorporano aspetti del bilanciamento del carico, come ad esempio:


- l'architettura di bilanciamento del carico dei servizi
- l'architettura del server virtuale con bilanciamento del carico
- l'architettura degli switch virtuali con bilanciamento del carico

Oltre al meccanismo di bilanciamento del carico di base e ai meccanismi del server virtuale e del dispositivo di archiviazione cloud a cui è possibile applicare il bilanciamento del carico, anche i seguenti meccanismi possono far parte di questa architettura cloud:


- **Audit Monitor:** quando si distribuiscono carichi di lavoro di runtime, il tipo e la posizione geografica delle risorse IT che elaborano i dati può determinare se il monitoraggio è necessario per soddisfare i requisiti legali e normativi.
- **Cloud Usage Monitor:** è possibile utilizzare diversi monitor per eseguire il monitoraggio del carico di lavoro in fase di esecuzione e l'elaborazione dei dati.
- **Hypervisor:** i carichi di lavoro tra hypervisor e server virtuali che ospitano potrebbero richiedere la distribuzione.
- **Logical Network Perimeter:** il logical network perimeter isola i confini della rete dei consumatori cloud in relazione a come e dove i carichi di lavoro vengono distribuiti.
- **Resource Cluster:** le risorse IT in cluster in modalità attiva / attiva vengono comunemente utilizzate per supportare il bilanciamento del carico di lavoro tra i diversi nodi del cluster.
- **Resource Replication:** questo meccanismo può generare nuove istanze di risorse IT virtualizzate in risposta alle richieste di distribuzione del carico di lavoro in fase di esecuzione.

Resource Pooling Architecture


Un'architettura di pooling delle risorse si basa sull'uso di uno o più pool di risorse, in cui sono raggruppate risorse IT identiche e mantenute da un sistema che garantisce automaticamente che rimangano sincronizzati. Di seguito vengono forniti esempi comuni di pool di risorse:




I pool di server fisici sono costituiti da server in rete che sono stati installati con i sistemi operativi e altri programmi e / o applicazioni necessari e sono pronti per l'uso immediato.




I virtual server pool vengono solitamente configurati utilizzando uno dei diversi modelli disponibili scelti dal consumatore cloud durante il provisioning. Ad esempio, un consumatore cloud può configurare un pool di server Windows di medio livello con 4 GB di RAM o un pool di server Ubuntu di basso livello con 2 GB di RAM.




I storage pool, o pool di dispositivi di archiviazione cloud, sono costituiti da file strutture di archiviazione basate su blocchi che contengono cloud vuoto e / o pieno dispositivi di memoria.




I network pool (pool di rete/interconnessione) sono composti da diversi dispositivi di connettività di rete preconfigurati. Ad esempio, un pool di È possibile creare dispositivi firewall virtuali o switch di rete fisici per la connettività ridondante, il bilanciamento del carico o l'aggregazione di link.



I CPU pool sono pronti per essere allocati ai server virtuali e sono generalmente suddivisi in singoli core di elaborazione.




I memory pool possono essere utilizzati nei server fisici di recente provisioning o per scalare verticalmente i server fisici. È possibile creare pool dedicati per ogni tipo di risorsa IT e raggruppare i singoli pool in un pool più grande, nel qual caso ogni singolo pool diventa un sotto-pool.



I resource pool possono diventare molto complessi, con più pool creati per specifici consumatori o applicazioni cloud. È possibile stabilire una struttura gerarchica per formare

pool principali, di pari livello e nidificati al fine di facilitare l'organizzazione di diversi requisiti di pool di risorse.



I resource pool di pari livello vengono solitamente estratti da risorse IT raggruppate fisicamente, a differenza delle risorse IT distribuite su diversi data center. I pool di pari livello sono isolati gli uni dagli altri in modo che ogni utente cloud abbia accesso solo al rispettivo pool. Nel modello di pool nidificato, i pool più grandi sono suddivisi in pool più piccoli che raggruppano individualmente lo stesso tipo di risorse IT. I pool nidificati possono essere utilizzati per assegnare pool di risorse a diversi reparti o gruppi nella stessa organizzazione di consumatori cloud. Dopo che i pool di risorse sono stati definiti, è possibile creare più istanze di

risorse IT da ciascun pool per fornire un pool in memoria di risorse IT "attive". Oltre ai dispositivi di archiviazione cloud e ai server virtuali, che sono comunemente meccanismi in pool. Anche i seguenti meccanismi possono far parte di questa architettura cloud:

- **Audit Monitor:** questo meccanismo monitora l'utilizzo del pool di risorse per garantire la conformità con i requisiti di privacy e regolamentazione, soprattutto quando i pool contengono dispositivi di archiviazione cloud o dati caricati in memoria.
- **Cloud Usage Monitor:** vari monitoraggi dell'utilizzo del cloud sono coinvolti nel monitoraggio e nella sincronizzazione del runtime richiesti dalle risorse IT in pool e da qualsiasi sistema di gestione sottostante.
- **Hypervisor:** il meccanismo dell'hypervisor è responsabile della fornitura di server virtuali con accesso ai pool di risorse, oltre a ospitare i server virtuali e talvolta i pool di risorse stessi.
- **Logical Network Perimeter:** il perimetro di rete logico viene utilizzato per organizzare e isolare logicamente i pool di risorse.
- **Pay-Per-Use Monitor:** il monitor pay-per-use raccoglie l'utilizzo e le informazioni di fatturazione su come vengono allocati i singoli consumatori cloud e utilizzano le risorse IT di vari pool.
- **Remote Administration System:** questo meccanismo viene comunemente utilizzato per interfacciarsi con sistemi e programmi di backend al fine di fornire funzionalità di amministrazione del pool di risorse tramite un portale front-end.
- **Resource Management System:** il meccanismo del sistema di gestione delle risorse fornisce ai consumatori del cloud gli strumenti e le opzioni di gestione delle autorizzazioni per l'amministrazione dei pool di risorse.
- **Resource Replication:** questo meccanismo viene utilizzato per generare nuove istanze di risorse IT per pool di risorse.

Dynamic Scalability Architecture

L'architettura di dynamic scalability è un modello architettonico basato su un sistema di condizioni di scalabilità predefinite che attivano l'allocazione dinamica delle risorse IT dai pool di risorse. L'allocazione dinamica consente l'utilizzo variabile come dettato dalle fluttuazioni della domanda di utilizzo, poiché le risorse IT non necessarie vengono recuperate in modo efficiente senza richiedere l'interazione manuale. Il listener di ridimensionamento automatico è configurato con soglie del carico di lavoro che stabiliscono quando è necessario aggiungere nuove risorse IT all'elaborazione del carico di lavoro. Questo meccanismo può essere fornito con una logica che determina quante risorse IT aggiuntive possono essere fornite dinamicamente, in base ai termini del contratto di fornitura di un

determinato consumatore cloud. Vengono comunemente utilizzati i seguenti tipi di ridimensionamento dinamico:

- **Dynamic Horizontal Scaling:** le istanze delle risorse IT vengono ridimensionate e ridotte per gestire i carichi di lavoro fluttuanti. Il listener con ridimensionamento automatico monitora le richieste e segnala alla resource replication di avviare la duplicazione delle risorse IT, secondo i requisiti e le autorizzazioni.
- **Dynamic Vertical Scaling:** le istanze delle risorse IT vengono ridimensionate quando è necessario regolare la capacità di elaborazione di una singola risorsa IT. Ad esempio, un server virtuale che viene sovraccaricato può avere la sua memoria aumentata dinamicamente o può avere un core di elaborazione aggiunto.
- **Dynamic Relocation:** la risorsa IT viene trasferita su un host con maggiore capacità. Ad esempio, potrebbe essere necessario spostare un database da un dispositivo di archiviazione SAN basato su nastro con capacità di I / O di 4 GB al secondo a un altro dispositivo di archiviazione SAN basato su disco con capacità di I / O di 8 GB al secondo. L'architettura di scalabilità dinamica può essere applicata a una vasta gamma di risorse IT, inclusi server virtuali e dispositivi di archiviazione cloud. Oltre al listener di ridimensionamento automatico di base e ai meccanismi di replica delle risorse, in questa forma di architettura cloud possono essere utilizzati anche i seguenti meccanismi:
- **Cloud Usage Monitor:** i monitoraggi dell'utilizzo del cloud specializzati possono monitorare l'utilizzo del runtime in risposta alle fluttuazioni dinamiche causate da questa architettura.
- **Hypervisor:** l'hypervisor viene richiamato da un sistema di scalabilità dinamica per creare o rimuovere istanze del server virtuale o per essere ridimensionato.
- **Pay-per-use Monitor:** il monitoraggio pay-per-use è utilizzato per raccogliere informazioni sui costi di utilizzo in risposta alla scalabilità delle risorse IT.

Elastic Resource Capacity Architecture

Elastic resource capacity architecture è principalmente correlata al provisioning dinamico dei server virtuali, utilizzando un sistema che alloca e recupera CPU e RAM in risposta immediata ai requisiti di elaborazione fluttuanti delle risorse IT ospitate. I pool di risorse vengono utilizzati dalla tecnologia di ridimensionamento che interagisce con l'hypervisor e / o VIM per recuperare e restituire risorse CPU e RAM in fase di esecuzione. L'elaborazione runtime del server virtuale viene monitorata in modo che la potenza di elaborazione aggiuntiva possa essere sfruttata dal pool di risorse tramite allocazione dinamica, prima che vengano soddisfatte le soglie di capacità. Il server virtuale e le sue applicazioni ospitate e le risorse IT vengono ridimensionate verticalmente in risposta.

Questo tipo di architettura cloud può essere progettato in modo che lo script del motore di automazione intelligente invii la sua richiesta di ridimensionamento tramite VIM anziché direttamente all'hypervisor. I server virtuali che partecipano a sistemi elastici di allocazione delle risorse potrebbero richiedere il riavvio affinché l'allocazione dinamica delle risorse abbia effetto. Alcuni meccanismi aggiuntivi che possono essere inclusi in questa architettura cloud sono i seguenti:

- **Cloud Usage Monitor:** i monitoraggi dell'utilizzo del cloud specializzati raccolgono informazioni sull'utilizzo delle risorse sulle risorse IT prima, durante e dopo il ridimensionamento, per aiutare a definire le soglie di capacità di elaborazione future dei server virtuali.
- **Pay-Per-Use Monitor:** il monitoraggio pay-per-use è responsabile della raccolta delle informazioni sui costi di utilizzo delle risorse mentre fluttua con il provisioning elastico.
- **Resource Replication:** questa funzione utilizza la replica di modello architetturale delle risorse per generare nuove istanze delle risorse IT ridimensionate.

Service Load Balancing Architecture


L'architettura di Service Load Balancing può essere considerata una variazione specializzata dell'architettura di Workload Distribution che è progettata specificamente per il ridimensionamento delle implementazioni del servizio cloud. Vengono create distribuzioni ridondanti di servizi cloud, con un sistema di bilanciamento del carico aggiunto per distribuire dinamicamente i carichi di lavoro. Le implementazioni duplicate del servizio cloud sono organizzate in un pool di risorse, mentre il load balancer è posizionato come componente esterno o integrato per consentire ai server host di bilanciare i carichi di lavoro stessi. A seconda del carico di lavoro previsto e della capacità di elaborazione degli ambienti server host, è possibile generare più istanze di ciascuna implementazione del servizio cloud come parte di un pool di risorse che risponde in modo più efficiente alle fluttuazioni dei volumi di richieste. Il sistema di bilanciamento del carico può essere posizionato indipendentemente dai servizi cloud e dai loro server host o integrato come parte dell'applicazione o dell'ambiente del server. In quest'ultimo caso, un server primario con la logica di bilanciamento del carico può comunicare con i server vicini per bilanciare il carico di lavoro.

L'architettura di bilanciamento del carico del servizio può coinvolgere i seguenti meccanismi oltre al bilanciamento del carico:

- **Cloud Usage Monitor:** i monitor dell'utilizzo del cloud possono essere coinvolti nel monitoraggio delle istanze del servizio cloud e dei rispettivi livelli di consumo delle risorse IT, nonché di varie attività di monitoraggio del runtime e raccolta dei dati di utilizzo.
- **Resource Cluster:** i gruppi di cluster attivi-attivi sono incorporati in questa architettura per aiutare a bilanciare i carichi di lavoro tra i diversi membri del cluster.
- **Resource Replication:** il meccanismo di replica delle risorse viene utilizzato per generare implementazioni di servizi cloud a supporto dei requisiti di bilanciamento del carico.

Cloud Bursting Architecture

L'architettura di Cloud Bursting stabilisce una forma di scalabilità dinamica che ridimensiona o "espande" le risorse IT on-premise in un cloud ogni volta che vengono raggiunte le soglie di capacità predefinite. Le corrispondenti risorse IT basate su cloud sono predistribuite in modo ridondante ma rimangono inattive fino a quando non si verifica il burst del cloud. Dopo che non sono più necessarie, le risorse IT basate su cloud vengono rilasciate e l'architettura "irrompe" nell'ambiente in sede. Il cloud bursting è un'architettura scalabile flessibile che offre ai consumatori cloud la possibilità di utilizzare risorse IT basate su cloud solo per soddisfare le esigenze di utilizzo più elevato. La base di questo modello architettonico si basa sul listener di



ridimensionamento automatizzato e sui meccanismi di replica delle risorse. Il listener di ridimensionamento automatico determina quando reindirizzare le richieste alle risorse IT basate su cloud e la replica delle risorse viene utilizzata per mantenere la sincronicità tra le risorse IT locali e basate su cloud in relazione alle informazioni sullo stato. Oltre al listener di ridimensionamento automatizzato e alla replica delle risorse, è possibile utilizzare numerosi altri meccanismi per automatizzare le dinamiche di burst in e out per questa architettura, a seconda principalmente del tipo di risorsa IT scalata.

Elastic Disk Provisioning Architecture

I Cloud consumer sono comunemente addebitati per lo spazio di archiviazione basato su cloud in base all'allocazione di archiviazione su disco fisso, il che significa che i costi sono predeterminati dalla capacità del disco e non sono allineati con il consumo effettivo di archiviazione dei dati. L'architettura di elastic disk provisioning stabilisce un sistema di provisioning dinamico dello storage che garantisce che il cloud consumer sia granularmente fatturato per la quantità esatta di spazio di archiviazione effettivamente utilizzata. Questo sistema utilizza la tecnologia thin provisioning per l'allocazione dinamica dello spazio di archiviazione ed è ulteriormente supportato dal monitoraggio dell'utilizzo del runtime per raccogliere dati di utilizzo accurati a fini della fatturazione del software thin-provisioning installato su server virtuali che elaborano l'allocazione dinamica dello spazio di archiviazione tramite l'hypervisor, mentre il monitor pay-per-use tiene traccia e segnala i dati granulari sull'utilizzo del disco relativi alla fatturazione. I seguenti meccanismi possono essere inclusi in questa architettura oltre al dispositivo di archiviazione cloud, al server virtuale, all'hypervisor e al monitor pay-per-use:

- **Cloud Usage Monitor:** è possibile utilizzare monitoraggi dell'utilizzo del cloud specializzati per monitorare e registrare le fluttuazioni dell'utilizzo dello spazio di archiviazione.
- **Resource Replication:** la replica delle risorse fa parte di un sistema di provisioning del disco elastico quando è richiesta la conversione dello storage thin-disk dinamico in storage thin-disk statico.

Redundant Storage Architecture

I dispositivi di archiviazione cloud sono occasionalmente soggetti a guasti e interruzioni causati da problemi di connettività di rete, controller o guasti hardware generali o violazioni della sicurezza. L'affidabilità di un dispositivo di archiviazione cloud compromesso può avere un effetto a catena e causare guasti su tutti i servizi, applicazioni e componenti dell'infrastruttura nel cloud che dipendono dalla sua disponibilità. L'architettura di archiviazione ridondante introduce un dispositivo di archiviazione cloud duplicato secondario come parte di un sistema di failover che sincronizza i propri dati con i dati nel dispositivo di archiviazione cloud principale. Un gateway del servizio di archiviazione devia le richieste dei consumatori cloud al dispositivo secondario ogni volta che il dispositivo principale si guasta. Questa architettura cloud si basa principalmente su un sistema di replica dell'archiviazione che mantiene sincronizzato il dispositivo di archiviazione cloud principale con i suoi dispositivi di archiviazione cloud secondari duplicati. I cloud provider possono individuare dispositivi di archiviazione cloud secondari in una regione geografica diversa rispetto al dispositivo di archiviazione principale, di solito per motivi economici. Tuttavia, questo può introdurre problemi legali per alcuni tipi di dati. La posizione dei dispositivi di archiviazione cloud secondari può determinare il protocollo e il metodo utilizzati per la sincronizzazione, poiché alcuni protocolli di trasporto della replica hanno limitazioni di distanza. Alcuni fornitori di servizi cloud utilizzano dispositivi di archiviazione con dual array e controller di archiviazione per migliorare la ridondanza del dispositivo e collocano i dispositivi di archiviazione secondari in una posizione fisica diversa per il bilanciamento del cloud e il ripristino di emergenza. In questo caso, i fornitori di servizi cloud potrebbero dover affittare una connessione di rete tramite un fornitore di servizi cloud di terze parti per stabilire la replica tra i due dispositivi.

Case Study

Una soluzione interna che ATN non ha migrato al cloud è il Remote Upload Module, un programma utilizzato dai propri clienti per caricare quotidianamente documenti contabili e legali in un archivio centrale. I picchi di utilizzo si verificano senza preavviso, poiché la quantità di documenti ricevuti su base giornaliera è imprevedibile. Il modulo di caricamento remoto attualmente rifiuta i tentativi di


caricamento quando funziona a pieno regime, il che è problematico per gli utenti che devono archiviare determinati documenti prima della fine di una giornata lavorativa o prima di una scadenza. ATN decide di trarre vantaggio dal suo ambiente basato su cloud creando un'architettura cloud-bursting attorno all'implementazione on-premise del servizio Remote Upload Module. Ciò gli consente di esplodere nel cloud ogni volta che vengono superate le soglie di elaborazione in sede. Un sistema "burst in" viene richiamato dopo che l'utilizzo del servizio è diminuito a sufficienza in modo che le richieste dei consumatori del servizio possano essere elaborate nuovamente dall'implementazione del modulo di caricamento remoto in loco. Vengono rilasciate istanze dei servizi cloud e non vengono addebitati costi aggiuntivi per l'utilizzo correlato al cloud.



Lezione – Advanced Cloud Architectures

Hypervisor Clustering

Gli hypervisor possono essere responsabili della creazione e dell'hosting di più server virtuali. A causa di questa dipendenza, qualsiasi condizione di errore che influisce su un hypervisor può ricadere sui suoi server virtuali



L'architettura di clustering dell'hypervisor stabilisce un cluster di hypervisor ad alta disponibilità su più server fisici. Se un dato hypervisor o il suo server fisico sottostante diventa non disponibile, i server virtuali ospitati possono essere spostati su un altro server fisico o hypervisor per mantenere le operazioni di runtime.

Il cluster dell'hypervisor è controllato tramite un VIM centrale, che invia messaggi heartbeat regolari agli hypervisor per confermare che sono attivi e in esecuzione. I


messaggi di heartbeat non riconosciuti fanno sì che il VIM avvii il programma di migrazione della VM live, al fine di spostare dinamicamente i server virtuali interessati su un nuovo host.

Oltre ai meccanismi dell'hypervisor e del cluster di risorse, che costituiscono il nucleo di questo modello di architettura e dei server virtuali protetti dall'ambiente cluster, è possibile incorporare i seguenti meccanismi:

- **Logical Network Perimeter:** i confini logici creati da questo meccanismo garantiscono che nessuno degli hypervisor di altri consumatori di cloud venga accidentalmente incluso in un dato cluster.
- **Resource Replication:** gli hypervisor nello stesso cluster si informano reciprocamente sul proprio stato e disponibilità. Gli aggiornamenti su eventuali modifiche che si verificano nel cluster, come la creazione o l'eliminazione di uno switch virtuale, devono essere replicati su tutti gli hypervisor tramite VIM.

Load Balanced Virtual Servers

Mantenere i carichi di lavoro cross-server bilanciati in modo uniforme tra i server fisici, le cui operazioni e gestione sono isolate, può essere difficile. Un server fisico può facilmente finire per ospitare più server virtuali o ricevere carichi di lavoro maggiori rispetto ai server fisici adiacenti. Sia il sovrautilizzo che il sottoutilizzo del server fisico possono aumentare notevolmente nel tempo, portando a continue sfide in termini di prestazioni (per server sovrautilizzati) e sprechi costanti (per la perdita di potenziale di elaborazione dei server sottoutilizzati). L'architettura delle istanze del server virtuale con bilanciamento del carico stabilisce un sistema di controllo della capacità che calcola dinamicamente le istanze del server virtuale e i carichi di lavoro associati, prima di distribuire l'elaborazione tra gli host del server fisico disponibili. Il sistema di controllo della capacità è composto da un monitoraggio dell'utilizzo del cloud del watchdog della capacità, dal programma di migrazione



della VM live e da un pianificatore di capacità. Il monitoraggio della capacità di controllo tiene traccia dell'utilizzo del server fisico e virtuale e segnala eventuali fluttuazioni significative al pianificatore di capacità, che è responsabile del calcolo dinamico delle capacità di elaborazione del server fisico rispetto ai requisiti di capacità del server virtuale. Se il pianificatore della capacità decide di spostare un server virtuale su un altro

host per distribuire il carico di lavoro, viene segnalato al programma di migrazione della VM live di spostare il server virtuale.

I seguenti meccanismi possono essere inclusi in questa architettura, oltre a hypervisor, Resource clustering, server virtuale e Cloud usage monitor:

- **Automated Scaling Listener:** il listener di ridimensionamento automatizzato può essere utilizzato per avviare il processo di bilanciamento del carico e per monitorare dinamicamente il carico di lavoro in arrivo ai server virtuali tramite gli hypervisor.
- **Load Balancer:** il meccanismo di bilanciamento del carico è responsabile della distribuzione del carico di lavoro dei server virtuali tra gli hypervisor.
- **Logical Network Perimeter:** un perimetro di rete logico garantisce che la destinazione di un determinato server virtuale trasferito sia conforme agli SLA e alle normative sulla privacy.
- **Resource Replication:** la replica delle istanze del server virtuale potrebbe essere richiesta come parte della funzionalità di bilanciamento del carico.


Non-disruptive Service Relocation

Un servizio cloud può diventare non disponibile per una serie di motivi, ad esempio:

- Richieste di utilizzo del runtime che superano la sua capacità di elaborazione
- Un aggiornamento di manutenzione che imponga un'interruzione temporanea
- Migrazione permanente a un nuovo host server fisico

Le richieste dei consumatori del servizio cloud vengono generalmente rifiutate se un servizio cloud diventa non disponibile, il che può potenzialmente causare condizioni di eccezione. Non è preferibile rendere il servizio cloud temporaneamente non disponibile per i consumatori cloud anche se l'interruzione è pianificata. L'architettura di rilocalizzazione del servizio senza interruzioni stabilisce un sistema mediante il quale un evento predefinito innesca la duplicazione o la migrazione di un'implementazione del servizio cloud in fase di runtime, evitando così qualsiasi interruzione. Invece di ridimensionare i servizi cloud in entrata o in uscita con implementazioni ridondanti, l'attività del servizio cloud può essere temporaneamente deviata a un altro ambiente di hosting in fase di runtime aggiungendo un'implementazione duplicata su un nuovo host. Allo stesso modo, le richieste dei consumatori del servizio cloud possono essere temporaneamente reindirizzate a un'implementazione duplicata quando l'implementazione originale deve subire un'interruzione di manutenzione. Il trasferimento dell'implementazione del servizio cloud e qualsiasi attività del servizio cloud può anche essere permanente per accogliere le migrazioni del servizio cloud verso nuovi host di server fisici. Un aspetto chiave dell'architettura sottostante è che è garantito che la nuova implementazione del servizio cloud riceva e risponda con successo alle richieste dei consumatori del servizio cloud prima che l'implementazione del servizio cloud originale venga disattivata o rimossa. Un approccio comune prevede la migrazione in tempo reale della VM per spostare l'intera istanza del server virtuale che ospita il servizio cloud. Il listener di ridimensionamento automatico e / o i

meccanismi di bilanciamento del carico possono essere utilizzati per attivare un reindirizzamento temporaneo delle richieste dei consumatori del servizio cloud, in risposta ai requisiti di ridimensionamento e distribuzione del carico di lavoro. Entrambi i meccanismi possono contattare il VIM per avviare il processo di migrazione della VM live, come mostrato nelle seguenti figure.



La migrazione del server virtuale può avvenire in uno dei due modi seguenti, a seconda della posizione dei dischi del server virtuale e configurazione:

- Una copia dei dischi del server virtuale viene creata sull'host di destinazione, se i dischi del server virtuale sono archiviati su un dispositivo di archiviazione locale o dispositivi di archiviazione remoti non condivisi collegati all'host di origine. Dopo la creazione della copia, entrambe le istanze del server virtuale vengono sincronizzate e i file del server virtuale vengono rimossi dall'host di origine.
- La copia dei dischi del server virtuale non è necessaria se i file del server virtuale sono archiviati su un dispositivo di archiviazione remoto condiviso tra gli host di origine e di destinazione. La proprietà del server virtuale viene semplicemente trasferita dall'origine all'host del server fisico di destinazione.


e lo stato del server virtuale viene sincronizzato automaticamente. Questa architettura può essere supportata dall'architettura delle configurazioni di rete virtuale persistente, in modo che le configurazioni di rete definite dei server virtuali migrati vengano preservate per mantenere la connessione con i consumatori del servizio cloud. Oltre all'automated scaling listener, al bilanciatore del carico, al dispositivo di archiviazione cloud, all'hypervisor e al server virtuale, altri meccanismi che possono far parte di questa architettura includono quanto segue:

- **Cloud usage monitor:** è possibile utilizzare diversi tipi di monitor dell'utilizzo del cloud per monitorare continuamente l'utilizzo delle risorse IT e attività di sistema.
- **Pay-per-use monitor:** il monitor pay-per-use viene utilizzato per raccogliere dati per il calcolo dei costi di utilizzo del servizio per le risorse IT nelle posizioni di origine e di destinazione.
- **Resource Replication:** il meccanismo di replica delle risorse viene utilizzato per creare un'istanza della copia shadow del servizio cloud a destinazione.
- **SLA Management System:** questo sistema di gestione è responsabile dell'elaborazione dei dati SLA forniti dallo SLA monitor per ottenere garanzie sulla disponibilità del servizio cloud, sia durante che dopo la duplicazione o il trasferimento del servizio cloud.
- **SLA Monitor:** questo meccanismo di monitoraggio raccoglie le informazioni sugli SLA richieste dal sistema di gestione degli SLA, che può essere rilevante se le garanzie di disponibilità si basano su questa architettura.

Zero Downtime Architecture

Un server fisico agisce naturalmente come un singolo punto di errore per i server virtuali che ospita. Di conseguenza, quando il server fisico si guasta o viene compromesso, la disponibilità di qualsiasi (o tutti) i server virtuali ospitati può risentirne. Ciò rende difficile l'emissione di garanzie di tempi di inattività pari a zero da parte di un fornitore di servizi cloud per i consumatori di cloud. L'architettura zero downtime stabilisce un sofisticato sistema di failover che consente ai server virtuali di essere spostati dinamicamente su diversi host di server fisici, nel caso in cui il loro host di server fisico originale si guasti. Più server fisici sono assemblati in un gruppo controllato da un sistema di tolleranza ai guasti in grado di trasferire l'attività da un server fisico a un altro, senza interruzioni. Il componente di migrazione della VM live è in genere una parte fondamentale di questa forma di architettura cloud ad alta disponibilità. La tolleranza agli errori risultante garantisce che, in caso di guasto del server fisico, i server virtuali ospitati verranno migrati su un server fisico secondario. Tutti i server virtuali sono archiviati su un volume condiviso (secondo l'architettura di configurazione della rete virtuale persistente) in modo che altri host di server fisici nello stesso gruppo possano accedere ai propri file. Oltre al sistema di failover, al dispositivo di archiviazione cloud e ai meccanismi del server virtuale, i seguenti meccanismi possono far parte di questa architettura:

- **Audit Monitor:** questo meccanismo potrebbe essere necessario per verificare se il trasferimento dei server virtuali trasferisce anche i dati ospitati in posizioni proibite.
- **Cloud usage monitor:** le incarnazioni di questo meccanismo vengono utilizzate per monitorare l'effettivo utilizzo delle risorse IT degli utenti del cloud per garantire che le capacità del server virtuale non vengano superate.
- **Hypervisor:** l'hypervisor di ogni server fisico interessato ospita i server virtuali interessati.



- **Logical Network Perimeter:** i perimetri di rete logica forniscono e mantengono l'isolamento necessario per garantire che ogni utente cloud rimanga all'interno del proprio confine logico dopo il trasferimento del server virtuale.
- **Resource Cluster:** il meccanismo del cluster di risorse viene applicato per creare diversi tipi di gruppi di cluster attivi-attivi che migliorano in modo collaborativo la disponibilità delle risorse IT ospitate dal server virtuale.
- **Resource Replication:** questo meccanismo può creare il nuovo server virtuale e le istanze del servizio cloud in caso di guasto del server virtuale primario.

Cloud Balancing Architecture

L'architettura di cloud balancing stabilisce un modello architettonico specializzato in cui è possibile bilanciare il carico delle risorse IT su più cloud. Il bilanciamento cross-cloud delle richieste dei consumatori di servizi cloud può aiutare a:

- Migliorare le prestazioni e la scalabilità delle risorse IT
- Aumentare la disponibilità e l'affidabilità delle risorse IT
- Migliorare il bilanciamento del carico e l'ottimizzazione delle risorse IT

La funzionalità di cloud balancing si basa principalmente sulla combinazione dell'automated scaling listener e dei meccanismi del sistema di failover. Molti più componenti (e forse altri meccanismi) possono far parte di un'architettura di bilanciamento del cloud completa. Come punto di partenza, i due meccanismi vengono utilizzati come segue:

- L'automated scaling listener reindirizza le richieste dei consumer di servizi cloud a una delle numerose implementazioni ridondanti di risorse IT, in base ai requisiti di scalabilità e prestazioni correnti.
- Il sistema di failover garantisce che le risorse IT ridondanti siano in grado di eseguire il failover cross-cloud in caso di guasto all'interno di una risorsa IT o del suo ambiente di hosting sottostante. Gli errori delle risorse IT vengono annunciati in modo che il listener di ridimensionamento automatizzato possa evitare di instradare inavvertitamente le richieste dei consumatori di servizi cloud a risorse IT non disponibili o instabili.

Affinché un'architettura di cloud balancing funzioni in modo efficace, il listener di scalabilità automatica deve essere a conoscenza di tutte le implementazioni di risorse IT ridondanti nell'ambito dell'architettura bilanciata del cloud. Si noti che se la sincronizzazione manuale delle implementazioni di risorse IT cross-cloud non fosse possibile, potrebbe essere necessario incorporare il meccanismo di replica delle risorse per automatizzare la sincronizzazione.


Resource Reservation Architecture

A seconda di come le risorse IT sono progettate per l'utilizzo condiviso e in base ai livelli di capacità disponibili, l'accesso simultaneo può portare a una condizione di eccezione di runtime chiamata vincolo delle risorse. Un vincolo di risorse è una condizione che si verifica quando due o più consumatori cloud sono stati assegnati per condividere una risorsa IT che non ha la capacità di soddisfare i requisiti di elaborazione totali dei consumatori cloud. Di conseguenza, uno o più consumatori di cloud riscontrano prestazioni ridotte o possono essere rifiutati del tutto. Il servizio cloud stesso potrebbe non funzionare, causando il rifiuto di tutti i consumatori di cloud. Altri tipi di conflitti di runtime possono verificarsi quando si accede contemporaneamente a una risorsa IT (in particolare una non progettata specificamente per consentire la condivisione) da diversi consumatori di servizi cloud. Ad esempio, pool di risorse nidificati e di pari livello introducono il concetto di prestito di risorse, in base al quale un pool può prendere temporaneamente in prestito risorse IT da altri pool. Un conflitto di runtime può essere attivato quando la risorsa IT presa in prestito non viene restituita

a causa dell'utilizzo prolungato da parte del consumatore del servizio cloud che la prende in prestito. Ciò può inevitabilmente ricondurre al verificarsi di vincoli di risorse. L'architettura di prenotazione delle risorse stabilisce un sistema in base al quale uno dei seguenti è riservato esclusivamente per un dato consumatore cloud:

- Singola risorsa IT
- Porzione di una risorsa IT
- Più risorse IT

Ciò protegge gli utenti del cloud gli uni dagli altri evitando i suddetti vincoli di risorse e le condizioni di prestito delle risorse. La creazione di un sistema di prenotazione delle risorse IT può richiedere il coinvolgimento del meccanismo del sistema di gestione delle risorse, che viene utilizzato per definire le soglie di utilizzo per singole risorse IT e pool di risorse. Le prenotazioni bloccano la quantità di risorse IT che ogni pool deve mantenere, con il saldo delle risorse IT del pool ancora disponibili per la condivisione e il prestito. Il meccanismo del sistema di amministrazione remota viene utilizzato anche per abilitare la personalizzazione del front-end, in modo che i consumatori cloud abbiano controlli amministrativi per la gestione delle allocazioni di risorse IT riservate. I tipi di



meccanismi comunemente riservati all'interno di questa architettura sono dispositivi di archiviazione cloud e server virtuali. Altri meccanismi che possono far parte dell'architettura possono includere:

- **Audit Monitor:** il monitoraggio dell'audit viene utilizzato per verificare se il sistema di prenotazione delle risorse è conforme al controllo dei consumatori cloud, alla privacy e ad altri requisiti normativi. Ad esempio, può tenere traccia della posizione geografica delle risorse IT riservate.
- **Cloud usage monitor:** un monitoraggio dell'utilizzo del cloud può sorvegliare le soglie che attivano l'allocazione delle risorse IT riservate.
- **Hypervisor:** il meccanismo dell'hypervisor può applicare prenotazioni per diversi consumatori cloud per garantire che siano correttamente allocati alle risorse IT garantite.
- **Logical Network Perimeter:** questo meccanismo stabilisce i confini necessari per garantire che le risorse IT riservate siano rese disponibili esclusivamente ai consumatori cloud.
- **Resource Replication:** questo componente deve essere informato sui limiti di ciascun consumatore cloud per il consumo di risorse IT, al fine di replicare e fornire rapidamente nuove istanze di risorse IT.

Dynamic Failure Detect/Recovery Architecture

Gli ambienti basati su cloud possono essere costituiti da grandi quantità di risorse IT a cui accedono contemporaneamente numerosi utenti cloud. Ognuna di queste risorse IT può riscontrare condizioni di errore che richiedono più dell'intervento manuale per essere risolte. L'amministrazione e la risoluzione manuale dei guasti delle risorse IT sono generalmente inefficienti e poco pratiche. L'architettura dinamica di rilevamento e ripristino dei guasti stabilisce un sistema watchdog resiliente per monitorare e rispondere a un'ampia gamma di scenari di guasto predefiniti. Questo sistema notifica e intensifica le condizioni di errore che non può risolversi automaticamente. Si basa su un monitoraggio dell'utilizzo del cloud specializzato chiamato monitor watchdog intelligente per monitorare attivamente le risorse IT e intraprendere azioni predefinite in risposta a eventi predefiniti. Il sistema di watchdog resiliente svolge le seguenti cinque funzioni principali:

- Osservare

- Decidere su un evento
- Agire su un evento
- Reporting
- Escalation

È possibile definire criteri di ripristino sequenziali per ciascuna risorsa IT per determinare i passaggi che il monitor watchdog intelligente deve eseguire quando si verifica una condizione di errore. Ad esempio, un criterio di ripristino può stabilire che un tentativo di ripristino deve essere eseguito automaticamente prima di inviare una notifica. Alcune delle azioni comunemente eseguite dal monitor watchdog intelligente per intensificare un problema includono:

- Eseguire un file batch
- Invio di un messaggio di console
- Invio di un messaggio di testo
- Invio di un messaggio di posta elettronica
- Invio di una trap SNMP
- Registrazione di un ticket

Esistono varietà di programmi e prodotti che possono agire come monitor watchdog intelligenti. La maggior parte può essere integrata con sistemi di biglietteria e gestione eventi standard. Questo modello architettonico può incorporare ulteriormente i seguenti meccanismi:

- **Audit Monitor:** questo meccanismo viene utilizzato per monitorare se il ripristino dei dati viene eseguito in conformità con i requisiti legali o dei criteri.
- **Failover System:** il meccanismo del sistema di failover viene solitamente utilizzato durante i tentativi iniziali di ripristino delle risorse IT guaste.
- **SLA Management System e SLA Monitor:** Poiché la funzionalità ottenuta applicando questa architettura è strettamente associata alle garanzie SLA, il sistema si basa comunemente sulle informazioni gestite ed elaborate da questi meccanismi.

Bare-Metal Provisioning Architecture

Il provisioning remoto dei server è comune perché il software di gestione remota è solitamente nativo del sistema operativo della maggior parte dei server fisici. Tuttavia, l'accesso ai tradizionali programmi di gestione remota non è disponibile per i server bare metal, ovvero i server fisici che non dispongono di sistemi operativi preinstallati o altri software. La maggior parte dei server fisici contemporanei offre la possibilità di installare il supporto per la gestione remota nella ROM del server. Questo è offerto da alcuni fornitori tramite una scheda di espansione, mentre altri hanno i componenti già integrati nel chipset. L'architettura di provisioning bare metal stabilisce un sistema che utilizza questa funzionalità con agenti di servizio specializzati, che vengono utilizzati per rilevare ed eseguire in modo efficace il provisioning di interi sistemi operativi da remoto.

Il software di gestione remota integrato con la ROM del server diventa disponibile all'avvio del server. Un'interfaccia utente proprietaria o basata sul Web, come il portale fornito dal sistema di amministrazione remota, viene solitamente utilizzata per connettersi all'interfaccia di gestione remota nativa del server fisico. L'indirizzo IP dell'interfaccia di gestione remota può essere configurato manualmente, tramite l'IP predefinito, o in alternativa impostato tramite la configurazione di un servizio DHCP. Gli indirizzi IP nelle piattaforme IaaS possono essere inoltrati direttamente ai consumatori cloud in modo che possano eseguire installazioni del sistema operativo bare metal in modo indipendente. Sebbene il software di gestione remota venga utilizzato per abilitare le connessioni alle console dei server fisici e distribuire i sistemi operativi, ci sono due preoccupazioni comuni sul suo utilizzo:

- L'implementazione manuale su più server può essere vulnerabile a errori umani e di configurazione involontari.
- Il software di gestione remota può richiedere molto tempo e un'elaborazione significativa delle risorse IT in fase di esecuzione. Il sistema di provisioning bare metal risolve questi problemi utilizzando i seguenti componenti:
 - **Discovery Agent:** un tipo di agent di monitoraggio che cerca e trova i server fisici disponibili da assegnare ai cloud consumer.
 - **Deployment Agent:** un agente di gestione installato nella memoria di un server fisico, da posizionare come client per il sistema di distribuzione del provisioning bare metal.
 - **Discovery Section:** un componente software che esegue la scansione della rete e individua i server fisici disponibili con cui connettersi.
 - **Management Loader:** il componente che si connette al server fisico e carica le opzioni di gestione per l'utente cloud.
 - **Deployment Component:** componente responsabile dell'installazione del sistema operativo sui server fisici selezionati.

Il sistema di provisioning bare metal fornisce una funzione di distribuzione automatica che consente ai consumatori di cloud di connettersi al software di distribuzione e di eseguire il provisioning di più di un server o sistema operativo contemporaneamente. Il sistema di distribuzione centrale si collega ai server tramite le loro interfacce di gestione e utilizza lo stesso protocollo per caricare e operare come agente nella RAM del server fisico. Il server bare metal diventa quindi un client non elaborato con un agente di gestione installato e il software di distribuzione carica i file di configurazione richiesti per distribuire il sistema operativo. Le immagini di distribuzione, l'automazione della distribuzione del sistema operativo o la distribuzione automatica e gli script di configurazione post installazione possono essere utilizzati tramite il motore di automazione intelligente e il portale self-service per estendere questa funzionalità. I seguenti meccanismi aggiuntivi possono far parte di questa architettura:

- **Cloud Storage Device:** questo meccanismo archivia i modelli del sistema operativo e i file di installazione, nonché gli agenti di distribuzione e i pacchetti di distribuzione per il sistema di provisioning.
- **Hypervisor:** può essere richiesta la distribuzione di hypervisor su server fisici come parte del provisioning del sistema operativo.
- **Logical Network Perimeter:** i confini del perimetro di rete logica aiutano a garantire che i server fisici non elaborati siano accessibili solo da utenti cloud autorizzati.
- **Resource Replication:** questo meccanismo viene implementato per la replica delle risorse IT distribuendo un nuovo hypervisor su un server fisico per bilanciare il carico di lavoro dell'hypervisor durante o dopo il provisioning.
- **SLA Management System:** questo sistema di gestione garantisce che la disponibilità di server bare metal fisici sia conforme alle stipulazioni SLA predefinite.

Rapid Provisioning Architecture

Un processo di provisioning convenzionale può comportare una serie di attività che vengono tradizionalmente completate manualmente da amministratori ed esperti di tecnologia che preparano le risorse IT richieste secondo le specifiche preconfezionate o le richieste personalizzate dei clienti. Negli ambienti cloud, dove vengono serviti volumi più elevati di clienti e dove il cliente medio richiede volumi più elevati di risorse IT, i processi di provisioning manuale sono inadeguati e possono persino portare a rischi irragionevoli a causa di errori umani e tempi di risposta inefficienti. Ad esempio, un utente cloud che richiede l'installazione, la configurazione e l'aggiornamento di venticinque server

Windows con diverse applicazioni richiede che metà delle applicazioni siano installazioni identiche, mentre l'altra metà sia personalizzata. Ogni distribuzione del sistema operativo può richiedere fino a 30 minuti, seguiti da tempo aggiuntivo per patch di sicurezza e aggiornamenti del sistema operativo che richiedono il riavvio del server. Le applicazioni devono finalmente essere distribuite e configurate. L'utilizzo di un approccio manuale o semiautomatico richiede tempi eccessivi e introduce una probabilità di errore umano che aumenta ad ogni installazione. L'architettura di provisioning rapido stabilisce un sistema che automatizza il provisioning di un'ampia gamma di risorse IT, individualmente o collettivamente. L'architettura tecnologica sottostante per il provisioning rapido delle risorse IT può essere sofisticata e complessa e si basa su un sistema composto da un programma di provisioning automatizzato, un motore di provisioning rapido, script e modelli per il provisioning su richiesta. Sono disponibili molti artefatti architetturici aggiuntivi per coordinare e automatizzare i diversi aspetti del provisioning delle risorse IT, come ad esempio:

- **Server Templates:** modelli di file di immagini virtuali utilizzati per automatizzare la creazione di istanze di nuovi server virtuali.
- **Server Images:** queste immagini sono simili ai modelli di server virtuali, ma vengono utilizzate per eseguire il provisioning dei server fisici.
- **Application Packages:** raccolte di applicazioni e altro software confezionati per la distribuzione automatica.
- **Application Packager:** il software utilizzato per creare i pacchetti dell'applicazione.
- **Custom Scripts:** script che automatizzano le attività amministrative, come parte di un motore di automazione intelligente.
- **Sequence Manager:** un programma che organizza sequenze di attività di provisioning automatizzato.
- **Sequence Logger:** un componente che registra l'esecuzione delle sequenze di attività di provisioning automatizzato.
- **Operating System Baseline:** un modello di configurazione che viene applicato dopo l'installazione del sistema operativo, per prepararlo rapidamente all'uso.
- **Application Configuration Baseline:** Un modello di configurazione con le impostazioni e i parametri ambientali necessari per preparare nuove applicazioni per l'uso.
- **Deployment Data Store:** il repository che archivia immagini virtuali, modelli, script, configurazioni di base e altri dati correlati.

La seguente descrizione aiuta a fornire alcune informazioni sul funzionamento interno di un motore di provisioning rapido, che coinvolge una serie di componenti di sistema elencati in precedenza:


1. Un cloud consumer richiede un nuovo server tramite il portale self-service.
2. Il Sequence Manager inoltra la richiesta al motore di distribuzione per la preparazione di un sistema operativo.
3. Il motore di distribuzione utilizza i modelli di server virtuale per il provisioning se la richiesta è per un server virtuale. In caso contrario, il motore di distribuzione invia la richiesta per eseguire il provisioning di un server fisico.
4. L'immagine predefinita per il tipo di sistema operativo richiesto viene utilizzata per il provisioning del sistema operativo, se disponibile. In caso contrario, viene eseguito il normale processo di distribuzione per installare il sistema operativo.
5. Il motore di distribuzione informa il gestore di sequenze quando il sistema operativo è pronto.
6. Il Sequence Manager aggiorna e invia i log al Sequence logger per l'archiviazione.
7. Il gestore di sequenza richiede che il motore di distribuzione applichi la linea di base del sistema operativo al provisioning sistema operativo.
8. Il motore di distribuzione applica la linea di base del sistema operativo richiesta.

9. Il motore di distribuzione informa il gestore di sequenze che la linea di base del sistema operativo è stata applicata.
10. Il Sequence Manager aggiorna e invia i log dei passaggi completati al Sequence logger per l'archiviazione.
11. Il gestore di sequenza richiede che il motore di distribuzione installi le applicazioni.
12. Il motore di distribuzione distribuisce le applicazioni sul server fornito.
13. Il motore di distribuzione informa il gestore di sequenze che le applicazioni sono state installate.
14. Il Sequence Manager aggiorna e invia i log dei passaggi completati al Sequence logger per l'archiviazione.
15. Il gestore di sequenza richiede che il motore di distribuzione applichi la linea di base di configurazione dell'applicazione.
16. Il motore di distribuzione applica la linea di base della configurazione.
17. Il motore di distribuzione informa il gestore di sequenze che la linea di base della configurazione è stata applicata.
18. Il Sequence Manager aggiorna e invia i log dei passaggi completati al Sequence logger per l'archiviazione.

Il meccanismo del cloud storage device viene utilizzato per fornire spazio di archiviazione per informazioni di base dell'applicazione, modelli e script, mentre l'hypervisor crea, distribuisce e ospita rapidamente i server virtuali di cui è stato eseguito il provisioning o che ospitano altre risorse IT fornite. Il meccanismo di replica delle risorse viene solitamente utilizzato per generare istanze replicate di risorse IT in risposta a requisiti di provisioning rapidi.

Storage Workload Management Architecture

I dispositivi di archiviazione cloud (Cloud Storage Device) sovrautilizzati aumentano il carico di lavoro sul controller di archiviazione e possono causare una serie di problemi di prestazioni. Al contrario, i dispositivi di archiviazione cloud che sono sottoutilizzati sono uno spreco, a causa della perdita di capacità di elaborazione e archiviazione.



L'architettura di Storage Workload Management consente ai LUN di essere distribuiti uniformemente tra i dispositivi di archiviazione cloud disponibili, mentre viene stabilito un sistema di capacità di archiviazione per garantire che i carichi di lavoro di runtime siano distribuiti uniformemente tra i LUN. La combinazione di dispositivi di archiviazione cloud in un gruppo consente ai dati LUN di essere distribuiti equamente tra gli host di archiviazione disponibili. Viene configurato un sistema di gestione dello storage e viene posizionato un listener di ridimensionamento automatico per monitorare ed equalizzare i carichi di lavoro di runtime tra i


dispositivi di archiviazione cloud raggruppati. Il sistema di capacità di archiviazione può mantenere il dispositivo di archiviazione host in modalità di risparmio energetico per i periodi in cui si accede ai LUN meno frequentemente o solo in orari specifici. Alcuni altri meccanismi che possono essere inclusi nell'architettura di gestione del carico di lavoro di archiviazione per accompagnare il dispositivo di archiviazione cloud sono i seguenti:

- **Audit Monitor:** questo meccanismo di monitoraggio viene utilizzato per verificare la conformità ai requisiti normativi, di privacy e di sicurezza, poiché il sistema stabilito da questa architettura può riposizionare fisicamente i dati.
- **Automated Scaling Listener:** il listener di ridimensionamento automatizzato viene utilizzato per osservare e rispondere alle fluttuazioni del carico di lavoro.
- **Cloud Usage Monitor:** oltre al monitoraggio del carico di lavoro della capacità, vengono utilizzati monitoraggi dell'utilizzo del cloud specializzati per tenere traccia dei movimenti dei LUN e raccogliere statistiche sulla distribuzione del carico di lavoro.
- **Load Balancer:** questo meccanismo può essere aggiunto per bilanciare orizzontalmente i carichi di lavoro tra i dispositivi di archiviazione cloud disponibili.
- **Logical Network Perimeter:** i perimetri di rete logici forniscono livelli di isolamento in modo che i dati dei consumatori cloud che subiscono il trasferimento rimangano inaccessibili a parti non autorizzate.

Case Study

Innovartus sta noleggiando due ambienti basati su cloud da due diversi fornitori di cloud e intende sfruttare questa opportunità per stabilire un'architettura pilota di bilanciamento del cloud per il suo servizio cloud Role Player. Dopo aver valutato i suoi requisiti rispetto ai rispettivi cloud, gli architetti del cloud di Innovartus producono una specifica di progettazione basata su ogni cloud con più implementazioni del servizio cloud. Questa architettura incorpora un listener di scalabilità automatizzato separato e implementazioni di sistemi di failover, insieme a un meccanismo di bilanciamento del carico centrale. Il sistema di bilanciamento del carico distribuisce le richieste dei consumatori di servizi cloud attraverso i cloud utilizzando un algoritmo di distribuzione del carico di lavoro, mentre il listener di ridimensionamento automatizzato di ogni cloud instrada le

richieste alle implementazioni del servizio cloud locale. I sistemi di failover possono eseguire il failover sulle implementazioni ridondanti del servizio cloud che si trovano sia all'interno che tra i cloud. Il failover inter-cloud viene eseguito principalmente quando le implementazioni del servizio cloud locale si stanno avvicinando alle soglie di elaborazione o se un cloud sta riscontrando un grave errore della piattaforma.



Lezione – Specialized Cloud Architectures

Direct I/O Access Architecture


L'accesso alle schede I / O fisiche installate su un server fisico viene solitamente fornito ai server virtuali ospitati tramite un livello di elaborazione basato su hypervisor chiamato virtualizzazione I / O. Tuttavia, a volte i server virtuali devono connettersi e utilizzare schede I / O senza alcuna interazione o emulazione dell'hypervisor. Con l'architettura di accesso I / O diretto, i server virtuali possono aggirare l'hypervisor e accedere direttamente alla scheda I / O del server fisico come alternativa all'emulazione di una connessione tramite l'hypervisor. Per ottenere questa soluzione e accedere alla scheda I / O fisica senza l'interazione con l'hypervisor, la CPU host deve supportare questo tipo di accesso con i driver appropriati installati sul server virtuale. Il server virtuale può quindi riconoscere la scheda I / O come dispositivo hardware dopo l'installazione dei driver. Altri meccanismi che possono essere coinvolti in questa architettura oltre al server virtuale e all'hypervisor includono:

- **Cloud Usage Monitor:** i dati sull'utilizzo del servizio cloud raccolti dai monitor di runtime possono includere e classificare separatamente l'accesso I / O diretto.
- **Logical Network Perimeter:** il perimetro di rete logico garantisce che la scheda I / O fisica assegnata non consenta ai consumatori del cloud di accedere alle risorse IT di altri consumatori del cloud.
- **Pay-Per-Use Monitor:** Questo monitor raccoglie le informazioni sui costi di utilizzo per la scheda I / O fisica assegnata.
- **Resource Replication:** la tecnologia di replica viene utilizzata per sostituire le schede I / O virtuali con schede I / O fisiche.

Direct LUN Access Architecture

I LUN di archiviazione vengono in genere mappati tramite un adattatore bus host (HBA) sull'hypervisor, con lo spazio di archiviazione emulato come archiviazione basata su file e su server virtuali. Tuttavia, i server virtuali a volte richiedono l'accesso diretto all'archiviazione basata su blocchi RAW. Ad esempio, l'accesso tramite un adattatore emulato non è sufficiente quando viene implementato un cluster e un LUN viene utilizzato come dispositivo di archiviazione del cluster condiviso tra due server virtuali. L'architettura di accesso LUN diretto fornisce ai server virtuali l'accesso LUN tramite una scheda HBA fisica, che è efficace perché i server virtuali nello stesso cluster possono utilizzare il LUN come volume condiviso per i database in cluster. Dopo aver implementato questa soluzione, la connettività fisica dei server virtuali al LUN e al dispositivo di archiviazione cloud viene abilitata dagli host fisici.

I LUN vengono creati e configurati sul dispositivo di archiviazione cloud per la presentazione dei LUN agli hypervisor. Il dispositivo di archiviazione cloud deve essere configurato utilizzando la mappatura del dispositivo grezzo per rendere i LUN visibili ai server virtuali come RAW SAN LUN basato su blocchi, che è uno storage non formattato e non partizionato. Il LUN deve essere rappresentato con un LUN ID univoco per essere utilizzato da tutti i server virtuali come archiviazione condivisa. Oltre al server virtuale,




all'hypervisor e al dispositivo di archiviazione cloud, in questa architettura possono essere incorporati i seguenti meccanismi:

- **Cloud Usage Monitor:** questo monitoraggio tiene traccia e raccoglie le informazioni sull'utilizzo dello spazio di archiviazione relative all'uso diretto dei LUN.
- **Pay-Per-Use Monitor:** il monitor pay-per-use raccoglie e classifica separatamente le informazioni sui costi di utilizzo per l'accesso diretto alla LUN.
- **Resource Replication:** questo meccanismo si riferisce al modo in cui i server virtuali accedono direttamente all'archiviazione basata su blocchi in sostituzione dell'archiviazione basata su file.

Dynamic Data Normalization Architecture

I dati ridondanti possono causare una serie di problemi negli ambienti basati su cloud, come:

- Aumento del tempo necessario per archiviare e catalogare i file
- Maggiore spazio di archiviazione e backup richiesto
- Aumento dei costi dovuto all'aumento del volume di dati
- Aumento del tempo necessario per la replica nell'archivio secondario
- Aumento del tempo necessario per il backup dei dati



Ad esempio, se un utente cloud copia 100 MB di file su un dispositivo di archiviazione cloud e i dati vengono copiati in modo ridondante dieci volte, le conseguenze possono essere considerevoli:


- Al consumatore cloud verrà addebitato l'utilizzo di 10 x 100 MB di spazio di archiviazione, anche se sono stati effettivamente archiviati solo 100 MB di dati univoci.
- Il fornitore di servizi cloud deve fornire 900 MB di spazio non necessari nel dispositivo di archiviazione cloud online e in qualsiasi sistema di archiviazione di backup.
- È necessario molto più tempo per archiviare e catalogare i dati.
- La durata e le prestazioni della replica dei dati vengono tassate inutilmente ogni volta che il

provider di servizi cloud esegue un ripristino del sito, poiché è necessario replicare 1.000 MB invece di 100 MB. Questi impatti possono essere notevolmente amplificati nei cloud pubblici multi-tenant. L'architettura di Dynamic Data Normalization stabilisce un sistema di de-duplicazione, che impedisce ai consumatori di cloud di salvare inavvertitamente copie ridondanti dei dati rilevando ed eliminando i dati ridondanti sui dispositivi di archiviazione cloud. Questo sistema può essere applicato sia a dispositivi di archiviazione basati su file che a blocchi, sebbene sia più efficace sui primi. Questo sistema di de-duplicazione controlla ogni blocco ricevuto per determinare se è ridondante con un blocco che è già stato ricevuto. I blocchi ridondanti vengono sostituiti con puntatori ai blocchi equivalenti già in memoria. Il sistema di de-duplicazione esamina i dati ricevuti prima di trasmetterli ai controller di archiviazione. Come parte del processo, a ogni dato che è stato elaborato e archiviato viene assegnato un codice hash. Viene inoltre mantenuto un indice di hash e pezzi. Di conseguenza, l'hash generato di un blocco di dati appena ricevuto viene confrontato con gli hash in memoria per

determinare se si tratta di un blocco di dati nuovo o duplicato. I nuovi blocchi vengono salvati, mentre i dati duplicati vengono eliminati e al suo posto viene creato e salvato un puntatore al blocco dati originale. Questo modello architetturale può essere utilizzato sia per l'archiviazione su disco sia per le unità nastro di backup. Un fornitore di servizi cloud può decidere di impedire la ridondanza dei dati solo sui dispositivi di archiviazione cloud di backup, mentre un altro può implementare in modo più aggressivo il sistema di de-duplicazione dei dati su tutti i suoi dispositivi di archiviazione cloud. Esistono diversi metodi e algoritmi per confrontare blocchi di dati per confermare la loro duplicità con altri blocchi.

Elastic Network Capacity Architecture

Anche se le risorse IT vengono ridimensionate su richiesta da una piattaforma cloud, le prestazioni e la scalabilità possono comunque essere inibite quando l'accesso remoto alle risorse IT è influenzato dai limiti della larghezza di banda della rete. L'architettura della Elastic Network Capacity stabilisce un sistema in cui la larghezza di banda aggiuntiva viene allocata dinamicamente alla rete per evitare colli di bottiglia in fase di esecuzione. Questo sistema garantisce che ogni cloud consumer utilizzi un diverso set di porte di rete per isolare i flussi di traffico dei singoli consumatori cloud. L'automated scaling listener e gli script del motore di automazione intelligente vengono utilizzati per rilevare quando il traffico raggiunge la soglia di larghezza di banda e per allocare dinamicamente larghezza di banda aggiuntiva e / o porte di rete quando necessario. L'architettura cloud può essere dotata



di un pool di risorse di rete contenente porte di rete rese disponibili per l'utilizzo condiviso. L'automated scaling listener monitora il carico di lavoro e il traffico di rete e segnala al motore di automazione intelligente di modificare il numero di porte di rete allocate e / o la larghezza di banda in risposta alle fluttuazioni di utilizzo. Si noti che quando questo modello di architettura viene implementato a livello di switch virtuale, il motore di automazione intelligente potrebbe dover eseguire uno script separato che aggiunge in modo specifico uplink fisici allo switch virtuale. In alternativa, è possibile incorporare anche l'architettura di accesso I / O diretto per aumentare la larghezza di banda di rete allocata al server virtuale. Oltre al listener di ridimensionamento automatizzato, i seguenti meccanismi possono far parte di questa architettura:

- **Cloud Usage Monitor:** questi monitor sono responsabili del monitoraggio della capacità di rete elastica prima, durante e dopo il ridimensionamento.
- **Hypervisor:** l'hypervisor fornisce ai server virtuali l'accesso alla rete fisica, tramite switch virtuali e uplink fisici.
- **Logical Network Perimeter:** questo meccanismo stabilisce i confini necessari per fornire ai singoli consumatori di cloud la capacità di rete assegnata.
- **Pay-Per-Use Monitor:** questo monitor tiene traccia di tutti i dati relativi alla fatturazione che riguardano il consumo dinamico della larghezza di banda della rete.
- **Resource Replication:** la replica delle risorse viene utilizzata per aggiungere porte di rete a server fisici e virtuali, in risposta alle richieste del carico di lavoro.
- **Virtual Server:** i server virtuali ospitano le risorse IT e i servizi cloud a cui sono allocate le risorse di rete e sono essi stessi influenzati dal ridimensionamento della capacità di rete.

Cross-storage device Vertical Tiering Architecture

I dispositivi di archiviazione cloud a volte non sono in grado di soddisfare i requisiti di prestazioni dei cloud consumer e hanno più potenza di elaborazione dati o larghezza di banda aggiunta per aumentare IOPS. Questi metodi convenzionali di ridimensionamento verticale sono generalmente inefficienti e richiedono molto tempo per l'implementazione e possono diventare dispendiosi quando la maggiore capacità non è più richiesta.


L'architettura di Tiering verticale di dispositivi di archiviazione multipla stabilisce un sistema che resiste ai vincoli di larghezza di banda e potenza di elaborazione dei dati scalando verticalmente tra dispositivi di archiviazione con capacità diverse. I LUN possono aumentare e diminuire automaticamente su più dispositivi in questo sistema in modo che le richieste possano utilizzare il livello del dispositivo di archiviazione appropriato per eseguire le attività dei consumatori cloud.

Possono essere resi disponibili anche nuovi dispositivi di archiviazione cloud con capacità maggiore, anche se la tecnologia di tiering automatizzato può spostare i dati su dispositivi di archiviazione cloud con la stessa capacità di elaborazione dello spazio di archiviazione. Ad esempio, le unità a stato solido (SSD) possono essere dispositivi adatti per gli aggiornamenti della potenza di elaborazione dei dati. L'Automated scaling listener monitora le richieste inviate a LUN specifici e segnala al programma di gestione dello storage di spostare il LUN su un dispositivo di capacità superiore una volta che identifica una soglia predefinita è stata raggiunta. Si evita l'interruzione del servizio perché non c'è mai una disconnessione durante il trasferimento. Il dispositivo originale rimane attivo e in esecuzione, mentre i dati LUN vengono scalati su un altro dispositivo. Le richieste dei consumatori cloud vengono reindirizzate automaticamente al nuovo dispositivo di archiviazione cloud non appena il ridimensionamento è completato. Oltre al listener di ridimensionamento automatizzato e al dispositivo di archiviazione cloud, i meccanismi che possono essere incorporati in questa architettura tecnologica includono:

- **Audit Monitor:** l'audit eseguito da questo monitor verifica se il trasferimento dei dati dei consumatori cloud non è in conflitto con alcuna normativa o policy legale o sulla privacy dei dati.
- **Cloud Usage Monitor:** questo meccanismo dell'infrastruttura rappresenta vari requisiti di monitoraggio del runtime per il monitoraggio e la registrazione del trasferimento e dell'utilizzo dei dati, sia nelle posizioni di archiviazione di origine che di destinazione.
- **Pay-per-use Monitor:** nel contesto di questa architettura, il monitoraggio pay-per-use raccoglie informazioni sull'utilizzo dello storage sia sulle posizioni di origine che su quelle di destinazione, nonché informazioni sull'utilizzo delle risorse IT per l'esecuzione della funzionalità di tiering cross-storage.

Intra-storage device Vertical Tiering Architecture

Alcuni cloud consumer potrebbero avere requisiti di archiviazione dei dati distinti che limitano la posizione fisica dei dati a un singolo dispositivo di archiviazione cloud. La distribuzione su altri dispositivi di archiviazione cloud potrebbe non essere consentita per motivi di sicurezza, privacy o vari motivi legali. Questo tipo di limitazione può imporre gravi limitazioni di scalabilità alla capacità di archiviazione e prestazioni del dispositivo. Queste limitazioni possono ricadere ulteriormente su qualsiasi servizio o applicazione cloud che dipenda dall'uso del dispositivo di archiviazione cloud. L'architettura di data tiering verticale del dispositivo intra-storage stabilisce un sistema per supportare il ridimensionamento verticale all'interno di un singolo dispositivo di archiviazione cloud. Questo sistema di ridimensionamento all'interno del dispositivo ottimizza la disponibilità di diversi tipi di dischi con capacità diverse. Questa architettura di archiviazione cloud richiede l'uso di un dispositivo di archiviazione complesso che supporti diversi tipi di dischi rigidi, in particolare dischi ad alte prestazioni come SATA, SAS e SSD. I tipi di disco sono organizzati in livelli graduati in modo che la migrazione LUN possa scalare verticalmente il dispositivo in base all'allocazione dei tipi di disco, in linea con i requisiti di capacità e di elaborazione. Le condizioni e le definizioni di caricamento dei dati vengono impostate dopo la categorizzazione del disco in modo che i LUN possano passare a un livello superiore o inferiore, a seconda delle condizioni predefinite. Queste soglie e condizioni vengono utilizzate dall'automated scaling listener durante il monitoraggio del traffico di elaborazione dei dati di runtime.




Load balanced Virtual Switches Architecture

I server virtuali sono collegati al mondo esterno tramite switch virtuali, che inviano e ricevono traffico con lo stesso uplink. I bandwidth bottleneck si formano quando il traffico di rete sulla porta dell'uplink aumenta al punto da causare ritardi di trasmissione, problemi di prestazioni, perdita di pacchetti e tempo di ritardo. L'architettura degli switch virtuali con load balancer stabilisce un sistema di bilanciamento del carico in cui vengono forniti più uplink per bilanciare i carichi di lavoro del traffico di rete su più uplink o percorsi ridondanti, il che può aiutare a evitare trasferimenti lenti e perdita di dati. L'aggregazione dei collegamenti può essere eseguita per bilanciare il traffico, il che consente di distribuire il carico di lavoro su più uplink contemporaneamente in modo che nessuna delle schede di rete sia sovraccarica. Lo switch virtuale deve essere configurato per supportare più uplink fisici, che di solito sono configurati come un NIC team che ha definito criteri di modellazione del traffico. I seguenti meccanismi possono essere incorporati in questa architettura:

- **Cloud usage monitor:** i cloud usage monitor vengono utilizzati per monitorare il traffico di rete e l'utilizzo della larghezza di banda.
- **Hypervisor:** questo meccanismo ospita e fornisce ai server virtuali l'accesso sia agli switch virtuali che alla rete esterna.
- **Load Balancer:** il load balancer distribuisce il carico di lavoro di rete tra i diversi uplink.
- **Logical Network Perimeter:** il perimetro di rete logico crea confini che proteggono e limitano l'utilizzo della larghezza di banda per ogni utente cloud.
- **Resource Replication:** questo meccanismo viene utilizzato per generare collegamenti aggiuntivi allo switch virtuale.
- **Virtual Server:** i server virtuali ospitano le risorse IT che beneficiano degli uplink aggiuntivi e della larghezza di banda tramite switch virtuali.

Multipath Resource Architecture

È possibile accedere ad alcune risorse IT solo utilizzando un percorso assegnato (o collegamento ipertestuale) che conduce alla loro posizione esatta. Questo percorso può essere perso o definito in modo errato dal cloud consumer o modificato dal cloud provider. Una risorsa IT il cui collegamento ipertestuale non è più in possesso del cloud consumer diventa inaccessibile e non disponibile. Le condizioni di eccezione che derivano dall'indisponibilità delle risorse IT possono compromettere la stabilità di soluzioni cloud più grandi che dipendono dalla risorsa IT. L'architettura di accesso alle risorse multipath stabilisce un sistema multipathing con percorsi alternativi alle risorse IT, in modo che i consumatori cloud abbiano i mezzi per superare programmaticamente o manualmente gli errori di percorso. Questa architettura tecnologica richiede l'uso di un sistema multipathing e la creazione di collegamenti ipertestuali alternativi fisici o virtuali assegnati a risorse IT specifiche. Il sistema multipathing risiede sul server o hypervisor e garantisce che ogni risorsa IT possa essere vista in modo identico tramite ogni percorso alternativo.




Questa architettura può coinvolgere i seguenti meccanismi:

- **Cloud Storage Device:** il dispositivo di archiviazione cloud è una risorsa IT comune che richiede la creazione di percorsi alternativi per rimanere accessibile a soluzioni che si basano sull'accesso ai dati.
- **Hypervisor:** sono necessari percorsi alternativi a un hypervisor per avere collegamenti ridondanti ai server virtuali ospitati.
- **Logical Network Perimeter:** questo meccanismo garantisce il mantenimento della privacy dei cloud consumer, anche quando vengono creati più percorsi per la stessa risorsa IT.
- **Resource Replication:** il meccanismo di replica delle risorse è necessario quando è necessario creare una nuova istanza di una risorsa IT per generare il percorso alternativo.
- **Virtual Server:** questi server ospitano le risorse IT che hanno accesso multipath tramite diversi collegamenti o switch virtuali. Gli hypervisor possono fornire l'accesso multipath ai server virtuali.

Persistent Virtual Network Configuration Architecture

Le configurazioni di rete e le assegnazioni delle porte per i server virtuali vengono generate durante la creazione dello switch virtuale sul server fisico host e l'hypervisor che ospita il server virtuale. Queste configurazioni e assegnazioni risiedono nell'ambiente di hosting immediato del server virtuale, il che significa che un server virtuale che viene spostato o migrato su un altro host perderà la connettività di rete perché gli ambienti di hosting di destinazione non hanno le assegnazioni di porte e le informazioni di configurazione di rete richieste. Nell'architettura di configurazione della rete virtuale persistente, le informazioni sulla configurazione della rete vengono archiviate in una posizione centralizzata e replicate sugli host del server fisico. Ciò consente all'host di destinazione di accedere alle informazioni di configurazione quando un server virtuale viene spostato da un host a un altro. Il sistema stabilito con questa architettura include uno switch virtuale centralizzato, VIM e una tecnologia di replica della configurazione. Lo switch virtuale centralizzato è condiviso dai server fisici e configurato tramite VIM, che avvia la replica delle impostazioni di configurazione sui server fisici. Oltre al meccanismo del server virtuale per il quale questa architettura fornisce un sistema di migrazione, possono essere inclusi i seguenti meccanismi:

- **Hypervisor:** l'hypervisor ospita i server virtuali che richiedono la replica delle impostazioni di configurazione sugli host fisici.
- **Logical Network Perimeter:** aiuta a garantire che l'accesso al server virtuale e alle sue risorse IT sia isolato al legittimo consumatore cloud, prima e dopo la migrazione di un server virtuale.
- **Resource Replication:** il meccanismo di replica delle risorse viene utilizzato per replicare le configurazioni degli switch virtuali e le allocazioni della capacità di rete tra gli hypervisor, tramite lo switch virtuale centralizzato.



Redundant Physical Connection for Virtual Servers Architecture

Un server virtuale è connesso a una rete esterna tramite una porta di uplink dello switch virtuale, il che significa che il server virtuale verrà isolato e disconnesso dalla rete esterna se l'uplink non riesce. La Redundant Physical Connection per l'architettura dei server virtuali stabilisce una o più connessioni uplink ridondanti e le posiziona in modalità standby. Questa architettura garantisce che sia disponibile una connessione uplink ridondante per connettere l'uplink attivo, ogni volta che la connessione uplink primaria diventa non disponibile. In un processo trasparente sia per i server virtuali che per i loro utenti, un uplink standby diventa automaticamente l'uplink attivo non appena l'uplink principale fallisce, e i server virtuali utilizzano l'uplink appena attivo per inviare pacchetti esternamente. La seconda NIC non inoltra alcun traffico mentre l'uplink primario è attivo, anche se riceve i pacchetti del server virtuale. Tuttavia, l'uplink secondario inizierà a inoltrare immediatamente i pacchetti se l'uplink primario dovesse fallire. L'uplink non riuscito diventa nuovamente l'uplink principale dopo che è tornato in funzione, mentre la seconda NIC torna in modalità standby. I seguenti meccanismi fanno comunemente parte di questa architettura, oltre al server virtuale:

- **Failover System:** il sistema di failover esegue la transizione degli uplink non disponibili agli uplink in standby.

- **Hypervisor:** questo meccanismo ospita server virtuali e alcuni switch virtuali e fornisce alle reti virtuali e agli switch virtuali l'accesso ai server virtuali.
- **Logical Network Perimeter:** i perimetri di rete logica assicurano che gli switch virtuali allocati o definiti per ciascun consumatore cloud rimangano isolati.
- **Resource Replication:** la replica delle risorse viene utilizzata per replicare lo stato corrente degli uplink attivi sugli uplink in standby in modo da mantenere la connessione di rete.

Storage Maintenance Windows Architecture

I Cloud Storage Devices soggetti a manutenzione e attività amministrative a volte devono essere temporaneamente chiusi, il che significa che i consumatori di servizi cloud e le risorse IT perdono di conseguenza l'accesso a questi dispositivi e ai dati memorizzati. I dati di un dispositivo di archiviazione cloud che sta per subire un'interruzione di manutenzione possono essere temporaneamente spostati su un dispositivo di archiviazione duplicato secondario. L'architettura della finestra di manutenzione dello storage consente ai consumatori di servizi cloud di essere reindirizzati automaticamente e in modo trasparente al dispositivo di archiviazione cloud secondario, senza rendersi conto che il loro dispositivo di archiviazione principale è stato portato offline. Oltre al meccanismo del dispositivo di archiviazione cloud principale di questa architettura, il meccanismo di replica delle risorse viene utilizzato per mantenere sincronizzati i dispositivi di archiviazione primaria e secondaria. Il failover avviato manualmente e automaticamente può anche essere incorporato in questa architettura cloud tramite il meccanismo del sistema di failover, anche se la migrazione è spesso pre-programmata.

