



Il processo sperimentale


II parte

I passi del processo sperimentale - II




Planning: passi





Validity evaluation


- Una questione fondamentale nell'analisi dei risultati di un esperimento è
 - Quanto validi sono i risultati?
 - Quantomeno dovrebbero esserlo per la popolazione di interesse
 - Poi, se si potesse anche generalizzare...
- **Attenzione: Una adeguata validità non implica la possibilità di generalizzare**
- Minacce di validità (threats to validity) [Campbell and Stanley, 63]
 1. Conclusion validity (C)
 2. Internal validity (I)
 3. Construct validity (S)
 4. External validity (E)




Threats to validity

- **Conclusion validity (C):** relativa alla relazione tra treatment e outcome
 - Deve esserci una relazione statisticamente significativa
- **Internal validity (I):** relativa alla relazione tra treatment e outcome
 - Relazione causale non relativa ad un fattore che non stiamo controllando (e eventualmente neanche misurando)
- **Construct validity (S):** relativa alla relazione tra teoria e osservazione
 - Il trattamento riflette il costrutto della causa
 - L'outcome riflette il costrutto dell'effetto
- **External validity (E):** relativa alla generalizzazione dei risultati
 - Se c'è una relazione causa e effetto, può tale relazione essere generalizzata?
 - Si tratta di una relazione tra treatment e outcome?


Mapping Experiment principles





Conclusion validity - I

- **Low statistical power:**
 - Potenza test statistico: abilità nel rilevare un pattern nei dati
 - Bassa potenza: risultati non statisticamente significativi (e.g. livello significatività 0.05 e il p-value >0.05) o livello di significatività troppo basso
- **Violated assumptions of statistical tests**
 - Eseguo un test quando non potrei farlo → conclusioni erranee
 - Molti test (e.g. t-test) presuppongono campioni normalmente distribuiti e indipendenti
- **Fishing and the error rate**
 - Guardo ad un risultato particolare e lo uso per trarre conclusioni
 - Error rate: se effettuo 3 investigazioni con livello di significatività 0.05 il totale è $(1-0.05)^3 \dots 0.14$
 - Quindi il livello di significatività va corretto quando conduco analisi multiple!



Conclusion validity - II

- **Reliability of measures**


- Se ripeto una misura nelle stesse condizioni, dovrei ottenere gli stessi risultati
- e.g. le LOC sono più affidabili dei Function Point → nessuna componente soggettiva
- Cattiva strumentazione
- Occorre preferire misure oggettive a misure soggettive, se possibile

- **Reliability of treatment implementation**

- L'implementazione del treatment potrebbe variare applicandolo a diversi soggetti
- e.g. usare un tool in un particolare sistema operativo, con particolari monitor, su macchine più veloci...


- **Random irrelevancies in experimental setting**

- Elementi esterni disturbano l'esperimento
- Anche il rumore fuori dalla stanza ☺




Conclusion validity - III

- **Random heterogeneity of subjects**
 - Un gruppo di soggetti porta inevitabilmente con sé eterogeneità
 - Attenzione se la variabilità legata all'eterogeneità dei soggetti supera quella conseguente al treatment
 - Studenti della stessa classe con abilità simile sono di solito abbastanza omogenei
 - Ma qui ho problemi di validità esterna!




Internal validity – Single group threats - I

- Non abbiamo “gruppi di controllo” ai quali non applichiamo il treatment
 - Uso lo stesso gruppo di studenti per sperimentare con il vecchio metodo e con il nuovo
- Difficoltà a capire se il treatment ha causato l’effetto, o ciò è dipeso da un altro fattore
- Single group threats:
 - **History:** quando l’esperimento è effettuato in momenti particolari (dopo le vacanze, prima di un esame...)
 - **Maturation:** i soggetti reagiscono differentemente col passare del tempo
 - Stanchezza, noia, apprendimento
 - **Testing:** se il test è ripetuto più volte sugli stessi soggetti, gli stessi la seconda volta hanno già familiarità col test
 - Non dare il feedback dopo il primo test




Internal validity – Single group threats - II

- **Instrumentation:** effetto causato dalla strumentazione
 - Form poco chiari, strumento di misura mal funzionante
- **Statistical regression:** quando classifico (e.g. per fare blocking) i soggetti in base ai risultati di un esperimento precedente
 - Assumo che un soggetto è poco performante in base all'esperimento precedente, ma potrebbe esserlo nell'esperimento attuale
 - Se metto uno studente tra i meno bravi solo in base ai dati dell'esperimento precedente (e non magari in base al voto di laurea) anche se nell'esperimento attuale va bene, resterà nel blocco sbagliato
- **Selection:** effetto della variabilità delle performance dei soggetti
 - Esperimento con volontari → persone più motivate della media della popolazione



Internal validity – Single group threats - III

- **Mortality:** alcuni soggetti abbandonano l'esperimento
 - E' importante caratterizzare tali soggetti per verificare se sono rappresentativi dell'intero campione
 - Attenzione se particolari categorie di soggetti abbandonano
 - E.s. tutti i reviewer senior in un esperimento di ispezione → risultati altamente influenzati
- **Ambiguity about direction of casual influence:**
 - A causa B, B causa A, oppure X causa A e B?
 - es. osservo una correlazione tra complessità del programma e difettosità
 - La complessità causa la difettosità... (A)
 - Oppure un codice difettoso (B) tende mediamente ad essere complesso (A)
 - Oppure la difficoltà del problema (X) ha portato ad avere codice complesso (A) e difetti (B)




Internal validity – Multiple group threats

- Studio differenti gruppi
- Il **gruppo di controllo** (e.g. quello su cui applico il vecchio metodo) e il **gruppo di esperimento** (e.g. quello su cui applico il nuovo metodo) sono influenzati differientemente dalle threat di gruppo singolo
- Threats:
 - **Interactions with selection:** differenti gruppi reagiscono in maniera diversa
 - L'effetto **maturation** influenza un gruppo più di un altro
 - Un gruppo apprende il nuovo metodo più velocemente di un altro
 - L'effetto **history** influenza un gruppo più di un altro
 - Ho sperimentato con i due gruppi in date diverse

Internal validity – Social threats - I

- Applicabili sia a esperimenti a gruppo singolo che a gruppi multipli
- Threats:
 - **Diffusion or imitation of treatments:** il gruppo di controllo apprende dal gruppo di esperimento e ne “imita” il comportamento
 - Il gruppo di controllo usa (anche inconsciamente) il nuovo metodo anziché il vecchio, presupponendo di performare in maniera migliore
 - **Compensatory equalization of treatments:**
 - Il gruppo di controllo non dovrebbe essere compensato per il fatto di applicare il metodo vecchio
 - Né bisogna insegnare al gruppo di controllo un terzo metodo alternativo



Internal validity – Social threats - II


- **Compensatory rivalry:** i soggetti che applicano il trattamento meno desiderabile potrebbero essere motivati (per orgoglio) ad agire meglio
 - Chi applica il metodo vecchio potrebbe essere portato a dare il massimo affinché il metodo vecchio resti migliore del nuovo
- **Resentful demoralization:** contrario del caso precedente
 - Un trattamento poco gradevole porta ad abbassamento delle performance se non all'abbandono
 - Applicare il solito metodo può essere noioso...
 - Invece, apprendere qualcosa di nuovo spesso motiva

Construct validity – Design threats - I

- Relative all'experiment design e la possibilità che lo stesso influisca sul costrutto oggetto dello studio
- Threats:
 - **Inadequate preoperational explication of constructs:** costrutto non sufficientemente definito prima di essere tradotto in misure a treatment
 - La teoria non è ben chiara → l'esperimento non è ben definito
 - Confronto due metodi, senza aver chiaro cosa significa che un metodo va meglio di un altro
 - **Mono-operation bias:** ho una sola variabile indipendente, un solo soggetto, oggetto o treatment → l'esperimento non è in grado di rappresentare pienamente la teoria
 - Conduco un esperimento di ispezione su un singolo documento, che non è rappresentativo dei documenti su cui normalmente la tecnica è applicata

Construct validity – Design threats - II

- **Mono-method bias:** uso un singolo tipo di misura
 - Se la misura è biased, mi influenza i risultati
 - Dovrei usare differenti fattori per misurare la complessità, la difettosità, diversi metodi per contare i cloni, differenti domande per misurare la user-friendliness di un programma
- **Confounding constructs and levels of constructs:** confondo la presenza o assenza di un costrutto con il livello del costrutto stesso
 - e.g. la conoscenza o non conoscenza (in senso assoluto) di un determinato linguaggio di programmazione potrebbe non influenzare l'esperimento,
 - ...invece gli anni di esperienza su quel linguaggio contano!
- **Interaction of different treatments:** se applico allo stesso soggetto differenti treatment, non riesco a capire se l'outcome è dovuta a un trattamento, all'altro o all'interazione degli stessi




Construct validity – Design threats - III

- **Interaction of testing and treatment:** l'applicazione dei treatment rende i soggetti più o meno recettivi al treatment stesso
 - Se i soggetti sanno che sto misurando gli errori, faranno di tutto per non commetterne!
- **Restricted generalizability across constructs:** un treatment agisce positivamente su un construct, ma negativamente su altri → difficile generalizzare i risultati
 - Il nuovo metodo migliora la produttività...
 - ...ma riduce la manutenibilità, anche se non la sto misurando...
 - Allora che faccio, posso dire che il nuovo metodo può essere applicato?


Construct validity – Social threats - I

- Legate al comportamento dei soggetti e degli sperimentatori
- Threats
 - **Hypothesis guessing:** i soggetti potrebbero capire qual è l'ipotesi alla base dell'esperimento, e reagire
 - Positivamente, influenzando i risultati verso il behavior atteso
 - Negativamente, contraddicendo il risultato atteso
 - **A proposito: normalmente un esperimento è un esperimento, non c'è mai un risultato atteso!!!**
 - **Evaluation apprehension:** se valuto i soggetti in base a come lavorano nell'esperimento, ciò potrebbe falsare i risultati
 - Es. sto sperimentando modelli di stima, e i soggetti riportano stime false pensando che una buona precisione li premierà con un miglior voto
 - Es. sto sperimentando una strategia di testing, e i soggetti aggiungono ulteriori casi di test per individuare più fault, pensando di essere premiati per questo




Construct validity – Social threats - II

- **Experimenter expectancies:** lo sperimentatore a sua volta potrebbe influenzare l'esperimento in base alle proprie aspettative
 - Preparo un questionario in maniera tale che "guiderà" i soggetti verso le risposte che voglio per validare la mia teoria
 - Per evitare ciò dovrei coinvolgere altri soggetti (inconsapevoli della teoria) nella preparazione dell'esperimento




External validity - I

- Threats:
 - **Interaction of selection and treatment: la popolazione dei soggetti non è rappresentativa di quella alla quale voglio generalizzare i risultati**
 - Sperimento con gli studenti per utilizzare i risultati in industria
 - Applico un esperimento di ispezione con programmatori, quando poi anche tester e system engineers prendono parte all'attività di ispezione
 - **Interaction of setting and treatment: l'experimental setting o il materiale non è rappresentativo**
 - Misuro l'effort nello sviluppo di pagine web usando editor di testi
 - Utilizzo casi di studio giocattolo




External validity - II

- **Interaction of history and treatment: eseguo l'esperimento in momenti particolari e ciò mi influenza i risultati**
 - Questionario sull'affidabilità di un sistema condotto il giorno dopo un crash
- **In conclusione:** occorre rendere l'environment sperimentale quanto più realistico possibile
 - Inoltre, devo documentare l'experimental setting (soggetti, oggetti) per capire dove posso generalizzare i risultati ottenuti



Priorizzare le threat to validity

- Molte threat to validity sono conflittuali tra loro
 - Quando riduco una threat, un'altra potrebbe aumentare
 - Abbiamo a che fare con un problema di ottimizzazione
- Utilizzo studenti nell'esperimento
 - Gruppi più ampi, più omogeneità → buona conclusion validity
 - Ridotta external validity
- Utilizzo diverse misure per fare in modo che treatment e outcome rappresentano il costrutto
 - Buona construct validity
 - Problemi di conclusion validity → effettuare molte misure potrebbe introdurre errori



Priorità in casi diversi

■ Theory testing


1. **Internal validity:** c'è relazione causa-effetto
2. **Construct validity:** le variabili rappresentano il costrutto
3. **Conclusion validity:** se poi ho anche significatività statistica...
4. **External validity:** solo alla fine eventualmente mi preoccupo di generalizzare i risultati

■ Ricerca applicata

1. **Internal validity:** di nuovo molto importante la relazione causa-effetto
2. **External validity:** se la ricerca è applicata, devo poter generalizzare a environment industriali
3. **Construct validity:** eventualmente considero interazioni più complesse/ulteriori fattori
4. **Conclusion validity:** in environment industriali ho spesso pochi punti → difficile ottenere significatività statistica




Operation




Operation

- Dopo aver disegnato l'esperimento, occorre eseguirlo
- Applico i treatment ai soggetti
- Una delle poche occasioni in cui lo sperimentatore è a contatto con i soggetti
 - A parte training o briefing prima dell'esperimento
- Anche se il disegno e il plan è perfetto, tutto dipende dall'operation!

Passi






Preparation

- Occorre innanzitutto individuare i soggetti
 - Devono essere motivati e disposti a partecipare all'intero esperimento
 - Devono essere sufficientemente rappresentativi

- Aspetti da considerare:
 - **Ottenere il consenso:**
 - Partecipanti d'accordo con gli obiettivi della ricerca
 - Descrivere come i risultati dell'esperimento saranno usati
 - La partecipazione non deve essere un obbligo
 - **Confidenzialità:** Tener conto della confidenzialità dei risultati (e.g. quando misuro la produttività degli sviluppatori)
 - **Premi:** premiare in qualche modo la partecipazione all'esperimento (non troppo...)
 - **Ingannare i partecipanti:** potrebbe servire per ridurre social threats to construct validity
 - e.g. mascherare un esperimento come un qualunque task di sviluppo o un'esercitazione
 - Da evitare se possibile
 - Rivelare appena possibile i fini dell'esperimento ai partecipanti!!




Preparation - Briefing

- E' consigliabile, prima dell'inizio dell'esperimento, mostrare una breve presentazione in cui:
 - Si illustra l'esperimento, sintetizzandone gli obbiettivi
 - **Attenzione: Non introdurre bias in questo modo!**
 - **Attenzione all'hypothesis guessing**
 - Si illustrano gli oggetti dell'esperimento (programmi da analizzare o da testare, class diagram, etc.)
 - Si introduce la strumentazione (form, tool, etc.)
 - Indicare come reperire form/tool
 - Indicare se necessario dove reperire documentazione...
 - Si spiega come usare i tool, se necessario
 - Si descrivono nel dettaglio i vari passi dell'esperimento
 - Attenti anche ai dettagli: nomi da dare ai file, directory in cui salvarli, etc.


Preparation: problemi di strumentazione

- Prima di eseguire l'esperimento, la strumentazione deve essere pronta
 - Objects, guidelines, tool e form di misura
 - Se i soggetti devono raccogliere dati, meglio predisporre form opportuni
 - Dati in formato omogeneo → minor fatica nell'analisi
 - Usare form anonimi se non serve distinguere tra partecipanti
 - Ma ciò ci impedisce di contattare successivamente il soggetto se qualcosa è poco chiara
 - A volte occorre preparare strumentazione personalizzata per i vari soggetti
 - Infine, se occorre effettuare interviste, le domande vanno preparate prima dell'esecuzione dell'esperimento




Execution

- Differenti modi di eseguire un esperimento
 - Tutti i partecipanti assieme
 - Nessuna necessità di contattare i soggetti per ottenere i risultati
 - Lo sperimentatore presenzia l'esperimento
 - A volte però occorre effettuare l'esperimento offline
 - e.g. studio l'intero sviluppo di un software da parte degli studenti durante l'intero corso
 - Oppure distribuisco via mail un task a varie persone e poi attendo la riconsegna dei risultati




Data collection

- Manuale: analizzare form, artefatti prodotti dagli sperimentatori
 - Form vs. interviste
 - I form non richiedono allo sperimentatore di prendere parte all'esperimento in maniera attiva
 - D'altro canto, le interviste consentono di rivelare inconsistenze nelle domande
- Automatica: web based forms, analisi automatica
 - Esecuzione dei casi di test



Experimental environment

- Se l'esperimento è eseguito nell'ambito di un progetto, dovrebbe essere il meno possibile "invasivo"
- Se l'esperimento cambia troppo l'environment, le assunzioni fatte non sono più valide



Data validation

- Una volta eseguito l'esperimento, occorre controllare che i dati raccolti siano consistenti
 - I trattamenti sono stati applicati correttamente
 - I soggetti hanno compreso i form
 - I soggetti hanno riempito i form correttamente
 - Occorre rimuovere punti relativi a soggetti che
 - Non hanno partecipato seriamente all'esperimento
 - Può essere molto utile presentare appena possibile i risultati ai soggetti per ottenere feedback
 - Almeno statistiche descrittive